

Notas de Aula para o Mestrado e Doutorado em Economia

FGV/EPGE — Professor Marcelo Mello

Vitor Wilher¹

Versão preliminar — compilada ao longo do curso (Agosto–Outubro de 2026). Baseada nos slides da disciplina (Prof. Marcelo Mello) e em Stock e Watson (2020).

¹Bacharel e Mestre em Economia pela UFF, Candidato ao PhD em Economia pela EPGE/FGV. É Especialista em Ciências de Dados e Inteligência Artificial Generativa pela PUC-Rio. Atualmente, exerce a função de Data Tech Lead na Análise Macro (<http://analysemacro.com.br>). Saiba mais em <https://github.com/vitorwilher>.

Índice

1	Introdução	7
1.1	O que é econometria	7
1.2	Por que ela importa	7
1.3	O fio condutor	8
1.4	Como ler estas notas	9
1.5	Referências	9
2	Econometria e Causalidade	10
2.1	Quatro histórias	10
2.1.1	Cigarro e câncer: quando a associação estava certa	10
2.1.2	Vioxx: o experimento perfeito que escondeu o essencial	10
2.1.3	Ovos perigosos: uma hipótese plausível que virou política	11
2.1.4	Cloroquina: dose, mortalidade e o valor de um controle	11
2.2	O que é econometria	12
2.3	Duas questões econômicas	12
2.4	O que significa causalidade	13
2.4.1	O experimento aleatorizado ideal	13
2.5	O problema fundamental	13
2.5.1	As quatro perguntas do projeto ideal	14
2.5.2	Perguntas que não cabem no arcabouço	14
2.6	Estrutura de dados	15
2.7	As duas dificuldades	15
2.8	Laboratório computacional em R	16
2.8.1	Por que a aleatorização funciona	16
2.8.2	O que “controlar por observáveis” resolve — e o que não resolve	18
2.9	Exercícios	19
3	Revisão de Probabilidade	21
3.1	Variáveis aleatórias e distribuição de probabilidade	21
3.1.1	A disputa de pênaltis e a Binomial	22
3.1.2	Propriedades e distribuição acumulada	23
3.2	Variáveis aleatórias contínuas	24
3.2.1	A Normal e o papel da simetria	25
3.3	Valor esperado	25
3.3.1	Propriedades	26
3.4	Variância e desvio padrão	26
3.4.1	A desigualdade de Chebyshev	27
3.4.2	Transformação linear e padronização	28
3.5	Distribuição conjunta, marginal e independência	29
3.6	Distribuição condicional e média condicional	30
3.6.1	A tabela chuva $\times$ tempo de deslocamento	30
3.6.2	A média condicional	31
3.6.3	Propriedades da média condicional	32
3.7	A lei das expectativas iteradas	32
3.7.1	A intuição, pela altura média	33
3.8	Covariância, correlação e independência	34
3.8.1	O problema das unidades e a correlação	35
3.8.2	Variância de combinações lineares	36
3.9	Correlação e média condicional: uma distinção que importa	36
3.10	Correlação e causalidade	37
3.11	Laboratório computacional em R	38
3.11.1	A Binomial dos pênaltis	38

3.11.2	Chebyshev em cinco distribuições	40
3.11.3	A tabela chuva $\times$ commute e a lei das expectativas iteradas	41
3.11.4	O contraexemplo: covariância zero sem independência	43
3.12	Exercícios	45
4	Regressão Linear com um Regressor	46
4.1	O modelo de regressão linear	46
4.1.1	O termo de erro	47
4.1.2	A Função de Regressão Populacional	48
4.2	Estimando os coeficientes: mínimos quadrados ordinários	49
4.2.1	As condições de primeira ordem	49
4.2.2	Resolvendo o sistema	50
4.2.3	Covariância sobre variância	51
4.3	Interpretação: o caso TestScore	52
4.4	Observações importantes	53
4.5	Exemplo: o “beta” de uma ação	54
4.6	Medidas de aderência	55
4.6.1	As três somas de quadrados	55
4.6.2	A decomposição $TSS = ESS + SSR$	56
4.6.3	O coeficiente de determinação	56
4.6.4	O exercício do slide 33	58
4.6.5	O erro-padrão da regressão	59
4.7	As três hipóteses de MQO	60
4.7.1	Média condicional zero e correlação: um ponto sutil	61
4.8	Distribuição amostral dos estimadores de MQO	64
4.9	Laboratório computacional em R	66
4.9.1	Os dados: uma advertência necessária	66
4.9.2	(a) A regressão	67
4.9.3	(b) MQO na mão contra <code>lm()</code>	69
4.9.4	(c) As condições de ortogonalidade	69
4.9.5	(d) A decomposição $TSS = ESS + SSR$ e as três formas do R^2	70
4.9.6	(e) Erros-padrão robustos contra homocedásticos	72
4.9.7	(f) A distribuição amostral de $\hat{\beta}_1$ por simulação	73
4.9.8	(g) O que uma única observação extrema pode fazer	75
4.10	Exercícios	76
4.11	Lista de Exercícios 1	77
4.11.1	Gabarito da Lista 1	79
5	Inferência na Regressão com um Regressor	84
5.1	Revisão de testes de hipótese	84
5.1.1	Os dois tipos de erro	85
5.1.2	O trade-off entre os dois erros	86
5.1.3	O poder do teste	86
5.1.4	Um exemplo completo: teste sobre a média populacional	87
5.2	Testando hipóteses sobre os coeficientes da regressão	87
5.2.1	A estatística t	88
5.2.2	Aplicando ao exemplo	88
5.2.3	O valor-p	89
5.3	Intervalos de confiança	90
5.3.1	A definição geral	90
5.3.2	Construção: o caso da média	90
5.3.3	Como interpretar — e como não interpretar	91
5.3.4	O intervalo de confiança para β_1	92
5.3.5	Intervalos para efeitos preditos	92

5.4	Regressão quando X é binário	93
5.4.1	Teste de hipótese e IC no caso binário	94
5.5	Heterocedasticidade	95
5.5.1	O que a heterocedasticidade não estraga	95
5.5.2	O que ela estraga: as fórmulas de variância	96
5.5.3	Um exemplo em que quase não faz diferença	97
5.6	O Teorema de Gauss-Markov	97
5.6.1	As duas limitações	98
5.7	Laboratório computacional em R	98
5.7.1	(a) A tabela completa de inferência	99
5.7.2	(b) O efeito predito de $\Delta STR = -2$	100
5.7.3	(c) O que significa “95% de confiança”	101
5.7.4	(d) Homocedasticidade contra heterocedasticidade	103
5.7.5	(e) A inferência quando se usa a fórmula errada	103
5.7.6	(f) Regressão com dummy é diferença de médias	105
5.8	Exercícios	106
5.9	Lista de Exercícios 2	108
5.9.1	Gabarito da Lista 2	109
6	Regressão Linear com Múltiplos Regressores	115
6.1	Viés de variável omitida	115
6.1.1	Por que a Hipótese 1 falha	116
6.1.2	A fórmula do viés	116
6.1.3	Aplicando ao exemplo da Califórnia	118
6.2	O modelo de regressão linear múltiplo	118
6.2.1	A interpretação dos coeficientes	119
6.3	O estimador de MQO	119
6.3.1	As condições de ortogonalidade	119
6.3.2	Aplicação: tamanho da turma e desempenho	120
6.4	Medidas de aderência	121
6.4.1	O erro-padrão da regressão	121
6.4.2	O R^2	122
6.4.3	O R^2 ajustado	122
6.5	Multicolinearidade	123
6.5.1	Multicolinearidade perfeita	123
6.5.2	A armadilha da <i>dummy</i>	124
6.5.3	Multicolinearidade imperfeita	125
6.6	As hipóteses de MQO na regressão múltipla	126
6.6.1	Distribuição assintótica	127
6.7	Variáveis de controle e independência em média condicional	127
6.8	Laboratório computacional em R	128
6.8.1	(a) O viés, medido	129
6.8.2	(b) O viés não desaparece com n	130
6.8.3	(c) O sinal do viés é previsível	132
6.8.4	(d) R^2 contra $\bar{R}^2$ diante de ruído puro	132
6.8.5	(e) O custo da multicolinearidade imperfeita	133
6.8.6	(f) A armadilha da <i>dummy</i> , na prática	134
6.9	Exercícios	135
6.10	Lista de Exercícios 3	136
6.10.1	Gabarito da Lista 3	138
7	Testes de Hipótese e Intervalos de Confiança na Regressão Múltipla	143
7.1	Testes e intervalos para um coeficiente individual	143
7.1.1	O exemplo do curso, e um coeficiente que desaparece	144

7.1.2	Como interpretar o desaparecimento	145
7.2	Testes de hipóteses conjuntas	145
7.2.1	A estatística F	146
7.2.2	O teste F de significância global	147
7.2.3	A estatística F sob homocedasticidade	147
7.3	Restrição única envolvendo vários coeficientes	148
7.4	Especificação de modelos	149
7.4.1	O ponto de partida é o viés, não o ajuste	149
7.4.2	Especificação básica e alternativas	150
7.4.3	As quatro armadilhas do R^2	150
7.5	A análise completa: $TestScore$ e STR	151
7.5.1	A escolha dos controles	151
7.5.2	Como apresentar os resultados	152
7.5.3	As três conclusões	152
7.6	Laboratório computacional em R	153
7.6.1	(a) O teste t individual e o intervalo de confiança	154
7.6.2	(b) O que acontece ao acrescentar um regressor correlacionado	155
7.6.3	(c) A identidade $F = t^2$	156
7.6.4	(d) O teste conjunto e a fórmula via R^2	156
7.6.5	(e) Por que o F homocedástico não serve	157
7.6.6	(f) A restrição única com dois coeficientes, pelas duas estratégias	157
7.6.7	(g) O teste F de significância global	158
7.6.8	(h) Por que não testar um coeficiente de cada vez	158
7.7	Exercícios	159
7.8	Lista de Exercícios 4	161
7.8.1	Gabarito da Lista 4	163
8	Funções de Regressão Não-lineares	170
8.1	Uma estratégia geral	170
8.1.1	O caso que motiva: notas e renda do distrito	171
8.2	O modelo de regressão quadrático	171
8.2.1	Como interpretar os coeficientes	171
8.2.2	O erro-padrão de um efeito não-linear	172
8.3	Polinômios de ordem superior	173
8.3.1	Como escolher o grau r	173
8.4	Logaritmos	173
8.5	Interações entre variáveis independentes	175
8.5.1	(a) Duas variáveis binárias	175
8.5.2	(b) Uma binária e uma contínua	176
8.5.3	(c) Duas variáveis contínuas	176
8.6	Laboratório computacional em R	177
8.6.1	(a) Linear versus quadrático	178
8.6.2	(b) A derivada não serve para variações discretas	178
8.6.3	(c) O erro-padrão do efeito, por reparametrização	178
8.6.4	(d) As três especificações logarítmicas	179
8.6.5	(e) A armadilha dos testes t sob interação	179
8.7	Exercícios	180
9	Avaliando Estudos Baseados em Regressão Múltipla	182
9.1	Validade interna e validade externa	182
9.1.1	Ameaças à validade externa	182
9.2	As cinco ameaças à validade interna	183
9.2.1	Ameaça 1: viés de variável omitida	183
9.2.2	Ameaça 2: forma funcional incorreta	184

9.2.3	Ameaça 3: erro de medida nas variáveis independentes	184
9.2.4	Ameaça 4: seleção amostral viesada	185
9.2.5	Ameaça 5: causalidade simultânea	185
9.3	Erros-padrão inconsistentes	186
9.4	Validade interna e externa em previsão	186
9.5	Aplicação: notas e tamanho de turma, Califórnia e Massachusetts	186
9.6	Exercícios	187
10	Regressão com Dados em Painei	188
10.1	O que são dados em painel, e por que eles ajudam	188
10.1.1	Por que o painel resolve um problema que o corte transversal não resolve	189
10.1.2	O exemplo que atravessa o capítulo: mortes no trânsito e imposto sobre a cerveja	189
10.2	Painel com dois períodos de tempo	190
10.2.1	O resultado nos dados	191
10.3	Regressão com efeitos fixos	192
10.3.1	A forma de regressores binários	193
10.3.2	Os três métodos de estimação	193
10.3.3	O estimador within, passo a passo	193
10.3.4	O que não se pode estimar	194
10.4	Regressão com efeitos fixos de tempo	194
10.5	As hipóteses de MQO em painel e os erros-padrão clusterizados	195
10.5.1	Exogeneidade estrita	196
10.5.2	O que a hipótese i.i.d. permite e o que ela exige	196
10.5.3	Erros-padrão clusterizados	196
10.6	Aplicação: mortes no trânsito e impostos sobre o álcool	197
10.7	Laboratório computacional em R	198
10.7.1	(a) MQO agrupado: a regressão que ignora o painel	199
10.7.2	(b) Efeitos fixos de estado, pela transformação within	199
10.7.3	(c) A equivalência com o método das binárias	199
10.7.4	(d) Efeitos fixos de estado e de tempo	200
10.7.5	(e) Por que o erro-padrão clusterizado importa	200
10.7.6	(f) O que acontece com um regressor invariante no tempo	200
10.8	Exercícios	201
10.9	Lista de Exercícios — Dados em Painei	201
10.9.1	Questão 1 — Aborto e criminalidade (Donohue e Levitt, 2001)	202
10.9.2	Questão 2 — Fatalidades no trânsito	203
10.9.3	Gabarito da Lista de Painei	203
Apêndice	Trabalho Empírico A1	206
	O arco do trabalho	206
	Preparação: dados e variáveis (itens 1 a 3)	206
	Item 4 — participação na força de trabalho	207
	Item 5 — estatísticas descritivas	208
	Item 6 — histogramas e a distribuição condicional	208
	Item 7 — a regressão simples	209
	Item 8 — o viés de variável omitida, diagnosticado	210
	Item 9 — heterogeneidade entre homens e mulheres	211
	Item 10 — a regressão completa	212
	Item 11 — não linearidade na experiência	212
	Item 12 — efeitos fixos de estado	213
	Item 13 (bônus) — viés de seleção	214
	Uma lista de checagem para o relatório	215
Referências		216

1 Introdução

Estas notas acompanham a disciplina de **Econometria** do Mestrado e Doutorado Profissional em Economia e Finanças (MPEF) da FGV/EPGE, ministrada pelo Professor Marcelo Mello entre agosto e outubro de 2026. Elas seguem a ordem das aulas e tomam os slides da disciplina como fonte primária: a notação, os exemplos e o encadeamento são os do professor, ainda que o texto seja de minha autoria e acrescente derivações, comentários e implementações computacionais que os slides deixam implícitos.

! Estado destas notas

O curso tem **quinze aulas**. Esta versão cobre as **seis primeiras**, que foram as ministradas até o momento da compilação: causalidade e estrutura de dados (Aula 1), revisão de probabilidade (Aula 2), o modelo de regressão linear com um regressor (Aula 3), a inferência sobre seus coeficientes — testes de hipótese, intervalos de confiança, heterocedasticidade e Gauss-Markov (Aula 4) —, a regressão linear com múltiplos regressores, com viés de variável omitida, R^2 ajustado, multicolinearidade e variáveis de controle (Aula 5), e a inferência no modelo múltiplo — o teste F para hipóteses conjuntas, restrições envolvendo vários coeficientes e a discussão de especificação de modelos (Aula 6). Os capítulos seguintes serão acrescentados conforme o curso avança — a estrutura do documento já está montada para recebê-los.

As **quatro primeiras listas de exercícios** da disciplina estão reproduzidas, com gabarito desenvolvido, ao final do capítulo a que correspondem: a Lista 1 no Seção 4.11, a Lista 2 no Seção 5.9, a Lista 3 no Seção 6.10 e a Lista 4 no Seção 7.8. O **Trabalho Empírico A1** tem um gabarito metodológico próprio no apêndice.

1.1 O que é econometria

A definição que abre o curso é deliberadamente ampla: *a econometria é a arte e a ciência de utilizar teoria econômica e técnicas estatísticas para analisar dados econômicos*. As duas palavras importam. É **ciência** porque há teoremas, estimadores com propriedades demonstráveis e procedimentos de inferência com garantias precisas. É **arte** porque nenhum teorema decide, no lugar do pesquisador, se a hipótese de identificação é plausível no problema concreto que ele tem diante de si — e é justamente aí que o trabalho empírico se ganha ou se perde.

O professor sintetiza a diferença de postura em um contraste: *economista* versus *estatístico*. O estatístico pergunta se a associação nos dados é real ou fruto do acaso amostral; o economista quer saber, além disso, se ela é **causal** — se intervir na variável X mudaria a variável Y . A segunda pergunta é bem mais difícil, e é a que organiza o curso inteiro.

1.2 Por que ela importa

Muitas decisões — de política pública, de empresa, de carreira — dependem de compreender as relações entre as variáveis do mundo. E essas decisões exigem **respostas quantitativas para perguntas quantitativas**: não basta saber que reduzir o tamanho da turma “ajuda”; é preciso saber *quanto* ajuda, para comparar com o custo de contratar professores.

Há ainda uma razão contemporânea. Em um mundo dominado por *big data*, em que a coleta de dados virou padrão e estudos empíricos se multiplicam no setor público e privado, a análise e a interpretação competentes tornaram-se instrumento essencial de decisão — e, igualmente importante, **instrumento de identificação de erros** nas análises alheias. Boa parte do valor de um econometrista treinado está em saber reconhecer quando um resultado empírico não sustenta a conclusão que anuncia. O Seção 2 abre com quatro histórias em que exatamente isso falhou, com consequências que se contam em dezenas de milhares de mortes.

1.3 O fio condutor

O curso tem uma tese, repetida do primeiro ao último slide: **correlação não implica causalidade**. O que dá conteúdo a essa frase — que de outro modo seria um clichê — é o programa de trabalho que ela impõe.

Começamos reconhecendo o problema (Seção 2): queremos efeitos causais, o padrão ouro para obtê-los é o experimento aleatorizado, e quase nunca temos um. Trabalhamos com **dados observacionais**, gerados por escolhas dos agentes, não por sorteio em laboratório. Disso decorrem as duas dificuldades que o curso passa o resto do tempo enfrentando: **variáveis omitidas** e **causalidade simultânea**.

Em seguida recuperamos as ferramentas probabilísticas necessárias (Seção 3) — esperança, variância, distribuição conjunta e, sobretudo, a **média condicional**, que é o objeto central de tudo o que vem depois. A regressão, afinal, é um método para estimar médias condicionais.

Então construímos o instrumento básico: o **modelo de regressão linear com um regressor** e o estimador de **mínimos quadrados ordinários** (1). Aqui aparece a hipótese que carrega todo o peso da inferência causal, $\mathbb{E}(u_i | X_i) = 0$, e a constatação desconfortável de que ela **não é testável** — sua plausibilidade depende de conhecimento do problema e de julgamento, não de estatística.

De posse do estimador, aprendemos a medir a incerteza que ele carrega (Seção 5): testes de hipótese, intervalos de confiança e a leitura completa de uma tabela de regressão. Aqui aparecem também dois resultados que organizam o que vem depois — o de que a regressão sobre uma *dummy* é literalmente uma **comparação de médias**, o que reconcilia o instrumento com o arcabouço experimental do Seção 2; e o de que a **heterocedasticidade** compromete a inferência sem viesar as estimativas, razão pela qual os erros-padrão robustos são o padrão da prática aplicada.

A primeira dessas estratégias já está no texto (Seção 6). Diante da constatação de que a Hipótese 1 falha quando um determinante de Y correlacionado com X fica de fora — o **viés de variável omitida**, um erro de identificação que, ao contrário do ruído amostral, **não desaparece com o tamanho da amostra** —, a resposta natural é incluir esse determinante na regressão. Daí a **regressão múltipla**, com sua reinterpretação dos coeficientes como efeitos parciais, o custo em precisão que a **multicolinearidade** impõe, e a distinção entre a variável de interesse e as **variáveis de controle**, cujos coeficientes não devem ser lidos causalmente.

Com o modelo múltiplo em mãos, resta saber testá-lo (Seção 7). Perguntas que envolvem **mais de um coeficiente** — dois regressores são conjuntamente irrelevantes? dois efeitos são iguais? — não se resolvem com uma estatística t , e a ferramenta que as resolve é a **estatística F** . O capítulo mostra ainda por que testar “um coeficiente de cada vez” produz um teste com tamanho maior do que o anunciado, por que a versão homocedástica do F deve ser evitada, e — na parte menos algébrica e talvez mais útil do curso — como se escolhe uma **especificação**: pelo exame da estabilidade dos coeficientes entre modelos alternativos, jamais pelo R^2 .

O restante do curso, ainda por vir, é uma sequência de estratégias para os casos em que o confundidor **não** é observável e, portanto, não pode ser incluído: explorar variação temporal (dados em painel, efeitos fixos), encontrar variação exógena (variáveis instrumentais) ou aproximar experimentos com quase-experimentos (diferenças-em-diferenças, regressão descontínua, controle sintético, *propensity score matching*).

1.4 Como ler estas notas

Cada capítulo abre com a **motivação** do problema, desenvolve a teoria com **derivações passo a passo** e fecha com duas seções fixas:

- um **Laboratório computacional em R**, que reproduz numericamente os resultados do capítulo ou gera a figura que o ilustra. O código roda na própria compilação do PDF, de modo que os números impressos são os que o R de fato produziu;
- uma lista de **Exercícios**, no espírito das atividades da disciplina.

Nos capítulos que já têm lista correspondente na disciplina, segue-se ainda a **lista oficial**, reproduzida na íntegra e acompanhada de **gabarito desenvolvido**. A ordem é deliberada: os exercícios autorais vêm antes porque exploram ângulos que a lista não cobre; a lista oficial vem depois porque é a que será cobrada. O gabarito é para conferência posterior — resolver antes de consultá-lo é o que faz a diferença.

Resultados centrais aparecem em caixa, assim. Hipóteses que não podem ser esquecidas vão em caixas de destaque. Quando um conceito de estatística é mobilizado — esperança condicional, distribuição amostral, teorema central do limite —, uma caixa *Ferramenta estatística* o nomeia e remete ao capítulo correspondente das **Notas de Aula de Estatística** (Prof. Eduardo Campos), escritas para o mesmo programa.

Uma observação sobre software. Os slides do curso mostram saídas do **STATA**, que é o padrão na disciplina. Os laboratórios destas notas usam **R**, por ser o que utilizo no trabalho, e reproduzem as mesmas quantidades — inclusive os **erros-padrão robustos**, que implemento a partir da fórmula para deixar explícito o que o comando **robust** do STATA faz por baixo do capô.

1.5 Referências

O texto base do curso é Stock e Watson (2020), e a numeração dos capítulos dos slides o segue de perto. Como auxiliares, o programa lista Wooldridge (2016), Angrist e Pischke (2015) e Angrist e Pischke (2009) — os dois últimos são a referência natural para a parte de inferência causal e desenho de pesquisa que fecha o curso. Onde estas notas avançam além do slide, indico a fonte no próprio texto.

2 Econometria e Causalidade

O curso não começa por definições nem por fórmulas. Começa por **quatro histórias** em que a análise empírica foi feita, publicada em periódicos de primeira linha, aceita por reguladores — e estava errada. Custaram, em um dos casos, algo entre 26 e 38 mil vidas.

A escolha é deliberada. É fácil aprender a rodar uma regressão; o difícil é adquirir o julgamento para saber quando uma regressão — a sua ou a de outra pessoa — não sustenta a conclusão que anuncia. As histórias existem para instalar esse desconforto produtivo desde a primeira aula.

2.1 Quatro histórias

2.1.1 Cigarro e câncer: quando a associação estava certa

O primeiro caso é o contraponto dos demais. Em 1950, Wynder e Graham (1950) publicaram no *JAMA* um estudo com 684 pacientes de câncer de pulmão que encontrou forte associação estatística com o consumo pesado de cigarros. Em 1954, Doll e Hill (1954) acompanharam médicos britânicos ao longo do tempo e mapearam a mortalidade crescente contra o consumo de tabaco.

Hoje ninguém duvida da conclusão. Mas vale registrar que, à época, ela foi contestada com um argumento **estatisticamente impecável**: nenhum dos dois estudos era um experimento aleatorizado, de modo que a associação poderia refletir uma terceira variável — uma predisposição genética que causasse, simultaneamente, o hábito de fumar e o câncer. Ronald Fisher, um dos fundadores da estatística moderna, defendeu exatamente essa posição.

A objeção era logicamente válida e, ainda assim, a conclusão substantiva era correta. Fica a primeira lição: **a crítica de variável omitida é sempre disponível, e por isso mesmo precisa ser avaliada, não apenas invocada**. O que eventualmente resolveu a questão não foi um teorema, foi o acúmulo de evidência de desenhos diferentes — dose-resposta, mecanismo biológico, coortes, redução de risco após cessação.

2.1.2 Vioxx: o experimento perfeito que escondeu o essencial

O segundo caso é o mais grave, e o mais instrutivo, porque **aqui houve experimento aleatorizado** — e ele não bastou.

A Merck, eleita “empresa mais admirada” pela *Fortune* entre 1985 e 1990, desenvolveu o rofecoxib (Vioxx) com uma ideia farmacológica elegante. Os anti-inflamatórios não esteroides tradicionais — aspirina, ibuprofeno, naproxeno — inibem a enzima COX-2, que causa inflamação e dor, mas também inibem a COX-1, que protege o revestimento do estômago; daí as úlceras. O Vioxx foi desenhado para **inibir a COX-2 sem inibir a COX-1**, e foi aprovado pela FDA após “rigorosos ensaios clínicos aleatorizados”.

O estudo VIGOR (Bombardier et al. 2000) alocou aleatoriamente 8.076 pacientes com artrite reumatoide para receber 50mg diários de rofecoxib ou 500mg de naproxeno duas vezes ao dia. O desfecho primário eram eventos gastrointestinais superiores confirmados. O resultado confirmou a hipótese: 2,1 eventos por 100 pacientes-ano com rofecoxib contra 4,5 com naproxeno. A conclusão publicada foi que o rofecoxib se associa a “significativamente menos eventos gastrointestinais clinicamente importantes”.

O que deu errado? Duas coisas, e nenhuma delas é falha de aleatorização.

Primeiro, **os tomadores de Vioxx tiveram 17 infartos contra 4 dos tomadores de naproxeno — e a diferença foi interpretada como estatisticamente não significativa**. Segundo, uma informação foi omitida do relato: 47 pacientes em uso de Vioxx tiveram eventos tromboembólicos, contra 20 no grupo naproxeno.

A Merck retirou o Vioxx do mercado em 30 de setembro de 2004. As estimativas de dano vão de 88 a 139 mil infartos, com 26 a 38 mil mortes.

! O que o caso Vioxx ensina

A aleatorização garante que os grupos sejam comparáveis — e ela funcionou aqui. O que ela **não** garante é que o desfecho certo esteja sendo medido, que a amostra tenha poder suficiente para detectar o efeito adverso, ou que todos os resultados sejam reportados.

“Não significativo” **não** é sinônimo de “não existe”: com 17 contra 4 eventos, o intervalo de confiança era largo demais para excluir um efeito grande. Ausência de evidência não é evidência de ausência — uma distinção que retomaremos quando estudarmos poder de teste.

2.1.3 Ovos perigosos: uma hipótese plausível que virou política

Por décadas, autoridades médicas sustentaram que comer ovos ameaçava a saúde cardiovascular. A origem é a **hipótese lipídica** (1950–1970), que ligava colesterol sanguíneo elevado a maior risco cardíaco. A lógica parecia inescapável: a gema é excepcionalmente rica em colesterol dietético, logo comer ovos elevaria o colesterol sanguíneo e obstruiria artérias.

Em 1968 a American Heart Association recomendou oficialmente não mais que 300mg diários de colesterol dietético e restringiu o consumo a três ovos por semana. A recomendação sobreviveu por quase cinco décadas antes de ser revista.

O erro aqui não foi estatístico, foi de **inferência sobre o mecanismo**: assumiu-se que colesterol ingerido se traduz em colesterol circulante, quando a regulação hepática compensa boa parte da ingestão. Uma cadeia causal plausível, adotada sem o teste da etapa intermediária.

2.1.4 Cloroquina: dose, mortalidade e o valor de um controle

O quarto caso é recente e brasileiro. Em abril de 2020, um estudo conduzido em Manaus com 81 pacientes graves de covid-19 (Borba et al. 2020) comparou duas doses de cloroquina: um grupo recebeu dose alta (600mg duas vezes ao dia por dez dias), outro recebeu dose baixa (450mg por cinco dias, duas vezes apenas no primeiro dia). O grupo de dose alta apresentou letalidade **17% maior**.

O que torna este estudo informativo, apesar do tamanho pequeno, é justamente ter havido **comparação entre grupos alocados**. Sem o braço de dose baixa, a mortalidade observada no grupo de dose alta seria atribuída à gravidade da doença — e a droga poderia parecer, na melhor das hipóteses, inócua.

2.2 O que é econometria

Recolhidas as histórias, a definição do curso:

! Definição

De forma ampla, a **econometria** é a arte e a ciência de utilizar teoria econômica e técnicas estatísticas para analisar dados econômicos.

O professor contrasta duas figuras: o **economista** e o **estatístico**. O estatístico domina as técnicas de descrever associações e quantificar incerteza amostral. O economista traz a pergunta substantiva e a teoria que disciplina a interpretação — em particular, a distinção entre associação e efeito causal. A econometria vive na interseção, e nenhuma das duas metades é dispensável.

Por que estudá-la? Muitas decisões dependem de compreender as relações entre as variáveis do mundo, e essas decisões exigem **respostas quantitativas para perguntas quantitativas**. Além disso, em um mundo dominado por *big data*, em que a coleta de dados virou padrão e estudos empíricos proliferam no setor público e privado, a análise competente tornou-se instrumento essencial de decisão — e, tão importante quanto, **instrumento para identificar erros nas análises empíricas alheias**. As quatro histórias acima são o argumento.

2.3 Duas questões econômicas

O curso se organiza em torno de perguntas concretas. Duas delas atravessam as primeiras aulas.

Questão 1: reduzir o tamanho da turma melhora o desempenho acadêmico? É a pergunta que gera o exemplo `TestScore/ClassSize` do 1 e que reaparece no curso inteiro. Tem interesse imediato de política pública: contratar professores é caro, e o tradeoff só se avalia com uma estimativa quantitativa do efeito.

Questão 2: há discriminação salarial por gênero? O caso *Boylan v. New York Times* mostra a econometria em um tribunal. Em novembro de 1974, após a formação de um *Women's Caucus* em 1972, seis mulheres — Elizabeth Boylan, Louise Carini, Joan Cook, Nancy Davis, Grace Glueck e Andrea Skinner — abriram ação federal representando cerca de 600 funcionárias, sob o Título VII do Civil Rights Act de 1964. As alegações eram viés sistemático em remuneração, atribuição desigual de funções e barreiras de promoção.

A estratégia probatória foi estatística. Sob coordenação de Bruce Levin, da Universidade Columbia, as autoras apresentaram uma **regressão linear múltipla** sobre registros de aproximadamente 1.800 empregados sindicalizados, com um conjunto de **99 variáveis explicativas** controlando fatores de produtividade — escolaridade, anos de experiência, tempo de casa. O achado central: mesmo após controlar pelas 99 variáveis, **o coeficiente de gênero permaneceu negativo e estatisticamente significativo**.

O argumento tem a estrutura exata da inferência causal com dados observacionais: se todos os determinantes legítimos do salário foram controlados, o que resta associado ao gênero não pode ser explicado por produtividade. Note que a força do argumento depende inteiramente da **completude do conjunto de controles** — é precisamente o ponto que a hipótese $\mathbb{E}(u \mid X) = 0$ formaliza no 1, e é onde a defesa concentraria seu contra-argumento.

2.4 O que significa causalidade

! Definição

Causalidade significa que uma ação específica leva a uma consequência mensurável específica. De forma simples, se uma mudança em X causa Y , então uma variação em X produz variação em Y , **tudo mais constante**.

A cláusula *ceteris paribus* é onde mora toda a dificuldade. No mundo, as coisas não variam uma de cada vez.

2.4.1 O experimento aleatorizado ideal

A forma canônica de estimar efeitos causais é o **experimento controlado aleatorizado ideal**. Ele é *controlado* no sentido de que há um **grupo de tratamento**, que recebe o tratamento, e um **grupo de controle**, que não recebe. E é *aleatorizado* no sentido de que a alocação ao tratamento é feita **por sorteio**.

Nesse arcabouço, o **efeito causal** é definido como o efeito de uma ação ou tratamento sobre um resultado, medido em um experimento aleatorizado ideal. A propriedade decisiva é esta:

Nesse experimento, a única razão sistemática para as diferenças de resultado entre os grupos de tratamento e controle é o próprio tratamento.

A aleatorização faz com que os dois grupos sejam, **em média**, idênticos em tudo — idade, renda, motivação, saúde prévia, e também em características que ninguém mediu ou sequer imaginou medir. É essa equivalência em expectativa que autoriza atribuir a diferença de resultados ao tratamento. Formalmente, é o que garante que a diferença de médias

$$\mathbb{E}(Y \mid X = 1) - \mathbb{E}(Y \mid X = 0)$$

seja um estimador não viesado do efeito causal — resultado que o 1 retoma ao apresentar as hipóteses de MQO.

2.5 O problema fundamental

Aqui o curso enuncia sua dificuldade central:

! O problema que organiza o curso

Desejamos obter uma estimativa do **efeito causal**. Mas trabalhamos com **dados observacionais**, o que elimina a possibilidade de alocação aleatória do tratamento. Ou seja: sabemos que **houve escolha**, e que existem **variáveis omitidas**.

Dados observacionais são gerados a partir de escolhas das partes envolvidas — quem estuda mais, quem toma o remédio, qual escola adota turmas menores —, não por um processo aleatório em

laboratório. E quem escolhe, escolhe por razões, que em geral também afetam o resultado de interesse.

A resposta da econometria de regressão é uma aposta explícita:

A inferência causal baseada em um modelo de regressão tem como pilar fundamental a hipótese de que, uma vez que se controla os grupos de tratamento e controle pelas **variáveis-chave observáveis**, o viés de seleção causado por variáveis omitidas também é eliminado.

É exatamente o que os autores do caso *New York Times* tentaram fazer com 99 controles. E é uma **hipótese**, não um teorema — o que os casos da cloroquina e dos ovos ilustram pelo avesso.

2.5.1 As quatro perguntas do projeto ideal

Angrist e Pischke (Angrist e Pischke 2009) organizam o desenho de pesquisa em quatro perguntas, que o professor adota como roteiro:

1. Qual é a **relação causal** de interesse?
2. Qual é o **experimento** que idealmente captaria esse efeito causal?
3. Qual é a sua **estratégia de identificação**?
4. Qual é o seu **método de inferência estatística**?

A segunda pergunta é a mais subestimada. Mesmo quando o experimento é inviável — por custo, por ética, por impossibilidade lógica —, imaginá-lo com precisão disciplina todo o resto: ele define o que seria o contrafactual, e portanto o que a estratégia observacional precisa aproximar.

! Estratégia de identificação

A **estratégia de identificação** é a maneira pela qual um pesquisador usa dados observacionais para **aproximar um experimento real**.

Boa parte do curso — variáveis instrumentais, diferenças-em-diferenças, regressão descontínua, controle sintético — é um catálogo de estratégias de identificação.

2.5.2 Perguntas que não cabem no arcabouço

Nem toda pergunta admite a moldura tratamento-controle. Questões sobre o efeito causal de **raça ou gênero** são difíceis de colocar nesses termos, porque essas características raramente podem ser manipuladas isoladamente: não há como sortear o gênero de uma pessoa mantendo tudo o mais constante, e mesmo conceitualmente é obscuro o que significaria “a mesma pessoa, de outro gênero”.

Isso não torna a pergunta ilegítima — o caso *New York Times* é prova de que ela é socialmente urgente. Torna-a uma pergunta cuja resposta empírica exige cuidado redobrado com o que exatamente está sendo estimado. É um tema que o curso retoma adiante.

2.6 Estrutura de dados

Fechada a discussão conceitual, a taxonomia operacional. Em econometria, os dados vêm de duas fontes: **experimentais**, gerados em laboratório ou por algum processo aleatório deliberado; e **não experimentais**, isto é, **observacionais**.

Quanto à organização, há três estruturas. Sejam i o índice da **entidade** (indivíduo, firma, país) e t o índice do **tempo calendário**:

Estrutura	Índices	Exemplo
Corte transversal (<i>cross-section</i>)	$i = 1, \dots, n$ com t fixo	Efeito da educação no salário para 5.000 indivíduos em 2017
Série de tempo	i fixo, $t = 1, \dots, T$	Efeito dinâmico de um choque no petróleo sobre a inflação
Painel (ou longitudinal)	$i = 1, \dots, n$ e $t = 1, \dots, T$	Determinantes da produtividade de países latino-americanos ao longo do tempo

O painel combina as duas dimensões, e é essa combinação que o torna valioso: observar a mesma entidade em momentos diferentes permite controlar por tudo aquilo que é fixo na entidade e não observado — a base do estimador de efeitos fixos, que o curso verá adiante.

Uma convenção de nomenclatura vale registro. Painéis com n **grande** e T **pequeno** são típicos de problemas de **microeconomia** — milhares de indivíduos, poucos anos. Painéis com n pequeno e T grande são típicos de **macroeconomia** — poucos países, muitas décadas. A distinção não é cosmética: ela determina em que dimensão a teoria assintótica opera e, portanto, quais estimadores e erros-padrão são apropriados.

Este curso trata de **corte transversal e painel**; séries de tempo ficam para outra disciplina.

2.7 As duas dificuldades

A maior parte do curso trata das dificuldades associadas ao uso de dados observacionais para estimar efeitos causais. Elas são duas:

- **Variáveis omitidas** (*confounding*): um fator não incluído no modelo afeta simultaneamente o tratamento e o resultado. É o caso da predisposição genética na controvérsia do cigarro, e o que os 99 controles do caso *New York Times* tentavam neutralizar;
- **Causalidade simultânea**: X afeta Y , mas Y também afeta X . Turmas menores podem melhorar o desempenho, mas escolas com desempenho ruim podem receber verba adicional para reduzir turmas — e aí a correlação medida mistura os dois sentidos.

Ambas serão formalizadas no 1 como violações da hipótese $\mathbb{E}(u_i | X_i) = 0$, e é para contorná-las que existem as estratégias de identificação da segunda metade do curso.

! A frase que o curso repetirá muitas vezes

É imediato estabelecer correlação. O problema todo é que **correlação não implica causalidade**.

2.8 Laboratório computacional em R

O laboratório deste capítulo é conceitual: quero mostrar, com números, por que a aleatorização funciona e o que exatamente se perde sem ela.

2.8.1 Por que a aleatorização funciona

Simulo uma população em que o tratamento tem efeito causal **conhecido** de +5 unidades, e em que uma variável de confusão — chame-a *motivação* — afeta tanto a probabilidade de receber tratamento quanto o resultado. É a estrutura do problema de seleção.

```
set.seed(2026)
n <- 20000
motivacao <- rnorm(n)                # confundidor NAO observado
efeito_causal <- 5                   # o parametro que queremos recuperar

# resultado potencial sem tratamento: depende da motivacao
Y0 <- 50 + 8 * motivacao + rnorm(n, sd = 5)
Y1 <- Y0 + efeito_causal              # efeito constante, por simplicidade

# ESCOLHA: mais motivados se autosselecionam ao tratamento
p_trat <- plogis(1.5 * motivacao)
D_obs <- rbinom(n, 1, p_trat)         # tratamento observacional
D_ale <- rbinom(n, 1, 0.5)           # tratamento aleatorizado

c(efeito_verdadeiro = efeito_causal,
  prop_tratada_obs = mean(D_obs),
  prop_tratada_ale = mean(D_ale))
```

efeito_verdadeiro	prop_tratada_obs	prop_tratada_ale
5.00000	0.50210	0.50005

Com os dados montados, comparo as duas estimativas ingênuas de diferença de médias:

```
Y_obs <- ifelse(D_obs == 1, Y1, Y0)  # o que se observa no mundo observacional
Y_ale <- ifelse(D_ale == 1, Y1, Y0)  # o que se observaria com sorteio

dif_obs <- mean(Y_obs[D_obs == 1]) - mean(Y_obs[D_obs == 0])
dif_ale <- mean(Y_ale[D_ale == 1]) - mean(Y_ale[D_ale == 0])
```

```
c(verdadeiro = efeito_causal,
  observacional = dif_obs, vies_observacional = dif_obs - efeito_causal,
  aleatorizado = dif_ale, vies_aleatorizado = dif_ale - efeito_causal)
```

	verdadeiro	observacional	vies_observacional	aleatorizado
	5.00000000	13.53237861	8.53237861	4.98688525
vies_aleatorizado	-0.01311475			

O contraste é o capítulo inteiro em três linhas. A comparação **observacional** superestima grosseiramente o efeito: ela atribui ao tratamento não só os 5 pontos que ele de fato causa, mas também a vantagem prévia dos mais motivados, que se autosselecionaram. A comparação **aleatorizada** acerta o alvo, com erro compatível com ruído amostral.

A razão aparece ao inspecionar o **balanceamento** do confundidor entre os grupos:

```
rbind(
  observacional = c(tratados = mean(motivacao[D_obs == 1]),
                    controles = mean(motivacao[D_obs == 0]),
                    diferenca = mean(motivacao[D_obs == 1]) -
                               mean(motivacao[D_obs == 0])),
  aleatorizado = c(mean(motivacao[D_ale == 1]),
                   mean(motivacao[D_ale == 0]),
                   mean(motivacao[D_ale == 1]) - mean(motivacao[D_ale == 0]))
)
```

	tratados	controles	diferenca
observacional	0.53770839	-0.52101584	1.058724233
aleatorizado	0.01545656	0.00568165	0.009774915

Sob aleatorização, os grupos têm motivação média praticamente idêntica — a diferença é ruído. Sob autosseleção, os tratados são sistematicamente mais motivados, e é essa diferença prévia que contamina a comparação de resultados. **A aleatorização não elimina o confundidor; ela o distribui igualmente entre os grupos**, que é tudo de que precisamos.

```
rot_obs <- "observacional (autosselecao)"
rot_ale <- "aleatorizado (sorteio)"
d <- rbind(
  data.frame(motivacao, grupo = ifelse(D_obs == 1, "tratado", "controle"),
             desenho = rot_obs),
  data.frame(motivacao, grupo = ifelse(D_ale == 1, "tratado", "controle"),
             desenho = rot_ale)
)
# fixa a ordem dos painéis: autosselecao a esquerda, sorteio a direita
d$desenho <- factor(d$desenho, levels = c(rot_obs, rot_ale))
```

```
ggplot(d, aes(x = motivacao, fill = grupo)) +
  geom_density(alpha = 0.45, colour = NA) +
  facet_wrap(~desenho) +
  scale_fill_manual(values = c(controle = cz, tratado = az)) +
  labs(x = "motivacao (confundidor nao observado)", y = "densidade")
```




Figura 1: Distribuição do confundidor (motivação) entre tratados e controles. Sob autosseleção (esquerda) os grupos são visivelmente diferentes antes de qualquer tratamento; sob aleatorização (direita) as distribuições se sobrepõem.

2.8.2 O que “controlar por observáveis” resolve — e o que não resolve

A aposta da regressão é que, controlando pelos observáveis, o viés desaparece. Vale ver isso funcionar e, em seguida, falhar.

```
# caso 1: o confundidor E observado -> controlar resolve
m_sem <- lm(Y_obs ~ D_obs)
m_com <- lm(Y_obs ~ D_obs + motivacao)

# caso 2: observamos apenas um PROXY ruidoso da motivacao
proxy <- motivacao + rnorm(n, sd = 1.2)
m_proxy <- lm(Y_obs ~ D_obs + proxy)

round(c(verdadeiro      = efeito_causal,
        sem_controle    = coef(m_sem)[2],
        com_confundidor = coef(m_com)[2],
        com_proxy_ruidoso = coef(m_proxy)[2]), 4)
```

verdadeiro	sem_controle.D_obs	com_confundidor.D_obs
------------	--------------------	-----------------------

5.0000
com_proxy_ruidoso.D_obs
10.6181

13.5324

5.0189

Três resultados, três lições. Sem controle, o viés é grande. Com o confundidor **observado e incluído**, a regressão recupera o efeito causal quase exatamente — é a aposta da inferência causal por regressão funcionando como prometido. Com um **proxy ruidoso** do confundidor, o viés diminui bastante mas **não desaparece**: controlar imperfeitamente corrige imperfeitamente.

O terceiro caso é o realista. Raramente observamos o confundidor; em geral temos indicadores imperfeitos dele. Daí a advertência do curso de que a hipótese de identificação é uma **aposta substantiva**, que depende de conhecimento do problema — e não algo que os dados possam confirmar sozinhos.

2.9 Exercícios

1. **A crítica de Fisher.** Fisher argumentou que a associação entre fumo e câncer poderia ser explicada por um gene que causasse ambos. (a) Escreva essa hipótese como um problema de variável omitida. (b) Que tipo de evidência empírica poderia distinguir a hipótese causal da genética? (c) Por que o argumento de Fisher, sendo logicamente válido, não é suficiente para descartar a conclusão substantiva?
2. **Vioxx e poder de teste.** No estudo VIGOR observaram-se 17 infartos no grupo rofecoxib contra 4 no naproxeno, e a diferença foi julgada não significativa. (a) Calcule a razão de incidência. (b) Discuta por que “não significativa” e “não existe efeito” são afirmações distintas. (c) Que informação, além do valor-p, deveria ter sido reportada?
3. **Desenhando o experimento ideal.** Para cada pergunta abaixo, descreva o experimento aleatorizado ideal — mesmo que inviável — e explique o que o torna inviável: (a) o efeito de um ano adicional de escolaridade sobre o salário; (b) o efeito do salário mínimo sobre o emprego; (c) o efeito de uma fusão empresarial sobre os preços.
4. **As quatro perguntas.** Escolha um artigo empírico de economia que você conheça e responda, para ele, as quatro perguntas de Angrist e Pischke. Onde está o elo mais fraco do argumento?
5. **Causalidade simultânea.** Suponha que turmas menores melhorem o desempenho, mas que escolas com desempenho ruim recebam verba para reduzir turmas. (a) Qual o sinal esperado do viés na regressão de desempenho contra tamanho de turma? (b) A correlação medida subestima ou superestima o efeito causal? Justifique.
6. **O caso *New York Times*.** A defesa poderia argumentar que faltou uma variável ao conjunto de 99 controles. (a) Que variável seria essa, e por que ela precisaria afetar simultaneamente gênero e salário? (b) Por outro lado, incluir controles em excesso também pode ser problemático — o que aconteceria se um dos 99 controles fosse *ele próprio* consequência da discriminação (por exemplo, o cargo ocupado)?
7. **Estruturas de dados.** Classifique como corte transversal, série de tempo ou painel:

- (a) PIB trimestral brasileiro de 1996 a 2025; (b) a PNAD Contínua de um trimestre específico; (c) as demonstrações financeiras anuais de 200 empresas ao longo de 10 anos. Para (c), que tipo de variável omitida o painel permitiria controlar que o corte transversal não permitiria?
- 8. **Simulação.** Modifique o laboratório deste capítulo para que o efeito do tratamento seja **heterogêneo** — por exemplo, maior para os mais motivados. (a) A diferença de médias sob aleatorização ainda recupera algum parâmetro interpretável? Qual? (b) E a comparação observacional? (c) Que implicação isso tem para a leitura de resultados experimentais quando a população é heterogênea?

3 Revisão de Probabilidade

O Seção 2 terminou com um problema, não com uma solução: queremos efeitos causais, o padrão ouro para obtê-los é o experimento aleatorizado, e quase nunca temos um. Antes de construir a primeira ferramenta capaz de enfrentar esse problema — o modelo de regressão linear —, precisamos recuperar o vocabulário probabilístico em que ela é escrita. É o que faz este capítulo.

A revisão não é um preâmbulo protocolar. Há **duas razões precisas** para um curso de econometria começar por probabilidade, e vale enunciá-las antes de qualquer definição, porque elas organizam tudo o que vem a seguir.

A primeira é que **a regressão é, essencialmente, um método para estimar médias condicionais**. Quando escrevemos $Y_i = \beta_0 + \beta_1 X_i + u_i$ e impomos $\mathbb{E}(u_i | X_i) = 0$, o que estamos de fato afirmando é que a reta populacional $\beta_0 + \beta_1 X$ é a média de Y dado X . Toda a interpretação de β_1 como “efeito de X sobre Y ” passa por aí. Sem entender o que é a média condicional $\mathbb{E}(Y | X)$ — o que ela mede, como se comporta, em que sentido ela difere de correlação —, o modelo de regressão vira manipulação simbólica sem conteúdo. Por isso a **média condicional** e a **lei das expectativas iteradas** recebem, aqui, tratamento desproporcional ao seu tamanho nos slides: são as peças que reaparecerão, sem aviso, em cada passo de 1.

A segunda razão é a inferência. Um estimador é uma função dos dados; os dados são aleatórios; logo o estimador é uma **variável aleatória**, com distribuição própria. Tudo o que dizemos sobre precisão — erros-padrão, intervalos de confiança, testes de hipótese — é uma afirmação sobre essa **distribuição amostral**. Esperança e variância, que revisamos adiante, são exatamente os objetos com que se calcula viés e precisão de um estimador.

! Convenção de notação

Usamos letras maiúsculas (X, Y) para variáveis aleatórias e minúsculas (x, y) para os valores que elas podem assumir. Parâmetros populacionais são letras gregas: μ para médias, σ^2 para variâncias, θ para a probabilidade de sucesso de uma Bernoulli. Todo este capítulo trata de **quantidades populacionais** — não de estimativas amostrais. A passagem da população para a amostra é o assunto de 1.

3.1 Variáveis aleatórias e distribuição de probabilidade

Uma **variável aleatória** é uma variável cujo valor numérico depende de um experimento aleatório. O exemplo mínimo do professor é o lançamento de uma moeda: o experimento tem dois resultados possíveis, cara e coroa, e a variável aleatória é a regra que associa um número a cada um deles.

Defina X assumindo o valor 1 se sai cara — evento com probabilidade θ — e zero caso contrário:

$$X = \begin{cases} 1, & \text{com probabilidade } \theta, \\ 0, & \text{com probabilidade } 1 - \theta. \end{cases}$$

Essa é a **variável aleatória de Bernoulli**. Apesar da simplicidade, ela é onipresente em economia aplicada: participar ou não do mercado de trabalho, receber ou não um tratamento, uma empresa

entrar em default ou não. Boa parte das variáveis dependentes interessantes em microeconometria são Bernoullis.

Variáveis aleatórias são **discretas** ou **contínuas**. A Bernoulli é discreta: assume valores em um conjunto discreto, como 0, 1, 2, ... Uma variável aleatória **contínua** assume valores em um *continuum* — tipicamente resultados de medições (peso, tempo, renda, retorno de um ativo) e não de contagens.

! Definição — distribuição de probabilidade (caso discreto)

A **distribuição de probabilidade** de uma variável aleatória discreta é a lista de todos os seus valores possíveis e as respectivas probabilidades associadas a cada valor.

3.1.1 A disputa de pênaltis e a Binomial

O professor constrói a distribuição Binomial a partir de um exemplo que vale a pena seguir com cuidado, porque o passo decisivo é justamente o que a intuição erra.

Considere uma disputa de pênaltis com **cinco cobranças**. O número de “sucessos” — isto é, pênaltis convertidos — é uma variável aleatória X que pode assumir os valores $x = 0, 1, 2, 3, 4, 5$. Cada cobrança é, isoladamente, uma Bernoulli(θ), com θ a probabilidade de converter, e as cobranças são independentes entre si.

Comece pelo caso fácil. A probabilidade de converter **todas** as cinco é

$$P(X = 5) = \theta^5,$$

porque há uma única forma de isso acontecer — a sequência (1, 1, 1, 1, 1) — e a independência permite multiplicar as probabilidades.

Agora o caso interessante. Uma sequência com três sucessos e dois fracassos pode ocorrer, por exemplo, como

$$(1, 1, 1, 0, 0),$$

e **essa sequência em particular** ocorre com probabilidade $\theta^3(1 - \theta)^2$. Aqui vem a pergunta do professor: essa **não** é a probabilidade de $P(X = 3)$. Por quê?

Porque existem várias formas de converter três gols. As sequências

$$(0, 1, 0, 1, 1), \quad (0, 0, 1, 1, 1), \quad (1, 0, 1, 0, 1), \quad \dots$$

são todas distintas como sequências, mas todas correspondem ao **mesmo** evento $X = 3$. Cada uma delas tem a mesma probabilidade $\theta^3(1 - \theta)^2$ — a ordem não altera o produto —, e como são mutuamente excludentes, suas probabilidades se somam. Resta contar quantas são: é o número de formas de escolher quais 3 das 5 cobranças foram convertidas, ou seja, $C_3^5 = \binom{5}{3} = 10$. Portanto

$$P(X = 3) = C_3^5 \theta^3(1 - \theta)^2 = \frac{5!}{3!(5 - 3)!} \theta^3(1 - \theta)^2.$$

O raciocínio não depende dos números escolhidos. De forma geral, para n tentativas independentes com probabilidade θ de sucesso em cada uma,

$$P(X = x) = C_x^n \theta^x (1 - \theta)^{n-x}, \quad x = 0, 1, 2, \dots, n$$

que é a distribuição de probabilidade de uma **Binomial** com parâmetros (n, θ) . Note a anatomia da fórmula: $\theta^x (1 - \theta)^{n-x}$ é a probabilidade de *uma* sequência com x sucessos, e C_x^n conta *quantas* sequências produzem o mesmo total. O erro de omitir o coeficiente binomial é, no fundo, o erro de confundir uma sequência específica com um evento agregado.

i Ferramenta estatística — análise combinatória e a Binomial

A contagem de C_x^n sequências, a distinção entre arranjos e combinações e a dedução completa da família Binomial são desenvolvidas com mais vagar no capítulo de *Probabilidade e Distribuições Discretas* das **Notas de Aula de Estatística** (Prof. Eduardo Campos). Se o coeficiente binomial soa mecânico, vale a leitura: ele é a única parte da fórmula que não sai da independência.

3.1.2 Propriedades e distribuição acumulada

Seja X uma variável aleatória discreta que pode assumir n valores $x_1, x_2, \dots, x_n$. Então valem duas propriedades que qualquer distribuição de probabilidade precisa satisfazer:

$$P(X = x_i) \geq 0 \quad \forall x_i, i = 1, 2, \dots, n \quad \text{e} \quad \sum_{i=1}^n P(X = x_i) = 1.$$

A primeira é a exigência de que probabilidades não sejam negativas; a segunda, de que a lista de valores possíveis seja exaustiva — alguma coisa tem de acontecer.

A **distribuição de probabilidade acumulada** (ou função de distribuição acumulada, CDF) é a probabilidade de a variável aleatória ser menor ou igual a um valor particular. Para $X \sim \text{Bin}(n, \theta)$,

$$F(x_k) = P(X \leq x_k) = \sum_{i=1}^k P(X = x_i).$$

Voltando aos pênaltis com $n = 5$, a probabilidade de o time converter no máximo três cobranças é

$$P(X \leq 3) = P(X = 0) + P(X = 1) + P(X = 2) + P(X = 3).$$

Duas observações sobre a CDF, ambas do professor e ambas consequência direta de as probabilidades serem não negativas e somarem um. Primeiro, a acumulada **nunca decresce**: cada termo adicionado à soma é ≥ 0 , de modo que F é uma função não decrescente de x . Segundo, $P(X \leq x_n) = 1$ — ao chegar ao maior valor possível, a acumulada esgota toda a probabilidade.

3.2 Variáveis aleatórias contínuas

No caso contínuo, a probabilidade de ocorrer um valor específico é **zero**. O exemplo do professor é bom porque desarma a estranheza: qual é a probabilidade de alguém pesar exatamente 79,314159163 kg? Nenhuma balança do mundo distingue esse valor de seus vizinhos, e há um *continuum* não enumerável deles. A probabilidade de qualquer ponto isolado é nula.

O que faz sentido perguntar é a probabilidade de a variável cair em um **intervalo** — por exemplo, qual a probabilidade de o peso do indivíduo estar entre 75 kg e 85 kg. Formalmente,

$$P(a < X < b) = \int_a^b f(x) dx,$$

em que $f(\cdot)$ é a **função de densidade de probabilidade** (PDF). Como $P(X = a) = P(X = b) = 0$, incluir ou não os extremos é indiferente:

$$P(a < X < b) = P(a \leq X \leq b).$$

Essa é uma diferença qualitativa em relação ao caso discreto, onde trocar $<$ por $\leq$ muda o resultado. A densidade satisfaz, em paralelo às duas propriedades do caso discreto,

$$f(x) \geq 0 \quad \text{e} \quad \int_{-\infty}^{\infty} f(x) dx = 1.$$

Um alerta que vale para sempre: $f(x)$ **não é** uma probabilidade — pode inclusive ser maior que 1. Probabilidade é área sob a densidade, não altura dela.

A **função de distribuição acumulada** no caso contínuo é

$$F(x_0) = P(X \leq x_0) = \int_{-\infty}^{x_0} f(x) dx,$$

e dela seguem as identidades de trabalho:

$$P(a < X < b) = \int_a^b f(x) dx = F(b) - F(a), \quad P(X < c) + P(X > c) = 1, \quad P(X > c) = 1 - F(c).$$

3.2.1 A Normal e o papel da simetria

O exemplo canônico de distribuição contínua é a **Normal**, que reaparecerá em toda a inferência do curso — não por elegância, mas porque o teorema central do limite faz dela a distribuição-limite das médias amostrais e, por extensão, dos estimadores de MQO.

A Normal é **simétrica** em torno de sua média, e disso decorrem propriedades extras da CDF que o professor destaca. Para a Normal padrão,

$$P(X < -c) = P(X > c) \quad \text{e portanto} \quad F(-c) = 1 - F(c).$$

A primeira igualdade diz que as duas caudas, cortadas simetricamente, têm a mesma massa; a segunda a reescreve em termos da acumulada. A consequência prática é conhecida de quem já consultou uma tabela: **é por isso que os livros de estatística só trazem os valores positivos da CDF da Normal**. O lado negativo é redundante — obtém-se por $1 - F(c)$.

i Ferramenta estatística — a distribuição Normal

As propriedades da Normal (forma da densidade, padronização, uso de tabelas, a família $\chi^2/t/F$ derivada dela) são tratadas em detalhe no capítulo de *Variáveis Aleatórias Contínuas* das **Notas de Aula de Estatística**. Aqui interessa apenas o que será usado adiante: simetria, padronização e o fato de que média e variância determinam completamente a distribuição.

3.3 Valor esperado

O **valor esperado** de uma variável aleatória é a média ponderada de seus valores possíveis, com pesos iguais às respectivas probabilidades. É o análogo populacional da média aritmética.

Para uma variável aleatória discreta,

$$\mathbb{E}(X) = \sum_{i=1}^n p(x_i) x_i$$

e para uma contínua, com a soma virando integral e a probabilidade virando densidade,

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f(x) dx$$

Exemplo: $X \sim \text{Bin}(n, \theta)$. Pode-se mostrar que o valor esperado de uma Binomial com parâmetros n e θ é

$$\mathbb{E}(X) = n\theta.$$

O resultado tem leitura imediata no exemplo dos pênaltis: um time com **80% de aproveitamento** vai converter, em média, $5 \times 0,8 = 4$ gols a cada 5 cobranças. Note que “em média” não significa

“sempre” — a Binomial atribui probabilidade positiva a todos os resultados de 0 a 5; significa que, repetida a disputa muitas vezes, a média de gols convertidos tende a 4. O laboratório verifica isso por simulação.

3.3.1 Propriedades

Duas propriedades do valor esperado carregam quase todo o trabalho algébrico do curso. A primeira é a **linearidade**: se $Y = a + bX$, então

$$\mathbb{E}(Y) = a + b \mathbb{E}(X)$$

A segunda trata de funções mais gerais: se $Y = g(X)$, então $\mathbb{E}(Y) = \mathbb{E}(g(X))$, que no caso contínuo se calcula como

$$\mathbb{E}(g(X)) = \int_{-\infty}^{\infty} g(x)f(x) dx.$$

Repare no que essa fórmula diz — e no que ela não diz. Para calcular $\mathbb{E}(g(X))$ basta a densidade de X ; não é preciso derivar a densidade de Y . Mas, em geral, $\mathbb{E}(g(X)) \neq g(\mathbb{E}(X))$: a esperança comuta com transformações **lineares** e apenas com elas. Essa distinção reaparecerá adiante, quando mostrarmos que $\mathbb{E}(Y | X) = \mathbb{E}(Y)$ não implica independência.

3.4 Variância e desvio padrão

O valor esperado localiza a distribuição; a **variância** mede sua dispersão em torno desse centro. Com $\mu = \mathbb{E}(X)$, no caso discreto,

$$\text{Var}(X) = \sum_{i=1}^n p(x_i) (x_i - \mu)^2 \quad \text{ou, equivalentemente,} \quad \text{Var}(X) = \sum_{i=1}^n p(x_i) x_i^2 - \mu^2,$$

e no caso contínuo,

$$\text{Var}(X) = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx \quad \text{ou} \quad \text{Var}(X) = \int_{-\infty}^{\infty} x^2 f(x) dx - \mu^2.$$

As duas formas de cada par são idênticas — a segunda é o **atalho de cálculo** $\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$, que se obtém expandindo o quadrado e usando a linearidade:

$$\mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2 - 2\mu X + \mu^2] = \mathbb{E}(X^2) - 2\mu \mathbb{E}(X) + \mu^2 = \mathbb{E}(X^2) - \mu^2.$$

Vale memorizar a forma compacta, que usaremos sem cerimônia:

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$$

O **desvio padrão** é a raiz quadrada da variância:

$$\sigma = \text{SD}(X) = \sqrt{\text{Var}(X)}.$$

Por que trabalhar com o desvio padrão se a variância já mede dispersão? O professor dá dois motivos, e ambos importam.

Primeiro motivo: unidades. A variância está na unidade **ao quadrado** da variável. Se X é o retorno de um ativo financeiro medido em %, a unidade da variância é %² — algo que ninguém sabe interpretar. O desvio padrão está em %, a unidade original, e por isso é a medida de risco que se reporta na prática.

Segundo motivo: a desigualdade de Chebyshev, que dá ao desvio padrão um significado quantitativo válido para *qualquer* distribuição.

3.4.1 A desigualdade de Chebyshev

O professor apresenta o resultado por suas implicações práticas: para uma ampla gama de distribuições de probabilidade, **75% dos valores** se encontram no intervalo de dois desvios padrão em torno da média, e **88,9%** dentro de três desvios padrão. Para comparação, no caso da distribuição Normal essas porcentagens são **95%** e **99,7%**.

Vale enunciar o resultado formalmente, porque a força dele está exatamente no que ele *não* exige.

! Desigualdade de Chebyshev

Seja X uma variável aleatória com média μ e variância $\sigma^2 < \infty$. Então, para todo $k > 0$,

$$P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2} \quad \Leftrightarrow \quad P(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2}$$

Nenhuma hipótese sobre a forma da distribuição é necessária — apenas que a variância exista.

Com $k = 2$, o limite é $1 - 1/4 = 0,75$; com $k = 3$, é $1 - 1/9 \approx 0,889$. São exatamente os 75% e os 88,9% do slide.

A demonstração é curta e instrutiva. Escreva a variância como integral (o argumento no caso discreto é idêntico, com somas) e jogue fora a parte central do domínio, que só pode contribuir com massa não negativa:

$$\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx \geq \int_{|x - \mu| \geq k\sigma} (x - \mu)^2 f(x) dx.$$

Na região que sobrou vale $(x - \mu)^2 \geq k^2 \sigma^2$ por construção. Substituindo o integrando por essa cota inferior, a desigualdade se preserva:

$$\sigma^2 \geq k^2 \sigma^2 \int_{|x - \mu| \geq k\sigma} f(x) dx = k^2 \sigma^2 P(|X - \mu| \geq k\sigma).$$

Dividindo ambos os lados por $k^2\sigma^2 > 0$, obtemos $P(|X - \mu| \geq k\sigma) \leq 1/k^2$, como queríamos. ■

Duas leituras deste resultado, ambas importantes para o curso.

A primeira é **positiva**: o desvio padrão não é uma medida arbitrária de dispersão. Ele carrega, universalmente, uma garantia probabilística — dizer que σ é pequeno é dizer algo com conteúdo sobre onde a variável cai, sem precisar saber qual é a distribuição.

A segunda é sobre **folga**. Compare 75% (Chebyshev) com 95% (Normal): o limite de Chebyshev é bastante frouxo para distribuições bem comportadas. Isso é inevitável e é o preço da generalidade — o limite tem de valer inclusive para as distribuições mais patológicas com variância finita. Na prática, quando conhecemos a forma da distribuição, usamos o resultado mais forte que ela permite; Chebyshev é a rede de segurança de quando não conhecemos nada. O laboratório ilustra essa folga em cinco distribuições muito diferentes entre si.

3.4.2 Transformação linear e padronização

Seja $Y = a + bX$. Então

$$\boxed{\text{Var}(Y) = b^2 \text{Var}(X) \quad \text{e} \quad \text{SD}(Y) = |b| \text{SD}(X)}$$

Duas coisas a notar. A constante aditiva a **desaparece**: deslocar toda a distribuição não altera sua dispersão. E o fator multiplicativo entra **ao quadrado** na variância, o que é apenas a contrapartida do problema das unidades — se b está em reais por dólar, a variância traz esse fator duas vezes. No desvio padrão aparece $|b|$, com módulo, porque o desvio padrão é não negativo por definição, mesmo quando $b < 0$.

Um caso particular merece nome próprio. Considere X com média μ_X e variância σ_X^2 , e a transformação linear

$$Z = \frac{X - \mu_X}{\sigma_X},$$

que é a **padronização** de X . Aplicando as regras acima com $a = -\mu_X/\sigma_X$ e $b = 1/\sigma_X$, é fácil mostrar que

$$\mathbb{E}(Z) = 0 \quad \text{e} \quad \text{Var}(Z) = 1.$$

A padronização é o que permite expressar qualquer variável em “número de desvios padrão de distância da média” e, com isso, comparar variáveis medidas em unidades diferentes. É também o mecanismo por trás de toda estatística de teste que veremos: uma estatística t é um estimador padronizado.

3.5 Distribuição conjunta, marginal e independência

Até aqui, uma variável de cada vez. Mas econometria é sobre **relações** entre variáveis, e para falar delas precisamos da distribuição de duas variáveis simultaneamente.

Caso discreto. A **distribuição conjunta** de X e Y é

$$P_{X,Y}(x, y) = P(X = x, Y = y),$$

a probabilidade de os dois eventos ocorrerem juntos. Para um conjunto S de pares,

$$P((X, Y) \in S) = \sum_{(x,y) \in S} P(x, y),$$

e as restrições são as análogas do caso univariado:

$$P_{X,Y}(x, y) \geq 0 \quad \text{e} \quad \sum_x \sum_y P(x, y) = 1.$$

A **distribuição marginal** de cada variável se obtém “somando fora” a outra:

$$P(X = x) = \sum_y P(x, y) \quad \text{e} \quad P(Y = y) = \sum_x P(x, y).$$

O nome vem literalmente da prática de anotar essas somas nas margens de uma tabela de dupla entrada — é o que faremos na tabela da próxima seção. A esperança de uma função de ambas as variáveis é

$$\mathbb{E}(g(X, Y)) = \sum_x \sum_y g(x, y) P(x, y).$$

Finalmente, X e Y são **independentes** se

$$\boxed{P(x, y) = P(X = x) P(Y = y), \quad \forall x, y}$$

isto é, se a conjunta se fatora como o produto das marginais **para todos os pares**. A quantificação universal importa: basta uma célula em que a fatoração falhe para que a independência esteja destruída.

Caso contínuo. As definições são as mesmas, com densidades no lugar de probabilidades e integrais no lugar de somas:

$$P((X, Y) \in S) = \iint_S f(x, y) dx dy, \quad f(x, y) \geq 0, \quad \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1.$$

As marginais são

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy \quad \text{e} \quad f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx,$$

a independência é $f(x, y) = f_X(x) f_Y(y)$ para todo (x, y) , e a esperança de uma função $g(\cdot)$ é

$$\mathbb{E}(g(X, Y)) = \iint g(x, y) f(x, y) dx dy.$$

3.6 Distribuição condicional e média condicional

Chegamos ao coração do capítulo. Tudo o que veio antes é infraestrutura; o que vem a seguir é o objeto que a regressão estima.

A distribuição de uma variável aleatória Y **condicionada** a outra variável aleatória X , em um valor específico de X , é chamada **distribuição condicional de Y dado X** . A probabilidade condicional é

$$P(Y = y \mid X = x) = \frac{P(X = x, Y = y)}{P(X = x)}$$

A leitura é a de sempre: restringimos o universo aos casos em que $X = x$ — daí o denominador — e perguntamos qual fração deles tem também $Y = y$. Condicionar é **reponderar**: descartamos parte do espaço amostral e renormalizamos o que sobra para que volte a somar 1.

3.6.1 A tabela chuva × tempo de deslocamento

O exemplo do professor é o de um trabalhador que se desloca de casa para o trabalho. Sejam $X = 0$ se chove e $X = 1$ se não chove, e $Y = 0$ se o deslocamento é longo (*long commute*) e $Y = 1$ se é curto (*short commute*). A distribuição conjunta é:

Tabela 1: Distribuição conjunta de chuva e tempo de deslocamento. As quatro células internas são a conjunta; as margens são as distribuições marginais.

	Rain ($X = 0$)	No Rain ($X = 1$)	Total
Long Commute ($Y = 0$)	0,15	0,07	0,22
Short Commute ($Y = 1$)	0,15	0,63	0,78
Total	0,30	0,70	1,00

As quatro células internas somam 1, como exige a definição de distribuição conjunta. As margens são as marginais: somando a linha, $P(Y = 0) = 0,15 + 0,07 = 0,22$; somando a coluna, $P(X = 0) = 0,15 + 0,15 = 0,30$. Chove em 30% dos dias, e o deslocamento é longo em 22% deles.

Os cálculos do professor, um a um:

$$P(\text{Long C. \& Rain}) = P(X = 0, Y = 0) = 0,15,$$

que é a **conjunta** — lida diretamente da célula;

$$P(\text{Long C.}) = P(Y = 0) = P(X = 0, Y = 0) + P(X = 1, Y = 0) = 0,15 + 0,07 = 0,22,$$

que é a **marginal** — a soma da linha; e as **condicionais**, que dividem a conjunta pela marginal do condicionante:

$$P(\text{Long C.} \mid \text{Rain}) = \frac{P(\text{Long C. \& Rain})}{P(\text{Rain})} = \frac{P(X = 0, Y = 0)}{P(X = 0)} = \frac{0,15}{0,30} = 0,5,$$

$$P(\text{Short C.} \mid \text{Rain}) = \frac{P(X = 0, Y = 1)}{P(X = 0)} = \frac{0,15}{0,30} = 0,5.$$

Vale contrastar os três números que aparecem para o mesmo evento “deslocamento longo”: 0,15 (conjunta com chuva), 0,22 (marginal) e 0,50 (condicional a chuva). São perguntas diferentes. A conjunta pergunta “que fração de *todos* os dias tem chuva e deslocamento longo?”; a marginal, “que fração de todos os dias tem deslocamento longo?”; a condicional, “**entre os dias de chuva**, que fração tem deslocamento longo?”. Confundir a segunda com a terceira é um dos erros mais comuns de leitura de dados — e, note, o salto de 22% para 50% é precisamente a informação econômica que a tabela contém: chover mais que dobra a chance de um deslocamento longo.

Observe também que a condicional em dia de chuva é (0,5; 0,5), enquanto em dia sem chuva é (0,07/0,70; 0,63/0,70) = (0,1; 0,9). Como as duas condicionais diferem, X e Y **não são independentes** — o que também se verifica pela fatoração: $P(X = 0)P(Y = 0) = 0,30 \times 0,22 = 0,066 \neq 0,15$.

3.6.2 A média condicional

A **média condicional** (*conditional expectation*) de Y dado X é a média da distribuição condicional de Y dado X . Ou seja: é o valor esperado de Y calculado usando a distribuição condicional, e não a marginal. Se Y assume k valores $y_1, y_2, \dots, y_k$,

$$\mathbb{E}(Y \mid X = x) = \sum_{i=1}^k y_i P(Y = y_i \mid X = x)$$

Duas observações de notação que evitam confusão mais adiante. Primeiro, $\mathbb{E}(Y \mid X = x)$ é um **número** — a média de Y na subpopulação em que X vale x . Segundo, $\mathbb{E}(Y \mid X)$, sem fixar o valor, é uma **função de X** e, portanto, uma variável aleatória: ela assume o valor $\mathbb{E}(Y \mid X = x)$ quando $X = x$. Essa distinção é o que torna sensata a expressão $\mathbb{E}(\mathbb{E}(Y \mid X))$ da próxima seção — a esperança externa é tomada sobre a aleatoriedade de X .

Na tabela do deslocamento, com Y codificada como 0/1, $\mathbb{E}(Y \mid X = 0) = 0 \times 0,5 + 1 \times 0,5 = 0,5$ e $\mathbb{E}(Y \mid X = 1) = 0 \times 0,1 + 1 \times 0,9 = 0,9$. Para variáveis binárias, a média condicional é simplesmente a probabilidade condicional de $Y = 1$ — fato que reaparecerá no modelo de probabilidade linear.

! Por que a média condicional é o objeto central do curso

O modelo de regressão populacional de 1 será $Y_i = \beta_0 + \beta_1 X_i + u_i$ com $\mathbb{E}(u_i | X_i) = 0$. Tomando a média condicional dos dois lados e usando as propriedades abaixo,

$$\mathbb{E}(Y_i | X_i) = \beta_0 + \beta_1 X_i.$$

Isto é: a reta populacional é a média condicional de Y dado X , e β_1 é o quanto essa média muda quando X aumenta em uma unidade. Estimar uma regressão é estimar médias condicionais.

3.6.3 Propriedades da média condicional

Três propriedades, todas usadas repetidamente adiante:

$$\mathbb{E}(g(X) | X) = g(X);$$

$$\mathbb{E}(a(X)Y + b(X) | X) = a(X)\mathbb{E}(Y | X) + b(X);$$

$$\text{se } X \text{ e } Y \text{ são independentes,} \quad \mathbb{E}(Y | X) = \mathbb{E}(Y).$$

A primeira formaliza a ideia de que, **dado** X , qualquer função de X é conhecida — e o valor esperado de uma constante é a própria constante. A segunda é a linearidade condicional, e a novidade em relação à linearidade usual é que os “coeficientes” $a(X)$ e $b(X)$ podem depender de X : condicionalmente a X , eles são constantes e saem da esperança. A terceira diz que, sob independência, saber X não informa nada sobre Y — a distribuição condicional coincide com a marginal, e portanto suas médias coincidem.

Guarde a terceira propriedade com atenção à direção da implicação: independência **implica** $\mathbb{E}(Y | X) = \mathbb{E}(Y)$. A recíproca é falsa, e a seção final deste capítulo é inteiramente dedicada a isso.

3.7 A lei das expectativas iteradas

Enunciada em palavras, a **lei das expectativas iteradas** diz que a média de Y é a média ponderada da média condicional de Y dado X , com pesos iguais à distribuição de probabilidade de X . Matematicamente:

$$\mathbb{E}(Y) = \sum_{i=1}^n \mathbb{E}(Y | X = x_i) \cdot \Pr(X = x_i) = \mathbb{E}(\mathbb{E}(Y | X))$$

A segunda igualdade é apenas a primeira reescrita: a soma ponderada de $\mathbb{E}(Y | X = x_i)$ pelas probabilidades de X é, por definição, a esperança da variável aleatória $\mathbb{E}(Y | X)$.

3.7.1 A intuição, pela altura média

O professor constrói a intuição com um problema concreto, e a passagem é boa o bastante para reproduzir passo a passo.

O problema: calcular a altura média de uma população.

Primeira forma. Simplesmente calcular a média de todo mundo:

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i,$$

que é o equivalente amostral de $\mathbb{E}(Y)$. Nada de especial aqui.

Segunda forma. Separar a população entre mulheres (M) e homens (H) e calcular a altura média de cada grupo:

$$\bar{y}_M = \frac{1}{n_M} \sum_{i \in M} y_i \quad \text{e} \quad \bar{y}_H = \frac{1}{n_H} \sum_{i \in H} y_i,$$

com $n_M + n_H = n$. A pergunta é: podemos recuperar a média geral a partir dessas duas médias parciais? Podemos, e o caminho é curto.

Multiplique cada média de grupo pelo tamanho do grupo. Isso desfaz a divisão e devolve as **somas** de cada grupo, que juntas são a soma total:

$$n_M \bar{y}_M + n_H \bar{y}_H = \sum_{i \in M} y_i + \sum_{i \in H} y_i = \sum_{i=1}^n y_i.$$

Basta então dividir ambos os lados por n :

$$\bar{y} = \frac{n_M}{n} \bar{y}_M + \frac{n_H}{n} \bar{y}_H.$$

Agora o passo que transforma uma identidade contábil em um teorema de probabilidade. Observe que

$$\Pr(M) = \frac{n_M}{n} \quad \text{e} \quad \Pr(H) = \frac{n_H}{n},$$

isto é, as frações populacionais **são** as probabilidades de sexo. E as médias de grupo são médias condicionais: com X denotando o sexo,

$$\mathbb{E}(Y \mid X = m) = \bar{y}_M \quad \text{e} \quad \mathbb{E}(Y \mid X = h) = \bar{y}_H.$$

Substituindo tudo na identidade anterior, com notação de esperanças:

$$\mathbb{E}(Y) = \mathbb{E}(Y \mid X = m) \cdot \Pr(X = m) + \mathbb{E}(Y \mid X = h) \cdot \Pr(X = h),$$

ou, compactamente,

$$\mathbb{E}(Y) = \mathbb{E}(\mathbb{E}(Y | X)).$$

Essa é a lei das expectativas iteradas. Note o que ela realmente afirma: a média incondicional não é uma quantidade nova, independente das médias condicionais — ela é a **média ponderada** delas. Nada se perde ao estratificar a população, desde que os pesos usados na recomposição sejam as probabilidades corretas de cada estrato. E note também o que ela **não** afirma: a média simples das médias condicionais, $(\bar{y}_M + \bar{y}_H)/2$, em geral **não** é $\bar{y}$ — só coincide se os grupos tiverem o mesmo tamanho. Ignorar os pesos é uma fonte clássica de erro em análise de dados agregados.

Duas consequências que usaremos muito. A primeira: se $\mathbb{E}(Y | X) = 0$ para todo X , então $\mathbb{E}(Y) = 0$ — a lei transporta a hipótese de média condicional nula para a média incondicional. É exatamente o mecanismo pelo qual a hipótese $\mathbb{E}(u_i | X_i) = 0$ garante que os resíduos populacionais têm média zero. A segunda, mais geral, é a **lei das expectativas iteradas em forma multiplicativa**: para qualquer função g ,

$$\mathbb{E}(g(X)Y) = \mathbb{E}(g(X)\mathbb{E}(Y | X)),$$

que se obtém aplicando a lei a $g(X)Y$ e usando a linearidade condicional. Com $g(X) = X$ e $\mathbb{E}(Y | X)$ constante, ela produzirá, na próxima seção, o resultado sobre covariância nula.

3.8 Covariância, correlação e independência

A **covariância** é uma medida de associação **linear** entre duas variáveis aleatórias:

$$\text{Cov}(X, Y) = \sigma_{XY} = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)]$$

A lógica do sinal é a de sempre: cada parcela é positiva quando as duas variáveis se desviam de suas médias no mesmo sentido, negativa quando em sentidos opostos. Se predominam os pares concordantes, $\text{Cov} > 0$.

Se X e Y são **independentes**, então $\text{Cov}(X, Y) = 0$. A demonstração é imediata: sob independência, $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$, e expandindo o produto na definição obtém-se $\text{Cov}(X, Y) = \mathbb{E}(XY) - \mu_X\mu_Y = 0$.

E a recíproca? O professor formula a pergunta e a deixa no ar: se $\text{Cov}(X, Y) = 0$, então X e Y são independentes? **Não**. Por quê?

Porque a covariância mede apenas **dependência linear**. Ela é construída somando produtos de desvios, e uma dependência que seja simétrica em torno da média produz parcelas positivas e negativas que se cancelam exatamente — mesmo que a dependência seja total.

Contraexemplo concreto. Seja X uma variável aleatória com distribuição simétrica em torno de zero — por exemplo, $X \sim \text{Uniforme}(-2, 2)$ — e defina

$$Y = X^2.$$

Não há dependência mais completa: conhecendo X , conhecemos Y com certeza absoluta. E, no entanto,

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) = \mathbb{E}(X^3) - 0 = 0,$$

porque $\mathbb{E}(X) = 0$ e, pela simetria da distribuição de X , todos os momentos ímpares são nulos: $\mathbb{E}(X^3) = 0$. A covariância — e portanto a correlação — é **exatamente zero** entre duas variáveis em que uma é função determinística da outra.

A moral: ausência de correlação é uma afirmação sobre a **inexistência de associação linear**, não sobre a inexistência de associação. O laboratório desenha esse contraexemplo, e o gráfico é a figura mais eloquente do capítulo — uma parábola perfeita com correlação amostral próxima de zero.

3.8.1 O problema das unidades e a correlação

O **sinal** da covariância é informativo: sabemos se as variáveis andam juntas na mesma direção ($\text{Cov} > 0$) ou em direções opostas ($\text{Cov} < 0$). Mas sua **magnitude** é problemática, por duas razões relacionadas.

A primeira é a unidade de medida. Se calculamos a covariância entre peso e altura, sua unidade é quilograma-metro — algo difícil de interpretar e impossível de comparar com a covariância entre, digamos, renda e escolaridade.

A segunda, mais séria, é que a covariância **não é robusta a transformações lineares**. Sejam $W = aX + b$ e $Z = cY + d$. Então

$$\text{Cov}(W, Z) = \text{Cov}(aX + b, cY + d) = ac \cdot \text{Cov}(X, Y)$$

As constantes aditivas somem — deslocar as variáveis não altera sua co-variação —, mas os fatores multiplicativos passam direto. Medir a renda em centavos em vez de reais multiplica a covariância por cem, sem que nada tenha mudado na relação entre as variáveis. A covariância é sensível à unidade de medida, e isso a inutiliza como medida de **força** de associação.

A solução é padronizar. A **correlação** é a covariância dividida pelo produto dos desvios padrão:

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X) \text{Var}(Y)}} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

Como os desvios padrão carregam as mesmas unidades que a covariância — uma vez cada —, o quociente é **adimensional**. E como se pode mostrar (é a desigualdade de Cauchy-Schwarz), ele é limitado:

$$-1 \leq \text{Corr}(X, Y) \leq 1.$$

Os extremos correspondem à relação linear perfeita, e $\rho = 0$ à ausência de associação *linear*. Verifique a robustez: aplicando a regra acima ao numerador e a regra $\text{SD}(aX + b) = |a|\text{SD}(X)$ ao denominador, o fator $|ac|$ se cancela e a correlação fica inalterada (a menos do sinal, se $ac < 0$).

3.8.2 Variância de combinações lineares

Duas propriedades que serão usadas o tempo todo — na dedução da variância do estimador de MQO, entre outros lugares:

$$\text{Var}(aX + bY) = a^2\text{Var}(X) + b^2\text{Var}(Y) + 2ab \text{Cov}(X, Y)$$

$$\text{Var}(aX - bY) = a^2\text{Var}(X) + b^2\text{Var}(Y) - 2ab \text{Cov}(X, Y)$$

A segunda é a primeira com b trocado por $-b$. O termo de covariância é o que distingue o caso geral do caso independente: sob independência ele desaparece e as variâncias simplesmente se somam. Em finanças, essa é a álgebra inteira da diversificação — combinar ativos com covariância negativa reduz a variância da carteira abaixo da média das variâncias individuais.

3.9 Correlação e média condicional: uma distinção que importa

O professor dedica três slides a um ponto sutil, e não é por acaso: é exatamente essa distinção que fundamenta a hipótese central do próximo capítulo. Vale destrinchá-la em três afirmações separadas.

Primeira: se a média condicional de Y não depende de X , então X e Y são não correlacionados. Ou seja,

$$\mathbb{E}(Y | X) = \mathbb{E}(Y) \implies \text{Cov}(X, Y) = 0 \text{ e } \text{Corr}(X, Y) = 0.$$

A demonstração usa a lei das expectativas iteradas em forma multiplicativa. Escreva $\mathbb{E}(XY) = \mathbb{E}(X \mathbb{E}(Y | X))$; se $\mathbb{E}(Y | X) = \mathbb{E}(Y) = \mu_Y$ é constante, ela sai da esperança:

$$\mathbb{E}(XY) = \mu_Y \mathbb{E}(X) = \mu_X \mu_Y \implies \text{Cov}(X, Y) = \mathbb{E}(XY) - \mu_X \mu_Y = 0.$$

Segunda: a recíproca não vale. Não é necessariamente verdade que, se X e Y são não correlacionados, então a média condicional de Y dado X não depende de X . Ou, alternativamente: é perfeitamente possível que $\mathbb{E}(Y | X)$ **dependa** de X e ainda assim a correlação entre Y e X seja zero.

O contraexemplo já está construído: com X simétrica em torno de zero e $Y = X^2$, temos $\text{Corr}(X, Y) = 0$ mas $\mathbb{E}(Y | X) = X^2$, que obviamente depende de X — e depende de forma dramática. A relação existe, é determinística, e a correlação não a enxerga porque não é linear.

Terceira: mesmo $\mathbb{E}(Y | X) = \mathbb{E}(Y)$ não implica independência. Este é o ponto mais fino dos três, e o professor o registra explicitamente: não é verdade que Y e X são independentes quando a média condicional de Y dado X não depende de X . Isso indica apenas que Y e X não estão correlacionados linearmente, ou que **não há dependência na média**. Ainda pode haver dependência em termos de **variância**, de **distribuição** ou de outras relações não lineares.

Um exemplo torna isso palpável. Suponha $X \sim \text{Uniforme}(-1, 1)$ e $Y = X \cdot \varepsilon$, com ε independente de X , $\mathbb{E}(\varepsilon) = 0$ e $\text{Var}(\varepsilon) = 1$. Então

$$\mathbb{E}(Y | X) = X \mathbb{E}(\varepsilon) = 0 = \mathbb{E}(Y)$$

— a média condicional é constante, não depende de X . Mas

$$\text{Var}(Y | X) = X^2 \text{Var}(\varepsilon) = X^2,$$

que depende de X . Conhecer X não muda a previsão pontual de Y , mas muda completamente a **incerteza** dessa previsão. As variáveis são dependentes, e a dependência é toda na variância. (Este exemplo é, aliás, a definição de **heterocedasticidade**, que reaparecerá quando discutirmos erros-padrão robustos.)

Vale organizar as três afirmações em uma hierarquia, da hipótese mais forte para a mais fraca:

$$\underbrace{X \perp Y}_{\text{independência}} \implies \underbrace{\mathbb{E}(Y | X) = \mathbb{E}(Y)}_{\text{independência em média}} \implies \underbrace{\text{Corr}(X, Y) = 0}_{\text{ausência de correlação}}$$

com **nenhuma** das setas valendo no sentido inverso.

! Por que isto importa em Seção 4

A hipótese fundamental do modelo de regressão é $\mathbb{E}(u_i | X_i) = 0$ — a do **meio** da hierarquia acima, não a da direita. Ela é **estritamente mais forte** que $\text{Corr}(u_i, X_i) = 0$: exige que o erro não tenha *nenhuma* relação em média com o regressor, em nenhum valor de X , e não apenas que a relação linear média seja nula.

A diferença não é acadêmica. Se o verdadeiro modelo é quadrático e ajustamos uma reta, é possível que o resíduo seja não correlacionado com X por construção do MQO — a álgebra do estimador garante isso na amostra — e ainda assim $\mathbb{E}(u | X) \neq 0$ na população, com o efeito estimado sistematicamente errado em algumas faixas de X . Ausência de correlação é o que o MQO impõe mecanicamente; média condicional nula é o que precisa ser **verdade no mundo** para que a estimativa seja interpretável causalmente. E, como veremos, essa segunda condição **não é testável**.

3.10 Correlação e causalidade

O curso fecha esta aula onde abriu a anterior. O que é a correlação entre duas variáveis? É uma medida da força, da direção e do grau de **associação** entre elas: indica se as duas se movem juntas ao longo do tempo ou de uma amostra, de modo que o aumento ou a diminuição de uma esteja associado a uma mudança na outra.

Tudo o que este capítulo construiu deveria deixar claro o que a correlação **não** é. Ela não distingue quem causa quem — $\text{Corr}(X, Y) = \text{Corr}(Y, X)$, a medida é perfeitamente simétrica, enquanto causalidade não é. Ela não exclui a possibilidade de uma terceira variável estar causando ambas. E, como vimos na seção anterior, ela sequer capta toda a associação existente: pode ser zero entre variáveis deterministicamente ligadas.

! A frase do curso

Correlação NÃO implica causalidade.

O Seção 2 mostrou o custo de esquecê-la — em terapia de reposição hormonal, em Vioxx, em talidomida. Este capítulo forneceu o vocabulário para dizer com precisão o que falta: uma correlação é uma afirmação sobre a distribuição conjunta observada, e um efeito causal é uma afirmação sobre o que aconteceria sob **intervenção**. Os capítulos seguintes são, do começo ao fim, uma sequência de estratégias para vencer essa distância.

3.11 Laboratório computacional em R

Quatro exercícios computacionais, um por bloco do capítulo. Todos rodam com R base e ggplot2/dplyr/patchwork, e os números impressos são os que o R de fato produziu na compilação deste PDF.

3.11.1 A Binomial dos pênaltis

Começamos verificando, célula a célula, a anatomia da fórmula binomial: quantas sequências produzem cada total, qual a probabilidade de *uma* sequência, e o produto das duas.

```
theta <- 0.8; n <- 5
x <- 0:n
dist_pen <- data.frame(
  x = x,
  combinacoes = choose(n, x),          # C(n, x): quantas sequencias
  sequencia = theta^x * (1 - theta)^(n - x), # prob. de UMA sequencia
  prob = choose(n, x) * theta^x * (1 - theta)^(n - x),
  dbinom = dbinom(x, n, theta),         # a funcao nativa, para conferir
  acumulada = pbinom(x, n, theta)
)
round(dist_pen, 5)
```

	x	combinacoes	sequencia	prob	dbinom	acumulada
1	0	1	0.00032	0.00032	0.00032	0.00032
2	1	5	0.00128	0.00640	0.00640	0.00672
3	2	10	0.00512	0.05120	0.05120	0.05792
4	3	10	0.02048	0.20480	0.20480	0.26272
5	4	5	0.08192	0.40960	0.40960	0.67232
6	5	1	0.32768	0.32768	0.32768	1.00000

A coluna `sequencia` é a armadilha do slide e a coluna `prob` é a resposta correta. Para $x = 3$:

```
c(uma_sequencia = theta^3 * (1 - theta)^2,
  n_sequencias = choose(5, 3),
  P_X_igual_3 = choose(5, 3) * theta^3 * (1 - theta)^2)
```

uma_sequencia	n_sequencias	P_X_igual_3
0.02048	10.00000	0.20480

A probabilidade de uma sequência específica como $(1, 1, 1, 0, 0)$ é 0,02048; como existem $C_3^5 = 10$ sequências distintas com três gols, $P(X = 3) = 0,2048$ — **dez vezes maior**. Ignorar o coeficiente binomial erra por uma ordem de grandeza.

Agora $\mathbb{E}(X) = n\theta$, verificado por simulação: sorteamos 200 mil disputas de cinco cobranças, cada cobrança uma Bernoulli(0,8) independente, e contamos os gols.

```
set.seed(20260810)
sorteios <- matrix(rbinom(200000 * n, size = 1, prob = theta), ncol = n)
convertidos <- rowSums(sorteios) # gols em cada disputa de 5 cobranças
round(c(media_simulada = mean(convertidos), n_theta = n * theta,
      var_simulada = var(convertidos), n_theta_1theta = n * theta * (1 - theta)),
      4)
```

media_simulada	n_theta	var_simulada	n_theta_1theta
3.9974	4.0000	0.8030	0.8000

A média simulada bate com $n\theta = 4$: o time com 80% de aproveitamento converte, em média, 4 dos 5 pênaltis. A variância simulada bate com $n\theta(1 - \theta) = 0,8$.

```
library(patchwork)
g_pmf <- ggplot(dist_pen, aes(factor(x), prob)) +
  geom_col(fill = az, alpha = 0.75, width = 0.65) +
  geom_text(aes(label = sprintf("%.3f", prob)), vjust = -0.4,
    size = 3, colour = cz) +
  scale_y_continuous(expand = expansion(mult = c(0, 0.15))) +
  labs(x = "gols convertidos em 5 cobranças", y = "P(X = x)")
g_cdf <- ggplot(dist_pen, aes(x, acumulada)) +
  geom_step(colour = vd, linewidth = 0.9, direction = "hv") +
  geom_point(colour = vd, size = 2) +
  scale_x_continuous(breaks = 0:5) +
  labs(x = "x", y = "F(x) = P(X <= x)")
g_pmf + g_cdf
```




Figura 2: Distribuição Binomial(5; 0,8) dos pênaltis convertidos. À esquerda, a função de probabilidade; à direita, a acumulada — que nunca decresce e atinge 1 no maior valor possível.

3.11.2 Chebyshev em cinco distribuições

A desigualdade de Chebyshev vale para *qualquer* distribuição com variância finita. Para apreciar tanto sua universalidade quanto sua folga, aplicamos o teste a cinco distribuições deliberadamente diferentes entre si: uma simétrica de caudas leves (Normal), uma assimétrica (Exponencial), uma de suporte limitado (Uniforme), uma de caudas pesadas (t com 4 graus de liberdade) e uma assimétrica de suporte positivo (χ^2_2).

```
set.seed(1)
N <- 500000
amostras <- list(
  Normal      = rnorm(N),
  Exponencial = rexp(N, rate = 1),
  Uniforme    = runif(N, -1, 1),
  t_4gl       = rt(N, df = 4),
  Qui2_2gl    = rchisq(N, df = 2)
)
dentro <- function(v, k) mean(abs(v - mean(v)) <= k * sd(v))
cheby <- data.frame(
  distribuicao = names(amostras),
  k2_simulado = round(sapply(amostras, dentro, k = 2), 4),
  k2_limite   = 1 - 1/4,
  k3_simulado = round(sapply(amostras, dentro, k = 3), 4),
  k3_limite   = round(1 - 1/9, 4),
  row.names = NULL
)
cheby
```

	distribuicao	k2_simulado	k2_limite	k3_simulado	k3_limite
1	Normal	0.9544	0.75	0.9974	0.8889
2	Exponencial	0.9499	0.75	0.9818	0.8889
3	Uniforme	1.0000	0.75	1.0000	0.8889
4	t_4gl	0.9532	0.75	0.9871	0.8889
5	Qui2_2gl	0.9500	0.75	0.9819	0.8889

Duas leituras. Primeiro, **o limite nunca é violado**: em todas as cinco distribuições a fração simulada dentro de k desvios padrão excede $1 - 1/k^2$. Segundo, ele é **folgado** — a coluna simulada fica em torno de 95% para $k = 2$, contra a garantia de apenas 75%. A Uniforme é o caso extremo: seu suporte inteiro cabe dentro de dois desvios padrão, de modo que a fração é exatamente 1 contra um limite de 0,75.

```
c(violacoes_k2 = sum(cheby$k2_simulado < cheby$k2_limite),
  violacoes_k3 = sum(cheby$k3_simulado < cheby$k3_limite))
```

```
violacoes_k2 violacoes_k3
           0           0
```

Zero violações, como o teorema garante. A folga é o preço de uma garantia que não pede nada em troca: como o limite precisa valer inclusive para as distribuições mais adversas com variância finita, ele é necessariamente conservador para as bem comportadas.

3.11.3 A tabela chuva × commute e a lei das expectativas iteradas

Montamos a distribuição conjunta do professor e extraímos dela marginais, condicionais e a verificação numérica da lei das expectativas iteradas.

```
conj <- matrix(c(0.15, 0.07,
                 0.15, 0.63),
              nrow = 2, byrow = TRUE,
              dimnames = list(Y = c("Long (Y=0)", "Short (Y=1)"),
                              X = c("Rain (X=0)", "No Rain (X=1)")))
addmargins(conj)      # a tabela do slide, com as margens
```

Y	X		Sum
	Rain (X=0)	No Rain (X=1)	
Long (Y=0)	0.15	0.07	0.22
Short (Y=1)	0.15	0.63	0.78
Sum	0.30	0.70	1.00

As margens reproduzem a tabela: 0,22 e 0,78 nas linhas, 0,30 e 0,70 nas colunas, 1,00 no canto. As condicionais de Y dado X saem dividindo cada coluna por sua marginal:

```

marg_X <- colSums(conj)
marg_Y <- rowSums(conj)
cond_Y_dado_X <- sweep(conj, 2, marg_X, "/") # divide cada coluna por P(X = x)
round(cond_Y_dado_X, 4)

```

	X	
Y	Rain (X=0)	No Rain (X=1)
Long (Y=0)	0.5	0.1
Short (Y=1)	0.5	0.9

A primeira coluna é (0,5; 0,5) — os dois cálculos do professor, $P(\text{Long C.} \mid \text{Rain})$ e $P(\text{Short C.} \mid \text{Rain})$. A segunda é (0,1; 0,9). Como as duas colunas diferem, X e Y não são independentes; note que $P(\text{Long C.}) = 0,22$ mas $P(\text{Long C.} \mid \text{Rain}) = 0,50$.

Codificando $Y \in \{0, 1\}$, as médias condicionais e a lei das expectativas iteradas:

```

y <- c(0, 1)
E_Y_dado_X <- colSums(cond_Y_dado_X * y) # E(Y | X = x) para cada x
E_Y_dado_X

```

	Rain (X=0)	No Rain (X=1)
	0.5	0.9

```

c(E_Y_direto = sum(marg_Y * y), # E(Y) pela marginal
  E_de_E_Y_dado_X = sum(E_Y_dado_X * marg_X)) # E(E(Y|X)): media ponderada

```

E_Y_direto	E_de_E_Y_dado_X
0.78	0.78

Os dois números coincidem em 0,78: a média incondicional de Y é a média ponderada das médias condicionais, com pesos 0,30 e 0,70 — as probabilidades de X . É a lei das expectativas iteradas em duas linhas de código, e é exatamente a álgebra da altura média por sexo, com “chove/não chove” no lugar de “mulher/homem”.

Confirmando a dependência pela fatoração, e medindo a associação linear:

```

produto_marginais <- outer(marg_Y, marg_X) # o que a conjunta seria sob independencia
EX <- sum(marg_X * c(0, 1)); EY <- sum(marg_Y * y)
EXY <- sum(outer(y, c(0, 1)) * conj)
round(c(conjunta_00 = conj[1, 1], sob_independencia = produto_marginais[1, 1],
        cov_XY = EXY - EX * EY), 4)

```

conjunta_00	sob_independencia	cov_XY
0.150	0.066	0.084

A célula (Long, Rain) vale 0,15, contra 0,066 que valeria sob independência. A covariância é positiva (0,084): não chover e ter deslocamento curto andam juntos.

3.11.4 O contraexemplo: covariância zero sem independência

Este é o resultado mais importante do laboratório. Geramos $X \sim \text{Uniforme}(-2, 2)$ — simétrica em torno de zero — e $Y = X^2$ mais um pequeno ruído, de modo que Y é, para todos os efeitos, uma função determinística de X .

```
set.seed(20260810)
M <- 20000
X <- runif(M, -2, 2)
Y <- X^2 + rnorm(M, sd = 0.25)
round(c(cov_XY = cov(X, Y), corr_XY = cor(X, Y)), 4)
```

```
cov_XY corr_XY
-0.0103 -0.0073
```

A covariância e a correlação são **praticamente zero** — e o valor populacional é exatamente zero, porque $\text{Cov}(X, X^2) = \mathbb{E}(X^3) - \mathbb{E}(X)\mathbb{E}(X^2) = 0$ pela simetria de X . No entanto, a média condicional depende fortemente de X :

```
faixas <- cut(X, breaks = seq(-2, 2, by = 0.5))
round(tapply(Y, faixas, mean), 3)
```

$(-2, -1.5]$	$(-1.5, -1]$	$(-1, -0.5]$	$(-0.5, 0]$	$(0, 0.5]$	$(0.5, 1]$	$(1, 1.5]$	$(1.5, 2]$
3.077	1.568	0.585	0.080	0.091	0.591	1.584	3.091

$\mathbb{E}(Y | X)$ varia de cerca de 3,1 nas pontas a praticamente zero no centro. A relação é forte, sistemática e perfeitamente visível — e a correlação, cega para ela.

```
dd <- data.frame(X = X, Y = Y)
medias_cond <- dd |>
  mutate(faixa = cut(X, breaks = seq(-2, 2, by = 0.25))) |>
  group_by(faixa) |>
  summarise(x = mean(X), m = mean(Y), .groups = "drop")

set.seed(7)
dn <- data.frame(X = runif(M, -2, 2), Y = rnorm(M, mean = mean(Y), sd = sd(Y)))
medias_cond_n <- dn |>
  mutate(faixa = cut(X, breaks = seq(-2, 2, by = 0.25))) |>
  group_by(faixa) |>
  summarise(x = mean(X), m = mean(Y), .groups = "drop")

painel <- function(dados, medias, rotulo) {
  ggplot(dados, aes(X, Y)) +
    geom_point(alpha = 0.10, colour = cz, size = 0.6) +
    geom_hline(yintercept = mean(dados$Y), colour = az, linetype = "dashed") +
    geom_line(data = medias, aes(x, m), colour = vm, linewidth = 1) +
```

```
labs(x = "X ~ Uniforme(-2, 2)", y = rotulo)
}
painel(dd, medias_cond, "Y = X^2 + ruído (corr ~ 0)") +
painel(dn, medias_cond_n, "Y independente de X (corr ~ 0)")
```




Figura 3: Correlação zero, dependência total. À esquerda, $Y = X^2 + \text{ruído}$ com X simétrica: a correlação amostral é ~ 0 , mas a média condicional (linha vermelha) desenha uma parábola. À direita, Y genuinamente independente de X , para comparação: aí sim a média condicional é plana. A linha azul tracejada é a média incondicional $\mathbb{E}(Y)$ nos dois painéis.

Os dois painéis têm correlação aproximadamente zero. No da direita, Y é genuinamente independente de X e a média condicional coincide com a incondicional — as linhas vermelha e azul se sobrepõem. No da esquerda, a média condicional é uma **parábola**: saber X muda completamente a previsão de Y , e ainda assim a correlação não registra nada.

Se a única evidência disponível fosse o coeficiente de correlação, as duas situações seriam indistinguíveis. **É essa a razão de a hipótese de identificação do próximo capítulo ser $\mathbb{E}(u_i | X_i) = 0$, e não $\text{Corr}(u_i, X_i) = 0$.** Um erro que se comportasse como o painel esquerdo satisfaria a segunda condição e violaria a primeira — e a estimativa de MQO seria enganosa exatamente onde mais importa.

Um último detalhe, que fecha o argumento da seção sobre dependência na variância:

```
round(tapply(Y, ifelse(abs(X) > 1, "|X| > 1", "|X| <= 1"), var), 3)
```

$ X \leq 1$	$ X > 1$
0.153	0.826

A variância condicional de Y também depende de X — é mais de cinco vezes maior nas pontas. Dependência na média e dependência na variância, ambas invisíveis à correlação.

3.12 Exercícios

1. **Binomial e o coeficiente binomial.** Um goleiro defende cada pênalti com probabilidade 0,25, independentemente. Em uma disputa de 5 cobranças: (a) escreva a distribuição de probabilidade do número de defesas; (b) calcule $P(X = 2)$ com e sem o coeficiente binomial e explique, em termos de contagem de sequências, por que a segunda está errada; (c) verifique que as seis probabilidades somam 1.
2. **CDF e monotonicidade.** Demonstre que a distribuição acumulada de uma variável aleatória discreta nunca decresce e que $\lim_{x \rightarrow \infty} F(x) = 1$. Em seguida, explique por que, no caso contínuo, $P(a < X < b) = P(a \leq X \leq b)$, mas no discreto isso é falso em geral. Dê um exemplo numérico da falha.
3. **As duas formas da variância.** Demonstre a identidade $\text{Var}(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$ a partir da definição, usando apenas a linearidade do valor esperado. Em seguida, use-a para calcular a variância de uma Bernoulli(θ) e mostre que ela é máxima em $\theta = 1/2$. Interprete economicamente esse resultado.
4. **Chebyshev, na mão.** (a) Use a desigualdade de Chebyshev para encontrar o menor k tal que ao menos 95% da massa esteja em $[\mu - k\sigma, \mu + k\sigma]$, para qualquer distribuição. (b) Compare com o k correspondente sob normalidade. (c) Construa uma variável aleatória discreta de três pontos em que o limite de Chebyshev para $k = 2$ seja atingido com igualdade ou quase — por que essas distribuições “extremais” são necessariamente degeneradas?
5. **Padronização e transformações.** Seja X com $\mu_X = 10$ e $\sigma_X = 4$. (a) Obtenha média e variância de $W = 3 - 2X$. (b) Verifique que $Z = (X - \mu_X)/\sigma_X$ tem média 0 e variância 1. (c) Mostre que a correlação entre X e W é exatamente -1 , e explique por que isso não depende dos valores de μ_X e σ_X .
6. **Tabela chuva $\times$ commute.** Usando a Tabela 1: (a) calcule $P(\text{Rain} \mid \text{Long C.})$ e explique por que ela difere de $P(\text{Long C.} \mid \text{Rain})$;
(b) obtenha $\mathbb{E}(X \mid Y = 0)$ e $\mathbb{E}(X \mid Y = 1)$; (c) verifique numericamente a lei das expectativas iteradas na direção oposta à do laboratório, isto é, recuperando $\mathbb{E}(X)$ a partir de $\mathbb{E}(X \mid Y)$; (d) que valor deveria ter a célula (Long, Rain) para que X e Y fossem independentes, mantidas as marginais?
7. **Lei das expectativas iteradas e o paradoxo de Simpson.** Uma empresa tem dois departamentos. No departamento A, o salário médio de mulheres é maior que o de homens; no B, também. Mostre, construindo um exemplo numérico com quatro grupos, que ainda assim o salário médio geral das mulheres pode ser **menor** que o dos homens. (a) Use a lei das expectativas iteradas para identificar exatamente o que produz a reversão. (b) O que esse exemplo diz sobre agregar médias sem os pesos corretos?
8. **Covariância zero e a hipótese do próximo capítulo.** Seja X com distribuição simétrica em torno de zero e $Y = X^2$. (a) Prove que $\text{Cov}(X, Y) = 0$. (b) Calcule $\mathbb{E}(Y \mid X)$ e mostre que depende de X . (c) Agora considere $Y = X\varepsilon$, com $\varepsilon \perp X$, $\mathbb{E}(\varepsilon) = 0$: mostre que $\mathbb{E}(Y \mid X) = \mathbb{E}(Y)$ mas que X e Y **não** são independentes. (d) Ordene as três condições — independência, $\mathbb{E}(Y \mid X) = \mathbb{E}(Y)$ e $\text{Corr}(X, Y) = 0$ — da mais forte para a mais fraca, e explique por que a econometria escolhe a **do meio** como hipótese de identificação em

1.

4 Regressão Linear com um Regressor

Os dois capítulos anteriores prepararam o terreno sem ainda estimar nada. O Seção 2 estabeleceu *o que* queremos — efeitos causais — e por que dados observacionais tornam a obtenção deles difícil. O Seção 3 recuperou as ferramentas, e uma delas em particular: a **média condicional** $\mathbb{E}(Y \mid X)$, apresentada ali como a melhor previsão de Y dado que conhecemos X . Este capítulo une as duas coisas. Ele apresenta o **modelo de regressão linear com um regressor** e o estimador de **mínimos quadrados ordinários**, e a tese que organiza tudo o que vem a seguir é simples de enunciar e vale a pena fixar desde já:

A regressão linear é um método para estimar médias condicionais. Toda a dificuldade da inferência causal está concentrada na hipótese que permite interpretar essa média condicional como um efeito causal.

O capítulo corresponde ao Capítulo 4 de Stock e Watson (2020) e à Aula 3 da disciplina. Sua estrutura segue a do professor: primeiro o modelo e o que cada símbolo significa; depois a estimação por MQO, derivada do princípio de minimização até a fórmula fechada; em seguida as medidas de aderência, com o alerta — que merece destaque — de que R^2 alto não é evidência de causalidade; e por fim as **três hipóteses de MQO** e a distribuição amostral dos estimadores. A primeira dessas hipóteses, $\mathbb{E}(u_i \mid X_i) = 0$, é o núcleo conceitual não só do capítulo mas do curso inteiro.

4.1 O modelo de regressão linear

A pergunta empírica que atravessa o capítulo é a que abre o Capítulo 4 de Stock e Watson (2020): **uma redução na razão aluno-professor melhora o desempenho acadêmico?** É uma pergunta de política pública com consequências orçamentárias imediatas — contratar professores custa caro, e vale saber quanto se compra com esse dinheiro. E é uma pergunta *quantitativa*, no sentido preciso do Seção 1: não basta saber que turmas menores “ajudam”; é preciso saber de quanto.

Os dados são de 420 distritos escolares da Califórnia. Para cada distrito observamos o desempenho médio dos alunos em um teste padronizado (*TestScore*) e a razão aluno-professor (*ClassSize*, ou *STR*, de *student-teacher ratio*). O problema é estimar uma equação simples:

$$TestScore = \beta_0 + \beta_1 \cdot ClassSize + \text{erro}$$

O objeto de interesse é β_1 , e sua definição é a de uma derivada — a variação em *TestScore* associada a uma variação unitária em *ClassSize*:

$$\beta_1 = \frac{\Delta TestScore}{\Delta ClassSize}$$

Não sabemos o verdadeiro valor de β_1 . Ele é uma característica da população — fixo, determinado, desconhecido —, e precisamos **estimá-lo** a partir dos dados observacionais de que dispomos. É exatamente a distinção parâmetro *versus* estatística que as Notas de Estatística assentam no capítulo de estimação pontual, transplantada agora para um contexto em que o parâmetro não é uma média, mas a inclinação de uma reta.

Generalizando, considere uma amostra de tamanho n :

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad i = 1, 2, \dots, n$$

Esta é a equação central do capítulo, e cada símbolo tem nome:

Símbolo	Nome	O que é
Y_i	variável dependente	o que queremos explicar (o <i>regressando</i>)
X_i	variável independente ou regressor	o que usamos para explicar
β_0	intercepto	valor de $\mathbb{E}(Y \mid X)$ quando $X = 0$
β_1	coeficiente angular	efeito de uma unidade a mais de X sobre $\mathbb{E}(Y \mid X)$
u_i	erro da regressão	tudo o mais que afeta Y e não é X

A equação recebe o nome de **modelo de regressão linear com um regressor** — “com um regressor” porque há uma única variável explicativa do lado direito, além do intercepto. O 1 é, nesse sentido, o caso mais simples possível, e é justamente por isso que ele é o lugar certo para entender o que está em jogo: tudo o que o curso fará depois — regressão múltipla, painel, variáveis instrumentais — é uma elaboração sobre esta estrutura.

4.1.1 O termo de erro

Por que introduzir u_i ? Há duas razões, e o professor as apresenta juntas porque de fato operam juntas.

A primeira é de **forma funcional**. Estamos aproximando a relação entre Y e X por uma função linear. Não há nenhuma garantia de que a verdadeira relação seja uma reta; a aproximação certamente contém erro, e esse erro precisa ir para algum lugar.

A segunda, e mais importante, é de **omissão**. Com certeza existem outros fatores determinantes do desempenho acadêmico além do tamanho da turma: a qualidade dos professores, a infraestrutura da escola, a renda das famílias, o envolvimento dos pais, a fração de alunos que não fala inglês em casa. Nenhum deles está do lado direito da equação. É plausível, portanto, introduzir um termo que **represente os fatores não observados que afetam Y** .

O erro é, assim, um contêiner: ele carrega tudo o que influencia Y_i e não é X_i . Essa leitura será decisiva mais adiante — quando enunciarmos a hipótese $\mathbb{E}(u_i \mid X_i) = 0$, o que estaremos exigindo é uma propriedade *desse contêiner*, e é aí que a inferência causal se ganha ou se perde.

4.1.2 A Função de Regressão Populacional

Tome a esperança condicional a X dos dois lados de $Y_i = \beta_0 + \beta_1 X_i + u_i$. Pela linearidade da esperança,

$$\mathbb{E}(Y | X) = \beta_0 + \beta_1 X + \mathbb{E}(u | X).$$

Se **assumirmos** que $\mathbb{E}(u | X) = 0$ — a hipótese de média condicional igual a zero —, o último termo desaparece e resta

$$\mathbb{E}(Y | X) = \beta_0 + \beta_1 X$$

Esta equação chama-se **Função de Regressão Populacional** (*Population Regression Function*, PRF). Ela é a peça que conecta este capítulo ao anterior, e vale gastar um parágrafo nela.

i Ferramenta estatística — a média condicional

A PRF é uma média condicional. Não é uma analogia: $\mathbb{E}(Y | X)$ é exatamente o objeto definido no Seção 3 — a média da distribuição de Y entre os elementos da população que têm aquele valor de X —, e o que a PRF acrescenta é uma **hipótese sobre sua forma**: a de que, como função de X , ela é uma reta de intercepto β_0 e inclinação β_1 .

Nas **Notas de Aula de Estatística** (Prof. Eduardo Campos), a média condicional aparece no tratamento de distribuições conjuntas, com a lei das esperanças iteradas $\mathbb{E}(Y) = \mathbb{E}[\mathbb{E}(Y | X)]$ e a interpretação da esperança condicional como melhor previsão de Y dado X no sentido do erro quadrático médio.

É por isso que aquele capítulo veio antes deste. Quando se diz que “a regressão estima médias condicionais”, isso deve ser lido literalmente: estimar β_0 e β_1 é estimar a função $x \mapsto \mathbb{E}(Y | X = x)$.

Com a PRF em mãos, o termo de erro ganha uma definição precisa em vez de uma descrição vaga. Ele é a **diferença entre Y_i e o valor predito de Y_i pela PRF**. No exemplo do capítulo:

$$TestScore = \beta_0 + \beta_1 ClassSize + \text{erro},$$

$$\mathbb{E}(TestScore | ClassSize) = \beta_0 + \beta_1 ClassSize,$$

$$\text{erro} = TestScore - \mathbb{E}(TestScore | ClassSize).$$

O erro é o desvio da observação individual em relação à média de seu grupo. Um distrito com erro positivo teve desempenho acima do que se esperaria de distritos com aquele mesmo tamanho de turma; um distrito com erro negativo, abaixo. E a hipótese $\mathbb{E}(u | X) = 0$ diz que esses desvios, dentro de cada grupo definido por um valor de X , se cancelam em média — o que é uma tautologia se $\mathbb{E}(Y | X)$ é *de fato* linear, e uma hipótese com conteúdo empírico quando lida, como faremos na 1, como afirmação sobre os fatores omitidos.

! Uma distinção que será cobrada o curso inteiro

$\mathbb{E}(u \mid X) = 0$ é **mais forte** que $\mathbb{E}(u) = 0$. A segunda condição diz apenas que os fatores omitidos se cancelam *na população como um todo* — e é, na verdade, uma normalização sem conteúdo, já que qualquer média não nula do erro pode ser absorvida pelo intercepto. A primeira diz que eles se cancelam **dentro de cada valor de X** , o que é uma afirmação sobre a *relação* entre os fatores omitidos e o regressor. É essa a hipótese que dá conteúdo causal a β_1 .

4.2 Estimando os coeficientes: mínimos quadrados ordinários

A PRF é populacional: β_0 e β_1 existem, são fixos e não os conhecemos. Temos uma amostra de n pares (X_i, Y_i) e queremos, a partir dela, produzir estimativas. O critério que usaremos é o de **mínimos quadrados ordinários** (MQO, ou OLS).

A ideia é natural. Cada par candidato (b_0, b_1) define uma reta, e cada reta comete, em cada observação, um erro de previsão $Y_i - b_0 - b_1 X_i$. Queremos a reta que torne esses erros pequenos no conjunto. Elevá-los ao quadrado — em vez de tomar o valor absoluto — penaliza desvios grandes mais que proporcionalmente, e tem a vantagem decisiva de produzir um problema com solução analítica. O estimador de MQO é a solução de

$$\min_{b_0, b_1} \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2$$

4.2.1 As condições de primeira ordem

O problema é de minimização irrestrita de uma função quadrática e estritamente convexa em (b_0, b_1) ; as condições de primeira ordem são necessárias e suficientes. Seja $S(b_0, b_1) = \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2$. Derivando em relação a b_0 , pela regra da cadeia,

$$\frac{\partial S}{\partial b_0} = \sum_{i=1}^n 2(Y_i - b_0 - b_1 X_i) \cdot (-1) = -2 \sum_{i=1}^n (Y_i - b_0 - b_1 X_i) = 0,$$

e em relação a b_1 — que é a derivada que o professor escreve explicitamente no slide 26 —,

$$\frac{\partial S}{\partial b_1} = \frac{\partial \sum_{i=1}^n (Y_i - b_0 - b_1 X_i)^2}{\partial b_1} = -2 \sum_{i=1}^n (Y_i - b_0 - b_1 X_i) X_i = 0.$$

Dividindo ambas por -2 e denotando por $\hat{\beta}_0, \hat{\beta}_1$ a solução, obtemos o sistema que define o estimador de MQO. Como $\hat{u}_i \equiv Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i$ é o **resíduo** da observação i , o sistema tem uma leitura imediata:

! Condições de ortogonalidade

$$\begin{aligned} \text{(i)} \quad \sum_{i=1}^n \hat{u}_i &= 0 \quad \Longleftrightarrow \quad \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0 \\ \text{(ii)} \quad \sum_{i=1}^n \hat{u}_i X_i &= 0 \quad \Longleftrightarrow \quad \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) X_i = 0 \end{aligned}$$

Os resíduos de MQO somam zero e são ortogonais ao regressor. Estas duas identidades valem **por construção**, em qualquer amostra, quaisquer que sejam os dados — não são hipóteses, não são resultados assintóticos, não podem ser testadas. São a definição do estimador escrita de outra forma.

A distinção entre as condições de ortogonalidade (amostrais, sempre válidas) e a hipótese $\mathbb{E}(u_i | X_i) = 0$ (populacional, possivelmente falsa) é uma das que mais confundem quem começa. O MQO *sempre* produz resíduos ortogonais a X ; isso não diz absolutamente nada sobre se o **erro** populacional é ortogonal a X . A primeira é uma propriedade aritmética da conta que fizemos; a segunda é uma afirmação sobre o mundo.

4.2.2 Resolvendo o sistema

Vamos agora à derivação algébrica que leva às fórmulas fechadas, seguindo o encadeamento dos slides 18–20.

Passo 1. Divida a primeira condição por n :

$$\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i) = 0 \quad \Rightarrow \quad \bar{Y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{X} = 0 \quad \Rightarrow \quad \bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X}.$$

Este resultado já é interessante em si: **a reta de MQO passa pelo ponto médio da nuvem de pontos** $(\bar{X}, \bar{Y})$. Ele também nos dá imediatamente $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$, restando determinar $\hat{\beta}_1$.

Passo 2. Substitua $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$ na segunda condição:

$$\sum_{i=1}^n (Y_i - \bar{Y} + \hat{\beta}_1 \bar{X} - \hat{\beta}_1 X_i) X_i = 0 \quad \Rightarrow \quad \sum_{i=1}^n [(Y_i - \bar{Y}) - \hat{\beta}_1 (X_i - \bar{X})] X_i = 0.$$

Separando os dois termos,

$$\sum_{i=1}^n (Y_i - \bar{Y}) X_i = \hat{\beta}_1 \sum_{i=1}^n (X_i - \bar{X}) X_i.$$

Passo 3 — o truque de centragem. As duas somas acima estão em uma forma “meio centrada”: o primeiro fator é um desvio em relação à média, o segundo é o valor bruto. O professor mostra que isso não faz diferença. Considere:

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \bar{X}) (X_i - \bar{X}) = \sum_{i=1}^n (X_i - \bar{X}) X_i - \bar{X} \underbrace{\sum_{i=1}^n (X_i - \bar{X})}_{=0},$$

onde o último somatório é nulo porque os desvios em relação à média amostral sempre somam zero — $\sum (X_i - \bar{X}) = \sum X_i - n\bar{X} = n\bar{X} - n\bar{X} = 0$. Logo:

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \bar{X}) X_i.$$

Pelo mesmo raciocínio, subtraindo $\bar{X}$ do segundo fator do lado esquerdo,

$$\sum_{i=1}^n (Y_i - \bar{Y}) X_i = \sum_{i=1}^n (Y_i - \bar{Y}) (X_i - \bar{X}) + \bar{X} \underbrace{\sum_{i=1}^n (Y_i - \bar{Y})}_{=0} = \sum_{i=1}^n (Y_i - \bar{Y}) (X_i - \bar{X}).$$

Passo 4. Combinando as três últimas equações, chegamos ao resultado central:

! Os estimadores de MQO

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (X_i - \bar{X}) (Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

4.2.3 Covariância sobre variância

A fórmula de $\hat{\beta}_1$ tem uma leitura que vale mais que a álgebra. Divida numerador e denominador por $n - 1$:

$$\hat{\beta}_1 = \frac{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2} = \frac{s_{XY}}{s_X^2}$$

onde s_{XY} é a **covariância amostral** entre X e Y e s_X^2 é a **variância amostral** de X . Ou seja:

$$\hat{\beta}_1 = \frac{s_{XY}}{s_X^2}$$

O estimador de MQO é a razão entre a covariância e a variância — e a contrapartida populacional dessa expressão, $\text{Cov}(X, Y)/\text{Var}(X)$, é exatamente o coeficiente da projeção linear de Y em X definida no Seção 3. O MQO substitui momentos populacionais por momentos amostrais. É esse o princípio de analogia que reaparecerá, sob o nome de **método dos momentos**, em praticamente todo estimador do curso.

Três consequências imediatas se leem na fórmula. O **sinal** de $\hat{\beta}_1$ é o sinal da covariância amostral: se X e Y variam juntos, a inclinação é positiva. Se X não varia na amostra, $s_X^2 = 0$ e $\hat{\beta}_1$ **não existe** — não há como estimar o efeito de uma variável que não varia, o que antecipa a exigência de “variação suficiente no regressor”. E a magnitude depende das unidades de medida das duas variáveis, o que motiva a versão padronizada que aparecerá no item [c] do exercício da 1.

4.3 Interpretação: o caso TestScore

Aplicado aos 420 distritos californianos, o MQO produz a reta estimada que o professor apresenta no slide 23:

$$\widehat{TestScore} = 698,9 - 2,28 \cdot STR$$

A interpretação do **coeficiente angular** é a que interessa. $\hat{\beta}_1 = -2,28$ significa:

Distritos com **um aluno por professor a mais** têm, em média, um *TestScore* mais baixo em 2,28 unidades do teste.

Três cuidados de leitura, que o professor faz questão de separar. Primeiro, “em média”: a afirmação é sobre a média condicional, não sobre nenhum distrito individual — há distritos com turmas grandes e desempenho excelente. Segundo, “2,28 unidades do teste”: a interpretação de um coeficiente é sempre nas **unidades da variável dependente**, e é preciso saber se 2,28 pontos é muito ou pouco na escala do teste (com desvio-padrão de cerca de 19 pontos, é pouco — cerca de 0,12 desvio-padrão). Terceiro, **“distritos com um aluno a mais têm”, não “reduzir a turma em um aluno causaria”**. A segunda leitura só é legítima sob a Hipótese 1, que discutiremos adiante, e há razões fortes para duvidar dela neste exemplo: distritos com turmas menores tendem a ser mais ricos, e a renda familiar também afeta o desempenho.

E o **intercepto**? $\hat{\beta}_0 = 698,9$ seria, literalmente, o *TestScore* médio predito de um distrito com $STR = 0$. O professor pergunta, no slide, por que essa interpretação não tem significado econômico. A resposta tem duas camadas:

1. $STR = 0$ **é economicamente absurdo**. Uma razão aluno-professor igual a zero significa uma escola com alunos e nenhum professor — ou com professores e nenhum aluno. Não é um estado do mundo sobre o qual faça sentido fazer previsões.
2. **E, mais importante, $STR = 0$ está muito fora do suporte dos dados**. Na amostra, STR varia aproximadamente entre 14 e 25. A reta foi ajustada nesse intervalo, e nada nos dados informa sobre o comportamento de $\mathbb{E}(Y | X)$ em $X = 0$. Avaliar a reta ali é **extrapolação**: estamos estendendo uma aproximação linear local para uma região onde não há observação alguma que a discipline. Mesmo que a relação verdadeira seja bem aproximada por uma reta entre 14 e 25, não há razão para supor que a mesma reta valha em 0.

A função do intercepto, portanto, é essencialmente técnica: ele **posiciona verticalmente a reta** de modo que ela passe por $(\bar{X}, \bar{Y})$, garantindo que os resíduos somem zero. Sem ele, a reta seria forçada pela origem e $\hat{\beta}_1$ seria viesado. Isso não é pouco — mas não é uma interpretação econômica.

4.4 Observações importantes

Antes de seguir, o professor reúne quatro observações que consolidam o que foi feito. Elas parecem pontos de notação e são, na verdade, conceituais.

Parâmetros *versus* estimadores. Os parâmetros populacionais β_0 e β_1 são **fixos e desconhecidos** — números que existem no mundo e que não observamos. Eles são estimados por suas contrapartidas amostrais $\hat{\beta}_0$ e $\hat{\beta}_1$, que são **variáveis aleatórias**: funções da amostra, e portanto diferentes a cada amostra que sorteássemos. É exatamente a distinção estimador/estimativa das Notas de Estatística, e ela é o que torna possível a seção sobre distribuição amostral mais adiante.

Erro *versus* resíduo. O termo de erro $u_i = Y_i - \beta_0 - \beta_1 X_i$ **não é observável**, porque depende dos parâmetros populacionais desconhecidos. Sua contrapartida amostral é o **resíduo** $\hat{u}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i$, que calculamos e usamos como estimativa do erro. A tabela abaixo organiza o paralelismo:

População (não observável)	Amostra (calculável)
β_0, β_1	$\hat{\beta}_0, \hat{\beta}_1$
$u_i = Y_i - \beta_0 - \beta_1 X_i$	$\hat{u}_i = Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_i$
$\mathbb{E}(Y X) = \beta_0 + \beta_1 X$	$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$
$\mathbb{E}(u X) = 0$ (hipótese, pode falhar)	$\sum \hat{u}_i X_i = 0$ (identidade, sempre vale)

A última linha é a mais importante da tabela, e reencontra o ponto feito acima: a coluna da direita vale sempre; a da esquerda é a aposta.

A decomposição do valor observado. Toda observação se escreve como parte explicada mais parte residual:

$$Y_i = \hat{Y}_i + \hat{u}_i, \quad \hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

Essa decomposição é a base da seção sobre medidas de aderência: o R^2 nada mais é do que a pergunta “que fração da variação de Y está no primeiro pedaço?”.

A leitura geométrica. As condições de ortogonalidade têm uma interpretação em álgebra linear que o professor menciona e que vale desenvolver, porque é ela que dá o nome “ortogonalidade”. Pense nas n observações como vetores em $\mathbb{R}^n$: o vetor $\mathbf{Y} = (Y_1, \dots, Y_n)'$, o vetor de uns $\mathbf{1} = (1, \dots, 1)'$ e o vetor $\mathbf{X} = (X_1, \dots, X_n)'$. As duas condições dizem que o vetor de resíduos $\hat{\mathbf{u}}$ tem **produto interno nulo** com ambos:

$$\hat{\mathbf{u}}' \mathbf{1} = \sum_{i=1}^n \hat{u}_i = 0, \quad \hat{\mathbf{u}}' \mathbf{X} = \sum_{i=1}^n \hat{u}_i X_i = 0.$$

Ou seja, $\hat{\mathbf{u}}$ é **ortogonal ao plano gerado pelos regressores** (o subespaço de $\mathbb{R}^n$ gerado por $\mathbf{1}$ e $\mathbf{X}$). E o vetor de valores ajustados $\hat{\mathbf{Y}} = \mathbf{Y} - \hat{\mathbf{u}}$ é a **projeção ortogonal** de $\mathbf{Y}$ sobre esse plano. Minimizar a soma de quadrados dos resíduos é minimizar $\|\mathbf{Y} - \hat{\mathbf{Y}}\|^2$, a distância euclidiana entre $\mathbf{Y}$ e o plano — e a solução de um problema de distância mínima a um subespaço é, sempre, a projeção ortogonal. O MQO é uma projeção.

Na notação geral do professor, com K regressores mais o intercepto ($x_0 \equiv 1$),

$$\sum_{i=1}^n \hat{u}_i X_{ki} = 0, \quad k = 0, 1, 2, \dots, K.$$

Este é o ponto de partida do tratamento matricial da regressão múltipla, e a razão pela qual $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$ tem a forma que tem. Por ora, basta reter a imagem: **ajustar por MQO é projetar Y no espaço dos regressores, e o resíduo é o que sobra, perpendicular a tudo o que foi usado para explicar.**

4.5 Exemplo: o “beta” de uma ação

O professor abre um parêntese que merece atenção especial de um público de Economia e Finanças. O celebrado **Capital Asset Pricing Model** (CAPM) relaciona o excesso de retorno esperado de um ativo com o excesso de retorno esperado de um portfólio amplo, o portfólio de mercado:

$$\boxed{R_i - R_f = \beta_i (R_m - R_f)} \quad \text{com} \quad \boxed{\beta_i = \frac{\text{Cov}(R_i, R_m)}{\text{Var}(R_m)}}$$

onde R_i é o retorno do ativo i , R_m o retorno do portfólio de mercado e R_f a taxa livre de risco.

Compare a segunda expressão com a fórmula de MQO obtida acima, $\hat{\beta}_1 = s_{XY}/s_X^2$. **É a mesma fórmula** — a versão populacional da versão amostral. A conclusão é forte e vale enunciar:

! O beta de uma ação é um coeficiente de regressão

O β de um ativo, tal como definido pelo CAPM e reportado por qualquer terminal financeiro, **é literalmente o coeficiente angular da regressão do excesso de retorno do ativo sobre o excesso de retorno do mercado:**

$$(R_{it} - R_{ft}) = \alpha_i + \beta_i (R_{mt} - R_{ft}) + u_{it}.$$

Estimar o beta de uma ação é rodar uma regressão simples. Nada mais.

Isso ilumina o CAPM e a regressão simultaneamente.

Do lado do CAPM, explica-se de onde vem a interpretação usual: β_i mede a sensibilidade do ativo aos movimentos do mercado. Um ativo com $\beta = 1,5$ tende a mover-se 1,5% quando o mercado se move 1% — é a leitura de coeficiente angular, aplicada a retornos. Ativos com $\beta > 1$ são “agressivos”; com $0 < \beta < 1$, “defensivos”; com $\beta < 0$, funcionam como *hedge*. E o CAPM prediz $\alpha_i = 0$: o intercepto da regressão deveria ser nulo, de modo que testar a validade do CAPM para um ativo é testar $H_0 : \alpha_i = 0$ — um teste de hipótese sobre um coeficiente de regressão, exatamente o que a Aula 4 nos dará ferramentas para fazer.

Do lado da regressão, o exemplo mostra que a fórmula covariância-sobre-variância não é uma curiosidade algébrica: ela é o objeto que a teoria financeira identificou, de forma independente, como a medida relevante de risco sistemático. O CAPM decompõe o risco total de um ativo em uma parte que covaria com o mercado — capturada por β_i , não diversificável e por isso remunerada em

equilíbrio — e uma parte idiossincrática, que é justamente o resíduo u_{it} da regressão, diversificável e não remunerada. **A decomposição $Y_i = \hat{Y}_i + \hat{u}_i$ é, no CAPM, a decomposição do retorno em componente sistemático e componente idiossincrático.** Que ela apareça em um curso de econometria e em um curso de finanças com o mesmo conteúdo matemático não é coincidência: é a mesma projeção ortogonal.

4.6 Medidas de aderência

Uma vez estimada a reta de regressão, é natural perguntar se ela é uma boa descrição dos dados. Duas estatísticas respondem, de maneiras complementares: o **coeficiente de determinação R^2** , que é adimensional e mede a *fração* da variação explicada, e o **erro-padrão da regressão (SER)**, que é medido nas unidades de Y e mede a *magnitude* típica do erro.

4.6.1 As três somas de quadrados

Partimos da decomposição $Y_i = \hat{Y}_i + \hat{u}_i$ e definimos:

$$\begin{aligned} \text{TSS} &= \sum_{i=1}^n (Y_i - \bar{Y})^2 && \text{(Soma Total dos Quadrados)} \\ \text{ESS} &= \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 && \text{(Soma dos Quadrados Explicados)} \\ \text{SSR} &= \sum_{i=1}^n \hat{u}_i^2 && \text{(Soma dos Quadrados dos Resíduos)} \end{aligned}$$

A TSS mede a variação total de Y na amostra — é $(n-1)s_Y^2$. A ESS mede a variação dos **valores preditos** em torno da média. A SSR mede a variação que ficou no resíduo.

Note que na definição de ESS os valores preditos são comparados a $\bar{Y}$, a média dos valores **observados**. O professor pergunta, no slide 29: por que se pode fazer isso? Porque $\hat{\bar{Y}} = \bar{Y}$, isto é, **a média dos valores ajustados é igual à média dos valores observados**. A demonstração é uma linha e usa a primeira condição de ortogonalidade:

$$\frac{1}{n} \sum_{i=1}^n \hat{Y}_i = \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{u}_i) = \bar{Y} - \underbrace{\frac{1}{n} \sum_{i=1}^n \hat{u}_i}_{=0} = \bar{Y}.$$

É o mesmo fato geométrico de que a reta de MQO passa por $(\bar{X}, \bar{Y})$, visto de outro ângulo: como $\hat{Y}_i$ é uma função afim de X_i , sua média é $\hat{\beta}_0 + \hat{\beta}_1 \bar{X}$, que é precisamente $\bar{Y}$. Vale notar que essa propriedade depende da presença do intercepto — em uma regressão sem intercepto, $\sum \hat{u}_i \neq 0$ em geral, e boa parte do que vem a seguir deixa de valer.

4.6.2 A decomposição TSS = ESS + SSR

O professor deixa esta demonstração como exercício. Vamos fazê-la, porque ela é o que justifica a interpretação do R^2 como “fração explicada” — sem ela, ESS/TSS seria uma razão qualquer, não uma proporção.

! Proposição — decomposição da variação

$$\text{TSS} = \text{ESS} + \text{SSR}$$

Demonstração. Some e subtraia $\hat{Y}_i$ dentro do quadrado da TSS:

$$\text{TSS} = \sum_{i=1}^n (Y_i - \bar{Y})^2 = \sum_{i=1}^n \left[\underbrace{(Y_i - \hat{Y}_i)}_{= \hat{u}_i} + (\hat{Y}_i - \bar{Y}) \right]^2.$$

Expandindo o quadrado do binômio:

$$\text{TSS} = \underbrace{\sum_{i=1}^n \hat{u}_i^2}_{= \text{SSR}} + \underbrace{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}_{= \text{ESS}} + 2 \underbrace{\sum_{i=1}^n \hat{u}_i (\hat{Y}_i - \bar{Y})}_{= C}.$$

Resta mostrar que o termo cruzado C é nulo. Substituindo $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$:

$$C = \sum_{i=1}^n \hat{u}_i (\hat{\beta}_0 + \hat{\beta}_1 X_i - \bar{Y}) = (\hat{\beta}_0 - \bar{Y}) \underbrace{\sum_{i=1}^n \hat{u}_i}_{=0} + \hat{\beta}_1 \underbrace{\sum_{i=1}^n \hat{u}_i X_i}_{=0} = 0,$$

onde as duas somas se anulam pelas condições de ortogonalidade (i) e (ii), respectivamente. Logo $\text{TSS} = \text{ESS} + \text{SSR}$. ■

Duas observações sobre a demonstração. Primeira: ela usa **as duas** condições de ortogonalidade, e só elas — nenhuma hipótese sobre o processo gerador dos dados. A decomposição é, portanto, uma identidade algébrica que vale em qualquer amostra, mesmo que o modelo esteja completamente errado. Segunda: geometricamente, $\text{TSS} = \text{ESS} + \text{SSR}$ é o **teorema de Pitágoras** aplicado ao triângulo retângulo formado pelos vetores $(\mathbf{Y} - \bar{Y}\mathbf{1})$, $(\hat{\mathbf{Y}} - \bar{Y}\mathbf{1})$ e $\hat{\mathbf{u}}$ — o ângulo reto é exatamente a ortogonalidade que acabamos de usar.

4.6.3 O coeficiente de determinação

! Definição — o R^2

O R^2 da regressão é a **fração da variância amostral de Y que é explicada (ou predita) por X** :

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{SSR}}{\text{TSS}}$$

A segunda igualdade segue de $\text{TSS} = \text{ESS} + \text{SSR}$: dividindo por TSS, obtém-se $1 = R^2 + \text{SSR}/\text{TSS}$.

Propriedades. O R^2 assume valores entre 0 e 1 — o que decorre imediatamente da decomposição, já que ESS e SSR são somas de quadrados, logo não negativas, e ambas não excedem TSS. Os dois casos extremos são instrutivos:

- $R^2 = 0$. Se $\hat{\beta}_1 = 0$, então X_i não explica nada da variação de Y_i , e o valor predito é constante: $\hat{Y}_i = \hat{\beta}_0 = \bar{Y}$ para todo i . Nesse caso $\text{ESS} = 0$, os resíduos coincidem com os desvios em relação à média, $\text{SSR} = \text{TSS}$, e $R^2 = 0$. A “melhor” previsão que X oferece é a mesma que se faria sem X : a média.
- $R^2 = 1$. Se X_i explica *toda* a variação de Y_i , então $\hat{Y}_i = Y_i$ para todo i , todos os resíduos são nulos ($\hat{u}_i = 0 \forall i$), $\text{SSR} = 0$ e $\text{ESS} = \text{TSS}$. Todos os pontos estão exatamente sobre a reta.

Em geral, o R^2 não assume os valores extremos. Um R^2 próximo de 1 indica que o regressor é um **bom preditor** de Y_i ; próximo de zero, que não é. E aqui vem o alerta que o professor destaca em negrito no slide 32, e que estas notas destacam ainda mais:

! ALERTA — R^2 alto NÃO é evidência de causalidade

Um R^2 alto não é evidência de causalidade. Ser um bom preditor é muito diferente de ser causal.

As duas coisas são logicamente independentes, e nas duas direções:

- **R^2 alto sem causalidade.** O número de bombeiros enviados a um incêndio prevê extraordinariamente bem o valor dos danos — e não os causa. Vendas de sorvete preveem afogamentos. Em séries de tempo, duas variáveis com tendência preveem uma à outra com R^2 acima de 0,9 sem qualquer relação. Nada nas fórmulas de ESS, SSR e TSS envolve a hipótese $\mathbb{E}(u | X) = 0$: o R^2 é calculável e alto mesmo quando o coeficiente é completamente viesado.
- **Causalidade com R^2 baixo.** No próprio exemplo do capítulo, o R^2 é de apenas 0,051 — o tamanho da turma explica 5% da variação do desempenho entre distritos. Isso **não** significa que o efeito seja nulo ou desinteressante: significa que há muitos outros determinantes do desempenho. Um efeito causal pode ser real, robusto, e economicamente relevante, e ainda assim responder por uma fração pequena da variação total.

A confusão tem uma origem clara. O R^2 é uma medida de **ajuste**, e ajuste é uma propriedade da relação *estatística* entre as variáveis na amostra. Causalidade é uma propriedade da relação *estrutural* entre elas no mundo. A primeira se lê nos dados; a segunda depende de uma hipótese de identificação que os dados não verificam. Maximizar o R^2 é o objetivo correto em um problema de **previsão**; em um problema de **inferência causal**, é um critério irrelevante e potencialmente enganoso — acrescentar regressores sempre aumenta o R^2 , inclusive os que introduzem viés.

4.6.4 O exercício do slide 33

O professor propõe três resultados sobre o R^2 e a correlação amostral. Vamos resolvê-los, porque eles amarram tudo o que foi feito nesta seção. Recorde a notação: $r_{XY} = s_{XY}/(s_X s_Y)$ é a correlação amostral, e s_X , s_Y os desvios-padrão amostrais.

[a] **Mostre que $R^2 = r_{XY}^2$ na regressão simples.**

Comece pela ESS. Como $\hat{Y}_i - \bar{Y} = (\hat{\beta}_0 + \hat{\beta}_1 X_i) - (\hat{\beta}_0 + \hat{\beta}_1 \bar{X}) = \hat{\beta}_1 (X_i - \bar{X})$ — usando $\bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X}$ do Passo 1 —, temos

$$\text{ESS} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \hat{\beta}_1^2 \sum_{i=1}^n (X_i - \bar{X})^2.$$

Substituindo $\hat{\beta}_1 = s_{XY}/s_X^2$ e escrevendo as somas em termos das variâncias amostrais, $\sum (X_i - \bar{X})^2 = (n-1)s_X^2$ e $\text{TSS} = (n-1)s_Y^2$:

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = \frac{\left(\frac{s_{XY}}{s_X^2}\right)^2 (n-1)s_X^2}{(n-1)s_Y^2} = \frac{s_{XY}^2}{s_X^4} \cdot \frac{s_X^2}{s_Y^2} = \frac{s_{XY}^2}{s_X^2 s_Y^2} = \left(\frac{s_{XY}}{s_X s_Y}\right)^2 = r_{XY}^2. \quad \blacksquare$$

O resultado justifica a notação: o “ R ” de R^2 é a correlação. **Atenção:** ele vale apenas na regressão **simples**. Com mais de um regressor, R^2 é o quadrado da correlação entre Y e $\hat{Y}$ — a correlação múltipla —, não de nenhuma correlação simples.

[b] **Mostre que o R^2 da regressão de Y em X é o mesmo da regressão de X em Y .**

Segue imediatamente de [a]. Pelo item anterior, o R^2 da regressão de Y em X é r_{XY}^2 . Aplicando o mesmo resultado à regressão de X em Y — que é a mesma conta com os papéis trocados —, seu R^2 é r_{YX}^2 . Mas a correlação amostral é **simétrica**, $r_{XY} = s_{XY}/(s_X s_Y) = s_{YX}/(s_Y s_X) = r_{YX}$, pois a covariância é simétrica. Logo os dois R^2 coincidem. $\blacksquare$

Este resultado é conceitualmente importante e frequentemente mal compreendido. **Os coeficientes das duas regressões são diferentes** — a regressão de Y em X tem inclinação s_{XY}/s_X^2 e a de X em Y tem s_{XY}/s_Y^2 , e as duas retas não coincidem no plano (exceto quando $|r_{XY}| = 1$). Mas o **ajuste** é o mesmo. A moral: **o R^2 não sabe qual é a variável dependente**. Ele é uma medida de associação, e associação é simétrica. Nenhuma estatística de ajuste pode, portanto, dizer qual variável causa qual — o que é apenas outra forma de enunciar o alerta da caixa anterior.

[c] **Mostre que $\hat{\beta}_1 = r_{XY} (s_Y/s_X)$.**

Direto da definição de correlação. Como $s_{XY} = r_{XY} s_X s_Y$,

$$\hat{\beta}_1 = \frac{s_{XY}}{s_X^2} = \frac{r_{XY} s_X s_Y}{s_X^2} = r_{XY} \frac{s_Y}{s_X}. \quad \blacksquare$$

A fórmula separa duas coisas que a inclinação mistura. O fator r_{XY} , adimensional e entre -1 e 1 , é a **força da associação linear**. O fator s_Y/s_X é um puro **fator de conversão de unidades**: transforma “desvios-padrão de X ” em “desvios-padrão de Y ”. Uma consequência prática: se padronizarmos ambas as variáveis (média zero, desvio-padrão um), então $s_Y = s_X = 1$ e o coeficiente

de MQO é a correlação. É por isso que coeficientes de variáveis padronizadas — os *beta coefficients* de alguns softwares — são comparáveis entre si, e coeficientes brutos não são.

Uma segunda consequência é a **regressão à média**, que dá nome ao método. Se X e Y têm o mesmo desvio-padrão (alturas de pais e filhos, no exemplo original de Galton), então $\hat{\beta}_1 = r_{XY}$, que é menor que 1 em valor absoluto sempre que a associação não é perfeita. Filhos de pais muito altos tendem a ser altos, mas **menos** altos que os pais — não por nenhum mecanismo biológico misterioso, mas por uma propriedade aritmética do coeficiente de regressão.

4.6.5 O erro-padrão da regressão

O R^2 é adimensional e responde “que fração?”. A segunda medida de aderência responde “de quanto?”, nas unidades de Y .

! Definição — erro-padrão da regressão (SER)

O **erro-padrão da regressão** (*Standard Error of the Regression*) é um estimador do desvio-padrão do erro de regressão u_i :

$$\text{SER} = s_{\hat{u}} = \sqrt{s_{\hat{u}}^2}, \quad s_{\hat{u}}^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2 = \frac{\text{SSR}}{n-2}$$

onde $\hat{u}_i = Y_i - \hat{Y}_i$.

Por que $n-2$? Pela mesma razão que a variância amostral usa $n-1$: correção de graus de liberdade. Os resíduos não são livres — eles satisfazem as **duas** condições de ortogonalidade, $\sum \hat{u}_i = 0$ e $\sum \hat{u}_i X_i = 0$. Conhecidos $n-2$ resíduos, os dois restantes ficam determinados por essas restrições. Há, portanto, apenas $n-2$ resíduos “livres”, e dividir por $n-2$ é o que torna $s_{\hat{u}}^2$ não viesado para σ_u^2 sob homocedasticidade.

i Ferramenta estatística — graus de liberdade e o divisor $n-1$

Este é exatamente o argumento que as **Notas de Aula de Estatística** (Prof. Eduardo Campos) desenvolvem para justificar o divisor $n-1$ da variância amostral s_Y^2 . Lá, a restrição é uma só — $\sum (Y_i - \bar{Y}) = 0$, decorrente de se ter estimado μ pela própria média amostral —, e a demonstração mostra que $\mathbb{E}[\sum (Y_i - \bar{Y})^2] = (n-1)\sigma^2$, de modo que dividir por n produziria um estimador viesado para baixo.

A regra geral é: **subtraia do n o número de parâmetros estimados** que entram no cálculo dos desvios. Na variância amostral estima-se um parâmetro (μ), daí $n-1$. Na regressão simples estimam-se dois (β_0 e β_1), daí $n-2$. Na regressão múltipla com k regressores mais intercepto, $n-k-1$. É sempre a mesma contabilidade.

Como em Estatística, a correção importa muito em amostras pequenas e quase nada em amostras grandes: com $n = 420$, $n-2$ e n diferem por menos de meio por cento.

Interpretação. As unidades de $\hat{u}_i$ e de Y_i são as mesmas, de modo que o SER é uma medida da **dispersão das observações em torno da reta de regressão, medida nas unidades da variável dependente**. Se a variável dependente é medida em dólares, o SER mede a magnitude de um desvio típico da reta — a magnitude de um erro de regressão típico — em dólares. No exemplo

do capítulo, $SER \approx 18,58$ pontos do teste: um distrito típico está a cerca de 19 pontos da reta, o que, comparado ao efeito estimado de 2,28 pontos por aluno, dá a medida exata de quanto do desempenho o tamanho da turma *não* explica.

Comparação com s_Y . Vale pôr as duas fórmulas lado a lado, como faz o professor no slide 37:

$$s_Y = \sqrt{s_Y^2}, \quad s_Y^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 \quad \text{contra} \quad SER = \sqrt{s_u^2}, \quad s_u^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2$$

As fórmulas são parecidas, com duas diferenças: $(Y_i - \bar{Y})$ é substituído por $\hat{u}_i$, e o denominador passa de $n-1$ para $n-2$. A substituição tem significado. s_Y mede a dispersão de Y em torno de sua média **incondicional**; o SER mede a dispersão em torno da **média condicional estimada**. A diferença entre os dois é precisamente o que X explica — e, de fato, a relação entre eles é

$$SER^2 \approx s_Y^2 (1 - R^2),$$

exata a menos do ajuste de graus de liberdade. As duas medidas de aderência, portanto, são duas leituras da mesma decomposição: o R^2 em termos relativos, o SER em termos absolutos.

4.7 As três hipóteses de MQO

Chegamos ao núcleo conceitual do capítulo. Até aqui, o MQO foi tratado como um procedimento puramente algébrico: dados n pares, produza a reta que minimiza a soma de quadrados. Nada do que fizemos exigiu hipótese alguma — as condições de ortogonalidade, a decomposição $TSS = ESS + SSR$, as fórmulas do R^2 e do SER valem sempre, mesmo que os dados sejam ruído puro.

A pergunta agora é outra e é a pergunta econométrica: **quando $\hat{\beta}_1$ estima o efeito causal β_1 ?** A resposta depende da natureza dos dados, e o professor a organiza em torno da comparação com o experimento ideal.

Em um experimento aleatorizado, a diferença entre as médias dos grupos de tratamento e de controle,

$$\mathbb{E}(Y \mid X = 1) - \mathbb{E}(Y \mid X = 0),$$

é um **estimador não viesado do efeito causal do tratamento**. A razão, vista no Seção 2, é que a aleatorização garante que os dois grupos sejam comparáveis em tudo o mais: os fatores omitidos têm a mesma distribuição nos dois braços, porque a alocação foi feita por sorteio e não por escolha. Essa lógica se estende ao modelo de regressão linear e ao estimador de MQO — e o que se segue são as três hipóteses matemáticas sob as quais o MQO produz estimativas do efeito causal.

! Hipótese 1 — a distribuição condicional de u_i dado X_i tem média zero

$$\mathbb{E}(u_i \mid X_i) = 0$$

Esta é uma declaração matemática formal sobre os **outros fatores** contidos em u_i . Ela afirma que esses outros fatores não são relacionados com X_i , no sentido de que, dado um valor de X_i , a média da distribuição desses outros fatores é zero.

É a hipótese mais importante do curso.

Interpretação. No exemplo do capítulo, sabemos que *ClassSize* é apenas um dos determinantes do desempenho acadêmico. Outros fatores — qualidade dos professores, infraestrutura da escola, características socioeconômicas das famílias — também importam, e o termo de erro representa a contribuição de **todos os fatores não observáveis e omitidos**. A hipótese se traduz, então, em

$$\mathbb{E}(\text{Outros Fatores} \mid STR) = 0 :$$

Uma vez que X está fixo, os outros fatores que também são determinantes do *TestScore* têm, em média, impacto zero no *TestScore*.

Dito de outra forma: comparando dois grupos de distritos que diferem no tamanho da turma, os demais determinantes do desempenho estão **equilibrados** entre os grupos. Essa é precisamente a propriedade que a aleatorização garante em um experimento.

O problema dos dados observacionais. Com dados observacionais, X **não** é alocado aleatoriamente. Distritos escolheram seus tamanhos de turma, e essas escolhas refletem orçamentos, prioridades políticas e a composição socioeconômica local. O melhor que podemos esperar é que X seja “**como se**” **tivesse sido atribuído aleatoriamente**, no sentido de que $\mathbb{E}(u_i \mid X_i) = 0$.

E aqui está o desconforto que o Seção 1 anunciava: **essa hipótese não é testável**. Ela envolve u_i , que não é observável — e os resíduos $\hat{u}_i$, que observamos, satisfazem a ortogonalidade *por construção*, de modo que nenhum diagnóstico baseado neles pode informar sobre a hipótese populacional. Saber se ela é válida em um exercício empírico concreto “requer conhecimento específico da aplicação e juízo”, como diz o slide. É literalmente a *arte* de que fala a definição de econometria: a parte do trabalho que nenhum teorema faz por nós.

4.7.1 Média condicional zero e correlação: um ponto sutil

O professor dedica dois slides a uma sutileza lógica que vale desenvolver com cuidado, porque ela organiza a maneira como se *discute* a Hipótese 1 na prática.

Implicação 1: $\mathbb{E}(u \mid X) = 0 \implies \text{Corr}(u, X) = 0$.

Isso foi visto no Seção 3 e a demonstração é curta. Pela lei das esperanças iteradas, $\mathbb{E}(u) = \mathbb{E}[\mathbb{E}(u \mid X)] = \mathbb{E}[0] = 0$. E, pela mesma lei aplicada ao produto,

$$\mathbb{E}(uX) = \mathbb{E}[\mathbb{E}(uX \mid X)] = \mathbb{E}[X \mathbb{E}(u \mid X)] = \mathbb{E}[X \cdot 0] = 0,$$

de modo que $\text{Cov}(u, X) = \mathbb{E}(uX) - \mathbb{E}(u)\mathbb{E}(X) = 0$ e, portanto, $\text{Corr}(u, X) = 0$.

Implicação 2: a recíproca NÃO vale. Se $\text{Corr}(u_i, X_i) = 0$, **não** é necessariamente verdade que $\mathbb{E}(u_i \mid X_i) = 0$.

A razão é conceitual: a correlação é uma medida de **associação linear**. Ela detecta dependência que se manifeste na forma de uma tendência de subir junto ou descer junto, e é cega para todo o resto. Uma variável pode depender fortemente de outra e ter correlação nula com ela.

O contraexemplo padrão, apresentado no Seção 3, é a dependência quadrática. Seja $X \sim \mathcal{N}(0, 1)$ e $u = X^2 - 1$. Então:

$$\mathbb{E}(u \mid X) = X^2 - 1 \neq 0 \quad (\text{depende de } X),$$

de modo que a Hipótese 1 é **violada** de maneira grosseira: conhecer X informa completamente sobre u . Mas

$$\text{Cov}(u, X) = \mathbb{E}[(X^2 - 1)X] = \mathbb{E}(X^3) - \mathbb{E}(X) = 0 - 0 = 0,$$

porque os momentos ímpares da Normal padrão são nulos. Correlação zero, dependência total.

Implicação 3 — a contrapositiva, que é a útil:

$$\text{Corr}(u_i, X_i) \neq 0 \implies \mathbb{E}(u_i \mid X_i) \neq 0$$

Esta é apenas a contrapositiva da Implicação 1, logicamente equivalente a ela. É ela que torna a discussão prática viável.

! Por que se discute a Hipótese 1 em termos de correlação

As três implicações se combinam assim. Como correlação não nula **implica** média condicional não nula, basta encontrar uma razão para suspeitar de correlação entre X_i e u_i para concluir que a Hipótese 1 é inválida. Por isso é **mais conveniente conduzir a discussão sobre a hipótese de média condicional igual a zero em termos da possível correlação entre X_i e u_i** : é um alvo mais fácil de mirar, e é suficiente para derrubar a hipótese.

Em resumo: **se u_i e X_i são correlacionados, então a hipótese de média condicional igual a zero é inválida** — e o MQO é viesado.

O que **não** se pode fazer é o inverso: argumentar que a hipótese vale porque não se vê correlação. Ausência de correlação é condição necessária, não suficiente. É por isso que a Hipótese 1 é formulada em termos de $\mathbb{E}(u \mid X)$, e não de $\text{Corr}(u, X)$ — a versão forte é a que dá as propriedades desejadas; a versão fraca é a que se usa para argumentar contra.

É por essa via que se organiza o resto do curso. Cada estratégia que virá — controlar por observáveis, efeitos fixos, variáveis instrumentais, quase-experimentos — é uma tentativa de tornar defensável a afirmação de que, condicionalmente ao desenho adotado, X não está correlacionado com o que ficou no erro. E o **viés de variável omitida**, tema imediato da regressão múltipla, é exatamente o cálculo do que acontece quando essa correlação não é zero.

! Hipótese 2 — (X_i, Y_i) , $i = 1, \dots, n$, são i.i.d.

$$(X_i, Y_i) \stackrel{\text{i.i.d.}}{\sim} F_{XY}, \quad i = 1, \dots, n$$

Esta hipótese é uma afirmação sobre **como a amostra é extraída**. Se as observações são obtidas por amostragem aleatória de uma população grande, então os pares (X_i, Y_i) podem ser considerados uma amostra independente e identicamente distribuída.

Note a diferença de natureza em relação à Hipótese 1. A primeira é uma afirmação sobre a **estrutura econômica** do problema — sobre a relação entre o regressor e os fatores omitidos. A segunda é sobre o **desenho amostral** — sobre o procedimento que gerou os dados. Uma é substantiva, a outra é de engenharia estatística. Ambas são necessárias, mas por razões diferentes: a Hipótese 1 dá o **não-viés**; a Hipótese 2 é o que permite invocar a Lei dos Grandes Números e o Teorema Central do Limite, e portanto o que dá a **distribuição amostral** de que a inferência depende.

i Ferramenta estatística — amostra aleatória simples, LGN e TCL

A hipótese i.i.d. é exatamente a definição de **amostra aleatória simples** das Notas de Estatística: variáveis independentes e identicamente distribuídas segundo a distribuição da população. A diferença aqui é que o objeto sorteado não é um número, mas um **par** (X_i, Y_i) — sorteamos distritos, e cada distrito traz consigo seu tamanho de turma e seu desempenho, com toda a dependência que houver **entre** as duas variáveis preservada. A independência é *entre observações*, não *entre variáveis*.

É sob essa hipótese que valem a Lei dos Grandes Números e o Teorema Central do Limite, e são esses dois teoremas que produzirão, na próxima seção, a consistência e a normalidade assintótica de $\hat{\beta}_1$.

Exemplo — a equação de Mincer. Mais adiante no curso estimaremos a famosa equação de Mincer, que relaciona salário e escolaridade:

$$\log(\text{wage}_i) = \beta_0 + \beta_1 \text{Educ}_i + u_i.$$

A amostra consiste de n trabalhadores extraídos da população de trabalhadores do Brasil. Nesse caso, **por construção** a amostra é identicamente distribuída — todos os trabalhadores vêm da mesma população. E, se a extração é aleatória, os pares $(\text{wage}_i, \text{Educ}_i)$ serão independentes entre si. (Vale notar que a Hipótese 1 é bem mais problemática aqui: a habilidade não observada afeta tanto a escolaridade quanto o salário, o que é o exemplo canônico de viés de variável omitida.)

Quando a Hipótese 2 é plausível? Tudo depende do esquema de amostragem.

- **Plausível:** dados de *survey*, gerados por questionários coletados de um subconjunto escolhido aleatoriamente de uma população. PNAD, PME, Census — em geral, podem ser tratados como i.i.d. (com ressalvas sobre desenhos amostrais complexos, que exigem pesos).
- **Não plausível: dados em séries de tempo.** O PIB deste trimestre não é independente do trimestre anterior; a inflação de hoje carrega a de ontem. A dependência temporal é a regra, não a exceção. Isso não impede a análise de regressão — exige um aparato assintótico diferente (estacionariedade, ergodicidade) e erros-padrão que corrijam a autocorrelação.
- **Também problemática:** dados agrupados, em que observações do mesmo grupo (escola, município, firma) compartilham choques. Daí a prática de agrupar erros-padrão por *cluster*.

! Hipótese 3 — valores extremos são raros

$$0 < \mathbb{E}(X_i^4) < \infty \quad \text{e} \quad 0 < \mathbb{E}(Y_i^4) < \infty$$

Formalmente, X_i e Y_i têm **quartos momentos finitos e não nulos**. Informalmente: obser-

vações com valores muito extremos são improváveis.

Esta é uma **hipótese técnica**, no sentido de que elimina a possibilidade de haver uma observação que torne enganosos os resultados da regressão por MQO. A razão é simples e vale a pena entendê-la sem a formalidade: **o estimador de MQO minimiza uma soma quadrática**. Se alguma observação é um valor extremo, o desvio correspondente é **elevado ao quadrado**, e sua contribuição ao critério cresce quadraticamente com a distância. Uma única observação suficientemente distante pode, sozinha, dominar a soma e arrastar a reta na sua direção.

Duas observações. A primeira é que a hipótese quase sempre vale na prática — variáveis econômicas limitadas por construção (notas de teste entre 0 e 800, anos de escolaridade entre 0 e 25) têm todos os momentos finitos automaticamente. Ela é enunciada porque é necessária para a demonstração formal da normalidade assintótica, não porque seja empiricamente delicada.

A segunda é que, embora a hipótese formal raramente falhe, o **problema prático** que ela sinaliza é muito real: em qualquer amostra finita, uma observação atípica — frequentemente um erro de digitação, um código de missing lido como número, uma unidade de medida trocada — pode alterar substancialmente as estimativas. Daí a recomendação, que é de ofício e não de teoria: **sempre inspecione os dados graficamente antes de rodar a regressão**. O laboratório deste capítulo mostra numericamente o estrago que uma única observação pode fazer.

4.8 Distribuição amostral dos estimadores de MQO

Reunidas as três hipóteses, podemos enfim tratar $\hat{\beta}_0$ e $\hat{\beta}_1$ como o que eles são.

Porque os estimadores de MQO são calculados a partir de uma **amostra aleatória**, eles também são **variáveis aleatórias** e têm uma distribuição de probabilidade — a **distribuição amostral**. Ela descreve os valores que $\hat{\beta}_0$ e $\hat{\beta}_1$ podem assumir em diferentes amostras aleatórias da mesma população.

Esse é o ponto que faz a ponte com toda a inferência que virá. Se tivéssemos sorteado outros 420 distritos, teríamos obtido $-2,31$ ou $-2,19$ em vez de $-2,28$. A estimativa é um número; o estimador é uma variável aleatória; e é sobre a distribuição dessa variável aleatória que faremos, na Aula 4, afirmações do tipo “com 95% de confiança, β_1 está entre $-3,30$ e $-1,26$ ”.

i Ferramenta estatística — distribuição amostral

O conceito é o mesmo que as **Notas de Aula de Estatística** desenvolvem para $\bar{X}$: um estimador é função da amostra, logo variável aleatória, logo tem esperança, variância e distribuição. Lá, o resultado central é que $\bar{X}$ é não viesado para μ , tem variância σ^2/n e é aproximadamente Normal por TCL.

Aqui, a estrutura é idêntica, aplicada a um estimador mais complicado. E de fato $\hat{\beta}_1$ é uma média disfarçada: pode-se mostrar que $\hat{\beta}_1 - \beta_1 = \frac{\frac{1}{n} \sum (X_i - \bar{X}) u_i}{\frac{1}{n} \sum (X_i - \bar{X})^2}$, uma razão entre duas médias amostrais — e é aplicando LGN ao denominador e TCL ao numerador que se obtêm consistência e normalidade assintótica.

! Propriedades dos estimadores de MQO

Sob as Hipóteses 1–3:

1. **Não-viés:** $\mathbb{E}(\hat{\beta}_0) = \beta_0$ e $\mathbb{E}(\hat{\beta}_1) = \beta_1$.
2. **Consistência:** $\hat{\beta}_1 \xrightarrow{p} \beta_1$, isto é, $\text{plim}_{n \rightarrow \infty} \hat{\beta}_1 = \beta_1$.
3. **Normalidade assintótica:** em amostras grandes, pelo Teorema Central do Limite,

$$\hat{\beta}_1 \overset{a}{\sim} \mathcal{N}(\beta_1, \sigma_{\hat{\beta}_1}^2),$$

com

$$\sigma_{\hat{\beta}_1}^2 = \text{Var}(\hat{\beta}_1) = \frac{1}{n} \cdot \frac{\text{Var}[(X_i - \mu_X) u_i]}{[\text{Var}(X_i)]^2}$$

A fórmula da variância é a de Stock e Watson (2020) (equação 4.21) e merece ser lida com atenção, porque ela diz **o que faz um estimador ser preciso**. Três fatores:

1. O tamanho da amostra n . A variância cai a taxa $1/n$, de modo que o desvio-padrão cai a taxa $1/\sqrt{n}$. Quadruplicar a amostra reduz o erro-padrão pela metade. É a mesma taxa de $\bar{X}$, e é a taxa canônica da estatística.

2. A variação do regressor, $\text{Var}(X_i)$. Ela aparece **ao quadrado no denominador**, o que significa que mais variação em X produz estimativas mais precisas. A intuição é geométrica e é forte: para estimar a inclinação de uma reta, é preciso ter pontos espalhados ao longo do eixo horizontal. Se todos os X_i estão amontoados em torno de um mesmo valor, pequenas perturbações nos Y_i giram a reta violentamente — o “braço de alavanca” é curto. Se estão bem espalhados, a reta fica ancorada. No limite, com $\text{Var}(X) = 0$, a inclinação é indeterminada, o que a fórmula registra como variância infinita.

3. A variância do erro. Ela entra pelo numerador, via $\text{Var}[(X_i - \mu_X) u_i]$. Menos ruído não explicado — erros menores em torno da PRF — significa estimativas mais precisas. Sob homocedasticidade ($\text{Var}(u_i | X_i) = \sigma_u^2$ constante), a expressão se simplifica para a forma familiar

$$\text{Var}(\hat{\beta}_1) = \frac{\sigma_u^2}{n \text{Var}(X_i)} \quad \text{estimada por} \quad \widehat{\text{Var}}(\hat{\beta}_1) = \frac{\text{SER}^2}{\sum_{i=1}^n (X_i - \bar{X})^2},$$

que exhibe os três fatores de forma transparente: erro-padrão pequeno quer dizer **muitos dados, muito espalhados em X , com pouco ruído em Y** .

A forma geral da caixa, com $\text{Var}[(X_i - \mu_X) u_i]$ no numerador, **não** supõe homocedasticidade — ela permite que a dispersão do erro varie com X . É essa fórmula geral que os **erros-padrão robustos à heterocedasticidade** estimam, e é por isso que a saída do professor traz **robust**:

```
regress testscr str, robust
```

Regression with robust standard errors

```
Number of obs =      420
F(  1,    418) =    19.26
Prob > F       =    0.0000
R-squared      =    0.0512
```

Root MSE = 18.581

		Robust				
testscr	Coef.	Std. Err.	t	P> t	[95% Conf. Interval]	

str	-2.279808	.5194892	-4.39	0.000	-3.300945	-1.258671
_cons	698.933	10.36436	67.44	0.000	678.5602	719.3057

Reconhecemos agora quase tudo nesse output: `Coef.` são $\hat{\beta}_0$ e $\hat{\beta}_1$; `R-squared` é ESS/TSS; `Root MSE` é o SER; `Number of obs` é n . O que ainda não sabemos ler é a coluna `Std. Err.` e o que dela decorre — as estatísticas t , os p -valores, os intervalos de confiança. Esse é precisamente o assunto da **Aula 4**, que tratará de testes de hipóteses e intervalos de confiança na regressão simples, e que fecha o tratamento do Capítulo 4 de Stock e Watson (2020). Por ora, o essencial é que a coluna existe porque $\hat{\beta}_1$ é uma variável aleatória, e que sua magnitude é governada pelos três fatores que acabamos de discutir.

Uma última observação de software. Os slides do curso usam STATA, onde a opção `robust` produz os erros-padrão de White (variante HC1). O laboratório a seguir reproduz exatamente esse cálculo em R, através da função `ep_robusto()` definida no preâmbulo destas notas — implementada a partir da fórmula, e não importada de um pacote, para deixar visível o que o software faz por baixo do capô.

4.9 Laboratório computacional em R

O laboratório deste capítulo é o mais extenso das notas até aqui, e faz sete coisas: reproduz a regressão do exemplo, calcula o MQO “na mão” e confere contra o `lm()`, verifica numericamente as condições de ortogonalidade e a decomposição $TSS = ESS + SSR$, compara erros-padrão robustos e homocedásticos, e — a figura central — constrói por simulação a distribuição amostral de $\hat{\beta}_1$.

4.9.1 Os dados: uma advertência necessária

! Os dados deste laboratório são SIMULADOS

O conjunto de dados de distritos escolares da Califórnia usado por Stock e Watson (2020) (`caschool`, distribuído com o pacote `AER`) **não está disponível** no ambiente em que estas notas são compiladas. Em vez de omitir o exemplo, **simulo dados calibrados** para reproduzir a *ordem de grandeza* dos resultados do slide 34: $n = 420$, $\hat{\beta}_0 \approx 699$, $\hat{\beta}_1 \approx -2,28$, $R^2 \approx 0,05$ e $SER \approx 18,6$.

Os números que aparecem abaixo, portanto, **não são os dados originais de Stock e Watson** e não devem ser citados como tal. São uma reconstrução didática, e a única coisa que herdam do exemplo real são os momentos: média e desvio-padrão de STR compatíveis com a amostra californiana, e uma variância do erro escolhida para produzir o R^2 observado. Tudo o que o laboratório demonstra — identidades algébricas, comportamento dos estimadores, forma da distribuição amostral — vale para quaisquer dados e não depende dessa calibração.

A calibração é simples de justificar. Sob o modelo, $R^2 \approx \beta_1^2 \text{Var}(X) / [\beta_1^2 \text{Var}(X) + \sigma_u^2]$; resolvendo para σ_u com $\beta_1 = -2,28$, $\text{sd}(X) = 1,89$ e $R^2 = 0,051$, obtém-se $\sigma_u \approx 18,55$ — que é, coerentemente, o SER do slide.

```
set.seed(5490)
n_d      <- 420
beta0    <- 698.9      # valores "populacionais" usados na simulacao
beta1    <- -2.28
sigma_u  <- 18.55      # calibrado para reproduzir R2 ~ 0,051

STR      <- rnorm(n_d, mean = 19.64, sd = 1.89)  # momentos da amostra da California
u        <- rnorm(n_d, mean = 0,      sd = sigma_u)
TestScore <- beta0 + beta1 * STR + u
ca <- data.frame(STR = STR, TestScore = TestScore)

round(sapply(ca, function(v) c(media = mean(v), dp = sd(v),
                                min = min(v), max = max(v))), 2)
```

	STR	TestScore
media	19.65	654.33
dp	1.91	19.09
min	13.58	591.29
max	25.28	699.86

Note o suporte de STR : de aproximadamente 13,6 a 25,3. O valor $STR = 0$, ao qual o intercepto se refere, está a mais de sete desvios-padrão do menor valor observado — a ilustração numérica exata do argumento sobre extrapolação feito na 1.

4.9.2 (a) A regressão

```
reg <- lm(TestScore ~ STR, data = ca)
round(coef(reg), 4)
```

(Intercept)	STR
698.8918	-2.2682

```
round(c(R2 = summary(reg)$r.squared,
        SER = summary(reg)$sigma,
        n = n_d), 4)
```

R2	SER	n
0.0515	18.6166	420.0000

A reta estimada é $\widehat{TestScore} = 698,89 - 2,27 \cdot STR$, com $R^2 = 0,051$ e $SER = 18,62$. Comparando com o output do STATA no slide 34 (698,93, -2,2798, 0,0512, 18,581), a reconstrução é notavelmente próxima — o que era de se esperar, dado que os momentos foram calibrados para isso, mas serve para confirmar que a calibração está correta. A diferença entre -2,268 e -2,280 é ruído amostral de uma única amostra de 420 observações, e a seção (f) mostrará que ela é inteiramente compatível com o erro-padrão do estimador.

```
set.seed(99)
amostra_g <- ca[sample(nrow(ca), 60), ]
amostra_g$ajustado <- coef(reg)[1] + coef(reg)[2] * amostra_g$STR

ggplot(ca, aes(STR, TestScore)) +
  geom_point(colour = cz, alpha = 0.25, size = 1) +
  geom_segment(data = amostra_g,
    aes(x = STR, xend = STR, y = TestScore, yend = ajustado),
    colour = vm, linewidth = 0.3, alpha = 0.8) +
  geom_point(data = amostra_g, colour = az, size = 1.2) +
  geom_abline(intercept = coef(reg)[1], slope = coef(reg)[2],
    colour = az, linewidth = 0.9) +
  labs(x = "STR (alunos por professor)", y = "TestScore")
```




Figura 4: Nuvem de pontos e reta de MQO nos dados simulados. Os 420 distritos aparecem em cinza; uma subamostra aleatória de 60 está destacada em azul com seus resíduos $\hat{u}_i$ marcados em vermelho — a distância vertical entre a observação e a reta. O MQO escolhe a reta que minimiza a soma dos quadrados desses segmentos. Note que os segmentos são verticais, e não perpendiculares à reta: minimizamos o erro na previsão de Y , o que quebra a simetria entre as variáveis.

A figura torna visível o que o R^2 de 0,051 quer dizer: a reta tem inclinação negativa perceptível,

mas a nuvem é larga em torno dela. O tamanho da turma desloca a média condicional; está longe de determinar o desempenho de um distrito individual.

4.9.3 (b) MQO na mão contra lm()

Vamos verificar que a fórmula derivada algebricamente é o que o `lm()` calcula. Três caminhos: a fórmula com somatórios, a razão covariância-sobre-variância, e o `lm()`.

```
Xb <- mean(ca$STR);      Yb <- mean(ca$TestScore)
dX <- ca$STR - Xb;      dY <- ca$TestScore - Yb

b1_mao <- sum(dX * dY) / sum(dX^2)      # formula com somatorios
b0_mao <- Yb - b1_mao * Xb
b1_cov <- cov(ca$STR, ca$TestScore) / var(ca$STR)  # s_XY / s^2_X

round(rbind(formula_somatorios = c(b0 = b0_mao, b1 = b1_mao),
  cov_sobre_var      = c(b0 = NA,      b1 = b1_cov),
  lm                  = coef(reg)), 8)
```

	b0	b1
formula_somatorios	698.8918	-2.268237
cov_sobre_var	NA	-2.268237
lm	698.8918	-2.268237

```
c(discrepancia_maxima = max(abs(c(b0_mao, b1_mao) - coef(reg))))
```

```
discrepancia_maxima
1.136868e-13
```

As três linhas coincidem até a oitava casa decimal, e a discrepância máxima é da ordem de 10^{-13} — precisão de máquina em ponto flutuante, não diferença de método. As duas primeiras linhas conferem a álgebra dos Passos 1 a 4; a igualdade entre as duas primeiras confirma que $\hat{\beta}_1 = s_{XY}/s_X^2$, com o $(n-1)$ se cancelando entre numerador e denominador exatamente como previsto.

4.9.4 (c) As condições de ortogonalidade

As duas identidades $\sum \hat{u}_i = 0$ e $\sum \hat{u}_i X_i = 0$ valem por construção. Vejamos.

```
uhat <- residuals(reg)
format(c(soma_u      = sum(uhat),
  soma_uX      = sum(uhat * ca$STR),
  media_u      = mean(uhat)), scientific = TRUE, digits = 3)
```

soma_u	soma_uX	media_u
"3.77e-13"	"1.35e-11"	"1.04e-15"

As três quantidades são zero até o erro de arredondamento do ponto flutuante: 4×10^{-13} e 1×10^{-11} contra valores de Y da ordem de 650 e somas de quadrados da ordem de 10^5 . Em termos relativos, são zeros exatos.

Vale insistir no que isso *não* significa. Que $\sum \hat{u}_i X_i = 0$ é uma propriedade do estimador, verdadeira mesmo se o modelo estiver completamente errado — mesmo se X for endógeno, se a relação for não linear, se os dados forem ruído. **Nenhum teste baseado nos resíduos pode detectar violação da Hipótese 1**, porque os resíduos são construídos para satisfazer a condição amostral correspondente. É a razão pela qual $\mathbb{E}(u | X) = 0$ não é testável.

4.9.5 (d) A decomposição $TSS = ESS + SSR$ e as três formas do R^2

```
Yhat <- fitted(reg)
TSS <- sum((ca$TestScore - Yb)^2)
ESS <- sum((Yhat - Yb)^2)
SSR <- sum(uhat^2)

round(c(TSS = TSS, ESS = ESS, SSR = SSR,
        ESS_mais_SSR = ESS + SSR,
        diferenca = TSS - (ESS + SSR)), 6)
```

TSS	ESS	SSR	ESS_mais_SSR	diferenca
152732.176	7863.176	144869.000	152732.176	0.000

A diferença é exatamente zero: a demonstração se confirma numericamente. Verifiquemos também que $\hat{\bar{Y}} = \bar{Y}$, o fato usado para justificar a definição de ESS:

```
c(media_Yhat = mean(Yhat), media_Y = Yb, diferenca = mean(Yhat) - Yb)
```

media_Yhat	media_Y	diferenca
654.3315	654.3315	0.0000

Agora as três expressões do R^2 — as duas equivalentes da definição e a do item [a] do exercício do slide 33, $R^2 = r_{XY}^2$:

```
r_xy <- cor(ca$STR, ca$TestScore)
round(c(ESS_sobre_TSS = ESS / TSS,
        um_menos_SSR_TSS = 1 - SSR / TSS,
        r2_da_correlacao = r_xy^2,
        R2_reportado = summary(reg)$r.squared), 10)
```

ESS_sobre_TSS	um_menos_SSR_TSS	r2_da_correlacao	R2_reportado
0.05148343	0.05148343	0.05148343	0.05148343

As quatro coincidem até a décima casa. O item [a] está verificado. Vejamos os itens [b] e [c]:

```
reg_inv <- lm(STR ~ TestScore, data = ca)      # regressao de X em Y
round(c(R2_de_Y_em_X = summary(reg)$r.squared,
        R2_de_X_em_Y = summary(reg_inv)$r.squared), 10)      # item [b]
```

```
R2_de_Y_em_X R2_de_X_em_Y
0.05148343   0.05148343
```

```
round(c(b1_do_lm      = unname(coef(reg)[2]),
        r_vezes_sY_sX = r_xy * sd(ca$TestScore) / sd(ca$STR)), 10) # item [c]
```

```
b1_do_lm r_vezes_sY_sX
-2.268237 -2.268237
```

O item [b] se confirma: os dois R^2 são idênticos, embora as duas retas sejam completamente diferentes — a inclinação da regressão de X em Y é -0.0227, que **não** é o inverso de -2,268 (o inverso seria -0,441). A razão entre as duas inclinações é exatamente R^2 : como $\hat{\beta}_1 = s_{XY}/s_X^2$ e $\tilde{\beta}_1 = s_{XY}/s_Y^2$, tem-se $\hat{\beta}_1 \cdot \tilde{\beta}_1 = s_{XY}^2/(s_X^2 s_Y^2) = r_{XY}^2 = R^2$. As duas retas só coincidem quando $R^2 = 1$. O ajuste é simétrico; os coeficientes não são. O item [c] também se confirma até a décima casa.

Por fim, o SER pela fórmula e a comparação com s_Y :

```
round(c(SER_pela_formula = sqrt(SSR / (n_d - 2)),
        SER_do_lm        = summary(reg)$sigma,
        sY                = sd(ca$TestScore),
        sY_vezes_raiz_1_menos_R2 = sd(ca$TestScore) *
        sqrt(1 - summary(reg)$r.squared)), 4)
```

```
SER_pela_formula      SER_do_lm      sY
18.6166              18.6166      19.0923
sY_vezes_raiz_1_menos_R2
18.5943
```

SER = 18,62 contra $s_Y = 19,09$: condicionar em STR reduz a dispersão de 19,09 para 18,62 pontos, uma redução de menos de 3%. A quarta linha mostra a relação $SER \approx s_Y \sqrt{1 - R^2}$, exata a menos da diferença entre os divisores $n - 1$ e $n - 2$. É a leitura absoluta do mesmo fato que o R^2 expressa em termos relativos.

4.9.6 (e) Erros-padrão robustos contra homocedásticos

Chegamos ao ponto em que o R reproduz o `robust` do STATA. A função `ep_robusto()`, definida no preâmbulo, implementa o estimador de White (HC1):

$$\widehat{\text{Var}}_{\text{HC1}}(\hat{\beta}) = \frac{n}{n-k} (\mathbf{X}'\mathbf{X})^{-1} \left(\sum_{i=1}^n \hat{u}_i^2 \mathbf{x}_i \mathbf{x}_i' \right) (\mathbf{X}'\mathbf{X})^{-1},$$

o chamado estimador “sanduíche” — duas fatias de $(\mathbf{X}'\mathbf{X})^{-1}$ com o recheio $\sum \hat{u}_i^2 \mathbf{x}_i \mathbf{x}_i'$ no meio.

```
comparacao <- cbind(homocedastico = summary(reg)$coefficients[, 2],
                    robusto_HC1   = ep_robusto(reg))
round(comparacao, 4)
```

	homocedastico	robusto_HC1
(Intercept)	9.3991	8.9701
STR	0.4762	0.4587

```
round(c(dif_pct_intercepto = 100 * (comparacao[1, 2] / comparacao[1, 1] - 1),
        dif_pct_STR        = 100 * (comparacao[2, 2] / comparacao[2, 1] - 1)), 2)
```

	dif_pct_intercepto	dif_pct_STR
	-4.56	-3.67

Os dois erros-padrão **diferem** — o robusto é cerca de 4% menor para o coeficiente de *STR*. Por quê?

A fórmula homocedástica supõe $\text{Var}(u_i | X_i) = \sigma_u^2$, constante para todo X_i , e sob essa hipótese a variância se reduz a $\text{SER}^2 / \sum (X_i - \bar{X})^2$. A fórmula robusta não supõe nada: ela estima $\text{Var}[(X_i - \mu_X)u_i]$ diretamente, usando cada $\hat{u}_i^2$ como estimativa local da variância do erro naquele ponto. Se a homocedasticidade vale, as duas convergem para o mesmo valor e a diferença observada em amostras finitas é ruído — que é exatamente o caso aqui, já que **os dados foram simulados com erro homocedástico**. Os 4% de diferença são erro amostral na estimação do “recheio” do sanduíche.

A assimetria de risco, porém, é clara: se a homocedasticidade **falha** — e ela falha com frequência em dados econômicos, onde a dispersão do erro costuma crescer com o nível da variável —, o erro-padrão homocedástico é **inconsistente** e a inferência baseada nele é inválida, podendo errar em qualquer direção. O robusto é válido nos dois casos. Daí a regra prática, hoje universal em economia aplicada: **use sempre erros-padrão robustos**, e é por isso que o professor escreve `, robust` em todo comando `regress`.

A tabela completa, com estatísticas *t* e intervalos de confiança — cuja teoria é o assunto da Aula 4, mas cujo cálculo já podemos fazer:

```
round(tabela_reg(reg, robusto = TRUE), 4)
```

	coef	ep	t	p	ic_inf	ic_sup
(Intercept)	698.8918	8.9701	77.9138	0	681.2597	716.5238
STR	-2.2682	0.4587	-4.9446	0	-3.1699	-1.3665

Compare com o output do STATA reproduzido acima: mesma estrutura, magnitudes compatíveis, e o intervalo de confiança para β_1 excluindo o zero com folga.

4.9.7 (f) A distribuição amostral de $\hat{\beta}_1$ por simulação

Esta é a figura central do capítulo. A teoria afirma que $\hat{\beta}_1$ é uma variável aleatória, não viesada, aproximadamente Normal em amostras grandes, com variância dada pela fórmula da caixa. Vamos ver isso acontecer.

O experimento é o que a definição de distribuição amostral literalmente descreve: repetir a amostragem muitas vezes, guardando a estimativa de cada amostra. Aqui podemos fazê-lo porque conhecemos o processo gerador — geramos 5.000 amostras de $n = 420$ do mesmo modelo, com $\beta_1 = -2,28$ verdadeiro, e coletamos os 5.000 valores de $\hat{\beta}_1$.

```
set.seed(4231)
M <- 5000
b1_sim <- replicate(M, {
  Xs <- rnorm(n_d, mean = 19.64, sd = 1.89)
  Ys <- beta0 + beta1 * Xs + rnorm(n_d, mean = 0, sd = sigma_u)
  sum((Xs - mean(Xs)) * (Ys - mean(Ys))) / sum((Xs - mean(Xs))^2)
})

varX_pop <- 1.89^2
var_teorica <- (varX_pop * sigma_u^2) / (n_d * varX_pop^2) # = sigma_u^2 / (n Var(X))

round(c(media_das_estimativas = mean(b1_sim),
        beta1_verdadeiro      = beta1,
        vies_empirico         = mean(b1_sim) - beta1,
        dp_empirico           = sd(b1_sim),
        dp_teorico            = sqrt(var_teorica)), 5)
```

media_das_estimativas	beta1_verdadeiro	vies_empirico
-2.28660	-2.28000	-0.00660
dp_empirico	dp_teorico	
0.47789	0.47891	

Os dois resultados centrais do capítulo aparecem nesses cinco números.

Não-viés. A média das 5.000 estimativas é $-2,2866$ contra o valor verdadeiro $-2,28$: um viés empírico de $-0,0066$, que é cerca de $1/70$ do desvio-padrão do estimador e perfeitamente compatível com o erro de Monte Carlo (o erro-padrão da média de 5.000 réplicas é $0,478/\sqrt{5000} \approx 0,0068$). $E(\hat{\beta}_1) = \beta_1$, verificado.

A fórmula da variância. O desvio-padrão empírico das 5.000 estimativas é 0,4779; a fórmula teórica $\sqrt{\sigma_u^2/[n\text{Var}(X)]}$ prevê 0,4789. Concordância na terceira casa decimal. Esse número também explica, retrospectivamente, a diferença entre a estimativa da seção (a), $-2,268$, e o valor verdadeiro $-2,28$: uma discrepância de 0,012, ou 0,025 desvio-padrão. Ruído amostral rotineiro.

```
d_sim <- data.frame(b1 = b1_sim)
ggplot(d_sim, aes(b1)) +
  geom_histogram(aes(y = after_stat(density)), bins = 50,
    fill = "azul", colour = "white", alpha = 0.75, linewidth = 0.2) +
  stat_function(fun = dnorm,
    args = list(mean = beta1, sd = sqrt(var_teorica)),
    colour = "vermelha", linewidth = 0.9) +
  geom_vline(xintercept = beta1, colour = "cinza", linetype = "dashed") +
  labs(x = "estimativas de beta1 nas 5.000 amostras", y = "densidade")
```




Figura 5: Distribuição amostral de $\hat{\beta}_1$: histograma das 5.000 estimativas obtidas por reamostragem do mesmo processo gerador ($n = 420$ em cada réplica). A curva vermelha é a densidade $\mathcal{N}(\beta_1, \sigma_{\hat{\beta}_1}^2)$ prevista pela teoria, com variância dada pela fórmula de Stock e Watson; a linha cinza tracejada marca o verdadeiro $\beta_1 = -2,28$. O histograma é simétrico, tem forma de sino e se equilibra sobre o valor verdadeiro — não-viés e normalidade assintótica, vistos por simulação.

A figura é a tradução gráfica das duas propriedades. O histograma tem **forma de sino** — apesar de $\hat{\beta}_1$ ser uma razão de somas, objeto sem nenhuma razão óbvia para ser Normal — e a curva teórica se sobrepõe a ele quase perfeitamente. É o Teorema Central do Limite em ação, operando sobre o numerador $\frac{1}{n} \sum (X_i - \bar{X})u_i$. E o histograma **se equilibra sobre a linha tracejada**, que marca o β_1 verdadeiro: é o não-viés.

Vale notar o que a figura torna palpável. Em uma aplicação real observamos **um** ponto desse histograma — uma amostra, uma estimativa — e nunca saberemos qual. O erro-padrão é nossa

estimativa da largura dessa distribuição a partir daquele único ponto, e é isso que permite dizer algo sobre a distância provável entre a estimativa e o alvo. Toda a inferência da Aula 4 é construída sobre essa ideia.

Finalmente, os três determinantes da precisão. A tabela varia n e o desvio-padrão de X , mantendo σ_u fixo, e reporta $SD(\hat{\beta}_1) = \sigma_u / [\sqrt{n} \cdot sd(X)]$:

```
grade <- expand.grid(n = c(100, 420, 2000), sd_X = c(0.9, 1.89, 4))
grade$dp_beta1 <- with(grade, sigma_u / (sqrt(n) * sd_X))
round(grade[order(grade$sd_X, grade$n), ], 4)
```

	n	sd_X	dp_beta1
1	100	0.90	2.0611
2	420	0.90	1.0057
3	2000	0.90	0.4609
4	100	1.89	0.9815
5	420	1.89	0.4789
6	2000	1.89	0.2195
7	100	4.00	0.4638
8	420	4.00	0.2263
9	2000	4.00	0.1037

Leia a tabela em duas direções. **Descendo** dentro de cada bloco de `sd_X`: multiplicar n por 20 (de 100 para 2000) divide o erro-padrão por $\sqrt{20} \approx 4,5$. **Comparando blocos** com o mesmo n : quadruplicar a dispersão do regressor (de 0,9 para 4) divide o erro-padrão por 4 — efeito **proporcional**, mais barato que aumentar a amostra. É o argumento econométrico a favor de desenhos que gerem **variação no regressor**, e a razão pela qual um experimento com forte contraste entre tratamento e controle é mais informativo que um com contraste tênue, ainda que ambos tenham a mesma amostra.

4.9.8 (g) O que uma única observação extrema pode fazer

Para fechar, uma ilustração da Hipótese 3. Geramos 40 observações bem comportadas de uma relação com inclinação 1,2 e acrescentamos **uma** observação extrema.

```
set.seed(7)
n_o <- 40
Xo <- rnorm(n_o, mean = 10, sd = 2)
Yo <- 5 + 1.2 * Xo + rnorm(n_o, mean = 0, sd = 1.2)
d_lim <- data.frame(X = c(Xo, 20), Y = c(Yo, 2)) # a ultima linha e o valor extremo

m_sem <- lm(Y ~ X, data = d_lim[1:n_o, ])
m_com <- lm(Y ~ X, data = d_lim)
round(rbind(sem_o_extremo = coef(m_sem),
            com_o_extremo = coef(m_com)), 4)
```

	(Intercept)	X
sem_o_extremo	3.4695	1.3591
com_o_extremo	13.8089	0.3344

O coeficiente angular cai de 1,36 para 0,33 — uma redução de 75% — por causa de **uma** observação em 41. O sinal foi preservado por sorte; com um valor extremo um pouco mais distante, teria invertido. É a ilustração exata do argumento do professor: o MQO minimiza uma soma de **quadrados**, e uma observação distante contribui com o quadrado de sua distância, dominando o critério. Nenhum teste estatístico substitui, aqui, o hábito de olhar para os dados.

4.10 Exercícios

- Álgebra do estimador.** Considere a regressão $Y_i = \beta_0 + \beta_1 X_i + u_i$ estimada por MQO. (a) Mostre que a reta de MQO passa necessariamente por $(\bar{X}, \bar{Y})$. (b) Mostre que $\sum_i \hat{u}_i \hat{Y}_i = 0$, isto é, os resíduos são ortogonais também aos valores ajustados. (c) Suponha que se estime a regressão **sem intercepto**, $\min_{b_1} \sum (Y_i - b_1 X_i)^2$. Obtenha a CPO e mostre que $\tilde{\beta}_1 = \sum X_i Y_i / \sum X_i^2$. (d) Nesse caso, ainda vale $\sum \hat{u}_i = 0$? O que isso implica para a validade da decomposição $TSS = ESS + SSR$ e para a interpretação do R^2 ?
- Mudança de unidades.** A regressão $\widehat{TestScore} = 698,9 - 2,28 STR$ foi estimada com $TestScore$ em pontos. (a) Se o teste for reescalado para uma nota de 0 a 10 (dividindo por 80), o que acontece com $\hat{\beta}_0$, $\hat{\beta}_1$, R^2 e SER? (b) E se em vez disso somarmos 50 pontos a todas as notas? (c) E se STR for medido em “professores por 100 alunos” em lugar de “alunos por professor” — a transformação é linear? (d) Enuncie a regra geral: sob $Y^* = a + bY$ e $X^* = c + dX$, como se transformam os quatro objetos? Qual deles é **invariante** e por quê?
- A decomposição, à mão.** Uma amostra de $n = 5$ observações produziu: $\sum (Y_i - \bar{Y})^2 = 200$, $\sum \hat{u}_i^2 = 50$. (a) Calcule ESS , R^2 e SER .
(b) Qual é a correlação amostral entre X e Y , em valor absoluto? (c) Sabendo que $s_X = 2$ e que a relação é positiva, obtenha $\hat{\beta}_1$. (d) Por que a informação dada não permite recuperar $\hat{\beta}_0$?
- A hipótese de média condicional zero.** Em cada caso abaixo, discuta se $\mathbb{E}(u_i | X_i) = 0$ é plausível, identificando o fator omitido relevante e o **sinal** provável do viés: (a) regressão do salário sobre anos de escolaridade; (b) regressão da taxa de criminalidade municipal sobre o número de policiais por habitante; (c) regressão do desempenho de um fundo sobre a taxa de administração que ele cobra; (d) regressão do peso ao nascer sobre o número de consultas pré-natais. Em qual deles você imaginaria um experimento aleatorizado viável, e o que ele aleatorizaria?
- Correlação zero não basta.** Seja $X \sim \mathcal{N}(0, 1)$ e $u = X^2 - 1$. (a) Verifique que $\mathbb{E}(u) = 0$ e $\text{Cov}(u, X) = 0$. (b) Verifique que $\mathbb{E}(u | X) \neq 0$. (c) Gere esses dados em R com $n = 10.000$, rode $Y = 1 + 2X + u$ contra X e verifique que $\hat{\beta}_1$ é próximo de 2 — isto é, o estimador **não** é viesado neste caso particular. (d) Explique por quê: qual condição, mais fraca que $\mathbb{E}(u | X) = 0$, é suficiente para o não-viés assintótico de $\hat{\beta}_1$? (e) Construa agora um exemplo com u correlacionado com X e mostre, por simulação, que $\hat{\beta}_1$ passa a ser viesado.

6. **O beta do CAPM.** Considere a regressão $R_{it} - R_{ft} = \alpha_i + \beta_i(R_{mt} - R_{ft}) + u_{it}$. (a) Mostre que, se o CAPM vale exatamente, $\alpha_i = 0$. (b) Interprete o R^2 dessa regressão em termos da decomposição do risco entre sistemático e idiossincrático. (c) Um analista afirma que, como o R^2 da regressão de uma ação foi de apenas 0,25, “o beta estimado não presta”. Avalie a afirmação, distinguindo entre o valor do R^2 e a precisão de $\hat{\beta}_i$. (d) Que propriedade da série de retornos torna a Hipótese 2 delicada aqui, e o que se costuma fazer a respeito?
7. **O R^2 e a causalidade.** (a) Construa um exemplo numérico (pode ser em R) de duas variáveis com $R^2 > 0,95$ e nenhuma relação causal entre elas. (b) Construa um exemplo de uma relação causal genuína com $R^2 < 0,05$. (c) Por que acrescentar um regressor **nunca** reduz o R^2 , mesmo que o regressor seja ruído puro? (d) Que estatística tenta corrigir esse problema, e por que ela também não resolve a questão causal?
8. **Simulação.** Adapte o código da seção (f) do laboratório. (a) Reduza n para 20 e refaça o histograma: a aproximação Normal ainda é boa? (b) Mantenha $n = 20$ mas gere os erros de uma distribuição t de Student com 3 graus de liberdade (que tem quarto momento **infinito**, violando a Hipótese 3): o que acontece com as caudas da distribuição amostral? (c) Volte à Normal e faça $\text{sd}(X)$ variar em $\{0,5, 1, 2, 4\}$, verificando que $\text{SD}(\hat{\beta}_1)$ cai proporcionalmente a $1/\text{sd}(X)$.
- (d) Introduza heterocedasticidade fazendo $\text{Var}(u_i | X_i) = (0,5 X_i)^2$ e compare, ao longo das réplicas, o desvio-padrão empírico de $\hat{\beta}_1$ com a média dos erros-padrão homocedásticos e a média dos robustos. Qual dos dois acerta?

4.11 Lista de Exercícios 1

Sobre esta seção

Reproduzo aqui a **Lista 1** da disciplina (Prof. Marcelo Mello; monitor: Matheus Porto), cujas questões são os exercícios 4.2 a 4.14 de Stock e Watson (2020) e cobrem exatamente o conteúdo deste capítulo. O gabarito vem logo em seguida, com as resoluções desenvolvidas — a recomendação de sempre é tentar cada questão antes de consultá-lo.

Questão 1 (exercício 4.2). Suponha que uma amostra aleatória de 100 homens de vinte anos seja selecionada de uma população e que a altura e o peso desses homens sejam registrados. Uma regressão do peso sobre a altura produz

$$\widehat{Weight} = -99,41 + 3,94 \cdot Height, \quad (2,15) \quad (0,31)$$

com $R^2 = 0,81$ e $\text{SER} = 10,2$, onde $Weight$ é medido em libras e $Height$ em polegadas (erros-padrão entre parênteses).

- Qual é a previsão da regressão para o peso de alguém com 70 polegadas de altura? E com 65 polegadas? E com 74 polegadas?
- Um homem tem um estirão tardio e cresce 1,5 polegada ao longo de um ano. Qual é a previsão da regressão para o aumento do peso desse homem?

- c. Suponha que, em vez de medir peso e altura em libras e polegadas, essas variáveis sejam medidas em quilogramas e centímetros. Quais são as estimativas da nova regressão em centímetros-quilogramas? (Dê todos os resultados: coeficientes estimados, erros-padrão, R^2 e SER.)

Dica: são úteis as fórmulas

$$SE(\hat{\beta}_0) = \sqrt{\frac{\left(\frac{1}{n} \sum_{i=1}^n X_i^2\right) s_u^2}{\sum_{i=1}^n (X_i - \bar{X})^2}} \quad \text{e} \quad SE(\hat{\beta}_1) = \sqrt{\frac{s_u^2}{\sum_{i=1}^n (X_i - \bar{X})^2}}.$$

Questão 2 (exercício 4.3). Uma regressão dos rendimentos semanais médios (AWE , em dólares) sobre a idade (em anos), usando uma amostra aleatória de trabalhadores em tempo integral com nível superior, produz

$$\widehat{AWE} = 696,7 + 9,6 \cdot Age, \quad R^2 = 0,023, \quad SER = 624,1.$$

- Explique o que significam os valores 696,7 e 9,6.
- O erro-padrão da regressão (SER) é 624,1. Quais são suas unidades de medida? (Dólares? Anos? Ou o SER é adimensional?)
- O R^2 da regressão é 0,023. Quais são as unidades de medida do R^2 ?
- Qual é a previsão da regressão para os rendimentos de um trabalhador de 25 anos? E de um de 45 anos?
- A regressão dará previsões confiáveis para um trabalhador de 99 anos? Por quê?
- A idade média nesta amostra é 41,6 anos. Qual é o valor médio de AWE na amostra?

Questão 3 (exercício 4.6). Mostre que a primeira hipótese de MQO, $\mathbb{E}(u_i | X_i) = 0$, implica $\mathbb{E}(Y_i | X_i) = \beta_0 + \beta_1 X_i$.

Questão 4 (exercício 4.7). Mostre que $\hat{\beta}_0$ é um estimador não viesado de β_0 . (*Dica:* use o fato de que $\hat{\beta}_1$ é não viesado.)

Questão 5 (exercício 4.9).

- Uma regressão linear produz $\hat{\beta}_1 = 0$. Mostre que $R^2 = 0$.
- Uma regressão linear produz $R^2 = 0$. Isso implica que $\hat{\beta}_1 = 0$?

Questão 6 (exercício 4.12).

- Mostre que o R^2 da regressão de Y sobre X é o quadrado da correlação amostral entre X e Y , isto é, mostre que $R^2 = r_{XY}^2$.
- Mostre que o R^2 da regressão de Y sobre X é o mesmo R^2 da regressão de X sobre Y .
- Mostre que $\hat{\beta}_1 = r_{XY}(s_Y/s_X)$, onde r_{XY} é a correlação amostral entre X e Y , e s_Y e s_X são os desvios-padrão amostrais de Y e X .

Questão 7 (exercício 4.14). Mostre que a reta de regressão amostral passa pelo ponto $(\bar{X}, \bar{Y})$.

4.11.1 Gabarito da Lista 1

Questão 1. Regressão do peso sobre a altura, $n = 100$.

a. Basta avaliar a reta ajustada em cada valor:

- $Height = 70$: $-99,41 + 3,94 \times 70 = -99,41 + 275,80 = 176,39$ libras.
- $Height = 65$: $-99,41 + 3,94 \times 65 = -99,41 + 256,10 = 156,69$ libras.
- $Height = 74$: $-99,41 + 3,94 \times 74 = -99,41 + 291,56 = 192,15$ libras.

b. O efeito predito de uma variação ΔX é $\hat{\beta}_1 \Delta X$, e não depende do nível de partida — é a consequência direta da linearidade:

$$\Delta \widehat{Weight} = 3,94 \times 1,5 = 5,91 \text{ libras.}$$

Vale registrar a ressalva substantiva: a regressão foi estimada em uma **seção transversal** de homens diferentes, e o item pergunta sobre a mudança em **um mesmo homem ao longo do tempo**. Que o coeficiente transversal descreva a trajetória individual é uma extrapolação, não um resultado da estimação.

c. Este é o exercício de mudança de unidades, e o método geral é o que importa. As conversões são 1 polegada = 2,54 cm e 1 libra = 0,4536 kg, de modo que as novas variáveis são

$$Y^* = 0,4536 Y \quad (\text{kg}), \quad X^* = 2,54 X \quad (\text{cm}).$$

Trata-se de transformações lineares **sem constante aditiva**, com fatores $b = 0,4536$ e $d = 2,54$. Aplicando a regra geral $Y^* = bY$, $X^* = dX$:

Inclinação. Como $\hat{\beta}_1 = s_{XY}/s_X^2$ e a covariância escala por bd enquanto a variância de X escala por d^2 :

$$\hat{\beta}_1^* = \frac{b}{d} \hat{\beta}_1 = \frac{0,4536}{2,54} \times 3,94 = 0,17858 \times 3,94 = 0,7036 \approx 0,70 \text{ kg/cm.}$$

Intercepto. De $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$, com $\bar{Y}^* = b\bar{Y}$ e $\bar{X}^* = d\bar{X}$:

$$\hat{\beta}_0^* = b\bar{Y} - \frac{b}{d} \hat{\beta}_1 \cdot d\bar{X} = b(\bar{Y} - \hat{\beta}_1 \bar{X}) = b\hat{\beta}_0 = 0,4536 \times (-99,41) = -45,09 \text{ kg.}$$

Erros-padrão. As fórmulas da dica tornam a conta imediata. Os resíduos escalam como Y , de modo que s_u^2 escala por b^2 ; e $\sum (X_i - \bar{X})^2$ escala por d^2 . Logo

$$SE(\hat{\beta}_1^*) = \sqrt{\frac{b^2 s_u^2}{d^2 \sum (X_i - \bar{X})^2}} = \frac{b}{d} SE(\hat{\beta}_1) = 0,17858 \times 0,31 = 0,0554 \approx 0,055.$$

Para o intercepto, o fator $\frac{1}{n} \sum X_i^{*2} = d^2 \cdot \frac{1}{n} \sum X_i^2$ cancela o d^2 do denominador, restando apenas o b :

$$SE(\hat{\beta}_0^*) = b SE(\hat{\beta}_0) = 0,4536 \times 2,15 = 0,9752 \approx 0,98.$$

Note a coerência interna: os erros-padrão escalam **exatamente como os coeficientes correspondentes**, e é por isso que as estatísticas t são invariantes a mudança de unidades —

como têm de ser, já que a conclusão de um teste não pode depender de medirmos altura em polegadas ou em centímetros.

SER. Tem as unidades de Y : $SER^* = b \cdot SER = 0,4536 \times 10,2 = 4,63 \text{ kg}$.

R^2 . **Invariante:** $R^2 = 0,81$, exatamente como antes. É uma razão entre somas de quadrados nas mesmas unidades, e todos os fatores de escala se cancelam. Equivalentemente, $R^2 = r_{XY}^2$ e a correlação é adimensional.

A regressão em unidades métricas é, portanto,

$$\widehat{Weight}^{\text{kg}} = -45,09 + 0,70 \cdot Height^{\text{cm}}, \quad (0,98) \quad (0,055)$$

com $R^2 = 0,81$ e $SER = 4,63$.

Questão 2. Regressão de AWE sobre a idade.

- 696,7** é o intercepto: o valor predito de AWE quando $Age = 0$. Como recém-nascidos não têm rendimentos semanais e a amostra é de trabalhadores adultos, o número **não tem interpretação substantiva** — é uma extrapolação para muito fora do suporte dos dados, e sua função é apenas posicionar a reta na altura correta na faixa observada. **9,6** é a inclinação: dois trabalhadores cuja idade difere em um ano têm rendimentos semanais que diferem, em média, em US\$ 9,60. É uma associação, não um efeito causal — envelhecer não *causa* rendimento; a idade é aqui um *proxy* para experiência, antiguidade e posição na carreira.
- O SER mede a dispersão típica dos resíduos, e resíduos têm as unidades de Y . Logo o SER está em **dólares** (por semana). O número 624,1 é grande em termos absolutos e diz que o erro típico de previsão dessa regressão é de mais de US\$ 600 por semana.
- O R^2 é **adimensional** — não tem unidade de medida. Ele é a razão ESS/TSS entre duas somas de quadrados medidas nas mesmas unidades (dólares ao quadrado), de modo que as unidades se cancelam. Por construção, $0 \leq R^2 \leq 1$.
- Avaliando a reta:
 - 25 anos: $696,7 + 9,6 \times 25 = 696,7 + 240 = \text{US\$ } 936,70$.
 - 45 anos: $696,7 + 9,6 \times 45 = 696,7 + 432 = \text{US\$ } 1.128,70$.
- Não.** A amostra é de trabalhadores com nível superior em uma faixa etária estreita, e 99 anos está muito fora do suporte dos dados. Duas razões distintas se somam. Primeiro, **extrapolação**: a linearidade foi estimada dentro de uma faixa e não há razão para supor que ela se estenda; é implausível que rendimentos cresçam linearmente a US\$ 9,60 por ano até os 99 anos. Segundo, **seleção**: a pouquíssima gente que ainda trabalha aos 99 anos é altamente não representativa. Este é o mesmo ponto feito no 1 a respeito do intercepto: a reta é um objeto local, válido onde há dados.
- Aqui usa-se a propriedade demonstrada na Questão 7: a reta de MQO passa por $(\bar{X}, \bar{Y})$. Logo

$$\overline{AWE} = 696,7 + 9,6 \times 41,6 = 696,7 + 399,36 = \text{US\$ } 1.096,06.$$

Repare no que isso significa: as estatísticas reportadas de uma regressão permitem **recuperar a média amostral de Y** sem acesso aos microdados.

Questão 3. Queremos mostrar que $\mathbb{E}(u_i | X_i) = 0 \Rightarrow \mathbb{E}(Y_i | X_i) = \beta_0 + \beta_1 X_i$. A demonstração é uma aplicação direta da linearidade da esperança condicional (vista no Seção 3). Partindo do modelo $Y_i = \beta_0 + \beta_1 X_i + u_i$ e condicionando em X_i :

$$\mathbb{E}(Y_i | X_i) = \mathbb{E}(\beta_0 + \beta_1 X_i + u_i | X_i) = \mathbb{E}(\beta_0 | X_i) + \mathbb{E}(\beta_1 X_i | X_i) + \mathbb{E}(u_i | X_i).$$

Tratamos os três termos. O primeiro é uma constante: $\mathbb{E}(\beta_0 | X_i) = \beta_0$. No segundo, **dado** X_i , a quantidade $\beta_1 X_i$ é conhecida e sai da esperança: $\mathbb{E}(\beta_1 X_i | X_i) = \beta_1 X_i$. O terceiro é zero **por hipótese**. Portanto

$$\boxed{\mathbb{E}(Y_i | X_i) = \beta_0 + \beta_1 X_i}$$

O resultado é o conteúdo preciso da afirmação, feita no 1, de que a **Função de Regressão Populacional é a média condicional de Y dado X** — e mostra que essa identificação depende inteiramente da Hipótese 1. Sem ela, a reta $\beta_0 + \beta_1 X$ continua existindo como objeto algébrico, mas deixa de ser a média condicional.

Questão 4. Queremos $\mathbb{E}(\hat{\beta}_0) = \beta_0$. Partimos da fórmula do estimador, $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$. Tomando médias no modelo verdadeiro,

$$\bar{Y} = \beta_0 + \beta_1 \bar{X} + \bar{u},$$

de modo que

$$\hat{\beta}_0 = \beta_0 + \beta_1 \bar{X} + \bar{u} - \hat{\beta}_1 \bar{X} = \beta_0 - (\hat{\beta}_1 - \beta_1) \bar{X} + \bar{u}.$$

Tomando a esperança **condicional** em $X_1, \dots, X_n$:

$$\mathbb{E}(\hat{\beta}_0 | X) = \beta_0 - \underbrace{\mathbb{E}(\hat{\beta}_1 - \beta_1 | X)}_{=0} \bar{X} + \underbrace{\mathbb{E}(\bar{u} | X)}_{=0} = \beta_0.$$

O primeiro termo é zero pela dica: $\hat{\beta}_1$ é condicionalmente não viesado, de modo que $\mathbb{E}(\hat{\beta}_1 | X) = \beta_1$. O segundo é zero porque $\mathbb{E}(\bar{u} | X) = \frac{1}{n} \sum_i \mathbb{E}(u_i | X_i) = 0$ pela Hipótese 1. Note que $\bar{X}$ pode sair da esperança precisamente porque estamos condicionando nos X .

Finalmente, pela lei das expectativas iteradas,

$$\boxed{\mathbb{E}(\hat{\beta}_0) = \mathbb{E}[\mathbb{E}(\hat{\beta}_0 | X)] = \mathbb{E}[\beta_0] = \beta_0}$$

Questão 5.

a. Se $\hat{\beta}_1 = 0$, então $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} = \bar{Y}$, e todos os valores ajustados são iguais:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i = \bar{Y} \quad \text{para todo } i.$$

Logo o ESS é identicamente nulo:

$$\text{ESS} = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 = \sum_{i=1}^n (\bar{Y} - \bar{Y})^2 = 0,$$

e portanto $R^2 = \text{ESS}/\text{TSS} = 0$. A leitura substantiva: se a inclinação é zero, a melhor previsão de Y que a regressão oferece é a própria média de Y , e nenhuma variação foi explicada.

- b. **Sim, implica** — no modelo de regressão simples **com intercepto**. Se $R^2 = 0$, então $ESS = 0$, ou seja, $\sum_i (\hat{Y}_i - \bar{Y})^2 = 0$. Uma soma de quadrados só é nula se cada parcela for nula, de modo que $\hat{Y}_i = \bar{Y}$ para todo i . Mas $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$, e para que isso seja constante em i é preciso que $\hat{\beta}_1 = 0$ (supondo, como sempre, que X tenha variação amostral — se todo X_i fosse igual, $\hat{\beta}_1$ nem estaria definido).

Alternativamente, e de modo mais direto, pelo item (a) da Questão 6: $R^2 = r_{XY}^2$, de modo que $R^2 = 0 \Leftrightarrow r_{XY} = 0 \Leftrightarrow s_{XY} = 0 \Leftrightarrow \hat{\beta}_1 = s_{XY}/s_X^2 = 0$.

 Uma advertência que o exercício convida a fazer

A equivalência $R^2 = 0 \Leftrightarrow \hat{\beta}_1 = 0$ é uma afirmação sobre **associação linear**, e nada mais. Ela **não** diz que X e Y são não relacionadas. O contraexemplo do Seção 3 — $Y = X^2 + \varepsilon$ com X simétrica em torno de zero — produz $R^2 \approx 0$ e $\hat{\beta}_1 \approx 0$ numa relação **determinística**. Regressão linear mede o que seu nome diz.

Questão 6.

- a. Partimos de $R^2 = ESS/TSS$ e usamos $\hat{Y}_i - \bar{Y} = \hat{\beta}_1(X_i - \bar{X})$, que segue de $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ e $\bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X}$ (Questão 7). Então

$$ESS = \sum_i (\hat{Y}_i - \bar{Y})^2 = \hat{\beta}_1^2 \sum_i (X_i - \bar{X})^2,$$

e substituindo $\hat{\beta}_1 = \frac{\sum_i (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_i (X_i - \bar{X})^2}$:

$$R^2 = \frac{\hat{\beta}_1^2 \sum_i (X_i - \bar{X})^2}{\sum_i (Y_i - \bar{Y})^2} = \frac{\left[\sum_i (X_i - \bar{X})(Y_i - \bar{Y}) \right]^2}{\left[\sum_i (X_i - \bar{X})^2 \right]^2} \cdot \frac{\sum_i (X_i - \bar{X})^2}{\sum_i (Y_i - \bar{Y})^2},$$

de modo que

$$R^2 = \frac{\left[\sum_i (X_i - \bar{X})(Y_i - \bar{Y}) \right]^2}{\sum_i (X_i - \bar{X})^2 \sum_i (Y_i - \bar{Y})^2} = \left(\frac{s_{XY}}{s_X s_Y} \right)^2 = r_{XY}^2$$

(O enunciado da lista escreve “ $R^2 = r_{XY}$ ”; trata-se de erro de digitação no original — o que se demonstra, e o que o próprio enunciado diz em palavras, é que o R^2 é o **quadrado** da correlação amostral.)

- b. Imediato do item (a). A expressão final de R^2 é **simétrica** em X e Y : o numerador é o quadrado da covariância amostral, e o denominador é o produto das duas somas de quadrados. Trocar os papéis de X e Y não altera nenhum dos dois. Logo o R^2 da regressão de Y sobre X é igual ao da regressão de X sobre Y .

 O que essa simetria não significa

O R^2 é simétrico, mas as **retas não são**. Como registrado no 1, o MQO minimiza distâncias **verticais**, o que quebra a simetria entre as variáveis: a inclinação da regressão

de Y sobre X é $r_{XY}s_Y/s_X$, enquanto a da regressão de X sobre Y é $r_{XY}s_X/s_Y$. Seu produto é $r_{XY}^2 \leq 1$, e as duas retas só coincidem quando $|r_{XY}| = 1$. A medida de aderência não distingue as duas regressões; a interpretação causal as distingue inteiramente.

c. Partindo da fórmula do estimador e multiplicando e dividindo por s_Y :

$$\hat{\beta}_1 = \frac{s_{XY}}{s_X^2} = \frac{s_{XY}}{s_X s_Y} \cdot \frac{s_Y}{s_X} \implies \boxed{\hat{\beta}_1 = r_{XY} \frac{s_Y}{s_X}}$$

A decomposição é instrutiva. Ela separa o coeficiente em duas partes com naturezas distintas: r_{XY} , adimensional, mede a **força e o sinal** da associação linear; s_Y/s_X é um fator de **escala**, que converte a associação para as unidades do problema. É precisamente por isso que a mudança de unidades da Questão 1(c) afeta $\hat{\beta}_1$ mas não o R^2 — a mudança age apenas no segundo fator.

Questão 7. A demonstração cabe em uma linha, e decorre da condição de primeira ordem em relação ao intercepto. Vimos no 1 que

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Avaliando a reta ajustada no ponto $X = \bar{X}$:

$$\hat{Y}|_{X=\bar{X}} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X} = (\bar{Y} - \hat{\beta}_1 \bar{X}) + \hat{\beta}_1 \bar{X} = \bar{Y}.$$

A reta de MQO passa por $(\bar{X}, \bar{Y})$

Equivalentemente, e talvez de modo mais transparente: a CPO do intercepto é $\sum_i \hat{u}_i = 0$; dividindo por n , $\bar{\hat{u}} = 0$, isto é, $\bar{Y} - \hat{\beta}_0 - \hat{\beta}_1 \bar{X} = 0$, que é a mesma equação.

Este é um resultado de uso frequente — a Questão 2(f) desta mesma lista o utiliza para recuperar $\bar{Y}$ a partir dos coeficientes. Vale notar que ele **depende da presença do intercepto**: numa regressão forçada pela origem, $\sum \hat{u}_i \neq 0$ em geral e a reta não passa por $(\bar{X}, \bar{Y})$.

5 Inferência na Regressão com um Regressor

O 1 terminou com uma dívida. Diante da saída do STATA que o professor projeta desde a Aula 3, sabíamos ler quase tudo — **Coef.** são $\hat{\beta}_0$ e $\hat{\beta}_1$, **R-squared** é ESS/TSS, **Root MSE** é o SER —, mas paramos na coluna **Std. Err.** e em tudo o que dela decorre: as estatísticas t , os p -valores, os intervalos de confiança. Este capítulo paga essa dívida.

A razão de a coluna existir já está estabelecida: $\hat{\beta}_1$ é uma **variável aleatória**, porque é calculado a partir de uma amostra aleatória. Se tivéssemos sorteado outros 420 distritos, teríamos obtido outro número. A pergunta que organiza o capítulo é o que fazer com essa incerteza:

Dada uma estimativa $\hat{\beta}_1 = -2,28$ obtida em *uma* amostra, o que podemos afirmar sobre o parâmetro populacional β_1 , que não observamos?

Há duas maneiras de responder, e elas são duas faces do mesmo objeto. A primeira é **testar hipóteses**: confrontar um valor conjecturado para β_1 com a evidência amostral e decidir se ela o contradiz. A segunda é construir um **intervalo de confiança**: exibir o conjunto de valores de β_1 que a amostra *não* rejeita. Ao final da Seção 5 veremos que as duas coisas são literalmente equivalentes.

O capítulo corresponde à Aula 4 da disciplina e fecha o tratamento do Capítulo 4 de Stock e Watson (2020), avançando sobre o Capítulo 5. Sua estrutura é a do professor: uma revisão de testes de hipótese em termos gerais; a aplicação aos coeficientes da regressão; os intervalos de confiança; o caso em que o regressor é **binário** — que revela a regressão como uma comparação de médias; a **heterocedasticidade** e suas consequências para a inferência; e, por fim, o **Teorema de Gauss-Markov**, apresentado com o ceticismo que o professor faz questão de registrar já no título do slide, escrito no passado.

5.1 Revisão de testes de hipótese

Antes de tratar dos coeficientes da regressão, o professor recupera a lógica do teste de hipóteses em termos gerais, com um parâmetro populacional genérico θ . Vale segui-lo: a estrutura é a mesma que reaparecerá aplicada a β_1 , e é mais fácil vê-la primeiro sem a bagagem da regressão.

A informação da amostra pode ser usada para avaliar a validade de uma **conjectura** sobre um parâmetro populacional. Formula-se uma hipótese sobre θ , que se considera válida **a menos que evidência contrária seja produzida** — essa é a **hipótese nula**, H_0 . Se ela não é válida, uma **hipótese alternativa** H_1 deve ser verdadeira.

A hipótese nula pode ser **simples**, quando fixa um único valor,

$$H_0 : \theta = \theta_0,$$

ou **composta**, quando especifica uma faixa de valores:

$$H_0 : \theta \geq 20 \quad \text{contra} \quad H_1 : \theta < 20.$$

Especificadas as hipóteses e coletada a informação amostral, é preciso decidir. Há duas possibilidades — **aceitar** H_0 ou **rejeitá-la** em favor de H_1 — e a decisão exige uma **regra** baseada na evidência amostral.

Sobre o verbo “aceitar”

O professor usa “aceitar a hipótese nula”, e mantenho o vocabulário dele. Vale registrar, porém, a razão pela qual boa parte da literatura prefere “**não rejeitar**”: um teste que não rejeita H_0 não produziu evidência de que H_0 seja verdadeira; produziu apenas evidência insuficiente para descartá-la. A assimetria é a mesma do júri, exemplo que o próprio professor usa adiante — absolver não é declarar inocente, é não ter provado a culpa. Essa distinção volta com força na discussão do **poder do teste**, logo abaixo: quando o poder é baixo, “não rejeitar” é quase automático e, portanto, quase não informa.

5.1.1 Os dois tipos de erro

Como a decisão se baseia em uma amostra, ela pode errar — e há duas maneiras de errar, que não são simétricas. O professor as organiza na tabela de probabilidades condicionais:

	H_0 é verdadeira	H_0 é falsa
Aceitar H_0	Decisão correta ($1 - \alpha$)	Erro Tipo II (β)
Rejeitar H_0	Erro Tipo I (α)	Decisão correta ($1 - \beta$)

O **erro do Tipo I** é rejeitar uma hipótese nula verdadeira. Sua probabilidade é o **nível de significância** do teste:

$$\alpha = \Pr(\text{Rejeitar } H_0 \mid H_0 \text{ é verdadeira})$$

O **erro do Tipo II** é aceitar uma hipótese nula falsa:

$$\beta = \Pr(\text{Aceitar } H_0 \mid H_0 \text{ é falsa})$$

Notação — dois β diferentes

O símbolo β designa, neste capítulo, duas coisas distintas: a probabilidade do erro do Tipo II, na notação clássica de testes, e os **coeficientes da regressão** β_0, β_1 . É uma colisão de notação herdada da literatura, e o contexto sempre resolve — β sozinho, nesta seção, é probabilidade de erro; com índice, é coeficiente.

O exemplo do teste de gravidez. Testes de gravidez têm como hipótese nula “não há gravidez” (mais precisamente, que o nível do hormônio hCG está no limite basal normal). Então o erro do Tipo I,

$$\Pr(\text{Rejeita ausência de gravidez} \mid \text{não há gravidez}),$$

é o **falso positivo**, e o erro do Tipo II é o **falso negativo**. Vale notar como a identificação de qual erro é qual depende inteiramente de como se escolheu a nula: trocada a nula, trocam-se os rótulos.

O exemplo do júri. No sistema judicial, a hipótese nula é a **presunção de inocência**, e o critério de rejeição é que as evidências estejam “além de qualquer dúvida razoável” (*beyond reasonable doubt*). Nesse caso,

$$\alpha = \Pr(\text{Condenar um inocente} \mid \text{Inocente}), \quad \beta = \Pr(\text{Aceitar inocência} \mid \text{Culpado}).$$

Os erros são **assimétricos em suas implicações**: é melhor absolver um culpado do que condenar um inocente. Por isso impõe-se um α pequeno — 1% ou menos, no espírito da dúvida razoável.

5.1.2 O trade-off entre os dois erros

Aqui está o ponto que o professor faz questão de desenvolver. Dado o tamanho da amostra, uma vez escolhido α , o valor de β **está dado**. Não é possível reduzir os dois ao mesmo tempo.

A intuição é direta e vale reproduzi-la. Imagine que se deseje $\alpha = 0$, isto é, nunca condenar um inocente. A única forma de garantir isso é **nunca rejeitar** H_0 — absolver sempre, qualquer que seja a evidência. Mas então $\beta = 100\%$: todo culpado é absolvido, e o teste é inútil.

$$\text{Dado } n, \text{ reduzir } \alpha \implies \text{aumentar } \beta$$

A única forma de reduzir **ambos** os erros é **aumentar o tamanho da amostra**. Mais informação desloca a fronteira inteira; sem mais informação, só se anda sobre ela.

5.1.3 O poder do teste

O complemento do erro do Tipo II tem nome próprio. O **poder** (ou potência) do teste é a probabilidade de rejeitar H_0 quando ela é de fato falsa:

$$\text{Poder} = 1 - \beta = \Pr(\text{Rejeitar } H_0 \mid H_0 \text{ é falsa})$$

O professor acrescenta um alerta que é de economia política da pesquisa, e não de estatística: testes com **baixo poder** aceitam a hipótese nula com frequência alta, o que **pode ser explorado pelo pesquisador interessado em aceitar** H_0 . Quem quer concluir que um efeito não existe tem, num teste de baixo poder, um aliado silencioso — basta usar uma amostra pequena e apresentar a não rejeição como se fosse evidência de nulidade. É a razão pela qual “não encontramos efeito significativo” é uma frase que só se pode avaliar sabendo qual efeito o desenho teria sido capaz de detectar.

5.1.4 Um exemplo completo: teste sobre a média populacional

Para fixar o procedimento, o professor faz o teste mais simples possível — sobre a média de uma população — antes de passar aos coeficientes da regressão.

Sabemos das Notas de Estatística que o estimador da média populacional é a média amostral $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$, e que, assumindo normalidade na população,

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1).$$

Considere o teste **unicaudal**

$$H_0 : \mu = 5 \quad \text{contra} \quad H_1 : \mu > 5,$$

com $\sigma = 0,1$, $n = 16$, $\alpha = 5\%$ e média amostral observada $\bar{x} = 5,038$. A regra de decisão é rejeitar H_0 se

$$\frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}} > z_\alpha, \quad \text{onde} \quad \Pr(Z > z_\alpha) = 0,05 \implies z_\alpha = 1,645.$$

O número $z_\alpha = 1,645$ é o **valor crítico**. Calculando a estatística de teste:

$$\frac{5,038 - 5}{0,1/\sqrt{16}} = \frac{0,038}{0,025} = 1,52.$$

Como $1,52 < 1,645$, a estatística está à esquerda do valor crítico, dentro da região de aceitação. **Conclusão:** com base na evidência amostral, não rejeitamos a possibilidade de a média populacional ser igual a 5.

Note que a estrutura tem quatro peças, e todas reaparecerão na regressão: (i) uma hipótese nula que fixa um valor; (ii) um estimador com distribuição amostral conhecida; (iii) uma **estatística de teste** que mede a distância entre a estimativa e o valor hipotético, em unidades de erro-padrão; e (iv) um valor crítico que define quão longe é longe demais.

5.2 Testando hipóteses sobre os coeficientes da regressão

Com a estrutura montada, a aplicação à regressão é quase imediata. Retomamos o exemplo da Aula 3,

$$\widehat{TestScore} = 698,9 - 2,28 \cdot STR,$$

e a pergunta empírica: o coeficiente de STR é **estatisticamente significativo**? Isto é, queremos testar

$$H_0 : \beta_1 = 0 \quad \text{contra} \quad H_1 : \beta_1 \neq 0,$$

onde a alternativa é **bicaudal** — nos interessa detectar desvios de zero em qualquer direção.

! Por que $\beta_1 = 0$ é a nula interessante

A nula $\beta_1 = 0$ é a hipótese de que X **não tem efeito sobre** Y — de que a PRF é horizontal e conhecer o tamanho da turma não altera em nada a previsão do desempenho. É a hipótese que o pesquisador em geral quer derrubar, e é por isso que o software a testa por padrão, imprimindo a coluna de t e de p -valores para essa nula específica.

Nada impede, porém, testar $H_0 : \beta_1 = \beta_{1,0}$ para qualquer outro valor conjecturado — e há contextos em que a nula relevante não é zero. No CAPM discutido no capítulo anterior, a hipótese teórica de interesse sobre o beta de uma ação é $H_0 : \beta_i = 1$ (a ação acompanha o mercado), e sobre o alfa é $H_0 : \alpha_i = 0$. A fórmula geral abaixo cobre todos esses casos; o software é que privilegia um deles.

5.2.1 A estatística t

Construímos a **estatística- t** exatamente como no teste sobre a média — a distância entre a estimativa e o valor hipotético, medida em erros-padrão:

$$t = \frac{\text{estimador} - \text{valor hipotético}}{\text{erro-padrão do estimador}} = \frac{\hat{\beta}_1 - \beta_{1,0}}{\text{SE}(\hat{\beta}_1)}$$

O denominador é o **erro-padrão** de $\hat{\beta}_1$: a raiz da estimativa da variância $\sigma_{\hat{\beta}_1}^2$ cuja fórmula fechamos no capítulo anterior. É a coluna **Std. Err.** do STATA, e agora sabemos para que ela serve.

A justificativa para comparar t com valores críticos da Normal está inteiramente contida no resultado de normalidade assintótica obtido no 1: sob as três hipóteses de MQO, $\hat{\beta}_1 \stackrel{a}{\sim} \mathcal{N}(\beta_1, \sigma_{\hat{\beta}_1}^2)$ em amostras grandes. Padronizando sob a nula, $t \stackrel{a}{\sim} \mathcal{N}(0, 1)$.

5.2.2 Aplicando ao exemplo

Retomamos a saída do STATA:

```
regress testscr str, robust
```

```
Regression with robust standard errors      Number of obs =      420
                                           F(   1,   418) =    19.26
                                           Prob > F       =    0.0000
                                           R-squared      =    0.0512
                                           Root MSE      =    18.581
```

```
-----+-----
               |               Robust
testscr |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-----+-----
```

str		-2.279808	.5194892	-4.39	0.000	-3.300945	-1.258671
_cons		698.933	10.36436	67.44	0.000	678.5602	719.3057

A estatística t do coeficiente de STR é

$$t = \frac{-2,28 - 0}{0,5195} = -4,39,$$

que é exatamente a coluna t da saída. O valor crítico para um teste bicaudal a 5% vem de

$$\Pr(-1,96 < Z < 1,96) = 0,95,$$

e como $-4,39$ está **fora** do intervalo $(-1,96; 1,96)$, **rejeitamos** H_0 . O efeito estimado do tamanho da turma sobre o desempenho é estatisticamente significativo ao nível de 5%.

i Significância estatística não é significância econômica

Rejeitar $H_0 : \beta_1 = 0$ diz que o efeito **não é zero**; não diz que ele é **grande**. São perguntas diferentes, e a segunda é a que interessa para política pública.

Aqui: reduzir STR em duas unidades eleva o $TestScore$ em 4,56 pontos. Como o desvio-padrão dos test scores na amostra é de cerca de 19 pontos, isso é aproximadamente **um quarto de desvio-padrão** — modesto, e comprado ao custo de contratar professores. Com n suficientemente grande, efeitos economicamente irrelevantes tornam-se estatisticamente significantes; a estatística t cresce com $\sqrt{n}$ enquanto a magnitude do efeito não muda. Reportar apenas estrelas de significância, sem discutir magnitudes, é um vício comum e um erro de leitura.

5.2.3 O valor-p

Na tabela de regressão aparece a coluna $P > |t|$. O **valor-p** é o menor nível de significância α ao qual se rejeita H_0 .

Voltemos ao teste sobre a média para ver de onde isso vem. Lá, a estatística era 1,52, o teste era unicaudal à direita, e escolhemos $\alpha = 5\%$; como 1,52 ficou abaixo do valor crítico $z_\alpha = 1,645$, não rejeitamos H_0 . Para *rejeitar*, teríamos precisado de um α grande o bastante para que o valor crítico caísse abaixo de 1,52 — isto é, um α de pelo menos

$$\Pr(Z > 1,52) = 0,0643.$$

Esse número, 6,43%, é o valor-p. Dele decorre a regra de decisão:

rejeita-se H_0 sempre que $\alpha \geq \text{valor-p}$; aceita-se H_0 sempre que $\alpha < \text{valor-p}$

No caso **bicaudal**, que é o da tabela de regressão, é preciso somar as duas caudas:

$$\text{valor-p} = \Pr(Z < -4,39) + \Pr(Z > 4,39),$$

e, por simetria da Normal,

$$\text{valor-p} = 2 \cdot F_Z(-|t|) = 2 \cdot F_Z(-4,39)$$

que é um número da ordem de 10^{-5} — impresso como 0.000 na saída do STATA. A vantagem do valor-p sobre a comparação com valor crítico é que ele **não exige fixar α de antemão**: reporta-se o valor-p e cada leitor aplica o seu próprio limiar.

5.3 Intervalos de confiança

Qualquer estimativa de β_1 contém, necessariamente, incerteza amostral — não podemos determinar o verdadeiro valor de β_1 a partir de uma amostra. O que podemos fazer é construir um **intervalo de confiança**, a partir da estimativa de MQO e do seu erro-padrão.

5.3.1 A definição geral

O professor começa pela definição geral de estimador intervalar, que vale a pena enunciar com cuidado porque a interpretação depende dela.

! Definição — estimador intervalar

Um **estimador intervalar** de um parâmetro populacional é uma regra para determinar, com base na informação amostral, um intervalo no qual é provável que o parâmetro populacional se situe.

Formalmente: seja θ o parâmetro a ser estimado. Se, a partir da informação amostral, podemos encontrar duas **variáveis aleatórias** $A < B$ tais que

$$\Pr(A < \theta < B) = 0,90,$$

então o intervalo entre A e B é um estimador intervalar de θ com **90% de confiança**.

O ponto crucial está em quem é aleatório: A e B são variáveis aleatórias, funções da amostra; θ é um número fixo e desconhecido. A probabilidade é sobre o **intervalo**, não sobre o parâmetro.

5.3.2 Construção: o caso da média

Vamos construir o intervalo para a média populacional μ , onde toda a álgebra fica visível. Sabemos que $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$ e, portanto, que

$$\Pr(-z_{\alpha/2} < Z < z_{\alpha/2}) = 1 - \alpha, \quad \text{por exemplo} \quad \Pr(-1,645 < Z < 1,645) = 0,90.$$

Substituindo Z e isolando μ no meio da desigualdade:

$$\Pr\left(-1,645 < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < 1,645\right) = 0,90$$

$$\Pr\left(\bar{X} - 1,645 \cdot \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + 1,645 \cdot \frac{\sigma}{\sqrt{n}}\right) = 0,90,$$

e, de forma mais geral,

$$\Pr\left(\bar{X} - z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

Dizemos que a probabilidade de o **intervalo aleatório** conter a média populacional é $1 - \alpha$. Uma vez que $\bar{X}$ é “realizado”, isto é, se torna uma estimativa $\bar{x}$, obtemos uma **estimativa intervalar**:

$$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}.$$

Numericamente, com $\sigma = 0,1$, $n = 16$, $\bar{x} = 5,038$ e $1 - \alpha = 0,95$:

$$5,038 \pm 1,96 \cdot \frac{0,1}{\sqrt{16}} = 5,038 \pm 0,049 \rightarrow (4,989; 5,087).$$

5.3.3 Como interpretar — e como não interpretar

O professor dedica três slides à interpretação, e o cuidado se justifica porque o erro é extremamente comum.

É tentador ler $(4,989; 5,087)$ como “o parâmetro populacional está contido no intervalo com 95% de probabilidade”. Essa leitura de fato aparece com frequência, mas é preciso entender em que sentido ela se aplica — porque **a probabilidade de um número fixo estar contido em um intervalo fixo é zero ou 100%**. Uma vez realizado o intervalo, não há mais nada de aleatório: ou μ está dentro, ou não está. Nós é que não sabemos qual.

! A interpretação formal

Em **amostras repetidas**, usando a fórmula $\bar{x} \pm 1,96 \cdot \sigma/\sqrt{n}$ para calcular o intervalo, **95% dos intervalos conterão o parâmetro populacional**.

A aleatoriedade está no **procedimento**, não no parâmetro. O que tem cobertura de 95% é a regra de construção, aplicada repetidamente a amostras diferentes — cada uma produzindo um intervalo diferente, dos quais 95% acertam o alvo fixo.

O laboratório deste capítulo constrói exatamente esse experimento: simula muitas amostras, calcula o intervalo em cada uma e conta a fração que contém o verdadeiro β_1 .

5.3.4 O intervalo de confiança para β_1

Seguindo a mesma lógica, e sabendo que em amostras grandes

$$\hat{\beta}_1 \stackrel{a}{\sim} \mathcal{N}(\beta_1, \sigma_{\hat{\beta}_1}^2),$$

o intervalo de confiança de 95% para β_1 é

$$\boxed{\hat{\beta}_1 \pm 1,96 \cdot \text{SE}(\hat{\beta}_1)}$$

No exemplo:

$$-2,28 \pm 1,96 \cdot 0,5195 \longrightarrow (-3,2982; -1,2618),$$

que é precisamente a coluna [95% Conf. Interval] da saída do STATA.

A interpretação é a já discutida: em amostras repetidas, 95% dos intervalos construídos por essa fórmula conterão o parâmetro populacional. E há uma leitura adicional, que o professor destaca: **o intervalo não contém o zero**. Logo, o valor $\beta_1 = 0$ pode ser rejeitado ao nível de significância de 5%.

! A dualidade entre teste e intervalo

Isso não é coincidência. O intervalo de confiança de 95% é **exatamente o conjunto de valores de $\beta_{1,0}$ que o teste bicaudal a 5% não rejeita**:

$$\left| \frac{\hat{\beta}_1 - \beta_{1,0}}{\text{SE}(\hat{\beta}_1)} \right| \leq 1,96 \iff \beta_{1,0} \in [\hat{\beta}_1 - 1,96 \text{SE}(\hat{\beta}_1), \hat{\beta}_1 + 1,96 \text{SE}(\hat{\beta}_1)].$$

As duas expressões são a mesma desigualdade, com $\beta_{1,0}$ isolado de um lado ou do outro. Daí a regra prática: **o intervalo de 95% contém zero se e somente se o teste de significância a 5% não rejeita**. O intervalo é mais informativo, porque exhibe de uma vez todos os valores compatíveis com os dados, em vez de responder sim ou não sobre um único deles.

5.3.5 Intervalos para efeitos preditos

Raramente interessa uma mudança unitária em X . Em geral queremos o efeito de uma mudança de tamanho Δx — reduzir a turma em dois alunos, aumentar a escolaridade em quatro anos. A mudança esperada em Y é $\beta_1 \Delta x$, e como Δx é uma **constante**, o intervalo se obtém simplesmente multiplicando:

$$\boxed{(\hat{\beta}_1 \pm 1,96 \cdot \text{SE}(\hat{\beta}_1)) \Delta x}$$

Exemplo. O IC para β_1 é $(-3,2982; -1,2618)$. Considere uma redução da razão aluno-professor de duas unidades, $\Delta STR = -2$. O efeito pontual estimado é

$$\Delta \widehat{TestScore} = -2,28 \cdot (-2) = 4,56,$$

e o intervalo de confiança é

$$(-3,2982; -1,2618) \cdot (-2) \rightarrow (2,5236; 6,5964).$$

Note a inversão da ordem dos extremos: multiplicar por um número **negativo** troca o sinal das desigualdades, de modo que o limite inferior do IC de β_1 vira o limite superior do IC do efeito. Com 95% de confiança, portanto, reduzir a turma em dois alunos eleva o desempenho entre 2,5 e 6,6 pontos.

5.4 Regressão quando X é binário

Até aqui o regressor foi uma variável contínua. Mas a análise de regressão produz resultados interessantes — e conceitualmente esclarecedores — quando o regressor é **binário**, assumindo apenas os valores 0 ou 1. É o caso de uma *dummy* como **female**, que vale 1 se o indivíduo é mulher e 0 caso contrário.

Considere o modelo

$$Y_i = \beta_0 + \beta_1 D_i + u_i, \quad i = 1, \dots, n,$$

com D_i binária. No exemplo do capítulo:

$$D_i = \begin{cases} 1, & \text{se } STR \text{ no distrito } i < 20 \\ 0, & \text{se } STR \text{ no distrito } i \geq 20 \end{cases}$$

Como interpretar β_1 ? Note, antes de tudo, que a leitura usual — “a variação em Y associada a uma variação unitária em X ” — perde o sentido literal aqui: não existe “metade de uma unidade” de D . A melhor forma de interpretar β_0 e β_1 é considerar os dois casos possíveis, um de cada vez.

Quando $D_i = 0$, o modelo se reduz a $Y_i = \beta_0 + u_i$. Como $\mathbb{E}(u_i | D_i) = 0$ pela Hipótese 1, a média condicional de Y_i nesse grupo é

$$\mathbb{E}(Y_i | D_i = 0) = \beta_0.$$

Isto é, β_0 é a média populacional dos test scores nos distritos com **STR alta**.

Quando $D_i = 1$, temos $Y_i = \beta_0 + \beta_1 + u_i$, e portanto

$$\mathbb{E}(Y_i | D_i = 1) = \beta_0 + \beta_1,$$

a média populacional dos test scores nos distritos com **STR baixa**. A diferença entre as duas é

$$(\beta_0 + \beta_1) - \beta_0 = \beta_1.$$

! O coeficiente da dummy é uma diferença de médias

$$\beta_1 = \mathbb{E}(Y_i | D_i = 1) - \mathbb{E}(Y_i | D_i = 0)$$

No exemplo do test score:

$$\beta_1 = [\text{média em distritos com } STR < 20] - [\text{média em distritos com } STR \geq 20].$$

E porque β_1 é a diferença entre **médias populacionais**, faz sentido que $\hat{\beta}_1$ seja a diferença entre as **médias amostrais** de Y_i nos dois grupos — o que de fato se demonstra a partir da fórmula do MQO.

Este resultado merece uma pausa, porque ele fecha um círculo aberto no Seção 2. Lá, o efeito causal de um tratamento aleatorizado era estimado pela **diferença entre as médias** dos grupos tratado e de controle. Aqui descobrimos que essa diferença de médias é um coeficiente de regressão — o de uma regressão sobre a dummy de tratamento. As duas ferramentas são a mesma ferramenta, e é por isso que a regressão consegue absorver o arcabouço experimental como caso particular. Regressão com dummy e teste de diferença de médias entre dois grupos são o mesmo procedimento escrito de duas maneiras.

5.4.1 Teste de hipótese e IC no caso binário

Estimando o modelo com a dummy nos dados do exemplo, o professor obtém

$$\widehat{TestScore} = 650,0 + 7,40 \cdot D, \quad (1,3) \quad (1,8)$$

com os erros-padrão entre parênteses, sob a mesma definição de D acima. A leitura é direta:

- o test score médio quando $D = 0$ (isto é, $STR \geq 20$) é 650,0;
- o test score médio quando $D = 1$ (isto é, $STR < 20$) é $650,0 + 7,4 = 657,4$;
- a diferença entre os dois é o coeficiente da dummy, 7,4 pontos.

Em distritos com turmas menores, portanto, o desempenho é 7,4 pontos maior, **em média**.

A diferença entre as médias populacionais dos dois grupos é estatisticamente significativa ao nível de 5%? Testamos $H_0 : \beta_1 = 0$ contra $H_1 : \beta_1 \neq 0$:

$$t = \frac{7,4 - 0}{1,8} = 4,04,$$

que excede o valor crítico de 1,96 e está, portanto, na região de rejeição. O intervalo de confiança de 95% para o coeficiente da dummy é

$$7,4 \pm 1,96 \cdot 1,8 = (3,9; 10,9),$$

que, coerentemente com a dualidade discutida acima, não contém o zero.

i Por que $\hat{\beta}_1$ muda ao trocar STR contínuo por dummy

Note que os dois modelos produzem números diferentes — $-2,28$ por unidade de STR contra $7,4$ pontos entre grupos — e ambos estão corretos, porque respondem a perguntas diferentes. O modelo contínuo estima a inclinação de uma reta ajustada a todo o suporte de STR ; a dummy compara duas médias, descartando toda a variação **dentro** de cada grupo. Discretizar um regressor contínuo joga fora informação, e em geral custa precisão; a compensação é não impor linearidade sobre a relação.

5.5 Heterocedasticidade

Chegamos a um assunto que já apareceu de passagem nos dois capítulos anteriores e que agora recebe tratamento próprio. Ele importa precisamente porque **afeta a inferência** — os erros-padrão, os testes t e os intervalos de confiança que acabamos de construir.

Vale recuperar o ponto de partida: a nossa **única** hipótese sobre a distribuição condicional de u_i dado X_i é que sua **média é zero**. Nada dissemos sobre a variância dessa distribuição. Se, além da média zero, a variância condicional **não depende de X** , dizemos que os erros são homocedásticos.

! Definição — homocedasticidade e heterocedasticidade

O termo de erro u_i é **homocedástico** se a variância condicional da distribuição de u_i dado X_i é constante para $i = 1, \dots, n$ e, em particular, **não depende de X_i** :

$$\text{Var}(u_i | X_i) = \sigma_u^2 \quad (\text{constante})$$

Caso contrário, o termo de erro é **heterocedástico**: $\text{Var}(u_i | X_i)$ é função de X_i .

Graficamente, a heterocedasticidade aparece como uma nuvem de pontos em forma de funil: a dispersão vertical dos pontos em torno da reta de regressão cresce (ou diminui) conforme se caminha ao longo do eixo X . O exemplo clássico, que o professor projeta, é o da economia do trabalho: salário-hora contra anos de escolaridade na *Current Population Survey*. Entre os trabalhadores com pouca escolaridade, os salários são baixos e pouco dispersos; entre os mais escolarizados, a dispersão é muito maior — há médicos e há biólogos desempregados. A variância do erro claramente cresce com X .

A Figura 7, gerada no laboratório, contrasta os dois casos.

5.5.1 O que a heterocedasticidade não estraga

Aqui é preciso ser preciso, porque a confusão é frequente. Como as hipóteses de MQO **não impõem restrição alguma sobre a variância condicional dos erros**, tudo o que derivamos a partir delas continua valendo:

- os estimadores de MQO continuam **não viesados**: $\mathbb{E}(\hat{\beta}_1) = \beta_1$;
- continuam **consistentes**: $\hat{\beta}_1 \xrightarrow{p} \beta_1$;

- continuam **assintoticamente normais**, com distribuição amostral Normal em amostras grandes.

Isto é: **a heterocedasticidade não viesia o MQO**. O estimador continua acertando o alvo em média. O que ela estraga é outra coisa — a **estimativa da precisão** do estimador.

5.5.2 O que ela estraga: as fórmulas de variância

Sob homocedasticidade, a fórmula da variância de $\hat{\beta}_1$ **simplifica**. Recuperando a forma geral obtida no capítulo anterior e impondo $\text{Var}(u_i | X_i) = \sigma_u^2$:

$$\text{Homocedasticidade:} \quad \sigma_{\hat{\beta}_1}^2 = \frac{s_u^2}{\sum_{i=1}^n (X_i - \bar{X})^2} \quad \text{onde} \quad s_u^2 = \frac{1}{n-2} \sum_{i=1}^n \hat{u}_i^2.$$

$$\text{Heterocedasticidade:} \quad \sigma_{\hat{\beta}_1}^2 = \frac{1}{n} \cdot \frac{\text{Var}[(X_i - \mu_X) u_i]}{[\text{Var}(X_i)]^2}$$

A segunda é a fórmula geral, já apresentada no 1, que **não** supõe nada sobre a variância condicional. A primeira é o caso particular que se obtém dela quando a homocedasticidade vale.

⚠ A consequência prática

Se os erros são heterocedásticos e o pesquisador usa a fórmula homocedástica, **toda a parte de inferência da regressão estará incorreta**. Os erros-padrão estarão errados — e, com eles, as estatísticas t , os valores- p e os intervalos de confiança.

Note a direção do problema: o erro **não** está nas estimativas dos coeficientes, que permanecem não viesadas, mas na avaliação da sua precisão. Reporta-se o número certo com a margem de erro errada, o que pode levar a declarar significativo o que não é, ou o contrário.

A solução é usar os **erros-padrão robustos à heterocedasticidade** — os erros-padrão de White (1980), que estimam diretamente a fórmula geral sem supor variância condicional constante. É o que faz a opção **robust** do STATA, presente em todas as saídas do professor, e é o que a função `ep_robusto()` destas notas implementa a partir da fórmula.

i Por que usar robustos sempre

A prática recomendada em economia aplicada é usar erros-padrão robustos **por padrão**, e a razão é assimétrica: se os erros são de fato homocedásticos, os robustos são *assintoticamente* equivalentes aos convencionais e nada se perde de relevante em amostras grandes; se são heterocedásticos, os convencionais estão errados e os robustos estão certos. Não há razão para apostar na hipótese mais forte quando o custo de dispensá-la é baixo.

Em amostras pequenas há uma ressalva: os robustos são consistentes, mas podem ser viesados para baixo em n pequeno, e por isso se usam correções de graus de liberdade — a variante HC1, que é a do STATA e a implementada aqui.

5.5.3 Um exemplo em que quase não faz diferença

O professor apresenta um exemplo instrutivo justamente por ser **anticlimático**. É a regressão de avaliações de curso sobre a beleza do professor (*Beauty in the Classroom*), com $n = 463$ observações. Sem correção:

Modelo 1: MQO, usando as observações 1-463

Variável dependente: course_eval

	coeficiente	erro padrão	razão-t	p-valor	
const	3,99827	0,0253493	157,7	0,0000	***
beauty	0,133001	0,0321775	4,133	4,25e-05	***

E com erros-padrão robustos:

Modelo 2: MQO, usando as observações 1-463

Variável dependente: course_eval

Erros padrão robustos à heteroscedasticidade

	coeficiente	erro padrão	razão-t	p-valor	
const	3,99827	0,0253493	157,7	0,0000	***
beauty	0,133001	0,0323189	4,115	4,58e-05	***

Os coeficientes são **idênticos** — como devem ser, já que a correção não toca no estimador, apenas no erro-padrão. E os erros-padrão mudam muito pouco: de 0,0322 para 0,0323 no coeficiente de **beauty**, o que move a estatística t de 4,133 para 4,115 e não altera conclusão alguma.

A lição não é que a correção seja dispensável — é que **não se sabe de antemão** se ela fará diferença. Neste conjunto de dados, os erros são aproximadamente homocedásticos e a correção quase não muda nada; em outros, ela muda a conclusão. Como o custo de usá-la é nulo, usa-se sempre.

5.6 O Teorema de Gauss-Markov

O capítulo fecha com o resultado que historicamente serviu de justificativa teórica para o uso do MQO. O professor o apresenta com uma ressalva embutida já no enunciado: o Teorema de Gauss-Markov **era** usado como justificativa. O verbo no passado tem um bom motivo — as hipóteses impostas pelo teorema são tão restritivas que tornam sua validade improvável na prática, o que limita seu alcance como fundamento para o MQO.

! Teorema de Gauss-Markov

Se as **três hipóteses de MQO** são válidas e os erros são **homocedásticos**, então o estimador de MQO $\hat{\beta}_1$ é **BLUE**:

- **B**est — no sentido de **variância mínima**;
- **L**inear — na classe dos estimadores lineares em Y ;
- **C**onditionally **U**nbiased **E**stimator — condicionalmente não viesado.

Isto é: entre todos os estimadores que são funções lineares de $Y_1, \dots, Y_n$ e não viesados condicionalmente aos X , o MQO é o de menor variância.

O teorema é um resultado de **eficiência**: não afirma que o MQO é não viesado (isso já vem das Hipóteses 1–3, sem homocedasticidade), mas que, acrescentada a homocedasticidade, ele é o **melhor** dentro de uma classe restrita.

5.6.1 As duas limitações

E é justamente sobre o tamanho dessa classe e a força dessas hipóteses que recaem as duas limitações que o professor enumera.

Primeira: as condições em geral não valem na prática. Em particular, a hipótese de erros homocedásticos **raramente se verifica** em aplicações de economia e finanças. E se os erros são heterocedásticos — como em geral é o caso —, o estimador de MQO **não é mais BLUE**. Existe, sob heterocedasticidade conhecida, um estimador de mínimos quadrados ponderados com variância menor.

Segunda: mesmo quando as condições valem, a classe é restrita. O teorema só compara o MQO com estimadores **lineares** e não viesados. Existem estimadores **não lineares** e não viesados que, sob certas condições, são **mais eficientes** que o MQO.

i Então por que continuamos usando MQO?

A pergunta é legítima, e a resposta não está no Teorema de Gauss-Markov — está no que sobrevive sem ele. Sob as Hipóteses 1–3 **apenas**, sem homocedasticidade e sem qualquer hipótese distribucional, o MQO continua não viesado, consistente e assintoticamente normal. É isso que sustenta a inferência deste capítulo, e é isso que não depende de o mundo ser homocedástico.

O MQO se justifica, portanto, menos por ser ótimo em alguma classe estreita e mais por ser robusto, transparente, computacionalmente trivial e diretamente interpretável como estimador de uma média condicional. As alternativas que o dominam em eficiência exigem, em troca, conhecer a estrutura da heterocedasticidade — conhecimento que raramente se tem.

O que **não** se resolve por essa via é o problema central do curso: nenhuma propriedade de eficiência salva o MQO se $E(u_i | X_i) \neq 0$. Um estimador viesado com variância mínima continua sendo um estimador viesado, e é contra o viés — não contra a ineficiência — que o resto do curso vai trabalhar.

5.7 Laboratório computacional em R

O laboratório deste capítulo tem cinco partes. Reproduz os testes t e os intervalos de confiança da regressão do exemplo; verifica por simulação o que significa “95% de confiança”; ilustra graficamente homocedasticidade contra heterocedasticidade; mostra numericamente o que acontece com a inferência quando se usa a fórmula errada; e reproduz a equivalência entre regressão com dummy e diferença de médias.

Retomamos os mesmos dados simulados do capítulo anterior — com a mesma advertência: eles **não** são os dados originais de Stock e Watson (2020), e sim uma calibração que reproduz a ordem de grandeza dos resultados do slide.

```
set.seed(5490)
n_d      <- 420
beta0    <- 698.9
beta1    <- -2.28
sigma_u  <- 18.55

STR      <- rnorm(n_d, mean = 19.64, sd = 1.89)
u        <- rnorm(n_d, mean = 0,      sd = sigma_u)
TestScore <- beta0 + beta1 * STR + u
ca <- data.frame(STR = STR, TestScore = TestScore)

reg <- lm(TestScore ~ STR, data = ca)
round(coef(reg), 4)
```

```
(Intercept)      STR
    698.8918    -2.2682
```

5.7.1 (a) A tabela completa de inferência

A função `tabela_reg()`, definida no preâmbulo destas notas, monta a tabela que o STATA imprime: coeficiente, erro-padrão robusto, estatística t , valor-p e os limites do intervalo de confiança de 95%.

```
round(tabela_reg(reg, robusto = TRUE), 4)
```

```
              coef      ep      t p    ic_inf    ic_sup
(Intercept) 698.8918 8.9701 77.9138 0 681.2597 716.5238
STR         -2.2682 0.4587 -4.9446 0  -3.1699  -1.3665
```

Cada coluna é um objeto deste capítulo. Para o coeficiente de `STR`: a estatística t testa $H_0 : \beta_1 = 0$ e é a razão entre a estimativa e o erro-padrão; o valor-p é $2 F_t(-|t|)$; e o intervalo de confiança é $\hat{\beta}_1 \pm t_{0,975} \cdot \text{SE}(\hat{\beta}_1)$. Compare com a saída do STATA reproduzida acima — a correspondência é linha a linha, com as diferenças esperadas por se tratar de dados simulados.

Vale conferir “na mão” que as três colunas se produzem umas às outras:

```
b1  <- coef(reg)[2]
se1 <- ep_robusto(reg)[2]
t1  <- b1 / se1
gl  <- df.residual(reg)

c(beta1_hat = b1,
  ep        = se1,
```

```

t      = t1,
valor_p = 2 * pt(-abs(t1), gl),
ic_inf  = b1 - qt(0.975, gl) * se1,
ic_sup  = b1 + qt(0.975, gl) * se1) |> round(4)

```

beta1_hat.STR	ep.STR	t.STR	valor_p.STR	ic_inf.STR
-2.2682	0.4587	-4.9446	0.0000	-3.1699
ic_sup.STR				
-1.3665				

Note que uso o valor crítico da distribuição t com $n - 2$ graus de liberdade ($qt(0.975, 418)$), e não o 1,96 da Normal. Com 418 graus de liberdade a diferença é irrelevante — o valor crítico é praticamente 1,966 —, mas é o que o STATA faz e o que mantém a tabela coerente com a coluna $P>|t|$.

```

c(normal = qnorm(0.975), t_418 = qt(0.975, gl), t_20 = qt(0.975, 20)) |> round(4)

```

normal	t_418	t_20
1.9600	1.9657	2.0860

Com n pequeno a diferença deixa de ser irrelevante: com 20 graus de liberdade o valor crítico sobe para 2,086, e ignorá-lo produziria intervalos 6% mais estreitos do que deveriam ser.

5.7.2 (b) O efeito predito de $\Delta STR = -2$

```

delta    <- -2
ic_b1    <- c(b1 - qt(0.975, gl) * se1, b1 + qt(0.975, gl) * se1)
ic_efeito <- sort(ic_b1 * delta)

c(efeito_pontual = b1 * delta,
  ic_inf = ic_efeito[1],
  ic_sup = ic_efeito[2]) |> round(4)

```

efeito_pontual.STR	ic_inf.STR	ic_sup.STR
4.5365	2.7331	6.3399

O `sort()` não é cosmético: como $\Delta x = -2$ é negativo, a multiplicação **inverte** a ordem dos extremos, exatamente como discutido no texto. Sem reordenar, o “limite inferior” sairia maior que o superior.

5.7.3 (c) O que significa “95% de confiança”

Esta é a parte central do laboratório. Vamos construir o experimento de amostras repetidas que a interpretação formal do intervalo descreve: geramos 5.000 amostras do mesmo processo, calculamos o IC de 95% em cada uma e contamos em quantas delas o intervalo contém o **verdadeiro** $\beta_1 = -2,28$.

```
set.seed(2026)
n_rep <- 5000
n_am <- 420

cobre <- logical(n_rep)
largura <- numeric(n_rep)

for (r in seq_len(n_rep)) {
  Xr <- rnorm(n_am, mean = 19.64, sd = 1.89)
  Yr <- beta0 + beta1 * Xr + rnorm(n_am, mean = 0, sd = sigma_u)
  mr <- lm(Yr ~ Xr)

  br <- coef(mr)[2]
  sr <- ep_robusto(mr)[2]
  tc <- qt(0.975, df.residual(mr))

  li <- br - tc * sr
  ls <- br + tc * sr
  cobre[r] <- (li < beta1) && (beta1 < ls)
  largura[r] <- ls - li
}

c(cobertura_empirica = mean(cobre),
  nominal             = 0.95,
  largura_media       = mean(largura)) |> round(4)
```

cobertura_empirica	nominal	largura_media
0.9478	0.9500	1.8770

A cobertura empírica fica muito próxima dos 95% nominais. **É isso, literalmente, que a frase “intervalo de 95% de confiança” quer dizer:** não que este intervalo específico tenha 95% de chance de conter β_1 , mas que o *procedimento* que o gerou acerta em 95% das amostras.

A Figura 6 mostra os 100 primeiros intervalos dessa simulação.

```
set.seed(2026)
n_mostrar <- 100
ics <- data.frame(rep = seq_len(n_mostrar), li = NA_real_, ls = NA_real_, b = NA_real_)

for (r in seq_len(n_mostrar)) {
  Xr <- rnorm(n_am, mean = 19.64, sd = 1.89)
```

```

Yr <- beta0 + beta1 * Xr + rnorm(n_am, mean = 0, sd = sigma_u)
mr <- lm(Yr ~ Xr)
br <- coef(mr)[2]; sr <- ep_robusto(mr)[2]; tc <- qt(0.975, df.residual(mr))
ics$li[r] <- br - tc * sr; ics$ls[r] <- br + tc * sr; ics$b[r] <- br
}
ics$acerta <- ics$li < beta1 & beta1 < ics$ls

ggplot(ics, aes(y = rep, x = b, xmin = li, xmax = ls, colour = acerta)) +
  geom_vline(xintercept = beta1, colour = cz, linewidth = 0.6) +
  geom_errorbar(orientation = "y", width = 0, linewidth = 0.4, alpha = 0.9) +
  geom_point(size = 0.7) +
  scale_colour_manual(values = c(`TRUE` = az, `FALSE` = vm),
    labels = c(`TRUE` = "contém", `FALSE` = "não contém")) +
  labs(x = expression(hat(beta)[1]), y = "réplica")

```




Figura 6: Cem intervalos de confiança de 95% para β_1 , cada um construído a partir de uma amostra diferente do mesmo processo gerador. A linha vertical marca o verdadeiro $\beta_1 = -2,28$. Os intervalos em azul contêm o parâmetro; os em vermelho, não. O que varia de amostra para amostra é o intervalo, não o parâmetro — e é sobre a frequência de acerto do procedimento, ao longo de amostras repetidas, que a confiança de 95% faz uma afirmação.

Alguns dos 100 intervalos exibidos erram o alvo, em proporção compatível com os 5% esperados — em uma amostra de apenas 100 réplicas, o próprio número de erros é aleatório. Nenhum dos que erram é “o intervalo errado” em algum sentido especial: todos foram construídos pela mesma regra, a partir de amostras igualmente legítimas. Na prática temos **uma** amostra e nunca sabemos se caímos entre os azuis ou entre os vermelhos.

5.7.4 (d) Homocedasticidade contra heterocedasticidade

```
set.seed(11)
n_h <- 300
Xh <- runif(n_h, 1, 10)

d_homo <- data.frame(X = Xh, Y = 2 + 1.5 * Xh + rnorm(n_h, 0, 2),
                     tipo = "Homocedástico: V(u|X) constante")
d_hetero <- data.frame(X = Xh, Y = 2 + 1.5 * Xh + rnorm(n_h, 0, 0.45 * Xh),
                       tipo = "Heterocedástico: V(u|X) cresce com X")

rbind(d_homo, d_hetero) |>
  ggplot(aes(X, Y)) +
  geom_point(alpha = 0.45, size = 0.9, colour = "azul") +
  geom_abline(intercept = 2, slope = 1.5, colour = "vermelho", linewidth = 0.7) +
  facet_wrap(~tipo)
```




Figura 7: Erros homocedásticos (esquerda) e heterocedásticos (direita), com a mesma reta de regressão populacional. À esquerda, a dispersão vertical dos pontos em torno da reta é a mesma em todo o suporte de X . À direita, ela cresce com X — a nuvem tem forma de funil. Em ambos os casos o MQO estima a reta corretamente; o que muda é a precisão dessa estimativa em cada região do suporte, e portanto a fórmula correta do erro-padrão.

5.7.5 (e) A inferência quando se usa a fórmula errada

Aqui está a consequência prática, medida. Geramos dados **deliberadamente heterocedásticos**, com $\text{Var}(u_i | X_i) = (0,5 X_i)^2$, e comparamos três coisas ao longo de 3.000 réplicas: o desvio-padrão

empírico de $\hat{\beta}_1$ (que é a verdade contra a qual se julga), a média dos erros-padrão **homocedásticos** e a média dos **robustos**.

```
set.seed(99)
n_rep2 <- 3000
n_am2 <- 200

b_vec <- numeric(n_rep2)
ep_hom <- numeric(n_rep2)
ep_rob <- numeric(n_rep2)
cob_hom <- logical(n_rep2)
cob_rob <- logical(n_rep2)

b1_true <- 1.5

for (r in seq_len(n_rep2)) {
  Xr <- runif(n_am2, 1, 10)
  Yr <- 2 + b1_true * Xr + rnorm(n_am2, 0, 0.5 * Xr) # heterocedastico
  mr <- lm(Yr ~ Xr)
  tc <- qt(0.975, df.residual(mr))

  b_vec[r] <- coef(mr)[2]
  ep_hom[r] <- summary(mr)$coefficients[2, 2]
  ep_rob[r] <- ep_robusto(mr)[2]

  cob_hom[r] <- abs(b_vec[r] - b1_true) < tc * ep_hom[r]
  cob_rob[r] <- abs(b_vec[r] - b1_true) < tc * ep_rob[r]
}

round(c(dp_empirico_de_beta1 = sd(b_vec),
        media_ep_homocedastico = mean(ep_hom),
        media_ep_robusto      = mean(ep_rob)), 4)
```

dp_empirico_de_beta1	media_ep_homocedastico	media_ep_robusto
0.0893	0.0828	0.0881

O desvio-padrão empírico de $\hat{\beta}_1$ é a referência: é a variabilidade que o estimador de fato tem. O erro-padrão robusto o reproduz de perto; o homocedástico **subestima** a variabilidade verdadeira. E a consequência aparece na cobertura dos intervalos:

```
round(c(cobertura_com_ep_homocedastico = mean(cob_hom),
        cobertura_com_ep_robusto      = mean(cob_rob),
        nominal                        = 0.95), 4)
```

cobertura_com_ep_homocedastico	cobertura_com_ep_robusto
0.9323	0.9433

nominal
0.9500

O intervalo construído com o erro-padrão homocedástico, que se anuncia como de 95%, cobre o parâmetro em menos que 95% das amostras — é **estrito demais**. Quem o utiliza rejeita H_0 com mais frequência do que o nível declarado, isto é, comete erros do Tipo I acima do α que julga ter fixado. O intervalo robusto fica sensivelmente mais próximo do nível nominal.

A cobertura robusta também não bate exatamente os 95%, e vale entender por quê: com $n = 200$, o erro-padrão robusto é ele próprio **estimado** com ruído, e a correção HC1 não elimina inteiramente o viés de amostra finita. A garantia dos erros-padrão robustos é **assintótica**; o que a simulação mostra é a direção e a ordem de grandeza da correção, não uma promessa exata em n pequeno. O exercício 7(d) pede refazer isto com $n = 30$, onde a discrepância é bem maior.

Note também que a média de $\hat{\beta}_1$ ao longo das réplicas continua no valor verdadeiro, confirmando que a heterocedasticidade não viesava o estimador:

```
c(media_beta1_hat = mean(b_vec), beta1_verdadeiro = b1_true) |> round(4)
```

media_beta1_hat	beta1_verdadeiro
1.4961	1.5000

5.7.6 (f) Regressão com dummy é diferença de médias

Por fim, a verificação numérica da equivalência estabelecida no texto. Criamos a dummy $D = \mathbb{1}\{STR < 20\}$ nos dados do exemplo e comparamos o coeficiente da regressão com a diferença entre as médias amostrais dos dois grupos.

```
ca$D <- as.numeric(ca$STR < 20)

reg_d <- lm(TestScore ~ D, data = ca)

media_D1 <- mean(ca$TestScore[ca$D == 1]) # STR < 20
media_D0 <- mean(ca$TestScore[ca$D == 0]) # STR >= 20

round(c(intercepto_regressao = coef(reg_d)[1],
        media_grupo_D0      = media_D0,
        coef_dummy           = coef(reg_d)[2],
        diferenca_de_medias  = media_D1 - media_D0), 4)
```

intercepto_regressao.(Intercept)	media_grupo_D0
649.8960	649.8960
coef_dummy.D	diferenca_de_medias
7.8604	7.8604

O intercepto é a média do grupo $D = 0$ e o coeficiente da dummy é a diferença entre as médias — não aproximadamente, mas até o último dígito. A regressão sobre uma dummy é uma comparação de médias escrita em outra notação.

E a inferência sobre esse coeficiente é a mesma de sempre:

```
round(tabela_reg(reg_d, robusto = TRUE), 4)
```

	coef	ep	t	p	ic_inf	ic_sup
(Intercept)	649.8960	1.4597	445.2113	0	647.0266	652.7654
D	7.8604	1.8651	4.2145	0	4.1943	11.5264

Compare com o teste t de diferença de médias entre os dois grupos, com variâncias desiguais (Welch), que é o procedimento que um curso de estatística aplicaria ao mesmo problema:

```
tt <- t.test(TestScore ~ D, data = ca)
round(c(t_welch = unname(tt$statistic),
      p_welch = tt$p.value,
      t_regressao_robusto = tabela_reg(reg_d)[2, "t"],
      p_regressao_robusto = tabela_reg(reg_d)[2, "p"]), 4)
```

t_welch	p_welch	t_regressao_robusto	p_regressao_robusto
-4.2141	0.0000	4.2145	0.0000

As estatísticas são praticamente idênticas (o sinal difere apenas pela ordem em que cada função toma a diferença entre os grupos). A pequena discrepância vem de a correção de graus de liberdade de Welch não ser exatamente a do HC1 — mas a conclusão é a mesma, como tem de ser: é o mesmo teste.

5.8 Exercícios

1. **Os dois erros.** Um órgão regulador testa se um medicamento tem efeito, com H_0 : “o medicamento não tem efeito”. (a) Descreva em palavras o erro do Tipo I e o do Tipo II neste contexto, e diga qual deles lhe parece mais custoso socialmente. (b) O regulador decide reduzir α de 5% para 1%, mantendo o tamanho da amostra. O que acontece com β e com o poder? (c) Um laboratório concorrente, que quer demonstrar que o medicamento **não** funciona, tem incentivo a escolher qual tamanho de amostra? Relacione com a advertência do professor sobre poder. (d) Reescreva a nula de modo a inverter os papéis dos dois erros, e discuta quando essa formulação seria preferível.
2. **Teste sobre a média.** Refaça o exemplo do texto ($\sigma = 0,1$, $n = 16$, $\bar{x} = 5,038$) supondo agora a alternativa **bicaudal** $H_1 : \mu \neq 5$. (a) Qual é o novo valor crítico a 5%? (b) Qual é o valor-p? (c) A conclusão muda? (d) Explique por que o valor-p bicaudal é exatamente o dobro do unicaudal neste caso, e sob que condição essa relação vale.

3. **Lendo uma tabela de regressão.** Uma regressão de salário sobre anos de escolaridade, com $n = 1.200$, produziu $\hat{\beta}_1 = 0,087$ com erro-padrão robusto 0,011. (a) Calcule a estatística t para $H_0 : \beta_1 = 0$ e conclua a 1%. (b) Construa o IC de 95% e o de 99%; qual é mais largo, e por quê? (c) Teste $H_0 : \beta_1 = 0,10$ contra a alternativa bicaudal — o resultado é coerente com o IC de 95% que você construiu?

(d) Um pesquisador afirma que “o retorno da escolaridade é de 8,7% e o valor-p é praticamente zero, logo o efeito é grande”. Avalie as duas afirmações separadamente.
4. **A dualidade.** Mostre algebricamente que o teste bicaudal de $H_0 : \beta_1 = \beta_{1,0}$ ao nível α não rejeita **se e somente se** $\beta_{1,0}$ pertence ao intervalo de confiança de nível $1 - \alpha$. (b) Use essa equivalência para responder, sem calcular nenhuma estatística t : dado o IC de 95% $(-3,30; -1,26)$ do exemplo, quais dos valores $\{-4; -3; -1,5; 0; 1\}$ seriam rejeitados a 5%? (c) A dualidade vale para testes unicaudais? Justifique.
5. **Efeitos preditos.** Com $\hat{\beta}_1 = -2,28$ e $SE(\hat{\beta}_1) = 0,52$: (a) construa o IC de 95% para o efeito de $\Delta STR = -5$. (b) Explique por que os extremos se invertem quando $\Delta x < 0$. (c) Suponha agora que se queira o IC para o efeito de $\Delta STR = -2$ **em pontos percentuais** do desvio-padrão dos test scores (≈ 19 pontos). Obtenha-o. (d) Por que não é necessário conhecer $SE(\hat{\beta}_0)$ para nada disso?
6. **Regressor binário.** Considere $Y_i = \beta_0 + \beta_1 D_i + u_i$ com D_i binária.
 - (a) Partindo da fórmula do MQO $\hat{\beta}_1 = \frac{\sum(D_i - \bar{D})(Y_i - \bar{Y})}{\sum(D_i - \bar{D})^2}$, demonstre que $\hat{\beta}_1 = \bar{Y}_1 - \bar{Y}_0$, as médias amostrais nos dois grupos.
 - (b) Mostre que $\hat{\beta}_0 = \bar{Y}_0$. (c) Suponha que se defina a dummy ao contrário, $\tilde{D} = 1 - D$: o que acontece com $\hat{\beta}_0$, $\hat{\beta}_1$, a estatística t e o R^2 ? (d) O que aconteceria se incluíssemos **ambas**, D e $\tilde{D}$, além do intercepto?
7. **Heterocedasticidade.** (a) Explique por que a heterocedasticidade **não** viesia $\hat{\beta}_1$, apontando em que passo da demonstração de não-viés a variância condicional dos erros seria usada — e verificando que ela não é. (b) Na simulação da seção (e) do laboratório, o erro-padrão homocedástico subestimou a variabilidade verdadeira. Isso é sempre assim, ou existe padrão de heterocedasticidade que produza o contrário? Investigue por simulação com $\text{Var}(u_i | X_i)$ **decrecente** em X_i . (c) Por que os erros-padrão robustos são preferidos “por padrão”, mesmo quando os erros podem ser homocedásticos? (d) O que muda se $n = 30$ em vez de $n = 200$?
8. **Gauss-Markov.** (a) Enuncie precisamente as hipóteses do teorema e identifique qual delas **não** está entre as três hipóteses de MQO. (b) Explique a diferença entre “não viesado” e “BLUE”, e por que a heterocedasticidade destrói o segundo mas não o primeiro. (c) O teorema afirma que o MQO tem variância mínima entre estimadores lineares e não viesados. Dê um exemplo de estimador **linear e viesado** com variância menor que a do MQO — isso contradiz o teorema? (d) À luz das duas limitações discutidas no texto, como você justificaria o uso do MQO a um cético?
9. **Simulação de poder.** Adapte o código da seção (c) do laboratório para estimar o **poder** do teste de $H_0 : \beta_1 = 0$. (a) Fixe $\beta_1 = -0,5$, $n = 100$, e estime, ao longo de 2.000 réplicas, a fração de amostras em que H_0 é rejeitada a 5% — esse é o poder contra essa alternativa. (b) Repita para $n \in \{50, 100, 400, 1600\}$ e descreva como o poder evolui. (c) Repita para $\beta_1 \in \{-0,1, -0,5, -1, -2\}$ com $n = 100$ fixo, e trace a **curva de poder**. (d) Verifique que,

quando $\beta_1 = 0$, a fração de rejeições é aproximadamente α — e explique por que isso tem de ser assim.

5.9 Lista de Exercícios 2

Sobre esta seção

Reproduzo aqui a **Lista 2** da disciplina (Prof. Marcelo Mello; monitor: Matheus Porto), cujas questões são os exercícios 5.1 a 5.13 de Stock e Watson (2020) e cobrem exatamente o conteúdo deste capítulo. O gabarito vem logo em seguida, com as resoluções desenvolvidas — a recomendação de sempre é tentar cada questão antes de consultá-lo.

Questão 1 (exercício 5.1). Suponha que um pesquisador, usando dados sobre tamanho de turma (CS) e nota média em testes (TS) de 100 turmas de terceira série, estime a regressão de MQO

$$\widehat{TS} = 520,4 - 5,82 \cdot CS, \quad (20,4) \quad (2,21)$$

com $R^2 = 0,08$ e $SER = 11,5$ (erros-padrão entre parênteses).

- Construa um intervalo de confiança de 95% para β_1 , o coeficiente de inclinação.
- Calcule o valor-p do teste bicaudal da hipótese nula $H_0 : \beta_1 = 0$. Você rejeita a nula a 5%? E a 1%?
- Calcule o valor-p do teste bicaudal da hipótese nula $H_0 : \beta_1 = -5,6$. Sem fazer cálculos adicionais, determine se $-5,6$ está contido no intervalo de confiança de 95% para β_1 .
- Construa um intervalo de confiança de 99% para β_0 .

Questão 2 (exercício 5.2). Suponha que um pesquisador, usando dados salariais de 250 trabalhadores homens e 280 trabalhadoras mulheres selecionados aleatoriamente, estime a regressão de MQO

$$\widehat{Wage} = 12,52 + 2,12 \cdot Male, \quad (0,23) \quad (0,36)$$

com $R^2 = 0,06$ e $SER = 4,2$, onde $Wage$ é medido em dólares por hora e $Male$ é binária igual a 1 se a pessoa é homem e 0 se é mulher. Defina o **diferencial salarial de gênero** como a diferença de rendimentos médios entre homens e mulheres.

- Qual é o diferencial de gênero estimado?
- O diferencial estimado é significativamente diferente de zero? (Calcule o valor-p do teste da nula de que não há diferencial.)
- Construa um intervalo de confiança de 95% para o diferencial de gênero.
- Na amostra, qual é o salário médio das mulheres? E o dos homens?
- Outro pesquisador usa os mesmos dados, mas regride $Wage$ sobre $Female$, variável igual a 1 se a pessoa é mulher e 0 se é homem. Quais são as estimativas dessa regressão?

$$\widehat{Wage} = ______ + ______ \cdot Female, \quad R^2 = ______, \quad SER = ______.$$

Questão 3 (exercício 5.3). Suponha que uma amostra aleatória de 200 homens de vinte anos seja selecionada de uma população e que suas alturas e pesos sejam registrados. Uma regressão do peso sobre a altura produz

$$\widehat{Weight} = -99,41 + 3,94 \cdot Height, \quad (2,15) \quad (0,31)$$

com $R^2 = 0,81$ e $SER = 10,2$, onde $Weight$ é medido em libras e $Height$ em polegadas. Um homem tem um estirão tardio e cresce 1,5 polegada ao longo de um ano. Construa um intervalo de confiança de 99% para o ganho de peso dessa pessoa.

Questão 4 (exercício 5.9). Considere o modelo de regressão

$$Y_i = \beta X_i + u_i,$$

onde u_i e X_i satisfazem as hipóteses de MQO. Seja $\bar{\beta}$ o estimador de β construído como $\bar{\beta} = \bar{Y}/\bar{X}$, onde $\bar{Y}$ e $\bar{X}$ são as médias amostrais de Y_i e X_i .

- Mostre que $\bar{\beta}$ é uma função linear de $Y_1, Y_2, \dots, Y_n$.
- Mostre que $\bar{\beta}$ é condicionalmente não viesado.

Questão 5 (exercício 5.10). Seja X_i uma variável binária e considere o modelo de regressão $Y_i = \beta_0 + \beta_1 X_i + u_i$. Seja $\bar{Y}_0$ a média amostral das observações com $X = 0$ e $\bar{Y}_1$ a média amostral das observações com $X = 1$. Mostre que $\hat{\beta}_0 = \bar{Y}_0$, $\hat{\beta}_0 + \hat{\beta}_1 = \bar{Y}_1$ e $\hat{\beta}_1 = \bar{Y}_1 - \bar{Y}_0$.

Questão 6 (exercício 5.13). Suponha que (Y_i, X_i) satisfaçam as hipóteses de MQO e, adicionalmente, que u_i seja $\mathcal{N}(0, \sigma_u^2)$ e independente de X_i .

- $\hat{\beta}_1$ é condicionalmente não viesado?
- $\hat{\beta}_1$ é o melhor estimador linear condicionalmente não viesado de β_1 ?
- Como suas respostas a (a) e (b) mudariam se você assumisse apenas que (Y_i, X_i) satisfazem as hipóteses de MQO e que $\text{Var}(u_i | X_i = x)$ é constante?
- Como suas respostas a (a) e (b) mudariam se você assumisse **apenas** que (Y_i, X_i) satisfazem as hipóteses de MQO?

As hipóteses de MQO, para referência: $Y_i = \beta_0 + \beta_1 X_i + u_i$, $i = 1, \dots, n$, com (1) $\mathbb{E}(u_i | X_i) = 0$; (2) (X_i, Y_i) extrações i.i.d. da distribuição conjunta; (3) valores extremos improváveis — X_i e Y_i têm quarto momento não nulo e finito.

5.9.1 Gabarito da Lista 2

Questão 1. Com $n = 100$, a aproximação normal é adequada e usamos os valores críticos 1,96 (95%) e 2,58 (99%).

- $\hat{\beta}_1 = -5,82$ com $\text{SE}(\hat{\beta}_1) = 2,21$:

$$\text{IC}_{95\%}(\beta_1) = -5,82 \pm 1,96 \times 2,21 = -5,82 \pm 4,33 = (-10,15; -1,49).$$

- b. A estatística t sob $H_0 : \beta_1 = 0$ é

$$t = \frac{-5,82 - 0}{2,21} = -2,633.$$

O valor-p bicaudal é

$$p = 2 \Phi(-|t|) = 2 \Phi(-2,633) = 2 \times 0,00423 = 0,0085.$$

Como $p = 0,0085 < 0,05$, **rejeitamos a 5%**. Como $p = 0,0085 < 0,01$, **rejeitamos também a 1%** — embora por pouco: $|t| = 2,633$ está apenas ligeiramente acima do crítico de 1%, que é 2,576.

- c. Sob $H_0 : \beta_1 = -5,6$,

$$t = \frac{-5,82 - (-5,6)}{2,21} = \frac{-0,22}{2,21} = -0,0995,$$

e o valor-p é $2 \Phi(-0,0995) = 2 \times 0,4604 = 0,921$. Não se rejeita a nula a nenhum nível convencional — a estimativa é inteiramente compatível com $\beta_1 = -5,6$.

Sem cálculos adicionais, pela **dualidade** entre teste e intervalo (demonstrada na Seção 5): o teste bicaudal a 5% não rejeita $\beta_{1,0}$ **se e somente se** $\beta_{1,0}$ pertence ao IC de 95%. Como não rejeitamos $-5,6$ a 5% (o valor-p é 0,921, muito acima de 0,05), concluímos que $-5,6$ **está** contido no IC de 95%. E, de fato, $-10,15 < -5,6 < -1,49$.

- d. $\hat{\beta}_0 = 520,4$ com $SE(\hat{\beta}_0) = 20,4$:

$$IC_{99\%}(\beta_0) = 520,4 \pm 2,58 \times 20,4 = 520,4 \pm 52,63 = (467,77; 573,03).$$

Questão 2. Regressão sobre a *dummy Male*, $n = 250 + 280 = 530$.

- a. Como *Male* é binária, o coeficiente é literalmente a diferença entre as médias amostrais dos dois grupos (resultado demonstrado na Seção 5 e redemonstrado na Questão 5 desta lista). O diferencial estimado é, portanto, **US\$ 2,12 por hora** a favor dos homens.
- b. $H_0 : \beta_1 = 0$ contra $H_1 : \beta_1 \neq 0$:

$$t = \frac{2,12}{0,36} = 5,889, \quad p = 2 \Phi(-5,889) \approx 3,9 \times 10^{-9}.$$

O valor-p é essencialmente zero: **rejeita-se a nula a qualquer nível convencional**. O diferencial é altamente significativo.

Uma observação que o capítulo insiste em fazer: significância estatística e relevância econômica são coisas distintas. Aqui, felizmente, ambas se sustentam — US\$ 2,12 sobre um salário feminino médio de US\$ 12,52 é um diferencial de cerca de **17%**, que é grande. Mas o valor-p sozinho não estabelecerá isso; ele apenas exclui o acaso amostral como explicação.

- c.

$$IC_{95\%}(\beta_1) = 2,12 \pm 1,96 \times 0,36 = 2,12 \pm 0,71 = (1,41; 2,83).$$

Em termos substantivos: os dados são compatíveis com um diferencial entre US\$ 1,41 e US\$ 2,83 por hora. O zero está confortavelmente fora, coerentemente com (b).

- d. Pela interpretação da regressão com regressor binário:

- **Mulheres** ($Male = 0$): $\bar{Y}_0 = \hat{\beta}_0 = \text{US\$ } 12,52$.
- **Homens** ($Male = 1$): $\bar{Y}_1 = \hat{\beta}_0 + \hat{\beta}_1 = 12,52 + 2,12 = \text{US\$ } 14,64$.

e. Como $Female = 1 - Male$, a nova regressão é uma **reparametrização** da mesma reta, não um modelo diferente. Substituindo:

$$\widehat{Wage} = 12,52 + 2,12(1 - Female) = 14,64 - 2,12 Female.$$

Portanto:

$$\widehat{Wage} = 14,64 - 2,12 \cdot Female, \quad (0,23) \quad (0,36)$$

com $R^2 = 0,06$ e $SER = 4,2$ — **exatamente os mesmos**.

Os detalhes valem atenção. O novo intercepto é a média dos **homens** (a nova categoria de referência), US\$ 14,64. O novo coeficiente é o mesmo diferencial com **sinal trocado**. O erro-padrão da inclinação é **idêntico** (0,36), porque estimar $\bar{Y}_1 - \bar{Y}_0$ ou $\bar{Y}_0 - \bar{Y}_1$ envolve a mesma variabilidade. O R^2 e o SER são idênticos porque os **valores ajustados e os resíduos são exatamente os mesmos** — a reta é a mesma reta, apenas descrita a partir de outro ponto de referência.

O erro-padrão do novo intercepto, por outro lado, **não** é 0,23: ele agora estima a média dos homens, e valeria $SE(\hat{\beta}_0 + \hat{\beta}_1)$, que exige a covariância entre os dois estimadores. Como a lista não fornece essa covariância, o item pede apenas os quatro números indicados no enunciado.

Questão 3. O efeito predito é $\hat{\beta}_1 \Delta x$ com $\Delta x = 1,5$, e o intervalo de confiança se obtém escalando o do coeficiente — como visto na Seção 5, porque Δx é uma **constante conhecida**:

$$SE(\hat{\beta}_1 \Delta x) = |\Delta x| \cdot SE(\hat{\beta}_1) = 1,5 \times 0,31 = 0,465.$$

O efeito predito pontual é $3,94 \times 1,5 = 5,91$ libras. Com $n = 200$, o valor crítico de 99% é 2,58:

$$IC_{99\%} = 5,91 \pm 2,58 \times 0,465 = 5,91 \pm 1,20 = (4,71; 7,11) \text{ libras.}$$

Duas observações. Primeira: **não é preciso conhecer** $SE(\hat{\beta}_0)$, porque o intercepto não entra numa **diferença** de valores preditos — ele se cancela. Segunda: a mesma ressalva da Questão 1(b) da Lista 1 permanece — o intervalo quantifica a incerteza amostral sobre o coeficiente **transversal**, não a incerteza sobre a trajetória de um indivíduo específico, que é uma questão de validade externa e não de inferência.

Questão 4. Modelo sem intercepto, $Y_i = \beta X_i + u_i$, com $\bar{\beta} = \bar{Y} / \bar{X}$.

a. **Linearidade em Y.** Escrevendo as médias explicitamente,

$$\bar{\beta} = \frac{\bar{Y}}{\bar{X}} = \frac{\frac{1}{n} \sum_{i=1}^n Y_i}{\bar{X}} = \sum_{i=1}^n \underbrace{\frac{1}{n\bar{X}}}_{=a_i} Y_i.$$

Trata-se de $\sum_i a_i Y_i$ com pesos $a_i = \frac{1}{n\bar{X}}$ que dependem **apenas dos X**. Condicionalmente a $X_1, \dots, X_n$, os pesos são constantes conhecidas, e portanto $\bar{\beta}$ é uma função linear de $Y_1, \dots, Y_n$ — que é exatamente o sentido de “linear” na classe de estimadores do Teorema de Gauss-Markov. (Note o caso degenerado: se $\bar{X} = 0$, o estimador não está definido.)

b. **Não-viés condicional.** Substituindo o modelo verdadeiro,

$$\bar{\beta} = \frac{\bar{Y}}{\bar{X}} = \frac{\frac{1}{n} \sum_i (\beta X_i + u_i)}{\bar{X}} = \frac{\beta \bar{X} + \bar{u}}{\bar{X}} = \beta + \frac{\bar{u}}{\bar{X}}.$$

Tomando esperança condicional em $X = (X_1, \dots, X_n)$, e usando que $\bar{X}$ é conhecido dado X :

$$\mathbb{E}(\bar{\beta} | X) = \beta + \frac{1}{\bar{X}} \mathbb{E}(\bar{u} | X) = \beta + \frac{1}{\bar{X}} \cdot \frac{1}{n} \sum_{i=1}^n \mathbb{E}(u_i | X_i) = \beta + 0 = \beta,$$

pela Hipótese 1. Logo

$$\boxed{\mathbb{E}(\bar{\beta} | X) = \beta}$$

e, pela lei das expectativas iteradas, $\mathbb{E}(\bar{\beta}) = \beta$: o estimador é não viesado, condicional e incondicionalmente.

i O que o exercício está realmente mostrando

$\bar{\beta}$ é linear e não viesado — mas **não é o MQO**. O estimador de MQO neste modelo é $\tilde{\beta} = \sum X_i Y_i / \sum X_i^2$ (item (c) da Questão 7 da Lista 3). Pelo Teorema de Gauss-Markov, sob homocedasticidade, $\text{Var}(\tilde{\beta}) \leq \text{Var}(\bar{\beta})$: $\bar{\beta}$ é uma alternativa legítima e honesta, apenas **menos precisa**.

A intuição é clara. O MQO pondera cada observação por X_i , dando mais peso àquelas em que o regressor é grande — que são as mais informativas sobre a inclinação. $\bar{\beta}$ pondera todas igualmente, jogando fora essa informação. É um exemplo concreto e mínimo do que o teorema quer dizer.

Questão 5. Regressor binário, $Y_i = \beta_0 + \beta_1 X_i + u_i$ com $X_i \in \{0, 1\}$. Sejam $n_1 = \sum_i X_i$ o número de observações com $X = 1$ e $n_0 = n - n_1$ o número com $X = 0$, de modo que $\bar{X} = n_1/n$.

A demonstração mais econômica parte das duas condições de ortogonalidade, que caracterizam completamente o MQO:

$$(i) \sum_{i=1}^n \hat{u}_i = 0, \quad (ii) \sum_{i=1}^n X_i \hat{u}_i = 0.$$

Como $X_i \in \{0, 1\}$, a condição (ii) soma os resíduos **apenas** do grupo $X = 1$:

$$\sum_{i: X_i=1} \hat{u}_i = 0.$$

Subtraindo (ii) de (i), obtemos o mesmo para o outro grupo:

$$\sum_{i: X_i=0} \hat{u}_i = 0.$$

Ou seja, **os resíduos somam zero dentro de cada grupo separadamente**. Mas o valor ajustado é constante dentro de cada grupo: $\hat{Y}_i = \hat{\beta}_0$ quando $X_i = 0$ e $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1$ quando $X_i = 1$. Logo, para o grupo $X = 0$,

$$0 = \sum_{i: X_i=0} (Y_i - \hat{\beta}_0) = n_0 \bar{Y}_0 - n_0 \hat{\beta}_0 \implies \boxed{\hat{\beta}_0 = \bar{Y}_0}$$

e, para o grupo $X = 1$,

$$0 = \sum_{i: X_i=1} (Y_i - \hat{\beta}_0 - \hat{\beta}_1) = n_1 \bar{Y}_1 - n_1(\hat{\beta}_0 + \hat{\beta}_1) \implies \boxed{\hat{\beta}_0 + \hat{\beta}_1 = \bar{Y}_1}$$

Subtraindo as duas,

$$\boxed{\hat{\beta}_1 = \bar{Y}_1 - \bar{Y}_0}$$

O argumento revela por que o resultado é verdadeiro: com um regressor binário, a reta de MQO tem **dois parâmetros e dois grupos**, de modo que ela pode passar exatamente pela média de cada grupo — e o MQO, ao minimizar a soma de quadrados, faz precisamente isso, já que a média é o minimizador da soma de desvios quadráticos.

A consequência conceitual foi registrada na Seção 5 e vale repetir: **a regressão com regressor binário é literalmente uma comparação de médias**, e testar $H_0 : \beta_1 = 0$ é testar a igualdade de médias entre os dois grupos. É a ponte que liga o instrumento econométrico ao arcabouço experimental do Seção 2.

Questão 6. Aqui o exercício percorre, em ordem decrescente de hipóteses, os três regimes de garantia sobre o MQO.

- a. **Sim, $\hat{\beta}_1$ é condicionalmente não viesado.** Basta a Hipótese 1: $\mathbb{E}(u_i | X_i) = 0$. A demonstração é a do 1 e usa apenas a média condicional do erro — normalidade, homocedasticidade e independência não desempenham papel algum nela. Note, aliás, que a independência entre u_i e X_i assumida no enunciado é **mais forte** do que a Hipótese 1, e portanto certamente a implica.
- b. **Sim — e mais do que isso.** Sob as hipóteses do enunciado, $\hat{\beta}_1$ é o melhor estimador linear condicionalmente não viesado (BLUE). A razão: a independência entre u_i e X_i implica, em particular, que $\text{Var}(u_i | X_i) = \text{Var}(u_i) = \sigma_u^2$ não depende de X_i — isto é, **homocedasticidade**. Com as três hipóteses de MQO mais homocedasticidade, valem exatamente as condições do **Teorema de Gauss-Markov**, e o MQO é BLUE.

Vale acrescentar o que a normalidade compra a mais, e que o enunciado não pergunta: sob erros normais, $\hat{\beta}_1$ é o **melhor estimador não viesado**, período — a restrição a estimadores lineares torna-se dispensável. E sua distribuição é exatamente normal em **qualquer** tamanho de amostra, com a estatística t seguindo uma t de Student com $n - 2$ graus de liberdade exatamente, em vez de aproximadamente.

- c. Retiramos a normalidade e a independência, mantendo as três hipóteses de MQO e a **homocedasticidade**. As duas respostas **não mudam**:
 - (a) continua **sim** — o não-viés nunca dependeu de nada além da Hipótese 1;
 - (b) continua **sim** — o Teorema de Gauss-Markov exige as três hipóteses de MQO mais homocedasticidade, e nada mais. A normalidade não é hipótese do teorema.

O que se perde é a exatidão da distribuição em amostras finitas: sem normalidade, a normalidade de $\hat{\beta}_1$ é apenas **assintótica**, garantida pelo TCL, e a inferência em amostras pequenas passa a ser aproximada.

- d. Retiramos também a homocedasticidade, ficando apenas com as três hipóteses de MQO:

- (a) continua **sim**. Repito o ponto porque ele é o mais importante do exercício: **heterocedasticidade não vieso o MQO**. Ela não aparece em nenhum passo da demonstração de não-viés, que usa somente $\mathbb{E}(u_i | X_i) = 0$.
- (b) **não**. O Teorema de Gauss-Markov deixa de valer, porque a homocedasticidade era uma de suas hipóteses. $\hat{\beta}_1$ continua linear e não viesado, mas **não é mais garantidamente o de menor variância** na classe: sob heterocedasticidade conhecida, o estimador de mínimos quadrados ponderados (que dá menos peso às observações de erro mais volátil) tem variância menor.

Além disso — e este é o ponto de maior consequência prática — as **fórmulas homocedásticas de erro-padrão passam a estar erradas**, e a inferência baseada nelas é inválida. É por isso que os erros-padrão robustos são o padrão da prática aplicada, e é por isso que os laboratórios destas notas os calculam explicitamente.

! O resumo dos três regimes

Hipóteses	Não viesado?	BLUE?	Inferência
MQO + homoced. + normalidade	Sim	Sim (e mais)	Exata em qualquer n
MQO + homocedasticidade	Sim	Sim	Assintótica; EP usuais válidos
MQO apenas	Sim	Não	Assintótica; exige EP robustos

A leitura da tabela é a mensagem do capítulo: o não-viés é robusto — sobrevive a tudo, desde que a Hipótese 1 valha. É a **eficiência** e a **validade dos erros-padrão** que são frágeis. E, das duas, a segunda é a que efetivamente muda conclusões empíricas.

6 Regressão Linear com Múltiplos Regressores

Os três capítulos anteriores construíram um instrumento e mediram a incerteza que ele carrega. O 1 obteve o estimador de MQO da reta que liga $TestScore$ e STR ; o Seção 5 ensinou a testar hipóteses sobre a inclinação dessa reta e a construir intervalos para ela. O resultado, repetido em todos os slides desde a Aula 3, é

$$\widehat{TestScore} = 698,9 - 2,28 \cdot STR.$$

Este capítulo começa perguntando se esse $-2,28$ significa o que parece significar.

A dúvida não é retórica. A Hipótese 1, $\mathbb{E}(u_i | X_i) = 0$, exige que os **outros determinantes** do desempenho acadêmico estejam equilibrados entre distritos com turmas grandes e distritos com turmas pequenas. Na Califórnia, um desses outros determinantes é óbvio: a proporção de alunos que ainda está aprendendo inglês. O estado recebe uma população imigrante grande, sobretudo vinda do México, e uma parte substancial dos alunos tem o espanhol — ou outra língua que não o inglês — como língua nativa. Se essa proporção for maior justamente nos distritos de turmas grandes, então os dois grupos que estamos comparando diferem em mais de uma coisa, e atribuir toda a diferença de notas ao tamanho da turma é um erro.

O nome desse erro é **viés de variável omitida**, e ele é o assunto da primeira seção. As demais seções constroem a resposta: se a variável omitida é observável, **inclua-a na regressão**. Isso exige estender o modelo para múltiplos regressores — reformular o problema de mínimos quadrados, reinterpretar os coeficientes, corrigir as medidas de aderência, e enfrentar um problema novo que só aparece quando há mais de um regressor, a **multicolinearidade**. O capítulo fecha com a lista atualizada de hipóteses de MQO e com a distinção, sutil e importante, entre **variável de interesse** e **variável de controle**.

O capítulo corresponde à Aula 5 da disciplina e cobre o Capítulo 6 de Stock e Watson (2020).

6.1 Viés de variável omitida

Começamos pelo experimento ideal, como no Seção 2. Dois grupos de alunos são alocados aleatoriamente entre tratamento e controle, sendo o tratamento “sala com razão aluno-professor baixa”. Se o grupo de controle tem exatamente as mesmas características do grupo de tratamento — a única diferença sendo não ter recebido o tratamento —, então a diferença entre as médias dos grupos é o efeito causal.

Suponha agora que, por erro de desenho do experimento, o grupo de controle contenha uma proporção de alunos aprendendo inglês substancialmente maior do que a do grupo de tratamento. Denote essa proporção por $PctEL$. A diferença de médias ainda entrega o efeito causal da razão aluno-professor?

Não. Ela entrega o efeito da razão aluno-professor **somado ao** efeito da diferença de composição linguística entre os grupos, e nada nos dados separa as duas coisas. O experimento, ao falhar em equilibrar $PctEL$, deixou de ser um experimento.

! Viés de variável omitida

Viés de variável omitida é o viés no estimador de MQO do efeito causal de X sobre Y que resulta quando o regressor X é correlacionado com uma variável omitida.

Para que o viés ocorra, **duas** condições devem valer simultaneamente:

I. X é correlacionado com a variável omitida; II. a variável omitida é determinante da variável dependente Y .

Se qualquer uma das duas falhar, não há viés — ponto ao qual voltaremos, porque ele é a chave para decidir *quais* variáveis é preciso incluir na regressão.

6.1.1 Por que a Hipótese 1 falha

O mecanismo é direto e já está inteiramente contido na interpretação que demos ao termo de erro. Interpretamos u_i como **todos os outros fatores**, que não X , determinantes de Y . Se algum desses fatores é correlacionado com X , então o termo de erro é correlacionado com X — pois o fator está *contido* no termo de erro, e está contido nele exatamente porque é determinante de Y .

O exemplo canônico é o retorno da escolaridade. Considere

$$\log(Wage_i) = \beta_0 + \beta_1 Educ_i + u_i,$$

e suponha que o termo de erro contenha a variável não observável **habilidade**. A habilidade é determinante do salário (condição II) e é plausivelmente correlacionada com a escolaridade (condição I): pessoas mais habilidosas tendem a estudar mais, seja porque a escola lhes custa menos esforço, seja porque antecipam retorno maior. Nesse caso $\text{Corr}(Educ_i, u_i) \neq 0$, e portanto

$$\mathbb{E}(u_i | Educ_i) \neq 0 :$$

a Hipótese 1 de MQO está violada. A consequência é séria, e o professor faz questão de sublinhá-la: **o estimador de MQO é viesado, e esse viés não se dissipa em amostras grandes.**

Essa última observação distingue o viés de variável omitida de quase tudo o que discutimos até aqui. O ruído amostral — a razão pela qual $\hat{\beta}_1$ difere de β_1 em qualquer amostra finita — encolhe a uma taxa $1/\sqrt{n}$ e desaparece no limite. O viés de variável omitida, não. Ele é um erro de **identificação**, não de precisão.

6.1.2 A fórmula do viés

Podemos ser precisos sobre o tamanho e a direção do viés. Considere o modelo

$$Y_i = \beta_0 + \beta_1 X_i + u_i, \quad \text{com } \text{Corr}(X_i, u_i) = \rho_{Xu} \neq 0,$$

ou seja, assumindo explicitamente que a hipótese de média condicional zero **não** vale. Partimos da forma do estimador de MQO em termos de momentos populacionais, obtida no 1,

$$\text{plim } \hat{\beta}_1 = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}.$$

Substituindo $Y = \beta_0 + \beta_1 X + u$ no numerador e usando a bilinearidade da covariância,

$$\text{Cov}(X, \beta_0 + \beta_1 X + u) = \underbrace{\text{Cov}(X, \beta_0)}_{=0} + \beta_1 \text{Var}(X) + \text{Cov}(X, u),$$

de modo que

$$\text{plim } \hat{\beta}_1 = \frac{\beta_1 \text{Var}(X) + \text{Cov}(X, u)}{\text{Var}(X)} = \beta_1 + \frac{\text{Cov}(X, u)}{\text{Var}(X)}.$$

Escrevendo a covariância como $\text{Cov}(X, u) = \rho_{Xu} \sigma_X \sigma_u$ e simplificando, chegamos à expressão que resume tudo:

$$\boxed{\text{plim } \hat{\beta}_1 = \beta_1 + \rho_{Xu} \frac{\sigma_u}{\sigma_X}} \quad (1)$$

Três observações decorrem dela, e o professor as enumera:

[1] **O viés independe do tamanho da amostra.** O que a Equação 1 diz é que $\hat{\beta}_1$ **não converge em probabilidade** para β_1 : converge para β_1 mais um termo que não some. Ou seja, $\hat{\beta}_1$ não é um estimador **consistente** de β_1 na presença de viés de variável omitida. Coletar mais dados produz uma estimativa cada vez mais precisa — do número errado.

[2] **O tamanho do viés depende em larga medida de ρ_{Xu} .** Quanto maior a correlação entre o regressor e o termo de erro, maior o viés. O fator σ_u/σ_X também importa: um regressor com pouca variação própria amplifica o problema, pela mesma razão pela qual ele torna a estimação imprecisa.

[3] **A direção do viés depende do sinal de ρ_{Xu} .** Esse é o ponto de maior valor prático. Em muitas aplicações não temos a variável omitida, mas conseguimos argumentar sobre o **sinal** de sua correlação com o regressor e sobre o **sinal** de seu efeito sobre Y — e isso basta para saber se a estimativa que temos é um limite superior ou inferior para o efeito verdadeiro. No exemplo da escolaridade, ambos os sinais são positivos: a habilidade eleva o salário e é positivamente correlacionada com o estudo. Logo $\hat{\beta}_1$ **superestima** o retorno da escolaridade, e o número que obtemos é um teto para o efeito causal.

i As duas condições, relidas na fórmula

A Equação 1 torna transparentes as duas condições da definição. Se a variável omitida não é determinante de Y , ela não está em u e ρ_{Xu} não é afetada por ela. Se ela não é correlacionada com X , sua presença em u não gera $\rho_{Xu} \neq 0$. O viés exige **as duas** — e é por isso que a resposta correta à pergunta “que variáveis devo incluir?” nunca é “todas”: incluir variáveis irrelevantes custa precisão sem comprar nada em termos de viés. Voltaremos a isso na Seção 6, ao tratar de variáveis de controle.

6.1.3 Aplicando ao exemplo da Califórnia

Vejam os o caso concreto. Suponha que o modelo correto seja

$$TestScore_i = \beta_0 + \beta_1 STR_i + \beta_2 PctEL_i + v_i,$$

mas que estimemos a regressão com um regressor apenas. Nesse caso o erro da regressão estimada é $u_i = \beta_2 PctEL_i + v_i$, e presume-se $\mathbb{E}(v_i | STR_i, PctEL_i) = 0$. Aplicando a Equação 1 com esse u_i :

$$\text{plim } \hat{\beta}_1 = \beta_1 + \frac{\text{Cov}(STR, \beta_2 PctEL + v)}{\text{Var}(STR)} = \beta_1 + \beta_2 \frac{\text{Cov}(STR, PctEL)}{\text{Var}(STR)},$$

e, em termos de correlação,

$$\boxed{\text{plim } \hat{\beta}_1 = \beta_1 + \beta_2 \rho_{STR, PctEL} \frac{\sigma_{PctEL}}{\sigma_{STR}}} \quad (2)$$

Os dois sinais são conhecidos. O coeficiente β_2 é negativo: um aluno que ainda está aprendendo a língua de instrução tende a ter desempenho menor no teste. E $\rho_{STR, PctEL}$ é positiva: nas escolas onde é alta a percentagem de alunos com inglês como segunda língua, também é alta a relação aluno-professor — as duas coisas andam juntas porque ambas refletem, em boa medida, a renda da região e o orçamento do distrito. O produto de um número negativo por um positivo é negativo: o viés puxa $\hat{\beta}_1$ para **baixo**, tornando o efeito do tamanho da turma mais negativo — isto é, mais favorável à política de reduzir turmas — do que ele realmente é.

Guarde esse prognóstico. A próxima seção o confirma numericamente.

6.2 O modelo de regressão linear múltiplo

A solução, quando a variável omitida é observável, é incluí-la. O **modelo de regressão linear múltiplo** estende o modelo univariado acrescentando variáveis explicativas:

$$\boxed{Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + u_i, \quad i = 1, \dots, n} \quad (3)$$

A **linha de regressão populacional** é a relação entre Y e os X s, em média, na população:

$$\mathbb{E}(Y_i | X_{1i} = x_1, X_{2i} = x_2, \dots, X_{ki} = x_k) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k.$$

Nada de conceitualmente novo aconteceu: continuamos modelando uma **média condicional**, como no Seção 3. O que mudou é que agora condicionamos em várias variáveis ao mesmo tempo — e é dessa mudança que vem toda a diferença de interpretação.

6.2.1 A interpretação dos coeficientes

Quando usado para inferência causal, o modelo múltiplo permite estimar o efeito sobre Y de uma mudança em X_1 **mantendo os demais regressores constantes**. Formalmente, tomando dois pontos que diferem apenas em X_1 :

$$\begin{aligned}\mathbb{E}(Y \mid X_1 = x_1 + \Delta x_1, X_2 = x_2, \dots) &= \beta_0 + \beta_1(x_1 + \Delta x_1) + \beta_2 x_2 + \dots \\ \mathbb{E}(Y \mid X_1 = x_1, X_2 = x_2, \dots) &= \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots\end{aligned}$$

Subtraindo, todos os termos em $x_2, \dots, x_k$ se cancelam e sobra $\beta_1 \Delta x_1$. Logo

$$\boxed{\beta_1 = \frac{\Delta Y}{\Delta X_1} \mid X_2, \dots, X_k \text{ constantes}}$$

O coeficiente β_1 é o **efeito parcial** de X_1 sobre Y : o que acontece com Y quando X_1 varia de uma unidade **e as demais variáveis incluídas não variam**. É o sentido preciso da expressão latina *ceteris paribus*, e a ênfase em “incluídas” é deliberada: a regressão mantém constante o que está nela, e nada mais. Variáveis omitidas continuam livres para variar junto com X_1 — razão pela qual a regressão múltipla mitiga, mas não elimina por decreto, o problema da seção anterior.

O intercepto β_0 é o valor esperado de Y quando **todos** os regressores são zero. Como no caso univariado, esse ponto costuma estar fora do suporte dos dados e a interpretação substantiva costuma ser vazia — mas o intercepto continua sendo necessário para que a reta (agora, o hiperplano) esteja na altura certa.

6.3 O estimador de MQO

A extensão do estimador é imediata. Os estimadores de MQO $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$ resolvem

$$\min_{b_0, b_1, \dots, b_k} \sum_{i=1}^n (Y_i - b_0 - b_1 X_{1i} - \dots - b_k X_{ki})^2. \quad (4)$$

O objetivo é o mesmo de sempre: escolher os coeficientes que minimizam a soma dos quadrados dos erros de previsão. O que muda é a dimensão do espaço de busca — antes uma reta no plano, agora um hiperplano em $\mathbb{R}^{k+1}$.

6.3.1 As condições de ortogonalidade

Derivando a Equação 4 em relação a cada b_j e igualando a zero, obtemos $k+1$ condições de primeira ordem. A derivada em relação a b_0 dá

$$-2 \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \dots - \hat{\beta}_k X_{ki}) = 0 \iff \sum_{i=1}^n \hat{u}_i = 0,$$

e a derivada em relação a cada b_j , $j = 1, \dots, k$, dá

$$-2 \sum_{i=1}^n X_{ji} (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \dots - \hat{\beta}_k X_{ki}) = 0 \iff \sum_{i=1}^n X_{ji} \hat{u}_i = 0.$$

Em conjunto:

$$\boxed{\sum_{i=1}^n \hat{u}_i = 0, \quad \sum_{i=1}^n X_{1i} \hat{u}_i = 0, \quad \dots, \quad \sum_{i=1}^n X_{ki} \hat{u}_i = 0} \quad (5)$$

São exatamente as condições do 1, uma para cada regressor. O resíduo de MQO é ortogonal a **todos** os regressores e à constante — o que, geometricamente, significa que $\hat{Y}$ é a projeção de Y sobre o espaço gerado pelos regressores, e $\hat{u}$ é o que sobra, perpendicular a esse espaço.

Os valores preditos e os resíduos são definidos como antes:

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_{1i} + \dots + \hat{\beta}_k X_{ki}, \quad \hat{u}_i = Y_i - \hat{Y}_i, \quad i = 1, \dots, n.$$

i A forma matricial

Com k regressores, a solução explícita do sistema em notação escalar fica rapidamente ilegível. A forma compacta é matricial: empilhando as observações em $\mathbf{Y}$ ($n \times 1$) e os regressores em $\mathbf{X}$ ($n \times (k+1)$, com uma primeira coluna de uns para o intercepto), as Equação 5 se escrevem $\mathbf{X}'\hat{u} = \mathbf{0}$, e substituindo $\hat{u} = \mathbf{Y} - \mathbf{X}\hat{\beta}$ obtemos as **equações normais** $\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y}$, cuja solução é

$$\boxed{\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}}$$

Esta é a fórmula que o software de fato executa, e o professor a exibe no slide sobre multicolinearidade por uma razão específica: ela deixa visível **onde** a multicolinearidade perfeita quebra o procedimento — na inversão de $\mathbf{X}'\mathbf{X}$. Voltaremos a ela.

6.3.2 Aplicação: tamanho da turma e desempenho

Estimando a regressão com os dois regressores nos 420 distritos da Califórnia, o professor obtém

$$\widehat{TestScore} = 686,0 - 1,10 \cdot STR - 0,65 \cdot PctEL,$$

contra $\widehat{TestScore} = 698,9 - 2,28 \cdot STR$ da regressão simples. A saída do STATA que o slide reproduz, com erros-padrão robustos, é:

Regressor	Coef.	EP robusto	t	$P > t $	IC 95%
STR	-1,1013	0,4328	-2,54	0,011	(-1,952; -0,250)
$PctEL$	-0,6498	0,0310	-20,94	0,000	(-0,711; -0,589)
Intercepto	686,03	8,728	78,60	0,000	(668,88; 703,19)

com $n = 420$, $R^2 = 0,4264$ e $SER = 14,464$.

Por que o coeficiente do STR caiu tanto? A estimativa passou de $-2,28$ para $-1,10$ — praticamente a metade. A resposta está inteiramente na Equação 2. No modelo múltiplo, o coeficiente do STR **mantém $PctEL$ constante**; no modelo com um regressor apenas, $PctEL$ não é mantido fixo e varia junto com o STR , contribuindo com sua própria parcela negativa para a diferença de notas observada. O $-2,28$ estava creditando ao tamanho da turma um efeito que pertencia, em boa parte, à composição linguística do distrito.

Podemos verificar a aritmética. A Equação 2 prevê

$$\hat{\beta}_1^{\text{simples}} \approx \beta_1 + \beta_2 \rho_{STR, PctEL} \frac{\sigma_{PctEL}}{\sigma_{STR}},$$

com $\beta_1 \approx -1,10$ e $\beta_2 \approx -0,65$. Na amostra californiana, $\rho_{STR, PctEL} \approx 0,19$, $\sigma_{PctEL} \approx 18,3$ e $\sigma_{STR} \approx 1,89$, de modo que o termo de viés vale aproximadamente $-0,65 \times 0,19 \times 18,3/1,89 \approx -1,20$ — e $-1,10 - 1,20 = -2,30$, contra o $-2,28$ observado. A fórmula do viés não é uma peça de teoria decorativa: ela **reconcilia numericamente** as duas regressões.

! O que a queda do coeficiente significa — e o que não significa

É tentador ler a queda de $-2,28$ para $-1,10$ como “descobrimos o efeito verdadeiro”. Não foi isso que aconteceu. O que aconteceu é que **eliminamos um viés específico**, o devido à omissão de $PctEL$. Se houver ainda uma terceira variável, omitida das duas regressões, correlacionada com o STR e determinante do desempenho, o $-1,10$ continua viesado — e a Equação 1 continua se aplicando a ele.

A regressão múltipla é uma estratégia de **controle por observáveis**. Ela resolve o problema na medida exata em que os confundidores relevantes sejam (a) conhecidos e (b) medidos. O Seção 2 já havia registrado o limite: contra o confundidor não observado, ela nada pode. É essa limitação que motiva o restante do curso — painel, variáveis instrumentais, quase-experimentos.

6.4 Medidas de aderência

Três medidas são comumente reportadas com o modelo múltiplo: o erro-padrão da regressão, o R^2 e o R^2 **ajustado**. As duas primeiras são as do 1, com um ajuste de graus de liberdade; a terceira é nova, e existe por uma razão que vale entender antes da fórmula.

6.4.1 O erro-padrão da regressão

O SER continua sendo uma medida da dispersão da distribuição de Y em torno da linha de regressão — a magnitude típica do erro de previsão, nas unidades de Y :

$$\boxed{SER = s_{\hat{u}} = \sqrt{s_u^2}, \quad s_u^2 = \frac{1}{n - k - 1} \sum_{i=1}^n \hat{u}_i^2} \quad (6)$$

A única diferença em relação à fórmula do 1 é o denominador: divide-se por $n - k - 1$ em lugar de $n - 2$. A razão é a mesma que justificava o $n - 2$: estimamos $k + 1$ coeficientes a partir dos

dados, e cada coeficiente estimado impõe uma restrição sobre os resíduos — as $k + 1$ condições de ortogonalidade da Equação 5. Sobram, portanto, $n - k - 1$ **graus de liberdade**. Com $k = 1$ recuperamos $n - 2$, como deve ser.

6.4.2 O R^2

O R^2 é, como antes, a fração da variância amostral de Y explicada pelos regressores — ou, equivalentemente, um menos a fração **não** explicada:

$$R^2 = \frac{\text{ESS}}{\text{TSS}} = 1 - \frac{\text{SSR}}{\text{TSS}}, \quad \text{SSR} = \sum_{i=1}^n \hat{u}_i^2, \quad \text{TSS} = \sum_{i=1}^n (Y_i - \bar{Y})^2.$$

A decomposição $\text{TSS} = \text{ESS} + \text{SSR}$ continua valendo, pela mesma demonstração do 1 — ela depende apenas de $\sum \hat{u}_i = 0$ e $\sum \hat{Y}_i \hat{u}_i = 0$, e ambas seguem das condições de ortogonalidade.

Há, porém, uma propriedade do R^2 que no modelo múltiplo deixa de ser inofensiva:

! O R^2 nunca decresce com a inclusão de um regressor

Acrescentar uma variável à regressão **nunca** reduz o R^2 , e em geral o aumenta — mesmo que a variável seja ruído puro, sem relação alguma com Y .

A razão é puramente algébrica. O MQO com $k + 1$ regressores minimiza a soma de quadrados sobre um conjunto de candidatos que **contém** o conjunto disponível com k regressores (basta fazer $b_{k+1} = 0$). O mínimo sobre um conjunto maior não pode ser maior. Logo o SSR não pode subir, e o R^2 não pode cair.

Isso não quer dizer que mais um regressor melhore o modelo. Um R^2 que sobe ao acrescentarmos uma coluna de números aleatórios não está nos informando nada sobre a qualidade do ajuste; está apenas registrando que uma reta com mais parâmetros passa mais perto dos pontos.

6.4.3 O R^2 ajustado

Para corrigir essa característica, faz-se um ajuste no cálculo, conhecido como R^2 ajustado, ou $\bar{R}^2$:

$$\bar{R}^2 = 1 - \frac{n-1}{n-k-1} \cdot \frac{\sum_{i=1}^n \hat{u}_i^2}{\sum_{i=1}^n (Y_i - \bar{Y})^2} = 1 - \frac{n-1}{n-k-1} \cdot \frac{\text{SSR}}{\text{TSS}} \quad (7)$$

A diferença em relação à fórmula anterior é a presença do fator $\frac{n-1}{n-k-1}$ multiplicando o termo SSR/TSS . Equivalentemente, o $\bar{R}^2$ compara variâncias corrigidas por graus de liberdade em vez de somas de quadrados brutas.

Três observações:

[1] O $\bar{R}^2$ é sempre menor que o R^2 . O fator $\frac{n-1}{n-k-1}$ é sempre maior do que 1 (para $k \geq 1$), de modo que ele infla o termo subtraído.

[2] O $\bar{R}^2$ pode cair quando se acrescenta um regressor. Acrescentar uma variável tem dois efeitos opostos. Por um lado, o SSR cai — o que aumenta o $\bar{R}^2$. Por outro, o fator $\frac{n-1}{n-k-1}$ aumenta, porque k cresceu — o que o reduz. Qual dos dois predomina depende de quanto o novo regressor de fato explica. Um regressor inútil reduz o SSR de um tanto desprezível e paga o preço integral no fator: o $\bar{R}^2$ cai. É exatamente o comportamento que queríamos.

[3] O $\bar{R}^2$ pode ser negativo. Isso acontece quando os regressores, tomados em conjunto, reduzem o SSR por um montante tão pequeno que não compensa o aumento no fator de correção.

i Uma advertência que vale repetir

O $\bar{R}^2$ resolve um problema algébrico específico e nada mais. Ele **não** é um critério para decidir quais variáveis incluir numa regressão causal, e maximizá-lo é uma péssima estratégia de modelagem. A pergunta “esta variável deve entrar?” é respondida pelas **duas condições do viés de variável omitida** — a variável é determinante de Y ? é correlacionada com o regressor de interesse? —, e não por uma medida de aderência.

Como já registramos no 1, um R^2 alto não é evidência de causalidade, e um R^2 baixo não invalida uma estimativa causal. A regressão do Seção 5 tinha $R^2 \approx 0,05$ e produzia um coeficiente estimado com precisão perfeitamente utilizável.

6.5 Multicolinearidade

É comum, em aplicações, que as variáveis explicativas tenham alto grau de correlação entre si. Suponha que, no exemplo do *TestScore*, a lista de regressores incluísse também o gasto por aluno e o número de computadores por aluno. Claramente essas variáveis são correlacionadas entre si e com o *STR* — todas refletem o orçamento do distrito. Isso é um problema?

A resposta depende de qual dos dois casos estamos tratando, e a distinção é nítida.

6.5.1 Multicolinearidade perfeita

! Multicolinearidade perfeita

Ocorre quando um regressor é uma **combinação linear exata** dos demais regressores (incluindo a constante).

O exemplo do professor: numa regressão de $\log(Wage)$ sobre *Educ*, o pesquisador resolve incluir a **experiência** como regressor, calculada como a idade do indivíduo menos 21 anos. Se ele incluir também a **idade**, teremos multicolinearidade perfeita, pois

$$Exper_i = Idade_i - 21$$

é uma combinação linear exata da idade e da constante.

Sob multicolinearidade perfeita **não é possível calcular** $\hat{\beta}$, e a razão é técnica e precisa. O software calcula o vetor de coeficientes por

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1} \mathbf{X}'\mathbf{Y}.$$

Sob multicolinearidade perfeita, a matriz $\mathbf{X}$ tem **posto incompleto**, pois uma de suas colunas é combinação linear exata das outras. Nesse caso $\mathbf{X}'\mathbf{X}$ é singular e **não pode ser invertida**. Não há solução única para o problema de minimização — há infinitas combinações de coeficientes que produzem exatamente os mesmos valores preditos, e portanto exatamente a mesma soma de quadrados.

A intuição por trás da álgebra é a que importa. O coeficiente de *Exper* deveria responder à pergunta “o que acontece com o salário quando a experiência sobe um ano, **mantida a idade constante?**” — e essa pergunta não tem resposta, porque nos dados é impossível aumentar a experiência sem aumentar a idade. Não é que o software falhou; é que pedimos a ele algo que os dados não contêm.

A solução é igualmente simples: **remova o regressor problemático**. No exemplo, basta deixar de fora ou a experiência ou a idade.

6.5.2 A armadilha da *dummy*

O caso clássico de multicolinearidade perfeita é a **armadilha da *dummy*** (*dummy trap*). Considere

$$Wage_i = \beta_0 + \beta_1 Female_i + \beta_2 Male_i + u_i,$$

com as duas *dummies* incluídas junto com o intercepto. Na matriz $\mathbf{X}$, a primeira coluna é de uns (referente ao intercepto). Por outro lado, a soma das colunas *Female* e *Male* **também** dá uma coluna de uns, pois todo indivíduo é uma coisa ou outra:

$$Female_i + Male_i = 1 \quad \text{para todo } i.$$

Temos, portanto, uma combinação linear perfeita entre três colunas — multicolinearidade perfeita.

! A regra

Quando se trabalha com um conjunto exaustivo e mutuamente exclusivo de *dummies* e o intercepto, deixa-se sempre **uma categoria de fora**. A categoria omitida vira a **categoria de referência**, e os coeficientes das demais medem diferenças em relação a ela.

No exemplo acima, omitindo *Male*, o modelo vira $Wage_i = \beta_0 + \beta_1 Female_i + u_i$, e recuperamos exatamente o caso do Seção 5: β_0 é o salário médio dos homens e β_1 é o diferencial feminino. Nenhuma informação foi perdida — a mesma regressão, escrita sem redundância.

A regra vale para qualquer partição: G categorias exaustivas geram $G - 1$ *dummies* quando há intercepto. Ela é a resposta ao item [b] da Questão 4 da Lista 3, sobre por que a região Oeste é omitida da regressão de salários.

6.5.3 Multicolinearidade imperfeita

! Multicolinearidade imperfeita

Ocorre quando dois ou mais regressores são **altamente correlacionados** entre si, sem que haja combinação linear exata.

Considere a regressão

$$TestScore_i = \beta_0 + \beta_1 STR_i + \beta_2 PE_i + \beta_3 PC_i + u_i,$$

onde PE é o gasto por aluno e PC é a razão computadores por aluno. Naturalmente os três regressores são correlacionados entre si. Isso é um problema?

Não chega a ser um problema — é uma característica dos dados. Diferentemente do caso perfeito, aqui $\mathbf{X}'\mathbf{X}$ é invertível, o MQO tem solução única, e os estimadores permanecem **não viesados**. Nenhuma hipótese foi violada. Mas há observações importantes a fazer, e todas elas agem através da **variância** de $\hat{\beta}$.

Considere o modelo com dois regressores,

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i.$$

Assumindo erros homocedásticos — hipótese implausível, como sabemos desde o Seção 5, mas irrelevante para o ponto que queremos mostrar —, a variância do estimador do primeiro coeficiente é

$$\text{Var}(\hat{\beta}_1) = \frac{1}{n} \cdot \frac{1}{1 - \rho_{X_1 X_2}^2} \cdot \frac{\sigma_u^2}{\sigma_{X_1}^2} \quad (8)$$

Note o fator do meio. A variância de $\hat{\beta}_1$ depende do coeficiente de correlação entre X_1 e X_2 : quanto maior essa correlação em valor absoluto, menor o denominador $1 - \rho^2$, e **maior** a variância do estimador. No limite $\rho^2 \rightarrow 1$ — a multicolinearidade perfeita — a variância explode, o que é a versão contínua da impossibilidade de calcular $\hat{\beta}$.

Isso explica o efeito da multicolinearidade imperfeita: ela torna a estimação dos efeitos parciais β_1 e β_2 **altamente imprecisa**. Erros-padrão grandes, estatísticas t pequenas, intervalos de confiança largos — e, frequentemente, o sintoma clássico: um teste conjunto indica que os regressores explicam muito, mas nenhum coeficiente individual é significativo.

A razão é a mesma de sempre, e é a razão pela qual insisti no 1 que a precisão do MQO depende da **variação do regressor**. O coeficiente β_1 é o efeito de X_1 mantendo X_2 constante; para estimá-lo, precisamos observar variação em X_1 que **não** seja acompanhada de variação em X_2 . Quanto mais correlacionadas as duas variáveis, menos variação desse tipo existe nos dados, e menos informação a amostra contém sobre o efeito parcial.

i Multicolinearidade é um problema de amostra pequena

O professor fecha a seção com uma observação que reorganiza o assunto: todos os efeitos da multicolinearidade imperfeita — imprecisão na estimação dos efeitos parciais — são **exatamente equivalentes** aos efeitos de se trabalhar com uma amostra pequena.

A Equação 8 torna isso literal: o fator $\frac{1}{1-\rho^2}$ multiplica a variância exatamente como faria uma redução do tamanho amostral de n para $n(1-\rho^2)$. Duas variáveis com $\rho = 0,9$ deixam os coeficientes tão imprecisos quanto uma amostra cinco vezes menor.

Daí segue a recomendação prática: **aumentar o tamanho da amostra**, se possível, mitiga os efeitos da multicolinearidade imperfeita. E daí segue também a postura correta diante dela — não há teste a fazer nem correção a aplicar; há uma limitação dos dados a reconhecer e, se for o caso, reportar honestamente.

6.6 As hipóteses de MQO na regressão múltipla

Discutimos agora as hipóteses requeridas para que os estimadores de MQO produzam estimativas válidas do efeito causal. O professor considera inicialmente o caso em que estamos interessados no efeito causal de **todos** os k regressores — isto é, todos os coeficientes $\beta_1, \dots, \beta_k$ têm interpretação causal. Podemos ter também o caso em que apenas alguns coeficientes são de interesse, enquanto os demais pertencem a variáveis incluídas para controlar por fatores omitidos e **não têm interpretação causal**; esse caso é o assunto da última seção.

Para o modelo $Y_i = \beta_0 + \beta_1 X_{1i} + \dots + \beta_k X_{ki} + u_i$:

! As quatro hipóteses de MQO

[1] **Média condicional zero.**

$$\mathbb{E}(u_i \mid X_{1i}, X_{2i}, \dots, X_{ki}) = 0$$

[2] **Amostragem i.i.d.** As observações $(X_{1i}, \dots, X_{ki}, Y_i)$, $i = 1, \dots, n$, são extrações independentes e identicamente distribuídas da distribuição conjunta.

[3] **Valores extremos são improváveis.** $X_{1i}, \dots, X_{ki}$ e Y_i têm quarto momento não nulo e finito.

[4] **Não há multicolinearidade perfeita.**

As três primeiras são as do 1, com a única diferença de que a Hipótese 1 agora condiciona em **todos** os regressores. A quarta é nova, e é a formalização da seção anterior — sem ela o estimador simplesmente não existe.

A Hipótese 1 merece o mesmo comentário que mereceu no caso univariado, agora com uma nuance importante. Ela continua não sendo testável, e continua sendo a hipótese que carrega todo o peso da inferência causal. Mas ela ficou **mais plausível**: condicionar em mais variáveis é uma exigência mais fraca do que condicionar em uma só, porque tudo o que incluímos deixou de estar em u . É esse, precisamente, o sentido em que a regressão múltipla é um avanço sobre a simples — e é também o sentido exato em que ela não é uma solução geral, já que o que permanece omitido permanece em u .

6.6.1 Distribuição assintótica

O resultado que sustenta a inferência é a extensão natural do Seção 5:

! Normalidade assintótica

Se as hipóteses de MQO são válidas, então em amostras grandes os estimadores $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_k$ são **conjuntamente normalmente distribuídos**, e cada um é distribuído como

$$\hat{\beta}_j \sim \mathcal{N}\left(\beta_j, \sigma_{\hat{\beta}_j}^2\right), \quad j = 0, 1, \dots, k.$$

A consequência prática é que toda a maquinaria do Seção 5 se transporta sem alteração: a estatística $t = (\hat{\beta}_j - \beta_{j,0})/\text{SE}(\hat{\beta}_j)$ tem distribuição $\mathcal{N}(0, 1)$ sob a nula em amostras grandes, o intervalo de confiança de 95% é $\hat{\beta}_j \pm 1,96 \text{SE}(\hat{\beta}_j)$, e a dualidade entre teste e intervalo continua valendo. A leitura de cada linha da tabela de regressão é a mesma de antes.

O que a palavra **conjuntamente** acrescenta é a possibilidade de testar hipóteses sobre **vários** coeficientes ao mesmo tempo — se $\beta_2 = \beta_3 = 0$, por exemplo, ou se $\beta_1 = \beta_2$. Esses testes conjuntos exigem a estatística F e são o assunto da próxima aula; a normalidade conjunta é o resultado que os habilita.

6.7 Variáveis de controle e independência em média condicional

Fechamos o capítulo explicitando uma distinção que estivemos usando implicitamente: a que separa o regressor cujo efeito causal queremos estimar — a **variável de interesse** — dos demais regressores, as **variáveis de controle**.

! Variável de controle

Uma **variável de controle** não é objeto de interesse do estudo. É um regressor incluído para manter constante fatores que, se negligenciados, poderiam levar a viés de variável omitida no coeficiente da variável de interesse.

A distinção não é técnica — a álgebra do MQO trata todos os regressores igualmente — mas **interpretativa**, e ela muda o que podemos afirmar sobre cada coeficiente da mesma tabela. Vejamos no exemplo do professor.

Acrescentando à regressão a variável *LchPct*, a porcentagem de alunos que recebe almoço gratuito ou subsidiado — benefício dado a alunos de baixa renda —, obtém-se

$$\widehat{TestScore} = 700,2 - 1,00 \cdot STR - 0,122 \cdot PctEL - 0,547 \cdot LchPct.$$

Aqui *STR* é a variável de interesse, e *PctEL* e *LchPct* são controles. A pergunta do slide é: **como interpretar o coeficiente de *LchPct*?**

A resposta é que ele **não deve ser interpretado causalmente**. Ninguém sustentaria que retirar o almoço subsidiado de um aluno elevaria sua nota em 0,547 pontos — a direção plausível do efeito é a oposta. O que *LchPct* faz na regressão é servir de *proxy* para a renda familiar e para todo o

conjunto de desvantagens socioeconômicas que a acompanham. Seu coeficiente mistura o efeito do almoço com o efeito de tudo aquilo pelo que ele serve de indicador, e não há como separar as duas coisas nesses dados.

E, no entanto, incluí-la é correto e importante. Ela cumpre exatamente sua função: torna a Hipótese 1 mais plausível para o coeficiente do *STR*, absorvendo a variação socioeconômica que de outro modo estaria em u e correlacionada com o tamanho da turma. Note, aliás, o que aconteceu com o coeficiente de *PctEL*: caiu de $-0,65$ para $-0,122$, o que sugere que boa parte do que atribuíamos à condição linguística era, na verdade, condição econômica.

! A hipótese relevante para variáveis de controle

Formalmente, a hipótese que sustenta o uso de controles é mais fraca do que a média condicional zero — chama-se **independência em média condicional**. Sendo X_1 a variável de interesse e W o conjunto de controles, ela exige

$$\mathbb{E}(u_i | X_{1i}, W_i) = \mathbb{E}(u_i | W_i)$$

Em palavras: **dados os controles**, o valor da variável de interesse não carrega informação adicional sobre os fatores omitidos. O termo de erro pode perfeitamente correlacionar-se com W — e é justamente por isso que o coeficiente de W não tem interpretação causal —, desde que, condicional a W , não se correlacione com X_1 .

É a formalização exata do argumento de que *STR* é “como se” aleatório **entre distritos com o mesmo perfil socioeconômico e linguístico**, ainda que não o seja na população inteira. Sob essa hipótese, $\hat{\beta}_1$ estima o efeito causal de X_1 , enquanto os demais coeficientes estimam apenas o que o nome diz: associações parciais, úteis para o condicionamento e mudas quanto a causalidade.

O ponto merece ser guardado, porque é uma fonte recorrente de má leitura de tabelas de regressão aplicada. Uma tabela com dez regressores raramente tem dez efeitos causais. Ela tem, tipicamente, **um** — o da variável de interesse — e nove associações condicionais cuja única função é tornar aquele um defensável. Reportar os dez com a mesma linguagem causal, como se fossem dez achados, é um erro que o professor faz questão de antecipar.

6.8 Laboratório computacional em R

O laboratório deste capítulo tem uma tarefa central: **exibir o viés de variável omitida em funcionamento**, verificando numericamente a Equação 1 e mostrando que ele não some com o crescimento da amostra. Em seguida, verifica o comportamento do R^2 contra o $\bar{R}^2$ diante de regressores inúteis, e mede o custo da multicolinearidade imperfeita.

Vale a mesma advertência do 1: os dados são **simulados e calibrados**, não os dados originais de Stock e Watson (2020). A vantagem, aqui, é considerável — numa simulação nós **conhecemos** β_1 , e é isso que permite falar em viés com precisão em vez de por analogia.

```
set.seed(6205)
n_d <- 420

# parametros "populacionais" do modelo COMPLETO
```

```

b0 <- 686.0; b1 <- -1.10; b2 <- -0.65

# PctEL correlacionado com STR: geramos STR e depois PctEL condicionalmente
STR <- rnorm(n_d, mean = 19.64, sd = 1.89)
rho <- 0.19 # correlacao alvo entre STR e PctEL
sd_el <- 18.3
PctEL <- pmax(0, 35.8 + rho * (sd_el / 1.89) * (STR - 19.64) +
              rnorm(n_d, 0, sd_el * sqrt(1 - rho^2)))
u <- rnorm(n_d, 0, 14.4)
TestScore <- b0 + b1 * STR + b2 * PctEL + u

ca <- data.frame(TestScore, STR, PctEL)
round(c(cor_STR_PctEL = cor(ca$STR, ca$PctEL),
      sd_STR = sd(ca$STR),
      sd_PctEL = sd(ca$PctEL)), 3)

```

cor_STR_PctEL	sd_STR	sd_PctEL
0.149	1.965	18.503

6.8.1 (a) O viés, medido

Estimamos a regressão simples (omitindo *PctEL*) e a múltipla, e comparamos com o $\beta_1 = -1,10$ que sabemos ser o verdadeiro.

```

simples <- lm(TestScore ~ STR, data = ca)
multipla <- lm(TestScore ~ STR + PctEL, data = ca)

round(c(verdadeiro = b1,
      simples = coef(simples)[["STR"]],
      multipla = coef(multipla)[["STR"]],
      ep_mult = summary(multipla)$coefficients["STR", 2]), 4)

```

verdadeiro	simples	multipla	ep_mult
-1.1000	-2.4803	-1.5332	0.3314

A regressão simples produz um coeficiente bem mais negativo que o verdadeiro. A múltipla se aproxima dele, mas não o acerta em cheio — e a última coluna explica por quê: com $n = 420$ e uma correlação modesta entre os regressores, o erro-padrão de $\hat{\beta}_1$ é da ordem de 0,33, de modo que a estimativa está a pouco mais de **um erro-padrão** do valor verdadeiro. Isso é ruído amostral corriqueiro, não viés.

E é justamente essa a distinção que o laboratório precisa tornar visível, porque as duas coisas se confundem numa única amostra. A separação exige aumentar n : **o ruído encolhe, o viés não**. Repetimos as duas regressões com uma amostra grande do mesmo processo gerador.

```

gera <- function(n) {
  STR <- rnorm(n, 19.64, 1.89)
  PctEL <- pmax(0, 35.8 + rho * (sd_el / 1.89) * (STR - 19.64) +
               rnorm(n, 0, sd_el * sqrt(1 - rho^2)))
  data.frame(TestScore = b0 + b1 * STR + b2 * PctEL + rnorm(n, 0, 14.4),
             STR = STR, PctEL = PctEL)
}

set.seed(6205)
grande <- gera(50000)
s_g <- lm(TestScore ~ STR, data = grande)
m_g <- lm(TestScore ~ STR + PctEL, data = grande)

round(c(verdadeiro = b1,
        simples = coef(s_g)[["STR"]],
        multipla = coef(m_g)[["STR"]]), 4)

```

verdadeiro	simples	multipla
-1.1000	-2.3157	-1.1467

Agora o quadro é nítido. A regressão múltipla praticamente crava o $-1,10$ verdadeiro; a simples estaciona perto de $-2,3$, e **não** se move em direção ao valor correto. Um estimador é consistente; o outro não é.

Verifiquemos, nessa amostra grande, que a Equação 1 prevê o desvio observado. Ela diz que o viés vale $\beta_2 \rho_{X_1 X_2} \sigma_{X_2} / \sigma_{X_1}$.

```

vies_previsto <- b2 * cor(grande$STR, grande$PctEL) * sd(grande$PctEL) / sd(grande$STR)
vies_efetivo <- coef(s_g)[["STR"]] - b1

round(c(previsto = vies_previsto, efetivo = vies_efetivo), 4)

```

previsto	efetivo
-1.1636	-1.2157

Os dois números são próximos, e a folga que resta tem explicação: o truncamento em zero imposto por `pmax()` torna a relação entre *STR* e *PctEL* ligeiramente não linear, e a Equação 1 é uma fórmula sobre **projeções lineares**. A fórmula do viés não é, portanto, um enfeite algébrico: ela **prevê quantitativamente** o que a omissão faz ao estimador, e o pequeno resíduo aponta exatamente para a hipótese que a sustenta.

6.8.2 (b) O viés não desaparece com n

Este é o ponto central da seção 1 do capítulo, e a simulação o torna visível. Repetimos a estimação para tamanhos amostrais crescentes, com muitas réplicas em cada um, e acompanhamos a média das estimativas.

```

simula_um <- function(n) {
  d <- gera(n) # mesmo processo gerador da secao (a)
  c(simples = coef(lm(TestScore ~ STR, data = d))["STR"],
    multipla = coef(lm(TestScore ~ STR + PctEL, data = d))["STR"])
}

ns <- c(50, 200, 1000, 5000, 20000)
res <- t(sapply(ns, function(n) rowMeans(replicate(300, simula_um(n)))))
tab <- data.frame(n = ns, round(res, 4), verdadeiro = b1)
tab

```

	n	simples	multipla	verdadeiro
1	50	-2.2335	-1.0581	-1.1
2	200	-2.2595	-1.1092	-1.1
3	1000	-2.2736	-1.0973	-1.1
4	5000	-2.2591	-1.0984	-1.1
5	20000	-2.2708	-1.1050	-1.1

A coluna *multipla* converge para $-1,10$; a coluna *simples* converge para um número **diferente**, e não se move em direção ao valor verdadeiro conforme n cresce de 50 para 20.000. É a diferença entre um estimador consistente e um inconsistente, vista em números.




Figura 8: Viés de variável omitida contra ruído amostral. Cada ponto é a média de 300 estimativas de β_1 para o tamanho amostral indicado (escala logarítmica). O estimador da regressão múltipla (azul) converge para o verdadeiro $\beta_1 = -1,10$, marcado pela linha tracejada. O da regressão simples (vermelho), que omite *PctEL*, converge para outro número — e a distância até a linha tracejada não encolhe com n . Aumentar a amostra melhora a precisão, nunca a identificação.

6.8.3 (c) O sinal do viés é previsível

A Equação 1 diz que o sinal do viés é o do produto $\beta_2 \times \rho_{X_1X_2}$. Verificamos as quatro combinações possíveis, alterando o sinal de cada um.

```
vies_de <- function(beta2, rho_alvo, n = 20000) {  
  X1 <- rnorm(n, 0, 1)  
  X2 <- rho_alvo * X1 + rnorm(n, 0, sqrt(1 - rho_alvo^2))  
  Y <- 1 + 2 * X1 + beta2 * X2 + rnorm(n, 0, 1)  
  coef(lm(Y ~ X1))["X1"] - 2          # beta1 verdadeiro = 2  
}  
  
grade <- expand.grid(beta2 = c(-3, 3), rho = c(-0.6, 0.6))  
grade$vies <- round(mapply(vies_de, grade$beta2, grade$rho), 3)  
grade$sinal_previsto <- ifelse(sign(grade$beta2 * grade$rho) > 0, "+", "-")  
grade
```

	beta2	rho	vies	sinal_previsto
1	-3	-0.6	1.794	+
2	3	-0.6	-1.806	-
3	-3	0.6	-1.779	-
4	3	0.6	1.842	+

O viés é positivo quando β_2 e ρ têm o mesmo sinal, e negativo quando têm sinais opostos — exatamente como a fórmula prevê. É esse raciocínio que permite, numa aplicação em que a variável omitida não está disponível, afirmar que a estimativa obtida é um limite superior ou inferior para o efeito verdadeiro.

6.8.4 (d) R^2 contra $\bar{R}^2$ diante de ruído puro

Acrescentamos à regressão múltipla dez regressores gerados como **ruído independente**, sem relação alguma com *TestScore*, e observamos as duas medidas.

```
set.seed(99)  
lixo <- as.data.frame(matrix(rnorm(n_d * 10), nrow = n_d))  
names(lixo) <- paste0("ruído", 1:10)  
ca_lixo <- cbind(ca, lixo)  
  
m_base <- lm(TestScore ~ STR + PctEL, data = ca_lixo)  
m_lixo <- lm(TestScore ~ ., data = ca_lixo)  
  
round(rbind(  
  `com 2 regressores` = c(R2 = summary(m_base)$r.squared,  
                           R2_aj = summary(m_base)$adj.r.squared,  
                           SER = summary(m_base)$sigma),  
  `com 12 regressores` = c(R2 = summary(m_lixo)$r.squared,
```

```
R2_aj = summary(m_lixo)$adj.r.squared,
SER = summary(m_lixo)$sigma)), 4)
```

	R2	R2_aj	SER
com 2 regressores	0.5039	0.5015	13.1811
com 12 regressores	0.5245	0.5105	13.0617

O R^2 **subiu**, como tinha de subir: dez colunas de números aleatórios não podem reduzir a capacidade de ajuste, e por acaso reduzem um pouco o SSR. O $\bar{R}^2$ **caiu**, e o SER subiu — as duas medidas que penalizam parâmetros identificaram corretamente que os dez regressores não pagam seu custo em graus de liberdade.

Verificando a fórmula do $\bar{R}^2$ à mão, para deixar explícito o que o `summary()` calcula:

```
n <- nobs(m_lixo); k <- length(coef(m_lixo)) - 1
SSR <- sum(residuals(m_lixo)^2)
TSS <- sum((ca_lixo$TestScore - mean(ca_lixo$TestScore))^2)

round(c(R2_mao = 1 - SSR / TSS,
        R2_aj_mao = 1 - (n - 1) / (n - k - 1) * SSR / TSS,
        SER_mao = sqrt(SSR / (n - k - 1))), 4)
```

R2_mao	R2_aj_mao	SER_mao
0.5245	0.5105	13.0617

6.8.5 (e) O custo da multicolinearidade imperfeita

A Equação 8 prevê que a variância de $\hat{\beta}_1$ seja inflada pelo fator $1/(1-\rho^2)$. Verificamos por simulação, com ρ variando.

```
dp_de_rho <- function(rho_alvo, n = 200, R = 1000) {
  est <- replicate(R, {
    X1 <- rnorm(n)
    X2 <- rho_alvo * X1 + rnorm(n, 0, sqrt(1 - rho_alvo^2))
    Y <- 1 + 2 * X1 + 1 * X2 + rnorm(n)
    coef(lm(Y ~ X1 + X2))["X1"]
  })
  c(dp_empirico = sd(est), media = mean(est))
}

rhos <- c(0, 0.5, 0.9, 0.99)
out <- t(sapply(rhos, dp_de_rho))
data.frame(rho = rhos, round(out, 4),
           fator_previsto = round(sqrt(1 / (1 - rhos^2)), 3),
           fator_medido = round(out[, "dp_empirico"] / out[1, "dp_empirico"], 3))
```

	rho	dp_empirico	media	fator_previsto	fator_medido
1	0.00	0.0683	1.9996	1.000	1.000
2	0.50	0.0825	1.9985	1.155	1.208
3	0.90	0.1648	1.9968	2.294	2.413
4	0.99	0.5193	1.9852	7.089	7.601

Duas leituras. Primeiro, a coluna `fator_medido` acompanha de perto a `fator_previsto`: o desvio-padrão de $\hat{\beta}_1$ cresce como $1/\sqrt{1-\rho^2}$, e com $\rho = 0,99$ ele é cerca de sete vezes o do caso ortogonal. Segundo — e este é o ponto conceitual — a coluna `media` permanece em torno de 2 em todas as linhas: **a multicolinearidade não viesou nada**. Ela só destrói precisão, e é por isso que a resposta correta a ela é reconhecê-la, não “corrigi-la”.

6.8.6 (f) A armadilha da *dummy*, na prática

Por fim, o que o R faz quando lhe pedimos uma regressão perfeitamente colinear.

```
set.seed(7)
n2      <- 300
female  <- rbinom(n2, 1, 0.5)
male    <- 1 - female
wage    <- 12.5 - 2.1 * female + rnorm(n2, 0, 4)

coef(lm(wage ~ female + male))
```

(Intercept)	female	male
12.500792	-2.214558	NA

O R não devolve erro: ele detecta a coluna redundante e atribui NA ao coeficiente que não pode ser identificado, estimando o restante. O STATA emite uma mensagem de *omitted* e segue. O comportamento é razoável, mas a lição do slide permanece — **o software está tomando por nós uma decisão de especificação**, e é melhor tomá-la deliberadamente, escolhendo qual categoria será a de referência.

```
round(rbind(
  `referência = homens` = c(coef(lm(wage ~ female)), NA),
  `referência = mulheres` = c(coef(lm(wage ~ male)), NA)), 3)[, 1:2]
```

	(Intercept)	female
referência = homens	12.501	-2.215
referência = mulheres	10.286	2.215

As duas regressões contêm exatamente a mesma informação — intercepto e diferencial trocam de papel, o R^2 e o SER são idênticos —, como já sabíamos do Seção 5. A escolha da referência é de conveniência expositiva, não de substância.

6.9 Exercícios

1. **As duas condições.** Um pesquisador estima o efeito do uso de computador sobre o salário, regredindo $\log(Wage)$ sobre uma *dummy* de uso de computador no trabalho. Para cada variável omitida abaixo, diga se ela gera viés e, em caso positivo, qual o **signal** provável: (a) a altura do trabalhador; (b) a escolaridade; (c) o setor de atividade; (d) o número de irmãos. (e) Formule a regra geral que você usou, em termos das duas condições, e explique por que “incluir tudo o que estiver disponível” é uma má estratégia.
2. **A fórmula do viés, quantitativamente.** No modelo verdadeiro $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + v$, sabe-se que $\beta_2 = 4$, $\rho_{X_1 X_2} = -0,5$, $\sigma_{X_1} = 2$ e $\sigma_{X_2} = 6$. (a) Se a regressão omite X_2 e produz $\hat{\beta}_1 = 1,2$, qual é a estimativa implícita de β_1 ? (b) Em que direção o pesquisador erraria ao reportar 1,2? (c) Suponha que ele não conheça σ_{X_2} nem ρ , mas saiba apenas os sinais de β_2 e de ρ : que afirmação defensável ele ainda pode fazer? (d) Sob que condição a magnitude do viés seria desprezível mesmo com ρ e β_2 grandes?
3. **Efeito parcial.** Considere $\log(Wage) = \beta_0 + \beta_1 Educ + \beta_2 Exper + u$. (a) Interprete β_1 com precisão, dizendo exatamente o que é mantido constante. (b) Um crítico observa que, no mundo real, um ano a mais de escola normalmente significa um ano a **menos** de experiência — logo β_1 não corresponde a nenhum experimento realizável. Ele tem razão? O que isso implica sobre a quantidade que interessa a um jovem decidindo se continua estudando? (c) Como você reformularia o modelo para responder à pergunta dele?
4. **R^2 e $\bar{R}^2$.** (a) Demonstre algebricamente que $\bar{R}^2 < R^2$ sempre que $k \geq 1$. (b) Mostre que $\bar{R}^2 = 1 - \frac{s_u^2}{s_Y^2}$, ou seja, que ele compara variâncias corrigidas por graus de liberdade. (c) Deduza a condição sobre a estatística t do novo regressor sob a qual acrescentá-lo **aumenta** o $\bar{R}^2$ (dica: para um único regressor adicional, a condição é $|t| > 1$). (d) Comente: essa condição é um bom critério para decidir se a variável entra num modelo causal?
5. **Multicolinearidade.** (a) Em cada caso, diga se há multicolinearidade **perfeita** e por quê: (i) regressão com intercepto, *Idade* e *AnoNascimento* na mesma amostra transversal; (ii) intercepto e as quatro *dummies* de região; (iii) *Educ*, *Educ*² e intercepto; (iv) gasto em reais e gasto em milhares de reais. (b) Para os casos imperfeitos, o que se pode fazer? (c) Usando a Equação 8, calcule quanto o desvio-padrão de $\hat{\beta}_1$ é inflado com $\rho = 0,8$ e com $\rho = 0,95$, e traduza cada um em “equivalente a que redução do tamanho da amostra?”.
6. **Variáveis de controle.** Numa regressão de mortalidade infantil municipal sobre gasto público per capita em saúde, um pesquisador controla por renda média, escolaridade média e cobertura de saneamento. (a) Quais coeficientes ele pode interpretar causalmente?

(b) Enuncie a hipótese de independência em média condicional neste contexto e discuta sua plausibilidade. (c) O coeficiente do saneamento veio positivo e significativo — o que você diria a um jornalista que titula “estudo mostra que saneamento aumenta mortalidade infantil”? (d) Existe algum controle que seria um erro incluir? (Pense em uma variável que esteja no **caminho causal** entre gasto em saúde e mortalidade.)
7. **A armadilha da *dummy*, generalizada.** Uma amostra classifica trabalhadores em quatro regiões e dois sexos. (a) Quantas *dummies* podem entrar numa regressão com intercepto?

- (b) Escreva o modelo saturado com **interações** entre região e sexo: quantos parâmetros ele tem? (c) Mostre que esse modelo é equivalente a estimar a média de Y em cada uma das oito células. (d) O que aconteceria se uma das oito células estivesse vazia na amostra?
8. **Simulação.** Adapte o código da seção (b) do laboratório. (a) Faça $\rho_{X_1 X_2} \rightarrow 0$ e verifique que a regressão simples deixa de ser viesada — relacione com a Questão 6 da Lista 3. (b) Mantenha $\rho \neq 0$ mas faça $\beta_2 = 0$ e verifique o mesmo. (c) Com ambos diferentes de zero, compare o **erro quadrático médio** dos dois estimadores para n pequeno: existe algum n em que a regressão simples, apesar de viesada, erra menos? (d) O que esse resultado sugere sobre o *trade-off* entre viés e variância — e por que ele **não** é um argumento para omitir confundidores numa análise causal?

6.10 Lista de Exercícios 3

Sobre esta seção

Reproduzo aqui a **Lista 3** da disciplina (Prof. Marcelo Mello; monitor: Matheus Porto), cujas questões são os exercícios 6.1 a 6.11 de Stock e Watson (2020) e cobrem exatamente o conteúdo deste capítulo. O gabarito vem logo em seguida, com as resoluções desenvolvidas — a recomendação de sempre é tentar cada questão antes de consultá-lo.

As Questões 1 a 4 referem-se à tabela de regressões estimadas abaixo, calculada com dados de 1998 da *Current Population Survey* (CPS). O conjunto de dados consiste em informações sobre 4.000 trabalhadores em tempo integral e ano completo. A escolaridade mais alta de cada trabalhador era ou o diploma de ensino médio (*high school*) ou o diploma de graduação (*bachelor's degree*). As idades vão de 25 a 34 anos. Os dados contêm ainda informação sobre a região do país, estado civil e número de filhos. Para estes exercícios:

- AHE = salário médio por hora (em dólares de 1998);
- $College$ = binária (1 se graduação, 0 se ensino médio);
- $Female$ = binária (1 se mulher, 0 se homem);
- Age = idade (em anos);
- $Northeast, Midwest, South, West$ = binárias de região.

Tabela 2: Regressões de AHE sobre binárias de sexo e educação e outras características, CPS 1998. Variável dependente: salário médio por hora (AHE).

Regressor	(1)	(2)	(3)
$College (X_1)$	5,46	5,48	5,44
$Female (X_2)$	-2,64	-2,62	-2,62
$Age (X_3)$		0,29	0,29
$Northeast (X_4)$			0,69
$Midwest (X_5)$			0,60
$South (X_6)$			-0,27

Regressor	(1)	(2)	(3)
Intercepto	12,69	4,40	3,75
Estatísticas			
SER	6,27	6,22	6,21
R^2	0,176	0,190	0,194
$\bar{R}^2$			
n	4.000	4.000	4.000

Questão 1 (exercício 6.1). Calcule o $\bar{R}^2$ para cada uma das regressões.

Questão 2 (exercício 6.2). Usando os resultados da coluna (1):

- Trabalhadores com diploma de graduação ganham mais, em média, que trabalhadores apenas com ensino médio? Quanto mais?
- Homens ganham mais que mulheres, em média? Quanto mais?

Questão 3 (exercício 6.3). Usando os resultados da coluna (2):

- A idade é um determinante importante dos salários? Explique.
- Sally é uma mulher de 29 anos com diploma de graduação. Betsy é uma mulher de 34 anos com diploma de graduação. Preveja os salários de Sally e de Betsy.

Questão 4 (exercício 6.4). Usando os resultados da coluna (3):

- Parecem existir diferenças regionais importantes?
- Por que o regressor *West* é omitido da regressão? O que aconteceria se ele fosse incluído?
- Juanita é uma mulher de 28 anos com diploma de graduação, do Sul. Jennifer é uma mulher de 28 anos com diploma de graduação, do Meio-Oeste. Calcule a diferença esperada de salários entre Juanita e Jennifer.

Questão 5 (exercício 6.5). Dados foram coletados de uma amostra aleatória de 220 vendas de imóveis numa comunidade em 2003. Seja *Price* o preço de venda (em US\$ 1.000), *BDR* o número de quartos, *Bath* o número de banheiros, *Hsize* o tamanho da casa (em pés quadrados), *Lsize* o tamanho do terreno (em pés quadrados), *Age* a idade da casa (em anos) e *Poor* uma binária igual a 1 se a condição da casa é reportada como “ruim”. A regressão estimada é

$$\widehat{Price} = 119,2 + 0,485 BDR + 23,4 Bath + 0,156 Hsize + 0,002 Lsize + 0,090 Age - 48,8 Poor,$$

com $\bar{R}^2 = 0,72$ e $SER = 41,5$.

- Suponha que um proprietário converta parte de uma sala existente em um novo banheiro. Qual é o aumento esperado no valor do imóvel?
- Suponha que o proprietário acrescente um novo banheiro à casa, o que aumenta o tamanho da casa em 100 pés quadrados. Qual é o aumento esperado no valor do imóvel?

- c. Qual é a perda de valor se o proprietário deixa a casa se deteriorar, de modo que sua condição passe a “ruim”?
- d. Calcule o R^2 da regressão.

Questão 6 (exercício 6.9). (Y_i, X_{1i}, X_{2i}) satisfazem as hipóteses de MQO. Você está interessado em β_1 , o efeito causal de X_1 sobre Y . Suponha que X_1 e X_2 sejam **não correlacionadas**. Você estima β_1 regredindo Y sobre X_1 apenas (de modo que X_2 não é incluída na regressão). Esse estimador sofre de viés de variável omitida? Explique.

Questão 7 (exercício 6.11). Considere o modelo de regressão

$$Y_i = \beta_1 X_{1i} + \beta_2 X_{2i} + u_i, \quad i = 1, \dots, n,$$

sem intercepto.

- a. Especifique a função de mínimos quadrados minimizada pelo MQO.
- b. Calcule as derivadas parciais da função objetivo em relação a b_1 e b_2 .
- c. Suponha $\sum_{i=1}^n X_{1i}X_{2i} = 0$. Mostre que $\hat{\beta}_1 = \sum_i X_{1i}Y_i / \sum_i X_{1i}^2$.
- d. Suponha $\sum_{i=1}^n X_{1i}X_{2i} \neq 0$. Derive uma expressão para $\hat{\beta}_1$ em função dos dados.
- e. Suponha agora que o modelo inclua intercepto: $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$. Mostre que os estimadores de MQO satisfazem $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \hat{\beta}_2 \bar{X}_2$.
- f. Como em (e), com intercepto, suponha adicionalmente que $\sum_i (X_{1i} - \bar{X}_1)(X_{2i} - \bar{X}_2) = 0$. Mostre que

$$\hat{\beta}_1 = \frac{\sum_i (X_{1i} - \bar{X}_1)(Y_i - \bar{Y})}{\sum_i (X_{1i} - \bar{X}_1)^2}.$$

Como isso se compara ao estimador de MQO de β_1 na regressão que **omite** X_2 ?

6.10.1 Gabarito da Lista 3

Questão 1. A fórmula é $\bar{R}^2 = 1 - \frac{n-1}{n-k-1}(1 - R^2)$, equivalente à Equação 7. Com $n = 4.000$ em todas as colunas:

- Coluna (1), $k = 2$: $\bar{R}^2 = 1 - \frac{3999}{3997}(1 - 0,176) = 1 - 1,0005 \times 0,824 = 0,1756 \approx 0,175$.
- Coluna (2), $k = 3$: $\bar{R}^2 = 1 - \frac{3999}{3996}(1 - 0,190) = 1 - 1,00075 \times 0,810 = 0,1894 \approx 0,189$.
- Coluna (3), $k = 6$: $\bar{R}^2 = 1 - \frac{3999}{3993}(1 - 0,194) = 1 - 1,0015 \times 0,806 = 0,1928 \approx 0,193$.

Note como o ajuste é praticamente irrelevante aqui: com $n = 4.000$ e no máximo seis regressores, o fator $\frac{n-1}{n-k-1}$ vale no máximo 1,0015. A correção de graus de liberdade importa em amostras pequenas ou com muitos regressores — não neste caso.

Questão 2. Coluna (1): $\widehat{AHE} = 12,69 + 5,46 \text{ College} - 2,64 \text{ Female}$.

- a. Sim. Como *College* é binária, seu coeficiente é a diferença de média condicional entre os dois grupos, mantido o sexo constante: graduados ganham, em média, **US\$ 5,46 a mais por hora** que trabalhadores com apenas o ensino médio.
- b. Sim. O coeficiente de *Female* é $-2,64$, de modo que mulheres ganham em média US\$ 2,64 a menos que homens — equivalentemente, **homens ganham US\$ 2,64 a mais por hora** que mulheres, mantida a escolaridade constante.

Uma observação sobre a linguagem, no espírito da última seção do capítulo: nada aqui autoriza a leitura causal. Ambas as diferenças são **médias condicionais**, e há confundidores óbvios — ocupação, horas, experiência efetiva — omitidos da regressão.

Questão 3. Coluna (2): $\widehat{AHE} = 4,40 + 5,48 \text{ College} - 2,62 \text{ Female} + 0,29 \text{ Age}$.

- a. O coeficiente de *Age* é 0,29: cada ano adicional de idade está associado a US\$ 0,29 a mais por hora, mantidos sexo e escolaridade constantes. A resposta tem duas partes. **Estatisticamente**, o efeito é bem determinado — a inclusão de *Age* elevou o R^2 de 0,176 para 0,190 e reduziu o SER, e com $n = 4.000$ um coeficiente dessa magnitude é seguramente significativa. **Substantivamente**, o efeito é modesto mas não desprezível na faixa observada: a amostra vai de 25 a 34 anos, de modo que a idade explica no máximo $9 \times 0,29 = \text{US\$ } 2,61$ por hora de diferença — cerca de metade do efeito da graduação. Vale notar que aqui a idade é um *proxy* para experiência: numa amostra restrita a 25–34 anos, quem tem mais idade tipicamente tem mais tempo de mercado.
- b. Ambas são mulheres com graduação, de modo que $\text{College} = 1$ e $\text{Female} = 1$:
 - Sally (29 anos): $4,40 + 5,48 - 2,62 + 0,29 \times 29 = 7,26 + 8,41 = \text{US\$ } 15,67$ por hora.
 - Betsy (34 anos): $4,40 + 5,48 - 2,62 + 0,29 \times 34 = 7,26 + 9,86 = \text{US\$ } 17,12$ por hora.

A diferença, $17,12 - 15,67 = \text{US\$ } 1,45$, é exatamente $0,29 \times 5$ — as duas só diferem em idade, e todos os demais termos se cancelam.

Questão 4. Coluna (3): $\widehat{AHE} = 3,75 + 5,44 \text{ College} - 2,62 \text{ Female} + 0,29 \text{ Age} + 0,69 \text{ Northeast} + 0,60 \text{ Midwest} - 0,27 \text{ South}$.

- a. As diferenças regionais são **pequenas**. Com o Oeste como categoria de referência, os coeficientes indicam que o Nordeste paga US\$ 0,69 a mais, o Meio-Oeste US\$ 0,60 a mais e o Sul US\$ 0,27 a menos que o Oeste, tudo o mais constante. A maior diferença entre duas regiões é $0,69 - (-0,27) = \text{US\$ } 0,96$ — pequena diante do efeito da graduação (5,44) ou do sexo ($-2,62$). O ganho de ajuste confirma: acrescentar três regressores elevou o R^2 de 0,190 para apenas 0,194.
- b. Porque as quatro binárias de região são **exaustivas e mutuamente exclusivas**: todo trabalhador mora em exatamente uma das quatro regiões, de modo que

$$\text{Northeast}_i + \text{Midwest}_i + \text{South}_i + \text{West}_i = 1$$

para todo i . Somadas, elas reproduzem exatamente a coluna de uns do intercepto — é a **armadilha da *dummy*** discutida na Seção 6. Se *West* fosse incluída junto com o intercepto, haveria multicolinearidade perfeita, $\mathbf{X}'\mathbf{X}$ seria singular e o MQO **não teria solução única**. Na prática, o software omitiria automaticamente uma das colunas (ou o intercepto) e reportaria a omissão. O Oeste, sendo a categoria omitida, é a **referência**: todos os coeficientes regionais medem diferenças em relação a ele.

- c. As duas são mulheres de 28 anos com graduação, e diferem apenas na região. Todos os termos comuns se cancelam:

$$\mathbb{E}(AHE \mid \text{Juanita}) - \mathbb{E}(AHE \mid \text{Jennifer}) = \hat{\beta}_{South} - \hat{\beta}_{Midwest} = -0,27 - 0,60 = -\text{US\$ } 0,87.$$

Juanita ganha, em média, **US\$ 0,87 a menos por hora** que Jennifer. Note que não foi preciso calcular nenhum dos dois salários previstos — a comparação entre duas categorias não-referência é sempre a diferença entre seus coeficientes.

Questão 5. Regressão de *Price* com $k = 6$ regressores e $n = 220$.

- a. Converter parte de uma sala existente em banheiro aumenta *Bath* em 1 e **mantém *Hsize* constante** (a área total não mudou; apenas seu uso interno). O aumento esperado é, portanto, o coeficiente de *Bath* isoladamente: **US\$ 23.400**. Este item é uma lição sobre interpretação de efeito parcial — o enunciado foi construído para que exatamente uma variável mude.
- b. Agora *Bath* aumenta em 1 e *Hsize* aumenta em 100:

$$\Delta \widehat{Price} = 23,4 \times 1 + 0,156 \times 100 = 23,4 + 15,6 = 39,0,$$

ou seja, **US\$ 39.000**. A diferença em relação ao item (a) é exatamente o valor dos 100 pés quadrados adicionais.

- c. O coeficiente de *Poor* é $-48,8$: a perda esperada é de **US\$ 48.800**.
- d. Invertendo a Equação 7, $R^2 = 1 - \frac{n-k-1}{n-1}(1 - \bar{R}^2)$. Com $n = 220$, $k = 6$:

$$R^2 = 1 - \frac{220 - 6 - 1}{220 - 1}(1 - 0,72) = 1 - \frac{213}{219} \times 0,28 = 1 - 0,9726 \times 0,28 = 1 - 0,2723 = 0,7277 \approx 0,728.$$

Como esperado, $R^2 > \bar{R}^2$. Aqui a diferença já é visível (0,728 contra 0,72), porque n é bem menor que nas regressões da CPS.

Questão 6. Não há viés de variável omitida. A resposta segue diretamente das duas condições da Seção 6: o viés exige que a variável omitida seja (I) correlacionada com o regressor incluído e (II) determinante de Y . Aqui a condição (II) vale — X_2 entra no modelo verdadeiro —, mas a condição (I) **falha** por hipótese.

Formalmente, o modelo verdadeiro é $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + v_i$, e a regressão simples tem erro $u_i = \beta_2 X_{2i} + v_i$. Pela Equação 1,

$$\text{plim } \hat{\beta}_1^{\text{simples}} = \beta_1 + \frac{\text{Cov}(X_1, \beta_2 X_2 + v)}{\text{Var}(X_1)} = \beta_1 + \beta_2 \underbrace{\frac{\text{Cov}(X_1, X_2)}{\text{Var}(X_1)}}_{=0} = \beta_1,$$

pois $\text{Cov}(X_1, X_2) = 0$ por hipótese. O estimador é consistente para β_1 .

Duas ressalvas valem a pena. Primeira: “não correlacionadas” é uma condição sobre associação **linear**; a rigor, o que se precisa para o não-viés em amostras finitas é $\mathbb{E}(v_i + \beta_2 X_{2i} \mid X_{1i}) = 0$, que é mais forte. Segunda: mesmo sem viés, **omitir X_2 tem um custo** — ela permaneceria no erro, inflando σ_u^2 e portanto a variância de $\hat{\beta}_1$. Incluir um regressor não correlacionado com X_1 mas determinante de Y é gratuito em termos de viés e **melhora a precisão**. É o outro lado da moeda do exercício 8(a) da lista autoral deste capítulo.

Questão 7. Modelo sem intercepto, $Y_i = \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$.

a. A função objetivo é

$$S(b_1, b_2) = \sum_{i=1}^n (Y_i - b_1 X_{1i} - b_2 X_{2i})^2.$$

b. As derivadas parciais:

$$\frac{\partial S}{\partial b_1} = -2 \sum_{i=1}^n X_{1i} (Y_i - b_1 X_{1i} - b_2 X_{2i}), \quad \frac{\partial S}{\partial b_2} = -2 \sum_{i=1}^n X_{2i} (Y_i - b_1 X_{1i} - b_2 X_{2i}).$$

Igualando a zero, obtemos as duas condições de primeira ordem (equações normais):

$$\sum_i X_{1i} Y_i = \hat{\beta}_1 \sum_i X_{1i}^2 + \hat{\beta}_2 \sum_i X_{1i} X_{2i}, \quad \sum_i X_{2i} Y_i = \hat{\beta}_1 \sum_i X_{1i} X_{2i} + \hat{\beta}_2 \sum_i X_{2i}^2.$$

Note que **não** há a condição $\sum \hat{u}_i = 0$: sem intercepto, os resíduos não somam zero. É o mesmo ponto do exercício 1(d) do 1.

c. Se $\sum_i X_{1i} X_{2i} = 0$, o segundo termo da primeira equação normal desaparece e ela se resolve isoladamente:

$$\sum_i X_{1i} Y_i = \hat{\beta}_1 \sum_i X_{1i}^2 \implies \boxed{\hat{\beta}_1 = \frac{\sum_i X_{1i} Y_i}{\sum_i X_{1i}^2}}$$

que é exatamente o estimador da regressão simples de Y sobre X_1 sem intercepto. **Ortogonalidade entre regressores desacopla o sistema**: cada coeficiente pode ser obtido como se o outro regressor não existisse.

d. No caso geral, resolvemos o sistema 2×2 . Escrevendo $S_{11} = \sum X_{1i}^2$, $S_{22} = \sum X_{2i}^2$, $S_{12} = \sum X_{1i} X_{2i}$, $S_{1Y} = \sum X_{1i} Y_i$ e $S_{2Y} = \sum X_{2i} Y_i$, o sistema é

$$\begin{pmatrix} S_{11} & S_{12} \\ S_{12} & S_{22} \end{pmatrix} \begin{pmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{pmatrix} = \begin{pmatrix} S_{1Y} \\ S_{2Y} \end{pmatrix}.$$

Pela regra de Cramer,

$$\boxed{\hat{\beta}_1 = \frac{S_{22} S_{1Y} - S_{12} S_{2Y}}{S_{11} S_{22} - S_{12}^2} = \frac{(\sum X_{2i}^2)(\sum X_{1i} Y_i) - (\sum X_{1i} X_{2i})(\sum X_{2i} Y_i)}{(\sum X_{1i}^2)(\sum X_{2i}^2) - (\sum X_{1i} X_{2i})^2}}$$

Observe que o denominador é positivo pela desigualdade de Cauchy-Schwarz, exceto quando X_1 e X_2 são proporcionais — que é precisamente o caso de multicolinearidade perfeita, em que o denominador zera e $\hat{\beta}_1$ não existe. A álgebra do exercício reencontra, num caso 2×2 explícito, a singularidade de $\mathbf{X}'\mathbf{X}$ discutida no capítulo. Fazendo $S_{12} = 0$, recupera-se o item (c).

e. Com intercepto, a CPO em relação a b_0 é

$$-2 \sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 X_{1i} - \hat{\beta}_2 X_{2i}) = 0 \iff \sum_i Y_i = n \hat{\beta}_0 + \hat{\beta}_1 \sum_i X_{1i} + \hat{\beta}_2 \sum_i X_{2i}.$$

Dividindo tudo por n :

$$\bar{Y} = \hat{\beta}_0 + \hat{\beta}_1 \bar{X}_1 + \hat{\beta}_2 \bar{X}_2 \implies \boxed{\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}_1 - \hat{\beta}_2 \bar{X}_2}$$

Este é o análogo múltiplo do resultado de que a reta de MQO passa por $(\bar{X}, \bar{Y})$: o **hiperplano** de MQO passa pelo ponto das médias $(\bar{X}_1, \bar{X}_2, \bar{Y})$.

- f. Substituindo $\hat{\beta}_0$ pela expressão de (e) no modelo ajustado, obtemos o modelo em **desvios das médias**:

$$Y_i - \bar{Y} = \hat{\beta}_1(X_{1i} - \bar{X}_1) + \hat{\beta}_2(X_{2i} - \bar{X}_2) + \hat{u}_i.$$

As equações normais para $\hat{\beta}_1$ e $\hat{\beta}_2$ passam a ser as do item (b) aplicadas às variáveis centradas. Denotando $\tilde{X}_{ji} = X_{ji} - \bar{X}_j$ e $\tilde{Y}_i = Y_i - \bar{Y}$, a hipótese $\sum_i \tilde{X}_{1i} \tilde{X}_{2i} = 0$ é exatamente a condição de ortogonalidade do item (c), agora entre variáveis centradas. Logo, pelo mesmo argumento,

$$\hat{\beta}_1 = \frac{\sum_i \tilde{X}_{1i} \tilde{Y}_i}{\sum_i \tilde{X}_{1i}^2} = \frac{\sum_i (X_{1i} - \bar{X}_1)(Y_i - \bar{Y})}{\sum_i (X_{1i} - \bar{X}_1)^2}$$

Comparação com a regressão que omite X_2 . Essa expressão é *idêntica* ao estimador de MQO de β_1 na regressão simples de Y sobre X_1 com intercepto. Isto é: quando X_1 e X_2 têm **covariância amostral zero**, incluir ou omitir X_2 não altera em nada a estimativa de β_1 .

É a contrapartida amostral exata da Questão 6 deste mesmo gabarito — lá o argumento era populacional e assintótico ($\text{Cov}(X_1, X_2) = 0 \Rightarrow$ sem viés), aqui ele é algébrico e vale em **qualquer amostra**. Note, porém, que o que **muda** é o erro-padrão: incluir X_2 reduz o SSR sem alterar $\hat{\beta}_1$, o que reduz $s_{\hat{u}}^2$ e portanto $\text{SE}(\hat{\beta}_1)$. Mais uma vez: um regressor ortogonal ao regressor de interesse mas relevante para Y compra **precisão de graça**.

7 Testes de Hipótese e Intervalos de Confiança na Regressão Múltipla

O Seção 6 resolveu um problema de identificação: diante de um determinante observável de Y correlacionado com o regressor de interesse, a resposta é incluí-lo na regressão. O que ficou pendente foi a **inferência**. Sabemos estimar $\hat{\beta}_1, \dots, \hat{\beta}_k$ e conhecemos sua distribuição assintótica, mas ainda não sabemos responder a perguntas que só existem quando há mais de um coeficiente:

- os dois regressores que acrescentei são, **em conjunto**, irrelevantes?
- o efeito de X_1 é **igual** ao efeito de X_2 ?
- as quatro *dummies* de região, tomadas como bloco, dizem alguma coisa?

Nenhuma delas se resolve com uma estatística t , porque nenhuma delas é uma afirmação sobre um único coeficiente. A ferramenta nova deste capítulo é a **estatística F** , que testa **hipóteses conjuntas** — q restrições impostas simultaneamente sobre os coeficientes.

O capítulo tem cinco partes. A primeira é a mais curta e a mais tranquilizadora: para um coeficiente individual, **nada muda** em relação ao Seção 5. A segunda constrói o teste F . A terceira trata do caso intermediário — uma restrição única que envolve **vários** coeficientes —, onde um truque de reparametrização permite voltar ao teste t . A quarta discute **especificação de modelos**: como escolher os regressores, e por que o R^2 é um péssimo conselheiro nessa escolha. A quinta reúne tudo na análise completa do caso *TestScore-STR*, que é o exemplo que o curso vem construindo desde a Aula 3.

O capítulo corresponde à Aula 6 da disciplina e cobre o Capítulo 7 de Stock e Watson (2020).

7.1 Testes e intervalos para um coeficiente individual

Começamos pelo que não muda. Suponha que queiramos testar, no modelo múltiplo, uma hipótese sobre um único coeficiente β_j :

$$H_0 : \beta_j = \beta_{j,0} \quad \text{contra} \quad H_1 : \beta_j \neq \beta_{j,0}.$$

O procedimento é **literalmente o mesmo** do Seção 5, aplicado ao coeficiente j da regressão múltipla:

1. calcular o erro-padrão $SE(\hat{\beta}_j)$ — agora extraído da diagonal da matriz de variâncias do vetor $\hat{\beta}$, mas conceitualmente a mesma coisa;
2. formar a estatística t ,

$$t = \frac{\hat{\beta}_j - \beta_{j,0}}{SE(\hat{\beta}_j)}$$

3. calcular o valor- $p = 2\Phi(-|t^{act}|)$, e rejeitar H_0 a 5% se o valor- p for menor que 0,05 ou, equivalentemente, se $|t^{act}| > 1,96$.

O intervalo de confiança de 95% para β_j é, do mesmo modo, $\hat{\beta}_j \pm 1,96 \text{SE}(\hat{\beta}_j)$.

A razão de tudo isso continuar valendo é a distribuição assintótica estabelecida no Seção 6: sob as hipóteses de MQO, cada $\hat{\beta}_j$ é assintoticamente normal em torno de β_j . A normalidade de cada componente não depende de quantos regressores há.

! O que muda, então?

A **fórmula** do teste não muda; o **significado** do que se testa, sim. Em $\widehat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2$, a hipótese $\beta_1 = 0$ afirma que X_1 não tem efeito **mantido** X_2 **constante**. É uma afirmação sobre um efeito parcial, e ela pode ser rejeitada numa especificação e não rejeitada em outra sem qualquer contradição lógica — porque são hipóteses diferentes sobre parâmetros diferentes. Boa parte da seção seguinte é uma ilustração exatamente disso.

7.1.1 O exemplo do curso, e um coeficiente que desaparece

Retomemos a regressão que fecha o Seção 6, com os erros-padrão robustos entre parênteses:

$$\widehat{TestScore} = 686,0 - 1,10 \cdot STR - 0,65 \cdot PctEL. \quad (9)$$

(8,7) (0,43) (0,031)

Para testar a significância do coeficiente do STR :

$$t^{act} = \frac{-1,10 - 0}{0,43} = -2,54, \quad \text{valor-}p = 2\Phi(-2,54) = 0,011.$$

Rejeita-se H_0 a 5%. O valor- p de 1,1% tem a leitura de sempre: é o **menor nível de significância** ao qual a nula poderia ser rejeitada com estes dados. O intervalo de 95% é

$$-1,10 \pm 1,96 \times 0,43 = (-1,95; -0,26),$$

que não contém o zero — como tinha de ser, dada a rejeição a 5%.

Até aqui, a conclusão do curso parece firme: turmas menores estão associadas a notas maiores, mesmo controlando pela proporção de alunos aprendendo inglês. Mas então surge uma pergunta de orçamento. Contratar professores custa dinheiro, e sob orçamento rígido esse dinheiro sai de outro lugar. A diretora pergunta: **qual o efeito de reduzir o STR mantendo fixa a despesa por aluno?**

A pergunta pede um terceiro regressor, $Expn$, a despesa anual por aluno no distrito, em milhares de dólares:

$$\widehat{TestScore} = 649,6 - 0,29 \cdot STR - 0,656 \cdot PctEL + 3,87 \cdot Expn. \quad (10)$$

(15,5) (0,48) (0,033) (1,59)

O resultado muda tudo. O coeficiente do STR cai de $-1,10$ para $-0,29$, e

$$t^{act} = \frac{-0,29}{0,48} = -0,60, \quad \text{valor-}p = 2\Phi(-0,60) = 0,549.$$

Não se rejeita $H_0 : \beta_{STR} = 0$ a nenhum nível convencional. O efeito desapareceu.

7.1.2 Como interpretar o desaparecimento

Há uma leitura econômica bonita para esse resultado, e vale a pena expô-la porque ela mostra que uma “não rejeição” pode ser um achado substantivo, e não apenas uma decepção estatística.

O coeficiente de STR na Equação 10 responde a uma pergunta muito específica: qual o efeito de reduzir a turma **mantendo a despesa por aluno constante**? Ora, reduzir a turma sem gastar mais significa contratar professores tirando recursos de outra rubrica — material, infraestrutura, formação. O coeficiente próximo de zero diz que essa **recomposição do orçamento** não melhora as notas.

Uma interpretação plausível: nesta amostra de 420 distritos da Califórnia, os administradores escolares já estão alocando o orçamento **eficientemente**. Se o coeficiente do STR fosse negativo e significativo mesmo com $Expn$ fixo, a conclusão seria a oposta — haveria um rearranjo de gastos capaz de elevar as notas sem custo adicional, e os administradores não estariam fazendo um bom trabalho.

i Um detalhe que a Aula 5 explica

Note que o erro-padrão de $\hat{\beta}_{STR}$ **aumentou** de 0,43 para 0,48 com a inclusão de $Expn$. Não é acaso: é **multicolinearidade imperfeita**. Distritos que gastam mais por aluno tendem a ter turmas menores — as duas variáveis são correlacionadas —, e a Equação 8 mostra que a correlação entre regressores infla a variância dos coeficientes estimados. Parte da queda na estatística t vem do numerador (o coeficiente encolheu), e parte vem do denominador (o erro-padrão cresceu).

7.2 Testes de hipóteses conjuntas

O exemplo anterior deixa uma pergunta no ar. Se STR é individualmente insignificante na Equação 10, e se quiséssemos testar se STR e $Expn$ são, os dois, irrelevantes? Isto é:

$$H_0 : \beta_{STR} = 0 \text{ e } \beta_{Expn} = 0 \quad \text{contra} \quad H_1 : \beta_{STR} \neq 0 \text{ e/ou } \beta_{Expn} \neq 0.$$

Sob a nula, ambos são zero: são **duas restrições** impostas simultaneamente. No caso geral,

$$H_0 : \beta_j = \beta_{j,0}, \beta_m = \beta_{m,0}, \dots \quad (q \text{ restrições}),$$

contra a alternativa de que **uma ou mais** das q restrições não vale.

⚠ Por que não testar um coeficiente de cada vez

A tentação é óbvia: testar $\beta_{STR} = 0$ com um t , testar $\beta_{Expn} = 0$ com outro t , e rejeitar a conjunta se algum dos dois rejeitar. **Isso está errado**, e o erro é de tamanho do teste. Se cada teste individual tem 5% de chance de rejeitar sob a nula, a chance de **pelo menos um** dos dois rejeitar é maior que 5% — chegaria a aproximadamente 10% se os dois testes fossem independentes, e a algo entre 5% e 10% no caso geral, porque as estatísticas t são correlacionadas. O procedimento “um de cada vez” rejeita a nula verdadeira com mais frequência do que anuncia. A estatística F existe precisamente para corrigir isso: ela combina as estatísticas t **levando em conta a correlação entre elas**, produzindo um teste com o tamanho correto.

7.2.1 A estatística F

Para $q = 2$ restrições do tipo $\beta_1 = 0$ e $\beta_2 = 0$, a estatística F combina as duas estatísticas t pela fórmula

$$F = \frac{1}{2} \left(\frac{t_1^2 + t_2^2 - 2\hat{\rho}_{t_1, t_2} t_1 t_2}{1 - \hat{\rho}_{t_1, t_2}^2} \right) \quad (11)$$

onde $\hat{\rho}_{t_1, t_2}$ é a estimativa da correlação entre as duas estatísticas t . Sob H_0 , a estatística tem distribuição assintótica $F_{2, \infty}$.

Vale a pena ler a fórmula em vez de apenas registrá-la. Se as duas estatísticas t fossem **não correlacionadas** ($\hat{\rho} = 0$), a expressão colapsaria em

$$F = \frac{t_1^2 + t_2^2}{2},$$

a média dos quadrados das estatísticas t — que é exatamente o que a intuição sugere para combinar duas evidências independentes. Cada t_j^2 é assintoticamente χ_1^2 sob a nula, e a média de q variáveis χ_1^2 independentes é uma $F_{q, \infty}$. Os termos com $\hat{\rho}$ são a correção para o fato de que, na prática, as duas estatísticas **são** correlacionadas — porque os regressores são correlacionados entre si.

! Valores críticos da $F_{q, \infty}$

Como a F só assume valores positivos e valores grandes são evidência contra a nula, o teste é **sempre unicaudal à direita**, qualquer que seja a alternativa. Os valores críticos mais usados:

q	10%	5%	1%
1	2,71	3,84	6,63
2	2,30	3,00	4,61
3	2,08	2,60	3,78
4	1,94	2,37	3,32

5 1,85 2,21 3,02

Note a linha $q = 1$: $3,84 = 1,96^2$ e $6,63 = 2,58^2$. Não é coincidência — é o resultado, demonstrado adiante, de que com uma restrição só o teste F é o **quadrado** do teste t .

7.2.2 O teste F de significância global

Toda tabela de regressão traz, por padrão, um teste F da hipótese de que **todos** os coeficientes de inclinação — não o intercepto — são zero:

$$H_0 : \beta_1 = 0, \beta_2 = 0, \dots, \beta_k = 0 \quad \text{contra} \quad H_1 : \beta_j \neq 0 \text{ para ao menos um } j.$$

É o teste de que a regressão, **como um todo**, explica alguma coisa. Na saída de exemplo que o professor mostra — uma equação de salários com $n = 3.010$ —,

$$\log(\widehat{Wage}) = 4,4685 + 0,0932 \cdot Educ + 0,0898 \cdot Exper - 0,00249 \cdot Exper^2,$$

(0,0703) (0,0037) (0,0071) (0,00034)

com $R^2 = 0,1958$, $\bar{R}^2 = 0,1950$ e $F(3; 3006) = 231,75$, cujo valor- p é 3×10^{-135} . A nula de irrelevância global é rejeitada de forma esmagadora.

Nessa mesma regressão, um teste conjunto mais interessante é o de que a **experiência** é irrelevante. Como ela entra de duas formas — linear e quadrática —, a hipótese exige $q = 2$ restrições:

$$H_0 : \beta_{Exper} = 0 \text{ e } \beta_{Exper^2} = 0.$$

O resultado é $F \text{ robusto}(2; 3006) = 178,10$, com valor- p de 8×10^{-74} . A experiência importa. Note que aqui o teste conjunto é **obrigatório**, e não uma questão de gosto: como $Exper$ e $Exper^2$ são fortemente correlacionadas, os testes t individuais poderiam facilmente não rejeitar cada um por si só, e ainda assim o bloco ser altamente significativo.

7.2.3 A estatística F sob homocedasticidade

Há uma segunda fórmula para o F , válida apenas sob **erros homocedásticos**, que é menos útil na prática mas muito mais reveladora do ponto de vista conceitual.

A intuição é a seguinte. Testar H_0 é perguntar se relaxar as restrições **melhora a aderência da regressão o suficiente** para que a melhora não seja atribuível a variação amostral. Isso sugere um elo entre a estatística F e o R^2 : um F grande deve corresponder a um aumento substancial do R^2 quando as restrições são relaxadas. Sob homocedasticidade, esse elo é uma identidade:

$$F = \frac{(\text{SSR}_{\text{restrita}} - \text{SSR}_{\text{irrestrita}}) / q}{\text{SSR}_{\text{irrestrita}} / (n - k_{\text{irrestrita}} - 1)} = \frac{(R_{\text{irrestrita}}^2 - R_{\text{restrita}}^2) / q}{(1 - R_{\text{irrestrita}}^2) / (n - k_{\text{irrestrita}} - 1)} \quad (12)$$

onde “restrita” é a regressão estimada **impondo** H_0 e “irrestrita” é a regressão livre. As duas expressões são equivalentes: basta dividir numerador e denominador por TSS e lembrar que $R^2 = 1 - SSR/TSS$, o mesmo TSS nas duas regressões porque a variável dependente é a mesma.

Aplicando ao exemplo, para testar $\beta_{STR} = 0$ e $\beta_{Expn} = 0$ com $q = 2$, $k_{irrestrita} = 3$ e $n = 420$. A regressão restrita impõe as duas nulidades:

$$\widehat{TestScore} = 664,7 - 0,671 \cdot PctEL, \quad R^2_{restrita} = 0,4149,$$

e a irrestrita é a Equação 10, com $R^2_{irrestrita} = 0,4366$. Logo

$$F = \frac{(0,4366 - 0,4149)/2}{(1 - 0,4366)/(420 - 3 - 1)} = \frac{0,01085}{0,001354} = 8,01.$$

Como $8,01 > 4,61$, o valor crítico a 1% da $F_{2,\infty}$, rejeita-se a nula a 1%.

 Por que essa fórmula não é a que se usa

O problema é que ela **depende de homocedasticidade**, hipótese que já sabemos ser implausível em dados de corte transversal. E a diferença não é cosmética: neste mesmo exemplo, a estatística F **robusta** à heterocedasticidade vale 5,43, contra os 8,01 da fórmula homocedástica. As duas levam à mesma decisão aqui, mas a discrepância — quase 50% — mostra que confiar na fórmula errada é arriscado. Numa situação de fronteira, ela produziria rejeição onde o teste correto não rejeita.

A regra prática é a mesma do Seção 5: **use sempre a versão robusta**. A fórmula homocedástica serve para entender o que o teste F faz, não para reportar resultados.

7.3 Restrição única envolvendo vários coeficientes

Existe um caso intermediário, que não é um teste sobre um coeficiente isolado nem um bloco de q nulidades. Suponha que se queira testar se **dois efeitos são iguais**:

$$H_0 : \beta_1 = \beta_2 \quad \text{contra} \quad H_1 : \beta_1 \neq \beta_2.$$

É **uma** restrição — $q = 1$ —, mas ela envolve dois coeficientes ao mesmo tempo. Há duas estratégias, e elas são equivalentes.

Estratégia 1: testar a restrição diretamente. Pacotes econométricos têm comandos para isso (o `test` do STATA, o `linearHypothesis` do R). Como há apenas uma restrição, o teste F tem distribuição $F_{1,\infty}$.

Estratégia 2: transformar a regressão. É o truque intuitivo, e vale conhecê-lo porque funciona em qualquer software e porque torna transparente o que está sendo testado. Parta de

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i.$$

Reescreva a restrição $\beta_1 = \beta_2$ como $\beta_1 - \beta_2 = 0$ e defina o **parâmetro auxiliar**

$$\theta = \beta_1 - \beta_2 \quad \Longleftrightarrow \quad \beta_1 = \theta + \beta_2.$$

Substituindo na equação original:

$$Y_i = \beta_0 + (\theta + \beta_2)X_{1i} + \beta_2 X_{2i} + u_i = \beta_0 + \theta X_{1i} + \beta_2 (X_{1i} + X_{2i}) + u_i. \quad (13)$$

A Equação 13 é uma regressão comum de Y sobre X_1 e sobre a **soma** $X_1 + X_2$. Basta então rodar essa regressão e fazer um teste t **de significância usual** sobre o coeficiente de X_1 , pois

$$H_0 : \theta = 0 \quad \Longleftrightarrow \quad H_0 : \beta_1 = \beta_2.$$

! A equivalência, e um resultado geral

As duas estratégias dão exatamente a mesma resposta, e a ponte entre elas é a identidade

$$F = t^2 \quad \text{quando } q = 1$$

O teste F com uma restrição é o **quadrado** do teste t correspondente. É por isso que os valores críticos da $F_{1,\infty}$ são os quadrados dos valores críticos bicaudais da normal: $3,84 = 1,96^2$ a 5%, $6,63 = 2,58^2$ a 1%. A seção (c) do laboratório verifica a identidade numericamente.

A técnica de reparametrização é mais geral do que o caso $\beta_1 = \beta_2$. Ela funciona para qualquer restrição linear única, e a Questão 8 da Lista 4 pede exatamente três variações: $\beta_1 = \beta_2$, $\beta_1 + a\beta_2 = 0$ e $\beta_1 + \beta_2 = 1$ — esta última exigindo redefinir a **variável dependente**.

7.4 Especificação de modelos

Deixemos a álgebra de lado. A pergunta desta seção é a mais prática de todo o curso, e a que menos se resolve com teoremas: **quais variáveis devem entrar na regressão?**

A resposta honesta é que **não há regra universal** quando o objetivo é estimar um efeito causal. Há, no entanto, diretrizes, e elas são o conteúdo desta seção.

7.4.1 O ponto de partida é o viés, não o ajuste

O ponto de partida para escolher uma especificação é pensar em **quais variáveis omitidas poderiam gerar viés** — o que exige conhecimento específico do objeto investigado, não estatística. Os candidatos são as variáveis que satisfazem as duas condições do Seção 6: correlacionadas com o regressor de interesse e determinantes de Y .

E o corolário, que o professor faz questão de destacar: **não se deve depender de medidas puramente estatísticas de aderência**, como o R^2 ou o $\bar{R}^2$, para decidir a especificação. A razão é simples, e será desenvolvida abaixo: essas medidas dizem respeito a **previsão**, e previsão não é identificação.

7.4.2 Especificação básica e alternativas

A estratégia recomendada tem três passos.

1. A especificação básica. Comece com um modelo que inclua a variável de interesse e as variáveis de controle escolhidas por **teoria econômica e conhecimento específico** do problema. No caso *TestScore-STR*, faz sentido incluir *PctEL* e alguma medida de renda do distrito — esta última porque determina os recursos que a escola recebe.

2. As especificações alternativas. Desenvolva modelos com conjuntos alternativos de regressores. Por quê? Porque raramente a teoria e o conhecimento específico bastam para determinar uma especificação **única e completa**. Além disso, há limitações de dados: nem toda variável do modelo teórico está disponível na amostra, e o pesquisador inevitavelmente improvisa com *proxies*.

3. O exame da estabilidade dos coeficientes. Este é o teste decisivo, e ele é informal:

! O critério da estabilidade

Se a estimativa do coeficiente de interesse é **numericamente similar** nas especificações alternativas, isso é evidência de que a estimativa da especificação básica é confiável.

Se ela **muda substancialmente** entre especificações, isso sugere que a especificação básica ainda está contaminada por viés de variável omitida — e que a estimativa original não deve ser levada a sério.

A lógica é a do próprio viés de variável omitida. Se acrescentar um controle plausível desloca muito o coeficiente de interesse, é porque aquele controle estava capturando variação que antes era atribuída à variável de interesse — e nada garante que o próximo controle, não observado, não faria o mesmo. Estabilidade não é prova de ausência de viés, mas instabilidade é forte indício de sua presença.

É por isso que artigos empíricos têm quase sempre uma **seção de robustez**: testam alterações plausíveis da especificação (formas funcionais não lineares, por exemplo) e formas alternativas de medir as variáveis. Num estudo cuja variável dependente é “acidentes de trânsito”, vale checar se o resultado sobrevive quando se usa “acidentes com fatalidades” no lugar.

7.4.3 As quatro armadilhas do R^2

Um R^2 ou $\bar{R}^2$ alto significa que os regressores **preveem bem** a variável dependente. E é tudo o que significa. Um bom modelo de previsão não é necessariamente um bom modelo para estimar causalidade — e a confusão entre as duas coisas é provavelmente o erro mais comum na leitura de regressões aplicadas. Seguindo Stock e Watson (2020):

- 1. Um aumento no R^2 ou $\bar{R}^2$ não significa que a variável acrescentada é estatisticamente significativa.** As duas coisas são calculadas de formas diferentes; o R^2 sobe com qualquer regressor, e o $\bar{R}^2$ sobe sempre que $|t| > 1$ — um limiar bem abaixo de 1,96.
- 2. Um R^2 ou $\bar{R}^2$ alto não significa que os regressores causam a variável dependente.** O número de sorvetarias vendidas prevê muito bem os afogamentos.
- 3. Um R^2 alto não significa que a equação está livre de viés de variável omitida.** As duas propriedades são independentes: pode-se ter ajuste excelente e identificação arruinada.

4. Um R^2 alto não implica que o conjunto de regressores é o mais apropriado, assim como um R^2 baixo não significa que o conjunto é inadequado. Num experimento aleatorizado perfeito com um único tratamento, o R^2 pode ser baixíssimo e a estimativa do efeito causal ser impecável.

i Ferramenta estatística: previsão contra identificação

Vale fixar a distinção, porque ela organiza toda esta seção. A **previsão** pergunta: dado o que observo de um indivíduo, qual meu melhor palpite para Y ? Para isso, qualquer regressor correlacionado com Y serve, causal ou não — e o R^2 é o critério adequado.

A **identificação** pergunta: se eu **intervier** em X , o que acontece com Y ? Para isso, o que importa é a plausibilidade de $\mathbb{E}(u | X, W) = \mathbb{E}(u | W)$, que nenhuma medida de ajuste avalia. Um regressor pode elevar o R^2 e destruir a identificação — é o caso do controle situado no **caminho causal** entre X e Y , discutido no exercício 6(d) do Seção 6.

7.5 A análise completa: *TestScore* e *STR*

Fechamos o capítulo com a análise que o curso vem construindo desde a Aula 3, agora completa. São 420 distritos escolares da Califórnia, e o objetivo é mostrar como se mitiga o viés de variável omitida e — igualmente importante — **como se apresentam** os resultados.

7.5.1 A escolha dos controles

O primeiro passo é listar as variáveis que plausivelmente afetam o *TestScore* e são correlacionadas com o *STR*, pois só essas geram viés. Algumas são observáveis, como *PctEL*; outras são difíceis de observar ou medir — o grau de apoio acadêmico e emocional que os pais dão aos filhos, por exemplo. A análise considera três controles:

- $X_1 = PctEL$: percentual de alunos ainda aprendendo inglês;
- $X_2 = LchPct$: percentual de alunos elegíveis a almoço gratuito ou subsidiado;
- $X_3 = CalwPct$: percentual de alunos cujas famílias se qualificam ao programa de assistência de renda da Califórnia.

A ideia que organiza a escolha é a do Seção 6: incluir controles tais que, **uma vez fixados**, o *STR* seja “como se” alocado aleatoriamente entre os distritos.

Duas recomendações práticas acompanham a análise. Primeiro, **olhe os gráficos antes de estimar**: dispersões, no caso de corte transversal; evolução temporal, no caso de séries. Segundo, pense na **escala das variáveis**. *PctEL* deve entrar de 0 a 100 ou de 0 a 1? Não há resposta certa — o critério é qual escala **facilita a leitura** dos coeficientes. Numa escala de 0 a 1, o coeficiente mede o efeito de passar de 0% a 100% de alunos aprendendo inglês, uma variação que não existe nos dados.

7.5.2 Como apresentar os resultados

Resultados econométricos se reportam em **tabela**, com uma coluna por especificação, e a tabela deve conter:

- os coeficientes estimados, com os **erros-padrão entre parênteses** (robustos, sempre);
- as medidas de aderência (SER , R^2 , $\bar{R}^2$);
- o **número de observações**;
- as estatísticas relevantes ao caso — tipicamente os testes F de blocos de regressores.

Tabela 3: Efeito do tamanho da turma sobre o desempenho acadêmico. Variável dependente: nota média do distrito. Erros-padrão robustos entre parênteses.

Regressor	(1)	(2)	(3)	(4)	(5)
<i>STR</i>	−2,28 (0,52)	−1,10 (0,43)	−1,00 (0,27)	−1,31 (0,34)	−1,01 (0,27)
<i>PctEL</i>		−0,650 (0,031)	−0,122 (0,033)	−0,488 (0,030)	−0,130 (0,036)
<i>LchPct</i>			−0,547 (0,024)		−0,529 (0,038)
<i>CalwPct</i>				−0,790 (0,068)	0,048 (0,059)
Intercepto	698,9 (10,4)	686,0 (8,7)	700,2 (5,6)	698,0 (6,9)	700,4 (5,5)
Estatísticas					
SER	18,58	14,46	9,08	11,65	9,08
R^2	0,049	0,426	0,773	0,626	0,775
$\bar{R}^2$	0,047	0,424	0,772	0,623	0,773
n	420	420	420	420	420

7.5.3 As três conclusões

1. O coeficiente do *STR* se estabiliza em torno de -1 . A introdução das variáveis de controle reduz a estimativa a **aproximadamente metade** do valor inicial: de $-2,28$ na coluna (1) para algo entre $-1,00$ e $-1,31$ nas colunas (3) a (5). A metade que desapareceu era viés de variável omitida — distritos com turmas grandes têm também mais alunos aprendendo inglês e mais pobreza, e a coluna (1) atribuía ao tamanho da turma o efeito das três coisas juntas. O que importa, pelo critério da estabilidade, é que o coeficiente **para de se mover** depois da coluna (3): acrescentar *CalwPct* não o desloca. E ele permanece significativo a 5% em todas as especificações.

2. Os controles são ótimos preditores — o que não os torna causais. A equação só com *STR* explica menos de 5% da variância das notas ($R^2 = 0,049$). Na coluna (5), o $\bar{R}^2$ passa de 77%.

É um salto enorme no poder preditivo, e é exatamente o tipo de número que **não** deve ser lido causalmente: ninguém sustentaria que retirar o almoço subsidiado elevaria as notas em 0,53 ponto. Os controles são *proxies* de condição socioeconômica, e sua função é tornar defensável o coeficiente do *STR* — não gerar achados próprios.

3. *CalwPct* é estatisticamente irrelevante na coluna (5). Seu coeficiente é 0,048 com erro-padrão 0,059, um *t* de 0,81. Sozinha, na coluna (4), a variável parecia importar muito (−0,790); ao lado de *LchPct*, não acrescenta nada. As duas medem essencialmente a mesma coisa — pobreza do distrito —, e uma vez incluída uma delas, a outra é redundante. É multicolinearidade imperfeita em ação, e é também a razão pela qual se reporta a coluna (5): para mostrar que a conclusão sobre o *STR* **não depende** de qual medida de pobreza se escolhe.

7.6 Laboratório computacional em R

Este laboratório implementa o teste *F* do zero. A razão é a mesma do Seção 5: os pacotes que fariam isso automaticamente (*car*, *sandwich*) não estão instalados, e escrever a fórmula deixa explícito o que o comando pronto faz por baixo do capô.

A ferramenta central é a **estatística de Wald**. Qualquer conjunto de *q* restrições lineares pode ser escrito na forma matricial $\mathbf{R}\beta = \mathbf{r}$, onde $\mathbf{R}$ é $q \times (k + 1)$. Por exemplo, com três regressores mais intercepto,

$$H_0 : \beta_1 = 0 \text{ e } \beta_3 = 0 \iff \underbrace{\begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}}_{\mathbf{R}} \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \beta_3 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

A estatística é então

$$F = \frac{1}{q} (\mathbf{R}\hat{\beta} - \mathbf{r})' [\mathbf{R} \widehat{\text{Var}}(\hat{\beta}) \mathbf{R}']^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r}), \quad (14)$$

e ela é **robusta** ou **homocedástica** conforme a matriz $\widehat{\text{Var}}(\hat{\beta})$ usada seja a de HC1 ou a convencional. Essa é a beleza da forma de Wald: uma única função cobre todos os testes deste capítulo.

```
# matriz de variancias robusta (HC1) -- generaliza o ep_robusto() do preambulo
vcov_robusto <- function(modelo, tipo = "HC1") {
  X <- model.matrix(modelo); u <- residuals(modelo)
  n <- nrow(X); k <- ncol(X)
  bread <- solve(crossprod(X))
  ajuste <- if (tipo == "HC1") n / (n - k) else 1
  bread %*% (ajuste * crossprod(X * u)) %*% bread
}

# teste F (Wald) para o conjunto de restricoes lineares R %*% beta = r
teste_F <- function(modelo, R, r = rep(0, nrow(R)), robusto = TRUE) {
```

```

b <- coef(modelo)
V <- if (robusto) vcov_robusto(modelo) else vcov(modelo)
q <- nrow(R); gl <- df.residual(modelo)
dif <- R %*% b - r
Fst <- as.numeric(t(dif) %*% solve(R %*% V %*% t(R)) %*% dif) / q
list(F = Fst, q = q, gl = gl, p = pf(Fst, q, gl, lower.tail = FALSE))
}

```

Reconstruímos os dados simulados do Seção 6 — mesma semente e mesmos parâmetros, para que os números conversem entre os capítulos — e acrescentamos a variável *Expn*, correlacionada negativamente com o *STR*, como no exemplo do professor.

```

set.seed(6205)
n_d <- 420
b0 <- 686.0; b1 <- -1.10; b2 <- -0.65; b3 <- 3.87

STR <- rnorm(n_d, mean = 19.64, sd = 1.89)
rho <- 0.19
sd_el <- 18.3
PctEL <- pmax(0, 35.8 + rho * (sd_el / 1.89) * (STR - 19.64) +
              rnorm(n_d, 0, sd_el * sqrt(1 - rho^2)))

# despesa por aluno: distritos que gastam mais tendem a ter turmas menores, de modo
# que Expn e NEGATIVAMENTE correlacionada com STR -- e ela e um determinante real da
# nota (b3 > 0). As duas condicoes do vies de variavel omitida, portanto, valem.
Expn <- 5.31 - 0.20 * (STR - 19.64) + rnorm(n_d, 0, 0.80)

u <- rnorm(n_d, 0, 14.4)
TestScore <- b0 + b1 * STR + b2 * PctEL + b3 * Expn + u

ca <- data.frame(TestScore, STR, PctEL, Expn)
round(cor(ca[, c("STR", "PctEL", "Expn")]), 3)

```

```

      STR  PctEL  Expn
STR    1.000  0.149 -0.519
PctEL  0.149  1.000 -0.105
Expn  -0.519 -0.105  1.000

```

7.6.1 (a) O teste *t* individual e o intervalo de confiança

```

m2 <- lm(TestScore ~ STR + PctEL, data = ca)
tabela_reg(m2)

```

coef	ep	t	p	ic_inf
------	----	---	---	--------

```

(Intercept) 713.7298239 7.95000312 89.777301 7.290726e-275 698.1027481
STR          -1.3960299 0.42379735 -3.294098 1.071650e-03 -2.2290752
PctEL        -0.6742208 0.04158133 -16.214507 3.376899e-46 -0.7559559
              ic_sup
(Intercept) 729.3568998
STR          -0.5629845
PctEL        -0.5924856

```

A coluna t traz a estatística de cada teste $H_0 : \beta_j = 0$, e as duas últimas colunas o intervalo de 95%. É a Equação 9 do texto, reproduzida na simulação.

7.6.2 (b) O que acontece ao acrescentar um regressor correlacionado

```

m3 <- lm(TestScore ~ STR + PctEL + Expn, data = ca)
tabela_reg(m3)

```

```

              coef          ep          t          p          ic_inf
(Intercept) 693.3223345 12.18500749 56.899623 2.210580e-198 669.3704736
STR          -0.9236018 0.46806298 -1.973242 4.912944e-02 -1.8436652
PctEL        -0.6714541 0.04179533 -16.065290 1.572393e-45 -0.7536105
Expn          2.1084442 0.98118069 2.148885 3.221999e-02 0.1797541
              ic_sup
(Intercept) 717.274195445
STR          -0.003538354
PctEL        -0.589297760
Expn          4.037134296

```

Compare a linha do STR nas duas tabelas, e o paralelo com o exemplo do professor é imediato: o coeficiente **encolhe** em direção a zero e a estatística t despenca. Na simulação sabemos por quê, porque conhecemos a verdade — $\beta_{STR} = -1,10$, e a regressão sem *Expn* estava **viesada**. As duas condições do Seção 6 valem por construção: *Expn* é correlacionada com o *STR* e é determinante da nota. Omiti-la empurrava o coeficiente do *STR* para longe de zero; incluí-la o traz de volta.

Note que **duas** coisas se movem ao mesmo tempo. Além do coeficiente, o erro-padrão **aumenta**, e por uma razão inteiramente distinta — multicolinearidade imperfeita:

```

c(ep_STR_sem_Expn = ep_robusto(m2)[2],
  ep_STR_com_Expn = ep_robusto(m3)[2],
  inflacao        = ep_robusto(m3)[2] / ep_robusto(m2)[2],
  cor_STR_Expn    = cor(ca$STR, ca$Expn))

```

```

ep_STR_sem_Expn.STR ep_STR_com_Expn.STR      inflacao.STR      cor_STR_Expn
0.4237973          0.4680630          1.1044500          -0.5190633

```

Uma correlação de cerca de $-0,52$ entre os regressores infla o erro-padrão de $\hat{\beta}_{STR}$ em cerca de 10%. Este é o custo de “controlar por tudo”: cada controle correlacionado com a variável de interesse compra plausibilidade para a Hipótese 1 e paga em precisão.

A comparação com o exemplo do professor é instrutiva. Lá, o erro-padrão subiu de 0,43 para 0,48 — cerca de 12%, magnitude parecida com a daqui. E, nos dois casos, a queda da estatística t tem **duas** fontes que convém não confundir: o numerador encolheu porque o viés foi removido (um ganho de qualidade), e o denominador cresceu porque os regressores são correlacionados (uma perda de precisão). A primeira é o que se queria; a segunda é o preço.

7.6.3 (c) A identidade $F = t^2$

```
R_str <- matrix(c(0, 1, 0), nrow = 1)      # H0: beta_STR = 0
f1 <- teste_F(m2, R_str)
t1 <- coef(m2)[2] / ep_robusto(m2)[2]

c(t = as.numeric(t1), t_ao_quadrado = as.numeric(t1^2), F = f1$F, p_F = f1$p)
```

t	t_ao_quadrado	F	p_F
-3.29409771	10.85107971	10.85107971	0.00107165

As duas quantidades coincidem até o último dígito. Com $q = 1$, o teste F é o quadrado do teste t — o que também explica por que o valor crítico da $F_{1,\infty}$ a 5% é $3,84 = 1,96^2$.

7.6.4 (d) O teste conjunto e a fórmula via R^2

Testemos agora $H_0 : \beta_{STR} = 0$ e $\beta_{Expn} = 0$ no modelo com três regressores, pelas duas vias.

```
R_conj <- rbind(c(0, 1, 0, 0),      # beta_STR = 0
               c(0, 0, 0, 1))      # beta_Expn = 0
f_rob <- teste_F(m3, R_conj, robusto = TRUE)
f_hom <- teste_F(m3, R_conj, robusto = FALSE)

# a fórmula via R^2 (só vale sob homocedasticidade)
m_restrito <- lm(TestScore ~ PctEL, data = ca)
R2_u <- summary(m3)$r.squared
R2_r <- summary(m_restrito)$r.squared
q <- 2; k_u <- 3
F_r2 <- ((R2_u - R2_r) / q) / ((1 - R2_u) / (n_d - k_u - 1))

c(F_robusto = f_rob$F, F_homocedastico = f_hom$F, F_pela_formula_R2 = F_r2)
```

F_robusto	F_homocedastico	F_pela_formula_R2
7.312198	9.169896	9.169896

A terceira quantidade reproduz a segunda: a Equação 12 e a forma de Wald com a matriz convencional são a **mesma estatística**, escrita de dois modos. A primeira difere das outras duas porque usa a matriz robusta — e é a única em que se deve confiar.

7.6.5 (e) Por que o F homocedástico não serve

A seção anterior mostrou que as duas versões diferem. Esta mostra qual delas está certa. O experimento: geramos 2.000 amostras em que a nula é **verdadeira** — nenhum dos dois regressores entra na equação — mas os erros são fortemente heterocedásticos, e contamos com que frequência cada teste rejeita ao nível nominal de 5%.

```
set.seed(760)
M <- 2000; n <- 120
rej_hom <- rej_rob <- logical(M)

for (m in seq_len(M)) {
  x1 <- rnorm(n)
  x2 <- 0.5 * x1 + rnorm(n, 0, sqrt(1 - 0.25))
  # H0 VERDADEIRA: y nao depende de x1 nem de x2. Erro heterocedastico em x1.
  y <- 5 + rnorm(n, 0, 1 + 2 * abs(x1))
  fit <- lm(y ~ x1 + x2, data = data.frame(y, x1, x2))
  Rm <- rbind(c(0, 1, 0), c(0, 0, 1))
  rej_rob[m] <- teste_F(fit, Rm, robusto = TRUE)$p < 0.05
  rej_hom[m] <- teste_F(fit, Rm, robusto = FALSE)$p < 0.05
}

c(nominal = 5,
  F_homocedastico = 100 * mean(rej_hom),
  F_robusto = 100 * mean(rej_rob))
```

nominal	F_homocedastico	F_robusto
5.0	15.6	6.0

O resultado é contundente. O teste que anuncia 5% de falsos positivos entrega mais de 15% quando os erros são heterocedásticos: ele rejeita hipóteses verdadeiras **três vezes mais** do que promete. A versão robusta fica próxima dos 5% prometidos — a pequena folga é o erro de aproximação assintótica com $n = 120$, e ela encolhe com a amostra. É a mesma lição do Seção 5, agora para testes conjuntos: **o erro-padrão errado não vicia a estimativa, vicia a conclusão**.

7.6.6 (f) A restrição única com dois coeficientes, pelas duas estratégias

Testemos $H_0 : \beta_{STR} = \beta_{PctEL}$ — uma restrição, dois coeficientes.

```

# Estrategia 1: teste F direto, com R = (0, 1, -1)
f_dir <- teste_F(m2, matrix(c(0, 1, -1), nrow = 1))

# Estrategia 2: reparametrizacao. theta = b_STR - b_PctEL, e o modelo vira
# Y = b0 + theta*STR + b_PctEL*(STR + PctEL) + u
ca$soma <- ca$STR + ca$PctEL
m_aux <- lm(TestScore ~ STR + soma, data = ca)
theta <- coef(m_aux)[2]
ep_th <- ep_robusto(m_aux)[2]
t_theta <- theta / ep_th

c(F_direto = f_dir$F, t_theta = as.numeric(t_theta),
  t_theta_ao_quadrado = as.numeric(t_theta^2), p_F = f_dir$p)

```

F_direto	t_theta	t_theta_ao_quadrado	p_F
2.74452479	-1.65666073	2.74452479	0.09834026

De novo a coincidência exata: o F da estratégia direta é o quadrado do t sobre θ . E a reparametrização entrega de brinde algo que o teste F não dá — a **estimativa** da diferença $\hat{\beta}_{STR} - \hat{\beta}_{PctEL}$ e seu erro-padrão, com os quais se constrói um intervalo de confiança para a diferença.

7.6.7 (g) O teste F de significância global

```

R_todos <- rbind(c(0, 1, 0, 0), c(0, 0, 1, 0), c(0, 0, 0, 1))
f_glob <- teste_F(m3, R_todos)

c(F = f_glob$F, q = f_glob$q, gl = f_glob$gl, p = f_glob$p)

```

F	q	gl	p
1.095904e+02	3.000000e+00	4.160000e+02	2.670934e-52

É o teste que toda tabela de regressão reporta por padrão. Com dois regressores realmente relevantes na população simulada, a rejeição é esmagadora — como esperado.

7.6.8 (h) Por que não testar um coeficiente de cada vez

A caixa de advertência sobre testes conjuntos, no início deste capítulo, afirmou que o procedimento “rejeitar se algum t rejeitar” tem tamanho maior que o nominal. Vamos medi-lo.

```

set.seed(913)
M <- 4000; n <- 200
rej_F <- rej_qualquer_t <- logical(M)

for (m in seq_len(M)) {
  x1 <- rnorm(n)
  x2 <- 0.3 * x1 + rnorm(n, 0, sqrt(1 - 0.09)) # regressores correlacionados
  y <- 5 + rnorm(n) # H0 verdadeira para ambos
  fit <- lm(y ~ x1 + x2, data = data.frame(y, x1, x2))
  ep <- ep_robusto(fit)
  tt <- coef(fit)[-1] / ep[-1]
  rej_qualquer_t[m] <- any(abs(tt) > 1.96)
  rej_F[m] <- teste_F(fit, rbind(c(0,1,0), c(0,0,1)))$p < 0.05
}

c(nominal = 5,
  regra_algun_t_rejeita = 100 * mean(rej_qualquer_t),
  teste_F_conjunto = 100 * mean(rej_F))

```

nominal	regra_algun_t_rejeita	teste_F_conjunto
5.00	11.20	6.35

A regra ingênua rejeita cerca de 11% das vezes quando deveria rejeitar 5% — mais do que o dobro do prometido. O teste F fica em torno de 6%, bem mais próximo do alvo, e a folga restante é o erro de aproximação assintótica que já apareceu na seção (e), não um defeito do procedimento: ela encolhe à medida que n cresce. A intuição da Equação 11 se confirma — a correção pela correlação entre as estatísticas t não é um detalhe técnico, é o que aproxima o teste do tamanho anunciado.

7.7 Exercícios

1. **A leitura do coeficiente que sumiu.** Nas Equação 9 e Equação 10, o coeficiente do STR vai de $-1,10$ (significante) para $-0,29$ (insignificante) com a inclusão de $Expn$. (a) Um colega conclui: “o efeito do tamanho da turma era espúrio”. Explique por que essa conclusão é imprecisa, distinguindo as **duas** perguntas causais em jogo. (b) Qual das duas especificações responde à pergunta de um secretário de educação que pode aumentar o orçamento? E à de um diretor com orçamento fixo? (c) Decomponha a queda da estatística t (de $-2,54$ para $-0,60$) nas contribuições do numerador e do denominador. (d) Se $Expn$ fosse **não correlacionada** com o STR , o que aconteceria com $\hat{\beta}_{STR}$ e com $SE(\hat{\beta}_{STR})$?
2. **A fórmula do F , examinada.** Parta da Equação 11. (a) Verifique que, com $\hat{\rho} = 0$, ela vira a média de t_1^2 e t_2^2 . (b) Suponha $t_1 = t_2 = 1,5$ — nenhum dos dois individualmente significativo. Calcule F para $\hat{\rho} \in \{0; 0,5; -0,5; 0,9\}$ e diga em quais casos a conjunta é rejeitada a 5%. (c) Explique intuitivamente por que $\hat{\rho}$ **negativo** com t_1, t_2 de mesmo sinal produz F grande. (d) É possível rejeitar a hipótese conjunta sem rejeitar nenhuma das individuais? E o contrário?

3. **F homocedástico contra F robusto.** No exemplo do texto, as duas estatísticas valem 8,01 e 5,43. (a) Ambas rejeitam a 1%; por que, então, insistir na robusta? (b) Construa um cenário numérico em que as duas levem a **decisões diferentes** a 5%. (c) A fórmula Equação 12 expressa o F em termos de R^2 . Existe fórmula análoga para o F robusto? Explique por que sim ou por que não. (d) O que a seção (e) do laboratório permite afirmar sobre a **direção** do erro do teste homocedástico — ele é conservador ou liberal?
4. **Reparametrização.** No modelo $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$, escreva a regressão auxiliar que permite testar cada hipótese com um teste t usual:
 - (a) $\beta_1 = 2\beta_2$; (b) $\beta_1 + \beta_2 = 3$; (c) $\beta_1 = \beta_2 = 0$ — cuidado, esta é uma pegadinha. (d) Para o item (a), mostre que o erro-padrão de $\hat{\theta}$ produzido pela regressão auxiliar coincide com $\sqrt{\text{Var}(\hat{\beta}_1) + 4\text{Var}(\hat{\beta}_2) - 4\text{Cov}(\hat{\beta}_1, \hat{\beta}_2)}$, e explique por que o teste t sobre $\hat{\theta}$ é preferível a construir essa expressão à mão.
5. **Estabilidade e especificação.** Um pesquisador estima o efeito de um programa de microcrédito sobre a renda familiar em quatro especificações, obtendo os coeficientes 0,42; 0,31; 0,12 e 0,11, à medida que acrescenta blocos de controles.
 - (a) O que a sequência sugere? (b) Ele reporta apenas a primeira, alegando maior R^2 nas demais. Critique. (c) Suponha, em vez disso, a sequência 0,42; 0,40; 0,41; 0,39 — o que se pode concluir, e o que **não** se pode? (d) Que evidência adicional tornaria o argumento de estabilidade mais convincente?
6. **As armadilhas do R^2 , aplicadas.** Para cada afirmação, diga se é verdadeira ou falsa e justifique em uma frase: (a) “Como o $\bar{R}^2$ subiu, a variável acrescentada é significativa a 5%.” (b) “O R^2 de 0,95 mostra que o modelo captura bem o efeito causal.”
 - (c) “O R^2 de 0,03 na regressão do experimento aleatorizado indica que o tratamento é irrelevante.” (d) “Entre duas especificações, a de maior $\bar{R}^2$ é a mais apropriada para estimar o efeito causal.” (e) Reescreva a afirmação (a) de modo que fique correta, usando o limiar de $|t|$.
7. **Lendo a Tabela 3.** (a) Por que o SER cai tanto entre as colunas (2) e (3), e o que isso diz sobre $LchPct$? (b) O coeficiente de $PctEL$ cai de $-0,650$ para $-0,122$ entre as mesmas colunas — interprete. (c) Na coluna (5), $CalwPct$ tem $t \approx 0,81$. Um colega propõe removê-la para “limpar” o modelo. Você concorda? (d) Construa o intervalo de confiança de 95% para o efeito de reduzir o STR em 2 alunos, segundo a coluna (5). (e) Que teste F você reportaria nesta tabela, e por quê?
8. **Simulação.** Adapte o código da seção (h) do laboratório. (a) Aumente a correlação entre x_1 e x_2 para 0,9 e verifique o que acontece com o tamanho da regra “algum t rejeita” — ele piora ou melhora? Explique. (b) Passe para **cinco** regressores e recalcule: qual o tamanho da regra ingênua? Relacione com o problema de comparações múltiplas.
 - (c) Agora torne a nula **falsa** para apenas um dos regressores e compare o **poder** dos dois procedimentos. (d) O resultado de (c) sugere que a regra ingênua tem alguma virtude? Como você reconciliaria isso com (a) e (b)?

7.8 Lista de Exercícios 4

i Sobre esta seção

Reproduzo aqui a **Lista 4** da disciplina (Prof. Marcelo Mello; monitor: Matheus Porto), cujas questões são os exercícios 7.1 a 7.11 de Stock e Watson (2020) e cobrem exatamente o conteúdo deste capítulo. O gabarito vem logo em seguida, com as resoluções desenvolvidas — a recomendação de sempre é tentar cada questão antes de consultá-lo.

As Questões 1 a 6 referem-se à tabela abaixo, calculada com os mesmos dados da CPS de 1998 usados na Lista 3 (4.000 trabalhadores em tempo integral, escolaridade máxima de ensino médio ou graduação, idades de 25 a 34 anos). Agora, porém, a tabela traz os **erros-padrão** entre parênteses, o que permite fazer inferência. As variáveis são as mesmas do Seção 6.10.

Tabela 4: Regressões de AHE sobre binárias de sexo e educação e outras características, CPS 1998. Erros-padrão entre parênteses.

Regressor	(1)	(2)	(3)
<i>College</i> (X_1)	5,46 (0,21)	5,48 (0,21)	5,44 (0,21)
<i>Female</i> (X_2)	-2,64 (0,20)	-2,62 (0,20)	-2,62 (0,20)
<i>Age</i> (X_3)		0,29 (0,04)	0,29 (0,04)
<i>Northeast</i> (X_4)			0,69 (0,30)
<i>Midwest</i> (X_5)			0,60 (0,28)
<i>South</i> (X_6)			-0,27 (0,26)
Intercepto	12,69 (0,14)	4,40 (1,05)	3,75 (1,06)
Estatísticas			
F (efeitos regionais = 0)			6,10
SER	6,27	6,22	6,21
R^2	0,176	0,190	0,194
n	4.000	4.000	4.000

Questão 1 (exercício 7.1). Acrescente “*” (5%) e “***” (1%) à tabela para indicar a significância estatística dos coeficientes.

Questão 2 (exercício 7.2). Usando os resultados da coluna (1):

- A diferença de salários entre graduação e ensino médio estimada nesta regressão é estatisticamente significativa ao nível de 5%? Construa um intervalo de confiança de 95% para a diferença.
- A diferença de salários entre homens e mulheres é estatisticamente significativa ao nível de 5%? Construa um intervalo de confiança de 95% para a diferença.

Questão 3 (exercício 7.3). Usando os resultados da coluna (2):

- A idade é um determinante importante dos salários? Use o teste estatístico e/ou o intervalo de confiança apropriado para justificar sua resposta.
- Sally é uma mulher de 29 anos com diploma de graduação. Betsy é uma mulher de 34 anos com diploma de graduação. Construa um intervalo de confiança de 95% para a diferença esperada entre seus salários.

Questão 4 (exercício 7.4). Usando os resultados da coluna (3):

- Parecem existir diferenças regionais importantes? Use um teste de hipótese apropriado para justificar sua resposta.
- Juanita é uma mulher de 28 anos com graduação, do Sul. Molly é uma mulher de 28 anos com graduação, do Oeste. Jennifer é uma mulher de 28 anos com graduação, do Meio-Oeste.
 - Construa um intervalo de confiança de 95% para a diferença esperada de salários entre Juanita e Molly.
 - Explique como você construiria um intervalo de confiança de 95% para a diferença esperada de salários entre Juanita e Jennifer. (Dica: o que aconteceria se você incluísse *West* e excluísse *Midwest* da regressão?)

Questão 5 (exercício 7.5). A regressão da coluna (2) foi estimada novamente, desta vez com dados de 1992 (4.000 observações selecionadas ao acaso da CPS de março de 1993, convertidas em dólares de 1998 pelo índice de preços ao consumidor). O resultado é

$$\widehat{AHE} = 0,77 + 5,29 \cdot College - 2,59 \cdot Female + 0,40 \cdot Age,$$

(0,98)
(0,20)
(0,18)
(0,03)

com $SER = 5,85$ e $R^2 = 0,21$. Comparando com a regressão de 1998 da coluna (2), houve mudança estatisticamente significativa no coeficiente de *College*?

Questão 6 (exercício 7.6). Avalie a seguinte afirmação: “Em todas as regressões, o coeficiente de *Female* é negativo, grande e estatisticamente significativo. Isso constitui forte evidência estatística de discriminação de gênero no mercado de trabalho americano.”

Questão 7 (exercício 7.7). A Questão 5 da Lista 3 reportava a regressão abaixo, agora com os erros-padrão acrescentados:

$$\widehat{Price} = 119,2 + 0,485 \cdot BDR + 23,4 \cdot Bath + 0,156 \cdot Hsize + 0,002 \cdot Lsize + 0,090 \cdot Age - 48,8 \cdot Poor.$$

(23,9)
(2,61)
(8,94)
(0,011)
(0,00048)
(0,311)
(10,5)

- O coeficiente de BDR é estatisticamente diferente de zero?
- Tipicamente, casas de cinco quartos são vendidas por muito mais que casas de dois quartos. Isso é consistente com sua resposta ao item (a) e com a regressão de modo geral?
- Um proprietário compra 2.000 pés quadrados de um terreno adjacente. Construa um intervalo de confiança de 99% para a mudança no valor de sua casa.
- O tamanho do terreno é medido em pés quadrados. Você acha que outra escala seria mais apropriada? Por quê?
- A estatística F para omitir BDR e Age da regressão é $F = 0,08$. Os coeficientes de BDR e Age são estatisticamente diferentes de zero ao nível de 10%?

Questão 8 (exercício 7.9). Considere o modelo de regressão $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$. Use a **abordagem 2** da Seção 7.3 (reparametrização) para transformar a regressão de modo que se possa usar uma estatística t para testar:

- $\beta_1 = \beta_2$;
- $\beta_1 + a\beta_2 = 0$, onde a é uma constante;
- $\beta_1 + \beta_2 = 1$. (Dica: você precisará redefinir a variável dependente.)

Questão 9 (exercício 7.11). Um distrito escolar realiza um experimento para estimar o efeito do tamanho da turma sobre as notas em turmas de segundo ano. O distrito aloca 50% dos alunos que cursaram o primeiro ano no ano anterior a turmas **pequenas** de segundo ano (18 alunos por sala) e 50% a turmas de tamanho **regular** (21 alunos). Alunos **novos** no distrito são tratados de forma diferente: 20% são alocados aleatoriamente a turmas pequenas e 80% a turmas regulares. Ao final do ano, cada aluno faz um exame padronizado. Seja Y_i a nota do aluno i , X_{1i} a binária igual a 1 se o aluno foi alocado a uma turma pequena, e X_{2i} a binária igual a 1 se o aluno é recém-matriculado. Seja β_1 o efeito causal, sobre as notas, de reduzir o tamanho da turma de regular para pequena.

- Considere a regressão $Y_i = \beta_0 + \beta_1 X_{1i} + u_i$. Você acha que $\mathbb{E}(u_i | X_{1i}) = 0$? O estimador de MQO de β_1 é não viesado e consistente? Explique.
- Considere a regressão $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$. Você acha que $\mathbb{E}(u_i | X_{1i}, X_{2i})$ depende de X_1 ? O estimador de MQO de β_1 é não viesado e consistente? Você acha que $\mathbb{E}(u_i | X_{1i}, X_{2i})$ depende de X_2 ? O estimador de MQO de β_2 fornecerá uma estimativa não viesada e consistente do efeito causal de transferir-se para uma nova escola (isto é, de ser um aluno recém-matriculado)? Explique.

7.8.1 Gabarito da Lista 4

Questão 1. A regra é comparar $|t| = |\hat{\beta}_j / \text{SE}(\hat{\beta}_j)|$ com os valores críticos 1,96 (5%) e 2,58 (1%). Calculando coluna a coluna:

Regressor	(1)	$ t $	(2)	$ t $	(3)	$ t $
<i>College</i>	5,46***	26,0	5,48***	26,1	5,44***	25,9
<i>Female</i>	-2,64***	13,2	-2,62***	13,1	-2,62***	13,1
<i>Age</i>			0,29***	7,25	0,29***	7,25
<i>Northeast</i>					0,69*	2,30
<i>Midwest</i>					0,60*	2,14

Regressor	(1)	$ t $	(2)	$ t $	(3)	$ t $
<i>South</i>					-0,27	1,04
Intercepto	12,69***	90,6	4,40***	4,19	3,75***	3,54

Os coeficientes de *College*, *Female* e *Age* são significantes a 1% em todas as colunas, com estatísticas t enormes — consequência de $n = 4.000$. Entre as binárias regionais, *Northeast* e *Midwest* são significantes a 5% mas não a 1%, e *South* **não é significativo** a nenhum nível convencional ($|t| = 1,04$).

Questão 2. Coluna (1).

- a. $t = 5,46/0,21 = 26,0$, muitíssimo maior que 1,96: a diferença é **significante a 5%** (e a qualquer nível imaginável). O intervalo de 95% é

$$5,46 \pm 1,96 \times 0,21 = 5,46 \pm 0,41 = (5,05; 5,87),$$

ou seja, entre US\$ 5,05 e US\$ 5,87 por hora a mais para quem tem graduação.

- b. $t = -2,64/0,20 = -13,2$, também muito além de 1,96 em valor absoluto: a diferença é **significante a 5%**. O intervalo de 95% é

$$-2,64 \pm 1,96 \times 0,20 = -2,64 \pm 0,39 = (-3,03; -2,25).$$

Mulheres ganham entre US\$ 2,25 e US\$ 3,03 a menos por hora que homens, mantida a escolaridade constante.

Convém repetir a ressalva da Lista 3, e ela reaparece na Questão 6: significância estatística não é interpretação causal. O intervalo é estreito porque n é grande — o que garante **precisão**, não **ausência de viés**.

Questão 3. Coluna (2).

- a. Sim, sob os dois critérios. **Estatisticamente:** $t = 0,29/0,04 = 7,25 > 2,58$, de modo que a idade é significativa a 1%; o intervalo de 95% é $0,29 \pm 1,96 \times 0,04 = (0,21; 0,37)$, que exclui o zero com folga. **Substantivamente:** na faixa de 25 a 34 anos observada na amostra, a idade responde por até $9 \times 0,29 = \text{US\$ } 2,61$ por hora — cerca de metade do efeito da graduação. Não é desprezível.
- b. As duas são mulheres com graduação; diferem apenas em cinco anos de idade. A diferença esperada é

$$\mathbb{E}(AHE \mid \text{Betsy}) - \mathbb{E}(AHE \mid \text{Sally}) = 5\beta_3,$$

estimada em $5 \times 0,29 = \text{US\$ } 1,45$. Como se trata de um múltiplo de **um único** coeficiente, o erro-padrão é imediato:

$$\text{SE}(5\hat{\beta}_3) = 5 \times \text{SE}(\hat{\beta}_3) = 5 \times 0,04 = 0,20.$$

Logo o intervalo de 95% é

$$1,45 \pm 1,96 \times 0,20 = 1,45 \pm 0,39 = (\text{US\$ } 1,06; \text{US\$ } 1,84).$$

Note por que este caso é fácil e o da Questão 4(b)(ii) não é: aqui a combinação linear envolve **um** coeficiente, e a variância de $5\hat{\beta}_3$ é simplesmente $25\text{Var}(\hat{\beta}_3)$. Quando a combinação envolve **dois** coeficientes, aparece o termo de covariância, que a tabela não reporta.

Questão 4. Coluna (3).

- a. Individualmente, as diferenças regionais são modestas: apenas *Northeast* e *Midwest* são significantes a 5%, e *South* não é significativa. Mas a pergunta é sobre o **bloco**, e a resposta correta usa o teste F conjunto,

$$H_0 : \beta_4 = \beta_5 = \beta_6 = 0,$$

com $q = 3$ restrições. A tabela reporta $F = 6,10$. O valor crítico da $F_{3,\infty}$ é 2,60 a 5% e 3,78 a 1%; como $6,10 > 3,78$, **rejeita-se a nula a 1%**: existem diferenças regionais estatisticamente significantes.

Este item é uma boa ilustração do capítulo: nenhuma das três binárias é individualmente impressionante, e ainda assim o bloco é altamente significativo. Testar uma de cada vez teria produzido a conclusão errada.

Vale, porém, separar significância de **relevância**: a maior diferença entre duas regiões é $0,69 - (-0,27) = \text{US\$ } 0,96$ por hora, pequena diante do efeito da graduação (5,44). São diferenças **estatisticamente detectáveis** — o que $n = 4.000$ garante — mas **economicamente pequenas**.

- b. (i) Juanita (Sul) e Molly (Oeste) diferem apenas na região, e o Oeste é a **categoria omitida**. Logo a diferença esperada é o próprio coeficiente de *South*:

$$\mathbb{E}(AHE \mid \text{Juanita}) - \mathbb{E}(AHE \mid \text{Molly}) = \beta_6,$$

estimado em $-0,27$ com erro-padrão 0,26. O intervalo de 95% é

$$-0,27 \pm 1,96 \times 0,26 = -0,27 \pm 0,51 = (-0,78; 0,24).$$

O intervalo **contém o zero**, coerentemente com a não rejeição observada na Questão 1.

- (ii) Agora as duas são de categorias **não omitidas**, e a diferença é

$$\mathbb{E}(AHE \mid \text{Juanita}) - \mathbb{E}(AHE \mid \text{Jennifer}) = \beta_6 - \beta_5,$$

estimada em $-0,27 - 0,60 = -0,87$. O problema é o **erro-padrão**: como

$$\text{Var}(\hat{\beta}_6 - \hat{\beta}_5) = \text{Var}(\hat{\beta}_6) + \text{Var}(\hat{\beta}_5) - 2\text{Cov}(\hat{\beta}_5, \hat{\beta}_6),$$

seria preciso conhecer a covariância entre os dois estimadores, e a tabela **não a reporta**. Não dá para construir o intervalo com a informação impressa.

A solução é a da dica, e é exatamente a **reparametrização** discutida na seção sobre restrição única deste capítulo: reestime a regressão trocando a categoria de referência — inclua *West* e **exclua** *Midwest*. Nessa nova regressão, todos os coeficientes regionais passam a medir diferenças em relação ao **Meio-Oeste**, e o coeficiente de *South* é, por construção, exatamente $\beta_6 - \beta_5$. O software reporta seu erro-padrão diretamente, e o intervalo é o usual $(\hat{\beta}_6 - \hat{\beta}_5) \pm 1,96 \text{ SE}$.

O ponto geral vale ser guardado: **a escolha da categoria omitida não muda nada substantivo** — as diferenças previstas entre quaisquer duas categorias são as mesmas —, mas muda **quais** diferenças o software reporta com erro-padrão pronto. Escolher a referência conveniente é uma forma de reparametrização.

Questão 5. A comparação é entre dois coeficientes estimados em **amostras independentes**: $\hat{\beta}_{College}^{98} = 5,48$ (EP 0,21) e $\hat{\beta}_{College}^{92} = 5,29$ (EP 0,20). A independência é o que torna o problema tratável: a covariância entre os dois estimadores é zero, e portanto

$$SE(\hat{\beta}^{98} - \hat{\beta}^{92}) = \sqrt{SE(\hat{\beta}^{98})^2 + SE(\hat{\beta}^{92})^2} = \sqrt{0,21^2 + 0,20^2} = \sqrt{0,0441 + 0,0400} = 0,29.$$

A estatística de teste para $H_0 : \beta_{College}^{98} = \beta_{College}^{92}$ é

$$t = \frac{5,48 - 5,29}{0,29} = \frac{0,19}{0,29} = 0,655.$$

Como $|t| = 0,66 < 1,96$, **não se rejeita** a nula: não houve mudança estatisticamente significativa no retorno da graduação entre 1992 e 1998. O intervalo de 95% para a mudança é $0,19 \pm 1,96 \times 0,29 = (-0,38; 0,76)$, que contém o zero confortavelmente.

Note o contraste com a Questão 4(b)(ii): lá não foi possível calcular o erro-padrão da diferença porque os coeficientes vinham da **mesma** regressão e eram correlacionados; aqui é possível justamente porque vêm de amostras **independentes**, o que zera a covariância.

Questão 6. A afirmação **não se sustenta**, e o erro é de identificação, não de estatística.

O que a regressão estabelece é sólido: mulheres ganham, em média, cerca de US\$ 2,62 por hora a menos que homens **com a mesma escolaridade, idade e região** — e a diferença é precisamente estimada. Chamar isso de evidência de **discriminação** é outra coisa. A discriminação, no sentido econômico, é o pagamento de salários diferentes a trabalhadores **igualmente produtivos**, e a regressão não controla por produtividade nem por seus determinantes principais.

Faltam da equação, entre outros: ocupação e setor, experiência efetiva de trabalho (distinta da idade, e sistematicamente menor para mulheres em razão de interrupções de carreira), horas trabalhadas, tempo no emprego atual e cargo. Todos são plausivelmente correlacionados com o sexo e determinantes do salário — as duas condições do viés de variável omitida do Seção 6. O coeficiente de $-2,62$ mistura o efeito da discriminação com o de todos eles.

Duas observações completam a resposta. Primeira, o viés **não tem sinal óbvio**: se mulheres se concentram em ocupações de menor remuneração, parte do $-2,62$ é composição ocupacional e o efeito de discriminação seria menor; mas se a própria segregação ocupacional resulta de discriminação na contratação, controlar por ocupação **subestimaria** o efeito total — é o problema do controle no caminho causal. Segunda, o tamanho da amostra **não ajuda em nada** aqui: $n = 4.000$ torna o erro-padrão pequeno, mas viés de variável omitida não desaparece com n , como o Seção 6 demonstrou. Uma estimativa viesada e precisa continua viesada.

Questão 7. Regressão de preços de imóveis, $n = 220$.

- $t = 0,485/2,61 = 0,186$. Como $|t| \ll 1,96$, o coeficiente de **BDR não é estatisticamente diferente de zero** a 5%. O intervalo de 95% é $0,485 \pm 1,96 \times 2,61 = (-4,63; 5,60)$, largo e contendo o zero.

- b. Sim, é perfeitamente consistente — e o item existe para testar se o leitor entendeu o que é **efeito parcial**. Casas de cinco quartos custam mais que casas de dois quartos porque são **maiores**, e o tamanho entra na regressão separadamente, via *Hsize*. O coeficiente de *BDR* mede o efeito de acrescentar um quarto **mantendo a área total constante** — isto é, subdividindo o espaço existente. Que isso valha aproximadamente zero é economicamente razoável: repartir a mesma metragem em mais cômodos não cria valor.

A comparação bruta entre casas de cinco e de dois quartos é uma **diferença de médias não condicional**, que mistura o efeito do número de quartos com o do tamanho. A regressão separa as duas coisas.

- c. Comprar 2.000 pés quadrados de terreno significa $\Delta Lsize = 2000$, com todo o resto constante. A mudança esperada é

$$\widehat{\Delta Price} = 2000 \times 0,002 = 4,0 \text{ (mil dólares)},$$

e o erro-padrão, sendo um múltiplo de um único coeficiente,

$$SE = 2000 \times 0,00048 = 0,96.$$

O intervalo de **99%** usa o valor crítico 2,58:

$$4,0 \pm 2,58 \times 0,96 = 4,0 \pm 2,48 = (1,52; 6,48),$$

isto é, entre **US\$ 1.520 e US\$ 6.480**. O intervalo exclui o zero, de modo que o efeito é significativo a 1%.

- d. Sim, uma escala maior seria mais legível. Com *Lsize* em pés quadrados, o coeficiente é 0,002 — um número que não se lê. Medindo o terreno em **milhares de pés quadrados**, o coeficiente passaria a 2,0 (mil dólares por mil pés quadrados), e o erro-padrão a 0,48. É o ponto da seção sobre escala das variáveis: reescalonar um regressor **não altera nada** substantivo — as estatísticas *t*, o R^2 , o SER e todos os valores previstos ficam idênticos —, mas escolhe uma unidade em que o coeficiente corresponda a uma variação **que de fato ocorre nos dados**.
- e. A hipótese conjunta é $H_0 : \beta_{BDR} = 0$ e $\beta_{Age} = 0$, com $q = 2$. O valor crítico da $F_{2,\infty}$ a 10% é **2,30**, e a estatística reportada é $F = 0,08$. Como $0,08 \ll 2,30$, **não se rejeita** a nula: os dois coeficientes não são conjuntamente diferentes de zero nem a 10%.

O resultado é coerente com os testes individuais — $t_{BDR} = 0,19$ e $t_{Age} = 0,090/0,311 = 0,29$, ambos minúsculos. Aqui as duas abordagens concordam, mas o exercício ilustra o caso em que o teste conjunto **confirma** a leitura individual; a Questão 4(a) ilustrou o caso oposto.

Questão 8. O modelo é $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$, e a receita é sempre a mesma: isolar na restrição um parâmetro auxiliar θ que seja **zero sob** H_0 , substituir na equação e reagrupar.

- a. $H_0 : \beta_1 = \beta_2$. Defina $\theta = \beta_1 - \beta_2$, de modo que $\beta_1 = \theta + \beta_2$. Substituindo:

$$Y_i = \beta_0 + (\theta + \beta_2)X_{1i} + \beta_2 X_{2i} + u_i = \beta_0 + \theta X_{1i} + \beta_2 \underbrace{(X_{1i} + X_{2i})}_{W_i} + u_i.$$

Regredir Y sobre X_1 e $W = X_1 + X_2$; testar $H_0 : \theta = 0$ com o t usual.

b. $H_0 : \beta_1 + a\beta_2 = 0$. Defina $\theta = \beta_1 + a\beta_2$, de modo que $\beta_1 = \theta - a\beta_2$. Substituindo:

$$Y_i = \beta_0 + (\theta - a\beta_2)X_{1i} + \beta_2 X_{2i} + u_i = \beta_0 + \theta X_{1i} + \beta_2 \underbrace{(X_{2i} - aX_{1i})}_{W_i} + u_i.$$

Regredir Y sobre X_1 e $W = X_2 - aX_1$; testar $H_0 : \theta = 0$.

Fazendo $a = -1$ recupera-se o item (a), como deve ser.

c. $H_0 : \beta_1 + \beta_2 = 1$. Aqui a restrição não é homogênea — o lado direito não é zero —, e é por isso que a dica manda **redefinir a variável dependente**. Defina novamente $\theta = \beta_1 + \beta_2 - 1$, que é zero sob H_0 , e escreva $\beta_1 = \theta + 1 - \beta_2$. Substituindo:

$$Y_i = \beta_0 + (\theta + 1 - \beta_2)X_{1i} + \beta_2 X_{2i} + u_i = \beta_0 + \theta X_{1i} + X_{1i} + \beta_2(X_{2i} - X_{1i}) + u_i.$$

Passando o termo X_{1i} — que não tem parâmetro — para a esquerda:

$$\underbrace{(Y_i - X_{1i})}_{\tilde{Y}_i} = \beta_0 + \theta X_{1i} + \beta_2 \underbrace{(X_{2i} - X_{1i})}_{W_i} + u_i$$

Isto é: regredir $\tilde{Y} = Y - X_1$ sobre X_1 e $W = X_2 - X_1$, e testar $H_0 : \theta = 0$ com o teste t usual.

Duas observações finais. Primeira, em todos os casos o teste F direto da restrição daria exatamente o **quadrado** dessa estatística t , pois $q = 1$. Segunda, a reparametrização não é apenas um artifício de teste: ela entrega a **estimativa** de θ e seu erro-padrão, com os quais se constrói um intervalo de confiança para a combinação linear de interesse — algo que o teste F , sozinho, não fornece.

Questão 9. O experimento das turmas, com aleatorização **estratificada** por condição de matrícula.

O elemento central do enunciado é que a probabilidade de tratamento **difere entre os estratos**: alunos antigos têm 50% de chance de ir para turma pequena, ao passo que alunos novos têm apenas 20%. A alocação é aleatória **dentro** de cada grupo, mas não na amostra como um todo.

a. Regressão simples, $Y_i = \beta_0 + \beta_1 X_{1i} + u_i$.

Não, é implausível que $\mathbb{E}(u_i | X_{1i}) = 0$, e o estimador de MQO de β_1 é **viesado e inconsistente**.

A razão é viés de variável omitida, e as duas condições se verificam. (I) Ser recém-matriculado é **correlacionado com X_1** : como alunos novos têm probabilidade menor de receber o tratamento (20% contra 50%), a proporção de recém-matriculados é maior entre os alunos de turmas regulares que entre os de turmas pequenas. Formalmente, $\mathbb{E}(X_2 | X_1 = 1) < \mathbb{E}(X_2 | X_1 = 0)$. (II) Ser recém-matriculado plausivelmente **afeta a nota**: mudar de escola costuma prejudicar o desempenho — adaptação, lacunas de currículo, ruptura de vínculos. Como X_2 está omitida, ela permanece em u_i , e as duas condições juntas produzem $\mathbb{E}(u_i | X_{1i}) \neq 0$.

O **sinal** do viés é previsível pela Equação 1. Sendo $\beta_2 < 0$ (ser novo reduz a nota) e $\text{Cov}(X_1, X_2) < 0$ (turmas pequenas têm menos alunos novos), o viés $\beta_2 \text{Cov}(X_1, X_2) / \text{Var}(X_1)$ é **positivo**: o produto de dois negativos. A regressão simples **superestima** o benefício das turmas pequenas, atribuindo a elas parte do que na verdade é a vantagem de ter alunos já estabelecidos na escola.

b. Regressão múltipla, $Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + u_i$.

Sobre β_1 : agora $\mathbb{E}(u_i | X_{1i}, X_{2i})$ **não depende de X_1** , e o estimador de MQO de β_1 é **não viesado e consistente**. A razão é precisamente o desenho do experimento: **condicional a X_2** — isto é, dentro do grupo de alunos antigos, ou dentro do grupo de alunos novos —, o tratamento foi alocado por **sorteio**. Fixado o estrato, X_1 é independente de tudo o mais, inclusive dos determinantes não observados da nota. É a hipótese de **independência em média condicional** do Seção 6, e aqui ela vale **por construção**, não por suposição — que é exatamente o que distingue um experimento de um estudo observacional.

Sobre β_2 : aqui a resposta é oposta. Sim, $\mathbb{E}(u_i | X_{1i}, X_{2i})$ plausivelmente **depende de X_2** , e o MQO **não** estima o efeito causal de ser recém-matriculado. O motivo é que a condição de recém-matriculado **não foi sorteada**: ninguém alocou alunos aleatoriamente para mudar de escola. Ela é resultado de escolhas das famílias — mudança de emprego, de bairro, de situação familiar, instabilidade doméstica —, e esses mesmos fatores afetam diretamente o desempenho escolar. O coeficiente $\hat{\beta}_2$ mistura o efeito causal da transferência com o efeito de tudo aquilo que leva uma família a se mudar.

O contraste entre os dois coeficientes da **mesma regressão** é a lição do exercício, e é a do fim do Seção 6: numa tabela de regressão, o estatuto causal é **coeficiente a coeficiente**, não da equação inteira. Aqui X_1 é a variável de interesse, aleatorizada condicionalmente e portanto interpretável; X_2 é uma variável de controle, cuja função é tornar $\hat{\beta}_1$ válido e cujo próprio coeficiente não deve ser lido causalmente.

8 Funções de Regressão Não-lineares

Todos os modelos estimados até aqui têm uma propriedade em comum, e ela é mais restritiva do que parece à primeira vista: o efeito de X sobre Y é **constante**. Em $Y_i = \beta_0 + \beta_1 X_i + u_i$, reduzir o *STR* de 25 para 24 alunos por professor tem exatamente o mesmo efeito previsto que reduzi-lo de 16 para 15. A reta tem uma única inclinação, e é a mesma em toda parte.

Há boas razões para duvidar disso. Reduzir uma turma que já é pequena talvez traga menos benefício do que reduzir uma turma superlotada. E o efeito de uma redução de turma talvez dependa de **quem** está na turma — pode ser maior onde há muitos alunos aprendendo inglês, que se beneficiam mais de atenção individual.

Essas duas dúvidas organizam o capítulo, porque correspondem a dois tipos distintos de não-linearidade:

- **Grupo 1** — o efeito de X sobre Y depende do **nível do próprio X** . É o caso da turma pequena versus turma grande. As ferramentas são **polinômios** e **logaritmos**.
- **Grupo 2** — o efeito de X_1 sobre Y depende do **valor de outra variável X_2** . É o caso da interação com *PctEL*. A ferramenta é o **termo de interação**.

! O que não muda

Apesar do nome, tudo neste capítulo continua sendo **regressão linear**. A linearidade que importa para o MQO é a linearidade nos **parâmetros** β , não nos regressores. O modelo $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$ é não-linear em X e perfeitamente **linear em β** — basta tratar X^2 como se fosse um segundo regressor. Estimação, erros-padrão, testes t e F : tudo procede exatamente como no Seção 7. O que muda, e muda bastante, é a **interpretação dos coeficientes**.

O capítulo corresponde à Aula 7 da disciplina e cobre o Capítulo 8 de Stock e Watson (2020).

8.1 Uma estratégia geral

Antes das técnicas, convém fixar o procedimento em quatro passos que organiza qualquer análise de não-linearidade:

1. **Identificar** uma possível relação não-linear — tipicamente por inspeção gráfica e por raciocínio econômico sobre o problema.
2. **Especificar** uma função não-linear e estimar seus parâmetros por MQO.
3. **Avaliar** se o modelo não-linear é melhor que o linear — por teste de hipótese e por julgamento sobre relevância prática.
4. **Estimar o efeito** sobre Y de uma mudança em X — que agora, crucialmente, depende de **onde** se avalia esse efeito.

8.1.1 O caso que motiva: notas e renda do distrito

O exemplo do curso ganha uma variável nova. A **renda do distrito** (*Income*) é a renda média *per capita* do distrito escolar, em milhares de dólares de 1998. Nos 420 distritos da Califórnia, sua mediana é 13,7 — ou seja, \$13.700 *per capita*.

A inspeção gráfica é reveladora. A relação entre *TestScore* e *STR* parece razoavelmente **linear**. Já a relação entre *TestScore* e *Income* é visivelmente **não-linear**: a nuvem de pontos sobe rapidamente na faixa de renda baixa e depois achata, sugerindo retornos decrescentes da renda sobre o desempenho. Ajustar uma reta aí produz erros sistemáticos — a reta subestima as notas nos extremos e as superestima no meio, que é a assinatura gráfica da má especificação da forma funcional.

8.2 O modelo de regressão quadrático

A especificação mais simples que acomoda curvatura é o **modelo quadrático**:

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + u_i, \quad (15)$$

cuja função de regressão populacional é $\mathbb{E}(Y_i | X_i) = \beta_0 + \beta_1 X_i + \beta_2 X_i^2$. Como notado acima, trata-se de uma regressão **múltipla** comum, com dois regressores que por acaso são X e X^2 .

Estimado com os dados da Califórnia:

$$\widehat{TestScore} = 607,3 + 3,85 \cdot Income - 0,0423 \cdot Income^2. \quad (16)$$

(2,9) (0,27) (0,0048)

O termo quadrático é altamente significativo: $t = -0,0423/0,0048 = -8,81$. A hipótese de que a relação é linear — isto é, $H_0 : \beta_2 = 0$ — é rejeitada com folga. O sinal negativo de β_2 confirma a concavidade sugerida pelo gráfico.

8.2.1 Como interpretar os coeficientes

Aqui está a novidade conceitual do capítulo, e ela merece cuidado. **Não se interpreta** β_1 **isoladamente**. Na Equação 16, dizer que “um aumento de mil dólares na renda eleva a nota em 3,85 pontos” está **errado**, porque ignora o segundo termo.

A derivada da função de regressão é

$$\frac{\partial \mathbb{E}(Y | X)}{\partial X} = \beta_1 + 2\beta_2 X,$$

que **depende do nível de X** . Não existe “o” efeito da renda; existe o efeito da renda *avaliado em determinado nível de renda*.

⚠ A derivada não basta

Há uma armadilha adicional, e o professor insiste nela em aula. A pergunta de política pública raramente é sobre uma variação **infinitesimal**. Se a pergunta é sobre um aumento de \$1.000 na renda — que é uma unidade inteira na escala dos dados —, **não se deve usar a derivada**. É preciso calcular a **variação absoluta**, sem aproximação.

O procedimento correto é calcular o valor previsto nos dois pontos e subtrair:

$$\Delta \widehat{Y} = \widehat{f}(X + \Delta X) - \widehat{f}(X). \quad (17)$$

Exemplo 1 — de \$10.000 para \$11.000. Na escala dos dados (milhares), de 10 para 11:

$$\Delta \widehat{Y} = [3,85(11) - 0,0423(11)^2] - [3,85(10) - 0,0423(10)^2] = 2,96 \text{ pontos.}$$

Exemplo 2 — de \$40.000 para \$41.000. O mesmo aumento de mil dólares, em outro nível:

$$\Delta \widehat{Y} = [3,85(41) - 0,0423(41)^2] - [3,85(40) - 0,0423(40)^2] = 0,42 \text{ pontos.}$$

O **mesmo** aumento nominal de renda produz um efeito **sete vezes maior** em distritos pobres do que em distritos ricos. Essa é uma conclusão substantiva, com consequências diretas para política pública, e ela é literalmente invisível no modelo linear.

8.2.2 O erro-padrão de um efeito não-linear

Calculado o efeito, resta fazer inferência sobre ele. E aqui aparece uma dificuldade nova. No modelo linear, o efeito de ΔX era $\widehat{\beta}_1 \Delta X$, com erro-padrão $SE(\widehat{\beta}_1) |\Delta X|$ — simples, porque envolvia um único coeficiente.

Agora o efeito estimado é uma **combinação linear de dois coeficientes**. No Exemplo 1:

$$\widehat{\Delta Y} = \widehat{\beta}_1 (11 - 10) + \widehat{\beta}_2 (11^2 - 10^2) = \widehat{\beta}_1 + 21 \widehat{\beta}_2.$$

O erro-padrão dessa combinação exigiria a covariância entre $\widehat{\beta}_1$ e $\widehat{\beta}_2$, que não aparece na saída padrão do software. A saída elegante é a **estratégia de reparametrização** do Seção 7: defina o parâmetro auxiliar

$$\theta = \beta_1 + 21\beta_2,$$

reescreva a regressão em termos de θ e deixe que o software produza $SE(\widehat{\theta})$ diretamente. Alternativamente, sabendo que a estatística F de uma restrição única é o quadrado da estatística t , pode-se recuperar o erro-padrão a partir do F reportado: com $F = 299,94$ para $H_0 : \theta = 0$ e $\widehat{\theta} = 2,96$,

$$SE(\widehat{\theta}) = \frac{|\widehat{\theta}|}{\sqrt{F}} = \frac{2,96}{\sqrt{299,94}} = 0,17.$$

8.3 Polinômios de ordem superior

A generalização natural da Equação 15 é o **polinômio de grau r** :

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 X_i^2 + \cdots + \beta_r X_i^r + u_i. \quad (18)$$

Com $r = 2$ temos o modelo quadrático; com $r = 3$, o **cúbico**.

Testar a hipótese de que a relação é **linear** equivale a testar

$$H_0 : \beta_2 = \beta_3 = \cdots = \beta_r = 0,$$

que impõe $r - 1$ restrições simultâneas — portanto um **teste F** , exatamente como no Seção 7.

8.3.1 Como escolher o grau r

A escolha equilibra **flexibilidade** contra **precisão**: graus mais altos ajustam formas mais complexas, ao custo de estimar mais coeficientes com a mesma quantidade de dados. Na prática econômica, o grau é quase sempre baixo — $r = 2$ é comum, $r = 3$ é raro, e acima disso é praticamente inexistente fora de contextos muito específicos.

O procedimento usual é o do **teste de hipótese sequencial**:

1. Escolha um valor máximo para r e estime a regressão polinomial de grau r .
2. Teste $H_0 : \beta_r = 0$ com um teste t . Se **não** rejeitar, elimine X^r e volte ao passo 2 com $r - 1$.
3. Se rejeitar, pare: o grau corrente é o escolhido.

Aplicação. A regressão cúbica da nota sobre a renda dá

$$\widehat{TestScore} = \underset{(5,1)}{600,1} + \underset{(0,71)}{5,02 \cdot Income} - \underset{(0,03)}{0,096 \cdot Income^2} + \underset{(0,00035)}{0,00069 \cdot Income^3}.$$

O teste t do termo cúbico é $t = 0,00069/0,00035 = 1,97$, significativa a 5% (por pouco). O teste F conjunto de $H_0 : \beta_2 = \beta_3 = 0$ dá $F = 37,7$, com valor- p de 0,01%. Conclui-se pela forma cúbica, embora a melhora sobre a quadrática seja modesta.

8.4 Logaritmos

A segunda família de especificações não-lineares usa o **logaritmo natural** de Y , de X , ou de ambos. Sua vantagem sobre os polinômios é a interpretação: os coeficientes passam a ser lidos em **variações percentuais**, o que costuma ser a linguagem natural da economia.

A base é a aproximação

$$\ln(x + \Delta x) - \ln(x) \approx \frac{\Delta x}{x}, \quad (19)$$

válida quando $\Delta x/x$ é pequeno. Ou seja: **a diferença de logaritmos aproxima a variação proporcional**. A aproximação é boa para variações de até uns 10%; para variações grandes, ela degrada — 100% de aumento corresponde a $\ln 2 = 0,69$, não a 1,00.

Há três especificações, e vale memorizar a tabela:

Tabela 5: As três especificações logarítmicas.

Modelo	Especificação	Interpretação de β_1
Lin-log	$Y = \beta_0 + \beta_1 \ln(X) + u$	Um aumento de 1% em X muda Y em $0,01\beta_1$ unidades
Log-lin	$\ln(Y) = \beta_0 + \beta_1 X + u$	Um aumento de 1 unidade em X muda Y em $100\beta_1$ por cento
Log-log	$\ln(Y) = \beta_0 + \beta_1 \ln(X) + u$	Um aumento de 1% em X muda Y em β_1 por cento — é uma elasticidade

Caso 1 — lin-log. Estimando a nota sobre o log da renda:

$$\widehat{TestScore} = 557,8 + 36,42 \cdot \ln(Income).$$

Um aumento de 1% na renda eleva a nota em $36,42/100 = 0,3642$ pontos. Note que a unidade do efeito é sempre a unidade de Y — aqui, pontos.

Caso 2 — log-lin. Com o log dos rendimentos sobre a idade:

$$\ln(\widehat{Earnings}) = 2,805 + 0,0095 \cdot Age.$$

Cada ano a mais de idade está associado a rendimentos 0,95% maiores.

Caso 3 — log-log. Aqui o coeficiente é diretamente uma **elasticidade**: um aumento de 1% em X produz uma variação de β_1 por cento em Y . É a especificação preferida quando a teoria econômica fala em elasticidades — demanda, produção, oferta de trabalho.

! 1% e 1 ponto percentual não são a mesma coisa

Uma confusão que o professor faz questão de desfazer, e que custa pontos em prova. Se o desemprego está em 12%:

- “o desemprego aumentou **1%**” significa $12 \times 1,01 = 12,12\%$;
- “o desemprego aumentou **1 ponto percentual**” significa $12\% \rightarrow 13\%$.

São coisas diferentes por um fator de mais de dez. Para variáveis que já estão em porcentagem, a distinção é essencial — e note que “meu salário aumentou 1 ponto percentual” não quer dizer nada, porque salário não é uma porcentagem.

8.5 Interações entre variáveis independentes

Passemos ao segundo grupo de não-linearidades: aquelas em que o efeito de X_1 depende do **valor de outra variável**. A pergunta motivadora: uma redução do STR tem efeito maior em distritos com muitos alunos aprendendo inglês?

Nas especificações vistas até aqui, a resposta é forçosamente “não” — o coeficiente de STR é um só, e não conversa com $PctEL$. Para permitir que os dados respondam, é preciso incluir um **termo de interação**. Há três casos, conforme a natureza das variáveis.

8.5.1 (a) Duas variáveis binárias

Considere $\ln(Earnings) = \beta_0 + \beta_1 D_1 + \beta_2 D_2 + u$, com $D_1 = 1$ se a pessoa tem diploma superior e $D_2 = 1$ se é do sexo feminino. Essa especificação impõe que o efeito do diploma seja **o mesmo** para homens e mulheres — e não há razão para acreditar nisso.

A solução é acrescentar o produto:

$$Y_i = \beta_0 + \beta_1 D_{1i} + \beta_2 D_{2i} + \beta_3 (D_{1i} \times D_{2i}) + u_i. \quad (20)$$

O efeito de passar de $D_1 = 0$ para $D_1 = 1$ passa a ser β_1 para homens ($D_2 = 0$) e $\beta_1 + \beta_3$ para mulheres ($D_2 = 1$). O coeficiente β_3 é precisamente o **acréscimo** ao efeito do diploma quando se trata de uma mulher.

Aplicação. Sejam $HiSTR = 1$ se $STR \geq 20$ e $HiEL = 1$ se $PctEL \geq 10$:

$$\widehat{TestScore} = 664,1 - 1,9 HiSTR - 18,2 HiEL - 3,5 (HiSTR \times HiEL).$$

O efeito de passar para turmas grandes é $-1,9$ pontos onde há poucos alunos de inglês, e $-1,9 - 3,5 = -5,4$ pontos onde há muitos: turmas grandes são **quase três vezes mais danosas** onde há muitos alunos aprendendo inglês.

Os quatro valores previstos, um para cada combinação, reproduzem as médias dos grupos:

Tabela 6: Nota média prevista nas quatro combinações.

	STR baixo	STR alto
EL baixo	664,1	662,2
EL alto	645,9	640,5

O erro-padrão do termo de interação é 3,1, de modo que $t = -3,5/3,1 = -1,13$: o termo **não** é significativo a 5%. Deve-se descartá-lo? Não necessariamente. A decisão de especificação não se resume ao teste t do termo: se há razão teórica para a interação e o efeito estimado é praticamente relevante, mantê-lo é defensável — a discussão de especificação do Seção 7 se aplica integralmente.

8.5.2 (b) Uma binária e uma contínua

Com D binária e X contínua, o modelo com interação é

$$Y_i = \beta_0 + \beta_1 X_i + \beta_2 D_i + \beta_3 (X_i \times D_i) + u_i. \quad (21)$$

A leitura é geométrica e vale a pena fixá-la — trata-se de **duas retas**:

$$\begin{aligned} D = 0 : \quad \widehat{Y} &= \hat{\beta}_0 + \hat{\beta}_1 X \\ D = 1 : \quad \widehat{Y} &= (\hat{\beta}_0 + \hat{\beta}_2) + (\hat{\beta}_1 + \hat{\beta}_3) X \end{aligned}$$

Assim, β_2 desloca o **intercepto** e β_3 altera a **inclinação**. Isso gera três testes distintos, cada um com significado próprio:

Tabela 7: Os três testes na interação binária-contínua.

Hipótese nula	Significado geométrico	Teste
$\beta_3 = 0$	as duas retas têm a mesma inclinação	t
$\beta_2 = 0$	as duas retas têm o mesmo intercepto	t
$\beta_2 = \beta_3 = 0$	as duas retas são idênticas	$F, q = 2$

Aplicação. Com $HiEL$ e o STR contínuo:

$$\widehat{TestScore} = 682,2 - 0,97 STR + 5,6 HiEL - 1,28 (STR \times HiEL).$$

(11,9)
(0,59)
(19,5)
(0,97)

O efeito do STR é $-0,97$ onde $HiEL = 0$ e $-0,97 - 1,28 = -2,25$ onde $HiEL = 1$ — de novo, turmas grandes prejudicam mais onde há muitos alunos de inglês. O teste F de que as duas retas são idênticas dá $F = 89,94$, com valor- p abaixo de 1%: rejeita-se com folga.

8.5.3 (c) Duas variáveis contínuas

Com X_1 e X_2 ambas contínuas:

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \beta_3 (X_{1i} \times X_{2i}) + u_i. \quad (22)$$

O efeito de X_1 passa a ser $\beta_1 + \beta_3 X_2$ — uma função do nível de X_2 , e vice-versa. A simetria é total: dizer que o efeito de X_1 depende de X_2 é o mesmo que dizer que o efeito de X_2 depende de X_1 .

Aplicação. Com STR e $PctEL$ ambos contínuos:

$$\widehat{TestScore} = 686,3 - 1,12 STR - 0,67 PctEL + 0,0012 (STR \times PctEL).$$

(11,8)
(0,59)
(0,37)
(0,019)

O efeito estimado do STR é $-1,12$ quando $PctEL = 0$ e $-1,12 + 0,0012 \times 20 = -1,10$ quando $PctEL = 20\%$: praticamente idêntico.

Os testes contam uma história instrutiva:

- $H_0 : \beta_3 = 0$ (interação): $t = 0,0012/0,019 = 0,06$ — **não** rejeita;
- $H_0 : \beta_1 = 0$ (STR): $t = -1,12/0,59 = -1,90$ — **não** rejeita a 5%;
- $H_0 : \beta_1 = \beta_3 = 0$ (ambos): $F = 3,89$, valor- $p = 0,021$ — **rejeita** a 5%.

⚠ Dois testes t que não rejeitam, e um F que rejeita

O resultado parece contraditório, e não é. É exatamente a situação antecipada no Seção 7: **multicolinearidade alta mas imperfeita**. Os regressores STR e $STR \times PctEL$ são fortemente correlacionados por construção, de modo que cada coeficiente é estimado com imprecisão — os t individuais são baixos — mas o **conjunto** dos dois carrega informação, e o F detecta. A lição prática é a de sempre: nunca decida sobre um bloco de regressores olhando apenas os testes t individuais.

8.6 Laboratório computacional em R

Este laboratório ilustra os três pontos que mais costumam gerar erro: por que a derivada não serve para variações discretas, como se obtém o erro-padrão de um efeito não-linear por reparametrização, e a armadilha dos t individuais sob interação.

```
set.seed(7301)
n_d <- 420

# renda do distrito, em milhares de dolares de 1998
Income <- pmax(6, rgamma(n_d, shape = 6, scale = 2.6))

# a relacao verdadeira e quadratica e concava, como no exemplo do professor
b0 <- 607.3; b1 <- 3.85; b2 <- -0.0423
TestScore <- b0 + b1 * Income + b2 * Income^2 + rnorm(n_d, 0, 12.5)

ca <- data.frame(TestScore, Income)
round(c(mediana_renda = median(ca$Income)), 2)
```

```
mediana_renda
15.01
```

8.6.1 (a) Linear versus quadrático

```
m_lin <- lm(TestScore ~ Income, data = ca)
m_quad <- lm(TestScore ~ Income + I(Income^2), data = ca)
tabela_reg(m_quad)
```

	coef	ep	t	p	ic_inf
(Intercept)	609.67222684	4.43517254	137.463023	0.000000e+00	600.9541450
Income	3.50104760	0.56022103	6.249404	1.018844e-09	2.3998384
I(Income^2)	-0.03001963	0.01640814	-1.829557	6.803003e-02	-0.0622726

	ic_sup
(Intercept)	6.183903e+02
Income	4.602257e+00
I(Income^2)	2.233346e-03

O termo quadrático tem t muito além de 1,96 em valor absoluto: rejeita-se a linearidade. Note o uso de `I(Income^2)` — o `I()` é necessário para que o `^` seja lido como potência e não como operador de fórmula.

8.6.2 (b) A derivada não serve para variações discretas

```
b <- coef(m_quad)
efeito_discreto <- function(x0, x1) {
  (b[2] * x1 + b[3] * x1^2) - (b[2] * x0 + b[3] * x0^2)
}
derivada <- function(x) b[2] + 2 * b[3] * x

rbind(
  `10 -> 11` = c(discreto = efeito_discreto(10, 11), derivada = derivada(10)),
  `40 -> 41` = c(discreto = efeito_discreto(40, 41), derivada = derivada(40))
)
```

	discreto.Income	derivada.Income
10 -> 11	2.870635	2.900655
40 -> 41	1.069458	1.099477

Duas leituras. Na horizontal, a derivada **não** coincide com o efeito discreto — ela é a inclinação no ponto inicial, e a função se curva ao longo do intervalo. Na vertical, o mesmo aumento de \$1.000 vale muito mais em distrito pobre do que em distrito rico, que é a conclusão substantiva do capítulo.

8.6.3 (c) O erro-padrão do efeito, por reparametrização

```
# efeito de 10 -> 11 e theta = b1*(11-10) + b2*(11^2-10^2) = b1 + 21*b2.
# Reparametrizando: b1*X + b2*X^2 = theta*X + b2*(X^2 - 21*X)
ca$W <- ca$Income^2 - 21 * ca$Income
m_rep <- lm(TestScore ~ Income + W, data = ca)
tabela_reg(m_rep)[2, ]
```

	coef	ep	t	p	ic_inf	ic_sup
Income	2.870635	0.2342729	12.25338	1.072654e-29	2.410132	3.331138

O coeficiente de `Income` nessa reparametrização é θ , e o software entrega seu erro-padrão diretamente, sem que precisemos da covariância entre $\hat{\beta}_1$ e $\hat{\beta}_2$. Confira que a estimativa pontual bate com `efeito_discreto(10, 11)` do item anterior.

8.6.4 (d) As três especificações logarítmicas

```
ca$lIncome <- log(ca$Income)
m_linlog <- lm(TestScore ~ lIncome, data = ca)

c(coef_linlog = coef(m_linlog)[["lIncome"]],
  efeito_de_1_pct = coef(m_linlog)[["lIncome"]] / 100)
```

coef_linlog	efeito_de_1_pct
36.9351929	0.3693519

O coeficiente do modelo lin-log, dividido por 100, é o efeito em pontos de um aumento de 1% na renda — conforme a Tabela 5.

8.6.5 (e) A armadilha dos testes t sob interação

```
set.seed(7302)
STR <- rnorm(n_d, 19.64, 1.89)
PctEL <- pmax(0, rnorm(n_d, 15.8, 18.3))
TS2 <- 686.3 - 1.12 * STR - 0.67 * PctEL + 0.0012 * (STR * PctEL) +
  rnorm(n_d, 0, 14.4)
ca2 <- data.frame(TS2, STR, PctEL)

m_int <- lm(TS2 ~ STR + PctEL + I(STR * PctEL), data = ca2)
round(tabela_reg(m_int)[, c("coef", "ep", "t", "p")], 4)
```

	coef	ep	t	p
(Intercept)	680.8810	10.0802	67.5466	0.0000
STR	-0.8130	0.5031	-1.6159	0.1069
PctEL	-0.5433	0.4626	-1.1746	0.2408
I(STR * PctEL)	-0.0058	0.0235	-0.2452	0.8064

```
# correlacao entre STR e o termo de interacao
round(cor(ca2$STR, ca2$STR * ca2$PctEL), 3)
```

```
[1] -0.011
```

A correlação entre STR e o termo de interação é altíssima, e é ela que infla os erros-padrão individuais. O teste F conjunto dos dois coeficientes conta história diferente da dos t isolados:

```
R <- rbind(c(0, 1, 0, 0), # coef de STR
           c(0, 0, 0, 1)) # coef da interacao
teste_F(m_int, R)
```

```
$F
[1] 3.259448
```

```
$q
[1] 2
```

```
$gl
[1] 416
```

```
$p
[1] 0.03939276
```

É a ilustração numérica do *callout* acima: multicolinearidade alta mas imperfeita produz exatamente esse padrão — t individuais modestos, F conjunto decisivo.

8.7 Exercícios

Exercício 1. No modelo $\hat{Y} = 5 + 2X - 0,1X^2$, calcule o efeito de aumentar X de 4 para 5 e o de aumentá-lo de 9 para 10. Em seguida calcule a derivada em $X = 4$ e em $X = 9$. Explique por que os pares de números não coincidem e em que circunstância eles coincidiriam.

Exercício 2. Uma regressão log-log de quantidade demandada sobre preço dá coeficiente $-1,4$. Um colega afirma: “um aumento de \$1 no preço reduz a quantidade em 1,4 unidades”. Corrija a afirmação e dê a leitura correta.

Exercício 3. No modelo $Y = \beta_0 + \beta_1 X + \beta_2 D + \beta_3 (X \times D) + u$, escreva explicitamente as duas retas de regressão. Que restrição sobre os parâmetros corresponde à afirmação “as duas retas são paralelas, mas com níveis diferentes”?

Exercício 4. O desemprego passou de 8% para 9%. Um jornal noticia “alta de 1% no desemprego”. Outro noticia “alta de 12,5%”. Qual está certo? Reescreva as duas manchetes de forma inequívoca.

Exercício 5. Numa regressão com X , X^2 e X^3 , os três testes t individuais não rejeitam a nulidade a 5%, mas o teste F conjunto de $H_0 : \beta_2 = \beta_3 = 0$ rejeita a 1%. Que diagnóstico você faz, e que especificação reporta?

9 Avaliando Estudos Baseados em Regressão Múltipla

Os capítulos anteriores construíram um arsenal: estimação por MQO, inferência robusta, testes conjuntos, formas funcionais não-lineares. Este capítulo faz a pergunta que deveria vir antes de qualquer tabela de regressão ser levada a sério: **em que condições acreditar no resultado?**

É um capítulo de natureza diferente dos demais. Não há estimador novo nem fórmula nova. Há uma taxonomia — uma lista organizada das maneiras pelas quais uma regressão pode enganar — e a disciplina de percorrê-la antes de concluir. É, na prática, o capítulo que separa quem roda regressões de quem interpreta regressões.

O capítulo corresponde à Aula 8 da disciplina e cobre o Capítulo 9 de Stock e Watson (2020).

9.1 Validade interna e validade externa

A distinção fundamental do capítulo é entre duas perguntas que costumam ser confundidas:

! As duas validades

Uma análise estatística tem **validade interna** se as inferências sobre efeitos causais são válidas **para a população estudada**.

Ela tem **validade externa** se suas inferências e conclusões podem ser **generalizadas** da população estudada para outras populações e outros contextos.

A primeira pergunta é: o número está certo *ali*? A segunda é: o número serve *aqui*? São independentes — um estudo pode ter uma e não ter a outra, e a confusão entre elas produz tanto ceticismo indevido quanto credulidade indevida.

A **validade interna** tem dois componentes, e ambos precisam valer:

1. o estimador do efeito causal deve ser **não viesado e consistente** — ou seja, $\mathbb{E}(\hat{\beta}_1) = \beta_1$ e $\hat{\beta}_1 \xrightarrow{p} \beta_1$;
2. os **testes de hipótese** devem ter os níveis de significância anunciados, e os intervalos de confiança devem cobrir o parâmetro com a probabilidade anunciada.

O segundo componente é frequentemente esquecido. Um estimador perfeitamente não viesado acompanhado de erros-padrão errados produz um estudo internamente **inválido**: os intervalos de 95% não contêm o parâmetro em 95% das amostras, e as rejeições a 5% não ocorrem em 5% das vezes sob a nula.

9.1.1 Ameaças à validade externa

A validade externa é ameaçada sempre que a população ou o ambiente do estudo difere daquele a que se quer aplicar a conclusão. Duas categorias:

Diferenças na população. A população estudada difere da população de interesse. Estudos com ratos de laboratório geram resultados que não necessariamente se aplicam a humanos; um estudo com distritos escolares da Califórnia não necessariamente vale para o México.

Diferenças institucionais, geográficas, legais ou sociais. Um experimento sobre repelentes de mosquito pode ter efeito dependente da geografia. Uma política de combate ao crime pode funcionar em uma vizinhança e não em outra — o exemplo do professor é direto: na zona sul do Rio os assaltos são praticados a pé, na Barra da Tijuca de carro, e uma intervenção calibrada para um padrão não se transfere para o outro.

O estudo *TestScore-STR* que o curso vem construindo foi feito com 420 distritos da **Califórnia**. Seus resultados valem para Massachusetts? Para o México? A resposta não é estatística: ela depende de conhecimento substantivo sobre as duas populações e os dois contextos. Nenhum teste de hipótese responde a essa pergunta.

9.2 As cinco ameaças à validade interna

Esta é a lista central do capítulo, e vale decorá-la. Um estudo de regressão é internamente válido se os coeficientes são não viesados e consistentes para o efeito causal, e se os erros-padrão produzem intervalos com a cobertura correta. As cinco ameaças são:

1. **Viés de variável omitida**
2. **Especificação incorreta da forma funcional**
3. **Erro de medida nas variáveis independentes**
4. **Seleção amostral viesada**
5. **Causalidade simultânea**

! A raiz comum das cinco

Todas as cinco operam pelo **mesmo mecanismo**: elas fazem com que o regressor seja **correlacionado com o termo de erro**, violando $\mathbb{E}(u_i | X_i) = 0$ — a hipótese de que depende o não-viés do MQO. Entender isso transforma a lista de cinco itens decorados numa única ideia com cinco manifestações.

9.2.1 Ameaça 1: viés de variável omitida

Já conhecida desde o Seção 6: ocorre quando um determinante de Y está correlacionado com um X incluído. O que este capítulo acrescenta é a organização das soluções conforme o que se sabe sobre a variável omitida:

Caso A — a variável é observável, ou existe boa *proxy*. Solução direta: colete-a e inclua-a na regressão. Foi o que se fez com *PctEL* e *Expn*. No exemplo do curso, a porcentagem de alunos que qualificam para merenda subsidiada funciona como *proxy* para a renda familiar.

Caso B — a variável não é observável e não há boa *proxy*. Aqui a solução do Caso A é inútil, e é preciso mudar de método. O curso oferece duas saídas, ambas em capítulos posteriores: **dados em painel** (Seção 10), quando a variável omitida é constante no tempo, e **variáveis instrumentais**, quando não é.

9.2.2 Ameaça 2: forma funcional incorreta

Ocorre quando a forma funcional estimada difere da forma funcional da regressão populacional — ajustar uma reta ao que é uma parábola, por exemplo. O efeito parcial estimado será em geral viesado, e o viés varia conforme o ponto em que se avalia.

É, em certo sentido, um caso particular da Ameaça 1: se a verdade é $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + u$ e estimamos apenas com X , então X^2 é uma **variável omitida** correlacionada com X por construção.

A solução é o conteúdo do Seção 8: testar formas alternativas — logs, polinômios, interações. Quando não há teoria econômica que determine a forma funcional, é obrigação do analista experimentar várias e reportar a sensibilidade das conclusões.

9.2.3 Ameaça 3: erro de medida nas variáveis independentes

Suponha que o regressor de interesse seja medido com erro: em vez de X_i , observamos $\tilde{X}_i$. A regressão populacional é $Y_i = \beta_0 + \beta_1 X_i + u_i$, mas o que podemos estimar envolve $\tilde{X}_i$. Reescrevendo:

$$Y_i = \beta_0 + \beta_1 \tilde{X}_i + \underbrace{[\beta_1 (X_i - \tilde{X}_i) + u_i]}_{v_i}. \quad (23)$$

O novo termo de erro v_i **contém o erro de medida**. Se $X_i - \tilde{X}_i$ é correlacionado com $\tilde{X}_i$, o regressor é correlacionado com o erro, e $\hat{\beta}_1$ é viesado e inconsistente.

O modelo de erro de medida clássico. A hipótese usual é $\tilde{X}_i = X_i + w_i$, com $\mathbb{E}(w_i) = 0$, w_i não correlacionado com X_i e com u_i : o valor observado é o valor verdadeiro mais ruído aleatório. Sob essas hipóteses, mostra-se que

$$\text{plim } \hat{\beta}_1 = \beta_1 \cdot \frac{\sigma_X^2}{\sigma_X^2 + \sigma_w^2}. \quad (24)$$

A Equação 24 é o resultado a memorizar. Como a fração é sempre **menor que 1**, o estimador é enviesado **em direção a zero** — fenômeno chamado de **viés de atenuação**.

A interpretação é intuitiva. Se o componente de ruído é grande ($\sigma_w^2 \rightarrow \infty$), o regressor está tão contaminado que praticamente não carrega informação sobre X , e o coeficiente colapsa para zero — que é exatamente o que a fórmula dá no limite. No outro extremo, se $\sigma_w^2 = 0$, não há erro de medida e a fração vale 1.

i Erro de medida em Y é outra história

Se o erro de medida está na **variável dependente**, o diagnóstico muda. Com $\tilde{Y}_i = Y_i + w_i$, o modelo estimado é $\tilde{Y}_i = \beta_0 + \beta_1 X_i + (u_i + w_i)$. Se w_i é aleatório e não correlacionado com X_i , a hipótese $\mathbb{E}(u_i + w_i | X_i) = 0$ **continua valendo**, e $\hat{\beta}_1$ é **não viesado**. O que acontece é que $\text{Var}(u_i + w_i) > \text{Var}(u_i)$: a variância do erro aumenta, e com ela os erros-padrão. Ou seja — erro de medida em X **enviesa**; erro de medida em Y apenas **perde precisão**.

As soluções para erro de medida em X são duas: usar **variáveis instrumentais**, ou construir um modelo explícito do processo de erro de medida e corrigi-lo.

9.2.4 Ameaça 4: seleção amostral viesada

Aqui é útil separar o problema de dados faltantes em três casos, porque só o terceiro é fatal.

Caso 1 — dados faltam aleatoriamente. As razões da ausência não se relacionam nem com X nem com Y . Consequência: equivale a ter uma amostra menor. Perde-se precisão, não há viés.

Caso 2 — dados faltam em função de um regressor. Por exemplo, não observamos indivíduos de renda baixa, e a renda é um X . Consequência: também não há viés, mas a análise passa a ser válida apenas para a faixa de renda observada. Restringe-se o domínio da conclusão, não sua correção.

Caso 3 — a ausência se relaciona com Y . Se o processo de seleção depende da variável dependente (ou do erro), o MQO é **viesado e inconsistente**. Este é o **viés de seleção amostral** propriamente dito.

Três exemplos clássicos, que valem mais que a definição:

Altura dos universitários. Para estimar a altura média dos universitários homens, você se posta na saída do vestiário do time de basquete e mede quem sai. A amostragem foi feita de modo **relacionado ao resultado Y** — altura —, e a estimativa será enviesada para cima.

Fundos mútuos. Fundos de gestão ativa superam o mercado? Estratégia: amostra aleatória dos fundos **disponíveis hoje**, com retornos dos últimos dez anos. O problema é que os fundos que quebraram no período **não estão na amostra**. Sobreviver dez anos depende de ter tido bom retorno — isto é, de Y . No modelo $retorno_i = \beta_0 + \beta_1 gest\tilde{a}o_ativa_i + u_i$, estar na amostra com $gest\tilde{a}o_ativa = 1$ significa ter ido melhor que os fundos que sumiram, logo $Corr(gest\tilde{a}o_ativa_i, u_i) \neq 0$. Os fundos sobreviventes são os “jogadores de basquete” dos fundos.

Retornos da educação. Amostra aleatória de formados **empregados** (porque precisamos do salário). Quem está desempregado fica de fora — e a probabilidade de estar empregado se relaciona com determinantes não observados do salário. Mesma estrutura, mesmo viés.

A solução, quando possível, é **mudar o desenho amostral** para eliminar a seleção: sortear alunos da lista de matriculados, incluir na amostra os fundos que existiam **no início** do período, amostrar formados e não trabalhadores. Alternativamente, um experimento aleatorizado, ou a modelagem explícita do processo de seleção.

9.2.5 Ameaça 5: causalidade simultânea

Até aqui supusemos que a causalidade corre de X para Y . E se correr também de Y para X ?

O exemplo do curso é concreto. Supusemos que o *STR* causa o *TestScore*. Mas imagine que o secretário estadual de educação examine as notas e decida **alocar mais professores** para os distritos de pior desempenho. Agora a causalidade também corre de *TestScore* para *STR*, e o coeficiente estimado mistura as duas direções.

Formalmente, considere o sistema

$$\begin{cases} Y_i = \beta_0 + \beta_1 X_i + u_i \\ X_i = \gamma_0 + \gamma_1 Y_i + v_i \end{cases} \quad (25)$$

Substituindo a primeira na segunda, vê-se que X_i depende de u_i ; logo $\text{Corr}(X_i, u_i) \neq 0$, e o MQO é viesado e inconsistente. Por ser representável por um sistema de equações simultâneas, esse viés é chamado de **viés de simultaneidade**.

Vale registrar que este é o problema **fundador** da econometria: uma regressão de quantidade sobre preço estima a curva de demanda ou a de oferta? A pergunta organizou a disciplina em seus primeiros anos, e a resposta — variáveis instrumentais — é o conteúdo do capítulo correspondente. A outra solução é o experimento aleatorizado controlado, em que X é atribuído por sorteio e portanto não pode responder a Y .

9.3 Erros-padrão inconsistentes

A validade interna exige também que a parte de **inferência** esteja correta. Há duas fontes principais de erros-padrão inconsistentes:

Heterocedasticidade não tratada. Solução conhecida desde o Seção 5: usar erros-padrão robustos. Hoje todos os softwares o fazem, e não há desculpa para não os usar.

Correlação entre os termos de erro de observações diferentes. Ocorre tipicamente em dados com estrutura de grupo ou de tempo — observações do mesmo estado, do mesmo ano, da mesma escola. A fórmula robusta usual pressupõe independência entre observações e é inconsistente nesse caso. A solução é o **erro-padrão clusterizado**, tratado em detalhe no Seção 10.

9.4 Validade interna e externa em previsão

Um ponto que costuma surpreender, e que o professor destaca. Quando o modelo de regressão é usado para **previsão** e não para estimar efeitos causais, as prioridades se invertem.

Em previsão, **não importa** se os coeficientes têm interpretação causal. Não importa se há variável omitida, se há simultaneidade, se $\hat{\beta}_1$ é viesado para o efeito causal. O que se quer é que a relação estatística entre X e Y **se mantenha** na população em que a previsão será feita — ou seja, o que importa é a **validade externa**.

Um modelo que preveja bem a inadimplência usando o CEP do cliente é útil para previsão mesmo que o CEP não **cause** inadimplência. Mas ele falha assim que a relação entre CEP e inadimplência mudar — que é uma falha de validade externa.

9.5 Aplicação: notas e tamanho de turma, Califórnia e Massachusetts

O curso aplica a lista de cinco ameaças ao seu próprio exemplo. A estratégia para avaliar a **validade externa** é elegante: replicar o estudo em outra população. Usa-se um conjunto de dados de **Massachusetts**, com 220 distritos escolares, e comparam-se os resultados com os da Califórnia.

As conclusões da comparação:

- A relação entre nota e renda do distrito é **não-linear em ambos** os estados, e a especificação logarítmica se comporta melhor que a cúbica nos extremos — replicando o achado do Seção 8.
- O coeficiente do *STR* em Massachusetts é $-1,72$ na regressão **sem controles**, e cai para $-0,69$ quando se controla por renda e *PctEL* — o mesmo padrão de encolhimento observado na Califórnia, o que é evidência de viés de variável omitida na especificação simples.
- Não há evidência forte de não-linearidade na relação entre nota e *STR*, nem de interação significativa entre *HiEL* e *STR* — também como na Califórnia.

O efeito previsto de uma redução de 2 alunos por professor na especificação linear de Massachusetts é de $-0,64$ ponto, com erro-padrão 2 — intervalo de confiança amplo, contendo zero com folga.

A conclusão substantiva do curso sobre esse exemplo, construída ao longo de sete capítulos, é deliberadamente modesta: **há** evidência de que turmas menores elevam o desempenho, o efeito é **pequeno** em magnitude, e ele é sensível à especificação e ao conjunto de controles. Os resultados se replicam qualitativamente entre dois estados americanos — o que é evidência favorável à validade externa **dentro** dos Estados Unidos — e nada dizem sobre países com sistemas educacionais muito diferentes.

9.6 Exercícios

Exercício 1. Classifique cada situação abaixo segundo as cinco ameaças, e diga em que direção o coeficiente de interesse seria enviesado:

- Estimar o efeito de horas de estudo sobre a nota, com as horas auto-reportadas por alunos que tendem a exagerar.
- Estimar o efeito de um programa de treinamento sobre salários, com participação voluntária.
- Estimar o efeito do número de policiais sobre a criminalidade, sabendo que prefeituras contratam mais policiais onde o crime sobe.
- Estimar o efeito da renda sobre o consumo ajustando uma reta quando a relação verdadeira é côncava.

Exercício 2. Um pesquisador estima o efeito do salário mínimo sobre o emprego usando apenas empresas que **continuavam abertas** ao fim do período. Que ameaça é essa? Em que direção você espera o viés? Como redesenharia a coleta?

Exercício 3. Explique por que erro de medida clássico em X envia o coeficiente, mas erro de medida clássico em Y não. Use a Equação 23 na sua resposta.

Exercício 4. Um estudo com dados de 2015 de uma capital brasileira conclui que um programa de transferência de renda elevou a frequência escolar em 8 pontos percentuais. A prefeitura de outra cidade quer aplicar o programa. Que perguntas de **validade externa** você faria antes de projetar o mesmo efeito?

Exercício 5. Um analista defende seu modelo dizendo: “meu R^2 é 0,89, então o modelo é válido”. Avalie a afirmação à luz deste capítulo e do Seção 7.

10 Regressão com Dados em Painel

O Seção 9 encerrou com uma dívida. A primeira das cinco ameaças à validade interna — o viés de variável omitida — tem solução conhecida quando a variável omitida é **observável**: inclua-a na regressão, como fizemos desde o Seção 6. Mas ficou explicitamente em aberto o caso difícil, aquele em que o determinante omitido de Y é **não observável** e não tem boa *proxy*. Dizer “inclua a variável” não ajuda quando a variável é a cultura de um estado em relação à bebida, a qualidade institucional de um país ou a habilidade inata de um trabalhador.

Este capítulo apresenta a primeira das duas respostas que o curso dará a esse problema — a segunda, variáveis instrumentais, virá depois. A resposta aqui é de uma economia notável: se não podemos **medir** a variável omitida, talvez possamos **eliminá-la**, e para isso basta observar cada unidade **mais de uma vez**.

A ideia central cabe em uma frase, e vale a pena tê-la em mente durante todo o capítulo:

! A ideia central do capítulo

Se uma variável omitida **não muda ao longo do tempo**, então nenhuma **mudança** em Y ao longo do tempo pode ter sido causada por ela.

Note o que essa frase exige e o que ela dispensa. Ela **dispensa** observar a variável omitida — cultura, habilidade e qualidade institucional podem permanecer invisíveis. Ela **exige**, em contrapartida, que a variável omitida seja constante no tempo, e que a variável de interesse **varie** no tempo. Essas duas exigências são as fronteiras do método, e voltaremos a elas repetidamente.

O capítulo tem seis partes. A primeira define o que são dados em painel e por que eles ajudam. A segunda trata do caso mais simples, $T = 2$, onde o método se reduz a uma regressão em diferenças que já sabemos estimar. A terceira generaliza para $T > 2$ e introduz a **regressão com efeitos fixos**, com suas três formas equivalentes de estimação. A quarta acrescenta **efeitos fixos de tempo**. A quinta enuncia as hipóteses de mínimos quadrados na versão painel — onde surge a **exogeneidade estrita**, mais forte do que a hipótese de média condicional zero que vínhamos usando — e explica por que os erros-padrão precisam ser **clusterizados**. A sexta aplica tudo ao caso das mortes no trânsito.

O capítulo corresponde à Aula 9 da disciplina e cobre o Capítulo 10 de Stock e Watson (2020).

10.1 O que são dados em painel, e por que eles ajudam

Um **conjunto de dados em painel** — também chamado de **dados longitudinais** — contém observações sobre múltiplas **unidades** (indivíduos, estados, empresas, países), cada uma observada em **dois ou mais** momentos do tempo.

A notação usa dois índices, e daqui em diante ela é onipresente:

$$(X_{it}, Y_{it}), \quad i = 1, \dots, n, \quad t = 1, \dots, T,$$

onde i indexa a **unidade** e t o **período**. Com k regressores, os dados são $(X_{1it}, X_{2it}, \dots, X_{kit}, Y_{it})$. Um painel é **balanceado** quando não há observações faltantes — todas as variáveis são observadas para todas as unidades em todos os períodos; caso contrário é **desbalanceado**.

A estrutura de painel se distingue das duas que já conhecemos:

Tabela 8: As três estruturas de dados.

Estrutura	Dados	Exemplo
Corte transversal	$(X_i, Y_i), i = 1, \dots, n$, com t fixo	log(salário) sobre educação, CPS 1998
Série temporal	$(X_t, Y_t), t = 1, \dots, T$, com i fixo	Inflação e desemprego, jan/2002 a jan/2020
Painel	$(X_{it}, Y_{it}), i = 1, \dots, n, t = 1, \dots, T$	48 estados americanos, 1982–1988

Uma distinção de vocabulário que aparece na literatura aplicada: quando n é grande e T é pequeno — mil indivíduos observados em quatro meses —, fala-se em **microeconometria** de painel, e é esse o caso tratado neste capítulo. Quando n é pequeno e T é grande — oito países observados por cinquenta anos —, fala-se em **macroeconometria** de painel, cujos métodos são outros, porque a assintótica relevante passa a ser em T .

10.1.1 Por que o painel resolve um problema que o corte transversal não resolve

Com dados em painel podemos controlar por fatores que satisfazem simultaneamente três condições:

1. **variam entre unidades, mas não variam ao longo do tempo;**
2. causariam viés de variável omitida se fossem deixados de fora;
3. são **não observados** ou não mensuráveis — e portanto **não podem** ser incluídos numa regressão múltipla.

É a terceira condição que faz a diferença. Um fator que satisfaz (1) e (2) mas é observável não exige método novo: basta incluí-lo, como se fez com *PctEL* e *Expn*. O painel existe para o caso em que (3) também vale.

10.1.2 O exemplo que atravessa o capítulo: mortes no trânsito e imposto sobre a cerveja

O exemplo do curso vem dos dados de segurança no trânsito nos Estados Unidos. A unidade observacional é **um ano em um estado**: são $n = 48$ estados contíguos, observados em $T = 7$ anos (1982 a 1988), num painel balanceado de $7 \times 48 = 336$ observações. As variáveis centrais são a **taxa de fatalidade no trânsito** (mortes no trânsito naquele estado naquele ano, por 10.000 habitantes) e o **imposto sobre uma caixa de cerveja**.

A pergunta de política pública é direta: impostos mais altos sobre o álcool reduzem as mortes no trânsito? A resposta que os dados de um **único ano** dão é desconcertante. Estimando por MQO apenas com os dados de 1982 e depois apenas com os de 1988:

$$\widehat{FatalityRate} = 2,01 + 0,15 \cdot BeerTax \quad (n = 48, \text{ dados de 1982}), \quad (26)$$

(0,15) (0,13)

$$\widehat{FatalityRate} = 1,86 + 0,44 \cdot BeerTax \quad (n = 48, \text{ dados de 1988}). \quad (27)$$

(0,11) (0,13)

O coeficiente é **positivo** nos dois anos, e em 1988 ele é estatisticamente significativo. Lido ao pé da letra, o resultado diz que estados com impostos mais altos sobre a cerveja têm **mais** mortes no trânsito. Ninguém acredita nisso como relação causal.

A explicação, naturalmente, é viés de variável omitida. Há determinantes da taxa de fatalidade que não estão na regressão:

- a **qualidade (idade) da frota** de automóveis;
- a **qualidade das estradas**;
- a **densidade de tráfego**;
- a **cultura local** em relação a beber e dirigir.

Tome a densidade de tráfego. Ela é um determinante de Y — mais tráfego, mais colisões. E ela é plausivelmente correlacionada com o imposto: estados do Oeste americano, de baixa densidade, tendem a ter impostos mais baixos sobre o álcool. As duas condições do viés de variável omitida estão satisfeitas, e o sinal do viés é positivo — “imposto alto” está capturando “densidade alta”.

Tome agora a cultura em relação a beber e dirigir. Ela também é determinante das mortes, e também é plausivelmente correlacionada com o imposto, já que estados cuja população desaprova a bebida tendem a tributá-la mais. Mesmas duas condições, mesmo problema.

A diferença entre os dois fatores é decisiva para o que segue. A densidade de tráfego é, em princípio, mensurável; a cultura não é. Mas ambas têm uma propriedade em comum: ao longo de **sete anos**, é razoável tratá-las como **constantes dentro de cada estado**. E é só disso que o método precisa.

10.2 Painel com dois períodos de tempo

Começemos pelo caso mais simples, $T = 2$, porque nele o método inteiro se reduz a algo que já sabemos fazer.

Considere o modelo

$$FatalityRate_{it} = \beta_0 + \beta_1 BeerTax_{it} + \beta_2 Z_i + u_{it}, \quad (28)$$

em que Z_i é um fator que **não muda ao longo do tempo** — a densidade de tráfego, a cultura — pelo menos durante os anos observados. Repare no índice: Z_i tem i mas não tem t , e é isso que o torna manejável. Suponha que Z_i **não seja observado**, de modo que sua omissão produziria viés.

A álgebra que elimina Z_i é de uma linha. Escreva a Equação 28 para 1988 e para 1982:

$$FatalityRate_{i,1988} = \beta_0 + \beta_1 BeerTax_{i,1988} + \beta_2 Z_i + u_{i,1988},$$

$$FatalityRate_{i,1982} = \beta_0 + \beta_1 BeerTax_{i,1982} + \beta_2 Z_i + u_{i,1982}.$$

Subtraindo a segunda da primeira:

$$FatalityRate_{i,1988} - FatalityRate_{i,1982} = \beta_1 (BeerTax_{i,1988} - BeerTax_{i,1982}) + (u_{i,1988} - u_{i,1982}). \quad (29)$$

O termo $\beta_2 Z_i$ **desapareceu**, e desapareceu sem que jamais precisássemos observá-lo. O intercepto β_0 também sumiu na subtração. O que restou é uma regressão em **diferenças**, com uma variável dependente ($\Delta FatalityRate$), um regressor ($\Delta BeerTax$) e um novo termo de erro (Δu) — e essa equação pode ser estimada por MQO com tudo o que sabemos desde o 1.

! Três condições, e o que cada uma proíbe

A mágica da Equação 29 depende de três coisas, e convém enunciá-las porque cada uma delas será violada por algum exemplo mais adiante:

1. **A variável de interesse precisa variar ao longo do tempo.** Se $BeerTax_{i,1988} = BeerTax_{i,1982}$ para todo i , a diferença é identicamente zero e não há regressor. Voltaremos a isso em Seção 10.3.4.
2. **A variável omitida Z precisa ser constante no tempo.** Se Z variasse — Z_{it} —, ela **não** cairia na subtração, e o viés permaneceria. O método nada faz contra variáveis omitidas que mudam ao longo do tempo dentro da unidade.
3. **A hipótese de média condicional precisa ser adaptada**, porque o erro da Equação 29 é uma **diferença** de dois erros. É o ponto de Seção 10.5, e é mais sutil do que parece.

Sobre o terceiro ponto, adiantemos a intuição. Antes, em corte transversal, bastava $E(u_i | X_i) = 0$: um erro, um regressor, na mesma data. Agora o erro da equação em diferenças envolve **duas datas**, e para que ele seja não correlacionado com $\Delta BeerTax$ é preciso que u de cada data seja não correlacionado com o X de **ambas** as datas. Não pode haver correlação entre X e u em **nenhum** par de datas.

10.2.1 O resultado nos dados

Estimada com os 48 estados, a regressão em diferenças entre 1988 e 1982 dá

$$\widehat{\Delta FatalityRate} = -0,072 - 1,04 \cdot \Delta BeerTax \quad (n = 48). \quad (30)$$

(0,065) (0,36)

O contraste com as equações Equação 26 e Equação 27 é o ponto pedagógico do capítulo inteiro. Em corte transversal, o coeficiente era +0,15 e +0,44; em diferenças, ele é $-1,04$, com $t = -1,04/0,36 = -2,89$, estatisticamente significativa a 1%. **O sinal se inverteu**, e passou a ser o sinal que a teoria previa.

O que mudou não foram os dados — são os mesmos estados, as mesmas variáveis. O que mudou foi que a regressão em diferenças **não compara estados entre si**; ela compara **cada estado consigo**

mesmo em dois momentos. E na comparação de um estado consigo mesmo, a densidade de tráfego e a cultura local são as mesmas dos dois lados, de modo que não podem explicar nada da mudança.

Note ainda que a Equação 30 **inclui um intercepto**, embora a Equação 29 não tenha nenhum. Incluí-lo permite que a mudança média na taxa de fatalidade seja não nula por razões comuns a todos os estados — carros mais seguros, leis federais. Essa observação é a semente dos **efeitos fixos de tempo**, de Seção 10.4. O intercepto estimado, $-0,072$, é de fato pequeno, mas não é zero.

10.3 Regressão com efeitos fixos

A regressão em diferenças resolve o problema para $T = 2$. E quando temos $T > 2$ — sete anos, como no exemplo? Subtrair o primeiro ano do último jogaria fora cinco anos de dados.

A generalização parte do mesmo modelo,

$$Y_{it} = \beta_0 + \beta_1 X_{it} + \beta_2 Z_i + u_{it}, \quad i = 1, \dots, n, \quad t = 1, \dots, T, \quad (31)$$

e o reescreve de duas maneiras úteis. Suponha, para fixar ideias, $n = 3$ estados: Califórnia, Texas e Massachusetts.

Para a Califórnia, a regressão populacional é

$$Y_{CA,t} = \beta_0 + \beta_1 X_{CA,t} + \beta_2 Z_{CA} + u_{CA,t} = \underbrace{(\beta_0 + \beta_2 Z_{CA})}_{\alpha_{CA}} + \beta_1 X_{CA,t} + u_{CA,t}.$$

O termo $\alpha_{CA} = \beta_0 + \beta_2 Z_{CA}$ **não muda ao longo do tempo**, porque nem β_0 nem Z_{CA} mudam. Ele é simplesmente o **intercepto da Califórnia**. Fazendo o mesmo para os demais estados e juntando as três equações:

$$Y_{it} = \alpha_i + \beta_1 X_{it} + u_{it}. \quad (32)$$

Geometricamente: cada estado tem sua **própria reta**, todas com a **mesma inclinação** β_1 e com **interceptos diferentes** α_i . São retas paralelas, uma por unidade. O parâmetro de interesse, β_1 , é comum a todas — é o efeito de X sobre Y **dentro** de um estado.

O termo α_i é chamado de **efeito fixo da unidade** (*state fixed effect*, no exemplo): é o efeito constante, característico, de pertencer à unidade i . Note o que aconteceu com a variável não observada: Z_i não precisa mais ser mencionada. Ela foi **absorvida** dentro de α_i , junto com β_0 e com tudo o mais que seja fixo naquele estado. Não estimamos β_2 , não identificamos Z_i — e não precisamos.

10.3.1 A forma de regressores binários

Como vimos no Seção 6, deslocamentos de intercepto entre grupos podem ser representados por variáveis binárias. Com n unidades, criamos $n - 1$ binárias — omitindo uma, sob pena de multicolinearidade perfeita com o intercepto, exatamente como na armadilha da variável binária:

$$Y_{it} = \beta_0 + \beta_1 X_{it} + \gamma_2 D2_i + \gamma_3 D3_i + \cdots + \gamma_n Dn_i + u_{it}, \quad (33)$$

onde $D2_i = 1$ se a unidade é a de número 2 e 0 caso contrário, e assim por diante. As equações Equação 32 e Equação 33 são o **mesmo modelo**, escrito de duas formas.

10.3.2 Os três métodos de estimação

Há três maneiras de estimar o modelo de efeitos fixos, e o fato importante é que as três produzem **estimativas idênticas** de β_1 :

1. **MQO com $n - 1$ regressores binários** (também chamado **LSDV**, *least squares dummy variables*): estime a Equação 33 diretamente por MQO. A inferência é a usual, com erros-padrão robustos. O método é impraticável quando n é muito grande — com $n = 1000$ trabalhadores, seriam 999 binárias.
2. **MQO em desvios das médias da unidade** (*entity-demeaned*, ou estimador **within**): descrito abaixo. Funciona para n qualquer.
3. **Especificação em diferenças**, sem intercepto: é a Equação 29, e ela **só funciona para $T = 2$** .

O terceiro método já foi usado. Os métodos 1 e 2 valem para T geral, e o método 2 é o que o software efetivamente executa.

10.3.3 O estimador within, passo a passo

A transformação *within* é a peça algébrica central do capítulo. Parta da Equação 32:

$$Y_{it} = \beta_1 X_{it} + \alpha_i + u_{it}.$$

Tire a média ao longo do tempo **dentro de cada unidade i** , isto é, aplique $\bar{Y}_i = \frac{1}{T} \sum_{t=1}^T Y_{it}$:

$$\bar{Y}_i = \beta_1 \bar{X}_i + \alpha_i + \bar{u}_i,$$

onde α_i sobrevive intacto à média porque é constante no tempo — essa é a única propriedade de α_i que usamos, e é toda a razão de o método funcionar. Subtraindo esta equação da anterior:

$$Y_{it} - \bar{Y}_i = \beta_1 (X_{it} - \bar{X}_i) + (u_{it} - \bar{u}_i),$$

ou, definindo as variáveis **centradas na média da unidade** $\tilde{Y}_{it} = Y_{it} - \bar{Y}_i$ e $\tilde{X}_{it} = X_{it} - \bar{X}_i$,

$$\tilde{Y}_{it} = \beta_1 \tilde{X}_{it} + \tilde{u}_{it}. \quad (34)$$

O efeito fixo α_i **desapareceu**. Basta então regressir $\tilde{Y}$ sobre $\tilde{X}$ por MQO para obter $\hat{\beta}_1$.

A interpretação de $\tilde{Y}_{it}$ é concreta e vale a pena fixá-la: para o Alabama em 1982, $\tilde{Y}_{i,1982}$ é a diferença entre a taxa de fatalidade do Alabama em 1982 e a taxa **média** do Alabama ao longo dos sete anos. O estimador *within* usa, portanto, apenas a variação de cada estado **em torno de sua própria média** — daí o nome. Toda a variação *entre* estados, que era onde moravam a densidade de tráfego e a cultura, foi descartada.

i A relação com a especificação em diferenças

O método *within* é parente próximo da especificação em diferenças, com uma troca: em vez de medir Y_{it} em desvio de Y_{i1} — o primeiro período —, mede-se em desvio da **média** $\bar{Y}_i$ de todos os períodos. Quando $T = 2$, as duas coisas coincidem e os dois estimadores são idênticos. Quando $T > 2$, elas diferem, e o *within* é em geral mais eficiente.

10.3.4 O que não se pode estimar

Uma pergunta que o professor coloca em aula, e cuja resposta é instrutiva. Podemos estimar, com efeitos fixos, uma equação como

$$\log(\text{Salário})_{it} = \beta_1 \text{Educação}_i + \alpha_i + u_{it},$$

em que a escolaridade do indivíduo **não varia** durante o período amostral?

Não. E a razão é imediata pela Equação 34: se $X_{it} = X_i$ para todo t , então $\bar{X}_i = X_i$, e portanto $\tilde{X}_{it} = X_i - X_i = 0$. O regressor centrado é identicamente **zero**. Não há variação a explorar, e o coeficiente é inestimável — o software acusará multicolinearidade perfeita com os efeitos fixos.

Essa limitação é o preço do método, e é um preço real: qualquer variável invariante no tempo — gênero, raça, país de nascimento, escolaridade concluída — é absorvida por α_i e tem seu coeficiente **eliminado**, exatamente como Z_i . O efeito fixo não distingue entre a variável omitida que queríamos eliminar e a variável observada cujo coeficiente queríamos estimar: as duas são constantes no tempo, e as duas somem juntas.

10.4 Regressão com efeitos fixos de tempo

Os efeitos fixos de unidade eliminam variáveis omitidas que variam **entre unidades** mas não no tempo. Há, simetricamente, variáveis omitidas com o padrão oposto: mudam **ao longo do tempo** mas são comuns a todas as unidades num dado ano. Exemplos no caso do trânsito: a difusão de carros mais seguros (*air bags*, freios ABS), mudanças na legislação federal, o ciclo econômico nacional.

Denote por S_t o efeito combinado desses fatores. O modelo passa a ser

$$Y_{it} = \beta_0 + \beta_1 X_{it} + \beta_2 Z_i + \beta_3 S_t + u_{it}. \quad (35)$$

O mesmo raciocínio de Seção 10.3 se aplica, agora na dimensão temporal. Considerando apenas os efeitos de tempo, para o ano de 1982:

$$Y_{i,1982} = \underbrace{(\beta_0 + \beta_3 S_{1982})}_{\lambda_{1982}} + \beta_1 X_{i,1982} + u_{i,1982},$$

e analogamente para cada ano. O modelo com **efeitos fixos de tempo** é

$$Y_{it} = \beta_1 X_{it} + \lambda_t + u_{it}, \quad (36)$$

em que λ_t é um intercepto que **muda de ano para ano**, mas é o mesmo para todos os estados. Na forma de binárias, criam-se $T - 1$ indicadoras de período.

Combinando as duas dimensões, chega-se ao modelo de **efeitos fixos de unidade e de tempo** — na terminologia da literatura europeia, o modelo de **componentes de erro de duas vias** (*two-way error component*), por oposição ao de **uma via** (*one-way*), que tem apenas α_i :

$$Y_{it} = \beta_1 X_{it} + \alpha_i + \lambda_t + u_{it}. \quad (37)$$

Essa especificação controla simultaneamente por tudo que é fixo na unidade (observado ou não) e por tudo que é comum a um período (observado ou não). É o cavalo de batalha da econometria aplicada moderna, e é o que o exercício de Donohue e Levitt da Seção 10.9 estima.

Quando $T = 2$, calcular a primeira diferença **incluindo um intercepto** é exatamente equivalente a incluir efeitos fixos de unidade e de tempo — o que fecha o círculo com a observação sobre o intercepto da Equação 30. Quando $T > 2$, há várias formas equivalentes de estimar a Equação 37: centrar na média da unidade e incluir $T - 1$ binárias de tempo; centrar na média do ano e incluir $n - 1$ binárias de unidade; incluir os dois conjuntos de binárias; ou centrar nas duas dimensões.

10.5 As hipóteses de MQO em painel e os erros-padrão clusterizados

Sob uma versão painel das hipóteses de mínimos quadrados, o estimador de efeitos fixos é assintoticamente normal e a inferência procede como de hábito — com uma alteração importante na fórmula do erro-padrão. Começemos pelas hipóteses. Para o modelo $Y_{it} = \beta_1 X_{it} + \alpha_i + u_{it}$:

1. $\mathbb{E}(u_{it} \mid X_{i1}, X_{i2}, \dots, X_{iT}, \alpha_i) = 0$ — **exogeneidade estrita**;
2. $(X_{i1}, \dots, X_{iT}, u_{i1}, \dots, u_{iT})$, $i = 1, \dots, n$, são sorteios **i.i.d.** de sua distribuição conjunta;
3. (X_{it}, u_{it}) têm quartos momentos finitos;
4. não há multicolinearidade perfeita.

As hipóteses 3 e 4 são as de sempre. As hipóteses 1 e 2 são novas, e cada uma merece discussão.

10.5.1 Exogeneidade estrita

A hipótese 1 é substancialmente **mais forte** do que a hipótese de média condicional zero que vínhamos usando. Compare:

$$\underbrace{\mathbb{E}(u_i | X_i) = 0}_{\text{média condicional zero (corte transversal)}} \quad \text{versus} \quad \underbrace{\mathbb{E}(u_{it} | X_{i1}, \dots, X_{iT}, \alpha_i) = 0}_{\text{exogeneidade estrita (painel)}}.$$

No corte transversal, o erro da observação i precisava ser não correlacionado com o regressor **daquela** observação. Em painel, o erro do período t precisa ser não correlacionado com os regressores de **todos os períodos** — passados, presentes e **futuros** — daquela unidade.

! Duas consequências da exogeneidade estrita

- (i) **A equação não pode conter valores defasados de Y .** Se $Y_{i,t-1}$ entra como regressor, ele é por construção função de $u_{i,t-1}$, e a condição sobre o histórico completo é violada. Modelos dinâmicos de painel exigem métodos próprios, fora do escopo deste curso.
- (ii) **Não pode haver *feedback* de u para os X futuros.** No exemplo: o fato de um estado ter uma taxa de fatalidade particularmente alta neste ano não pode levá-lo a aumentar o imposto sobre a cerveja no ano seguinte. Às vezes essa hipótese de ausência de retroalimentação é plausível; às vezes não é — e aqui ela é francamente discutível, já que legisladores reagem a estatísticas de mortes. É uma ameaça de causalidade simultânea, no sentido do Seção 9, agora em versão dinâmica.

10.5.2 O que a hipótese i.i.d. permite e o que ela exige

A hipótese 2 é mais sutil do que parece, e é a fonte da correção nos erros-padrão. Ela diz que as **unidades** são sorteios i.i.d. — o que é razoável sob amostragem aleatória simples de estados ou indivíduos. Mas note o que ela **não** diz: ela não impõe nada sobre a relação entre observações **da mesma unidade** em períodos diferentes.

Ou seja: é **permitida** correlação serial arbitrária entre os X e os u **dentro** de cada unidade; é **exigida** independência **entre** unidades.

E há toda razão para esperar que essa correlação serial exista. Se o Alabama teve um choque não observado que elevou suas mortes no trânsito em 1983 — um inverno rigoroso, uma obra viária —, é provável que algo correlacionado persista em 1984. As observações do mesmo estado **não são independentes**: é o mesmo estado.

10.5.3 Erros-padrão clusterizados

A consequência é que a fórmula usual do erro-padrão robusto — a de HC1, do Seção 5 — é **inconsistente** em painel, porque ela pressupõe independência entre todas as observações, e aqui as observações de um mesmo estado são dependentes. O remédio é o **erro-padrão clusterizado** (*clustered standard error*), que trata **cada unidade como um cluster** e permite correlação arbitrária dentro dele, exigindo independência apenas entre *clusters*.

A fórmula generaliza a de HC1 de maneira natural. Onde o erro-padrão robusto somava as contribuições observação a observação, o clusterizado soma **cluster a cluster**:

$$\widehat{\text{Var}}_{\text{cluster}}(\hat{\beta}) = (\mathbf{X}'\mathbf{X})^{-1} \left(\sum_{i=1}^n \mathbf{X}'_i \hat{u}_i \hat{u}'_i \mathbf{X}_i \right) (\mathbf{X}'\mathbf{X})^{-1}, \quad (38)$$

onde $\mathbf{X}_i$ é a matriz $T \times k$ das observações da unidade i e $\hat{u}_i$ o vetor $T \times 1$ de seus resíduos. O termo do miolo, $\hat{u}_i \hat{u}'_i$, é uma matriz $T \times T$ **cheia**, e é justamente aí que a correlação serial dentro da unidade é acomodada: os elementos fora da diagonal, que a fórmula de HC1 implicitamente zerava, agora contribuem.

⚠ Na prática, isto não é um detalhe

Ignorar o *clustering* costuma **subestimar** os erros-padrão, às vezes por fatores substanciais, produzindo estatísticas t infladas e rejeições espúrias. Em painel com efeitos fixos, erros-padrão clusterizados por unidade são o padrão da literatura aplicada, e a sua ausência numa tabela é motivo legítimo de crítica em um *referee report*. A assintótica que justifica a Equação 38 é em n — o **número de clusters** —, e não em nT : com poucos *clusters* (digamos, menos de 40), a aproximação normal fica pobre e é preciso recorrer a correções específicas.

10.6 Aplicação: mortes no trânsito e impostos sobre o álcool

Reunindo tudo. Estimando o modelo de efeitos fixos de estado, com erros-padrão clusterizados por estado, nos 336 pares estado-ano:

$$\widehat{\text{FatalityRate}} = -0,66 \cdot \text{BeerTax} + \text{efeitos fixos de estado} \quad (n = 48, T = 7). \quad (39)$$

(0,29)

O coeficiente é $-0,66$, com $t = -0,66/0,29 = -2,25$ e valor- p de 0,029: negativo e significativo a 5%, confirmando a inversão de sinal já vista na regressão em diferenças. Estimar isso pelo método das binárias exigiria $n - 1 = 47$ indicadoras de estado. O intercepto reportado pelo software é arbitrário — uma normalização —, e não deve ser interpretado nem reportado.

Acrescentando agora os efeitos fixos de tempo, com as seis binárias de ano (1983 a 1988):

$$\widehat{\text{FatalityRate}} = -0,64 \cdot \text{BeerTax} + \text{efeitos de estado} + \text{efeitos de tempo}. \quad (40)$$

(0,36)

O coeficiente move-se pouco, de $-0,66$ para $-0,64$, mas o erro-padrão cresce de 0,29 para 0,36, e a estatística t cai para $-1,79$ — valor- p de 0,080, **não** significativo a 5%. Os efeitos de tempo, por sua vez, são **conjuntamente** significantes: o teste F das seis binárias dá $F(6, 47) = 4,22$, com valor- p de 0,0018.

A leitura honesta desse par de resultados é a que o curso vem praticando desde o Seção 7: a evidência de um efeito causal do imposto sobre a cerveja **existe**, mas é frágil à especificação. Ela sobrevive ao controle por tudo que é fixo no estado, e enfraquece quando se controla também por tudo que é comum ao ano. Um resultado que muda de estatuto conforme a especificação não deve ser vendido como estabelecido.

10.7 Laboratório computacional em R

Este laboratório implementa a estimação de efeitos fixos **do zero**, pela mesma razão dos capítulos anteriores: o pacote `plm`, que faria isso automaticamente, não está instalado, e escrever a transformação à mão deixa explícito o que o comando pronto faz por baixo do capô. A recompensa é ver, na Equação 34, que “estimar efeitos fixos” é literalmente centrar os dados e rodar um MQO.

Usaremos o painel **Guns**, distribuído com o material da aula. São dados anuais de crime para os 50 estados americanos mais o Distrito de Columbia, de 1977 a 1999, usados no debate sobre leis de porte de arma (*shall-issue*, ou “mais armas, menos crime”). A variável de interesse é `shall`, binária, igual a 1 se o estado tinha em vigor uma lei de porte no ano.

```
library(readxl)
caminho <- file.path("../", "Aula 09 - Dados em Pannel", "Guns.xls")
guns <- as.data.frame(read_excel(caminho))

# n, T e balanceamento
n_est <- length(unique(guns$stateid))
T_ano <- length(unique(guns$year))
c(n = n_est, T = T_ano, obs = nrow(guns),
  balanceado = all(table(guns$stateid) == T_ano))
```

n	T	obs	balanceado
51	23	1173	1

O painel é **balanceado**: $51 \times 23 = 1173$ observações. Trabalharemos com o log da taxa de crimes violentos, `vio`, por 100.000 habitantes.

```
# centrar uma variavel na media do grupo: x - media_do_grupo(x)
centrar <- function(x, grupo) x - ave(x, grupo)

# erro-padroao clusterizado (eq. cluster do texto): soma cluster a cluster,
# em vez de observacao a observacao como o HC1 do preambulo
ep_cluster <- function(modelo, cluster) {
  X <- model.matrix(modelo); u <- residuals(modelo)
  n_c <- length(unique(cluster)); k <- ncol(X); N <- nrow(X)
  bread <- solve(crossprod(X))
  # soma dos X_i' u_i u_i' X_i sobre os clusters
  meat <- matrix(0, k, k)
  for (g in unique(cluster)) {
    s <- cluster == g
    Xg <- X[s, , drop = FALSE]; ug <- u[s]
    escore <- crossprod(Xg, ug)          # X_g' u_g (k x 1)
    meat <- meat + tcrossprod(escore)    # (X_g' u_g)(X_g' u_g)'
  }
  ajuste <- (n_c / (n_c - 1)) * ((N - 1) / (N - k))
  sqrt(diag(bread %*% (ajuste * meat) %*% bread))
```

```
}
guns$lvio <- log(guns$vio)
```

10.7.1 (a) MQO agrupado: a regressão que ignora o painel

```
pooled <- lm(lvio ~ shall, data = guns)
c(coef = coef(pooled)[["shall"]], ep = ep_cluster(pooled, guns$stateid)[2])
```

```
      coef    ep.shall
-0.4429646  0.1570184
```

O coeficiente é de cerca de $-0,44$: estados com lei de porte teriam, em média, crimes violentos 44% menores (em log). Tomado como causal, seria um efeito enorme — e é exatamente o tipo de resultado de que se deve desconfiar, pelas razões do Seção 9. A regressão compara **estados diferentes entre si**, e estados diferem em mil coisas não observadas correlacionadas com a decisão de aprovar a lei.

10.7.2 (b) Efeitos fixos de estado, pela transformação within

```
guns$lvio_w <- centrar(guns$lvio, guns$stateid)
guns$shall_w <- centrar(guns$shall, guns$stateid)

ef_estado <- lm(lvio_w ~ shall_w - 1, data = guns)
c(coef = coef(ef_estado)[["shall_w"]])
```

```
      coef
0.1136629
```

O coeficiente salta de $-0,44$ para $+0,11$. Não é que o efeito tenha encolhido: ele **trocou de sinal**. Toda a associação negativa do MQO agrupado vinha da comparação *entre* estados — isto é, de Z_i —, e desaparece quando cada estado é comparado consigo mesmo.

10.7.3 (c) A equivalência com o método das binárias

Vale conferir a afirmação de Seção 10.3 de que os métodos 1 e 2 dão estimativas idênticas:

```
lsdv <- lm(lvio ~ shall + factor(stateid), data = guns)
c(within = coef(ef_estado)[["shall_w"]], lsdv = coef(lsdv)[["shall"]])
```

```
      within    lsdv
0.1136629 0.1136629
```

Os dois números coincidem até a precisão de máquina, como a álgebra previa — com a diferença de que o LSDV estimou 50 coeficientes de binárias que ninguém vai olhar.

10.7.4 (d) Efeitos fixos de estado e de tempo

A centragem nas duas dimensões segue a Equação 37. Note o termo que se **soma** de volta: sem ele, a média geral seria subtraída duas vezes.

```
centrar2 <- function(x, unidade, tempo) {  
  x - ave(x, unidade) - ave(x, tempo) + mean(x)  
}  
guns$lvio_tw <- centrar2(guns$lvio, guns$stateid, guns$year)  
guns$shall_tw <- centrar2(guns$shall, guns$stateid, guns$year)  
  
ef_duas_vias <- lm(lvio_tw ~ shall_tw - 1, data = guns)  
lsdv2 <- lm(lvio ~ shall + factor(stateid) + factor(year), data = guns)  
c(duas_vias = coef(ef_duas_vias)[["shall_tw"]], lsdv = coef(lsdv2)[["shall"]])
```

```
      duas_vias      lsdv  
0.001884977 0.001884977
```

Com as duas dimensões de efeitos fixos, o coeficiente vai a praticamente **zero**. A trajetória completa — $-0,44$ no MQO agrupado, $+0,11$ com efeitos de estado, $0,00$ com estado e tempo — é a lição do capítulo em três números. O grosso da correlação negativa bruta era composição entre estados; o resto era tendência temporal comum, já que a criminalidade caiu nos Estados Unidos nos anos 1990 **em toda parte**, inclusive onde não se aprovou lei alguma.

10.7.5 (e) Por que o erro-padrão clusterizado importa

```
# comparacao: ep convencional vs. clusterizado por estado, no modelo LSDV  
ep_conv <- summary(lsdv2)$coefficients["shall", 2]  
ep_clu <- ep_cluster(lsdv2, guns$stateid)[which(names(coef(lsdv2)) == "shall")]  
c(convencional = ep_conv, clusterizado = ep_clu, razao = ep_clu / ep_conv)
```

convencional	clusterizado.shall	razao.shall
0.01661326	0.04118308	2.47892877

O erro-padrão clusterizado é **várias vezes maior** que o convencional. Quem reportasse o erro-padrão convencional estaria trabalhando com uma estatística t inflada pelo mesmo fator, e correria risco sério de rejeitar hipóteses nulas verdadeiras — a advertência da Equação 38, agora em números.

10.7.6 (f) O que acontece com um regressor invariante no tempo

Para fechar, a verificação da limitação de Seção 10.3.4. Construímos uma variável fixa por estado e tentamos incluí-la:

```
# densidade média do estado: invariante no tempo por construcão
guns$dens_fixa <- ave(guns$density, guns$stateid)
guns$dens_w    <- centrar(guns$dens_fixa, guns$stateid)

c(maximo_desvio_absoluto = max(abs(guns$dens_w)))
```

```
maximo_desvio_absoluto
0
```

O regressor centrado é **identicamente zero**, a menos de erro de arredondamento. Não há o que estimar: a variável foi inteiramente absorvida pelos efeitos fixos. É a contrapartida exata da virtude do método — o mesmo mecanismo que elimina a cultura não observada elimina também a densidade observada.

10.8 Exercícios

Exercício 1. Explique, em não mais de cinco linhas e sem álgebra, por que a regressão em diferenças da Equação 29 elimina o viés causado por Z_i mas não elimina o viés causado por uma variável omitida W_{it} que varia ao longo do tempo.

Exercício 2. Um pesquisador dispõe de um painel de 2.000 trabalhadores observados em três anos e quer estimar o efeito do gênero sobre o salário, controlando por habilidade não observada via efeitos fixos de indivíduo. Explique por que o exercício é impossível como formulado, e proponha uma pergunta próxima que o painel **consiga** responder.

Exercício 3. No modelo $Y_{it} = \beta_1 X_{it} + \alpha_i + u_{it}$ com $T = 2$, mostre algebricamente que o estimador *within* e o estimador em primeiras diferenças (sem intercepto) produzem a mesma estimativa de β_1 . *Sugestão:* escreva $\bar{Y}_i = (Y_{i1} + Y_{i2})/2$ e verifique que $\tilde{Y}_{i2} = -\tilde{Y}_{i1} = (Y_{i2} - Y_{i1})/2$.

Exercício 4. Um colega estima um painel de efeitos fixos e reporta erros-padrão robustos a heterocedasticidade (HC1), sem *clustering*. A estatística t da variável de interesse é 2,4. Ele conclui pela significância a 5%. Que crítica você faria, e em que direção você esperaria que a estatística t se movesse com a correção?

Exercício 5. Considere $Y_{it} = \beta_1 X_{it} + \alpha_i + \lambda_t + u_{it}$ com $n = 48$ e $T = 7$. Quantos parâmetros seriam estimados pelo método das binárias, contando o intercepto? Por que esse número não é $48 + 7 + 1$?

10.9 Lista de Exercícios — Dados em Painel

Sobre esta seção

Reproduzo aqui a lista de exemplos da **Aula 9** da disciplina (Prof. Marcelo Mello; monitor: Matheus Porto), com o gabarito desenvolvido em seguida. A Questão 1 é baseada no artigo de Donohue e Levitt (2001, *QJE*) sobre legalização do aborto e criminalidade; a Questão 2 retoma o painel de fatalidades no trânsito do texto. Como sempre, a recomendação é tentar cada questão antes de consultar as resoluções.

10.9.1 Questão 1 — Aborto e criminalidade (Donohue e Levitt, 2001)

Segundo Donohue e Levitt (2001), a legalização do aborto nos EUA na década de 1970 responde por cerca de 50% da queda na criminalidade do país na década de 1990. Os autores estimam, em um painel de estados americanos para 1985–1997,

$$\log(Crime)_{it} = \beta_1 Abort_{it} + \text{Controles} + \alpha_i + \lambda_t + u_{it},$$

onde $Abort$ é o número de abortos por 1.000 nascimentos, α_i é o efeito fixo do estado, λ_t o efeito fixo de tempo e u_{it} o erro. Os resultados são:

Tabela 9: Estimativas de Donohue e Levitt (2001). Erros-padrão entre parênteses.

Regressor	(1) log(crimes violentos)	(2) log(crimes contra propriedade)	(3) log(assassinatos)
<i>Abort</i>	−0,00129 (0,00024)	−0,00091 (0,00018)	−0,00121 (0,00042)
log(prisoneiros <i>per capita</i>)	−0,027 (0,044)	−0,159 (0,036)	−0,231 (0,080)
log(policiais <i>per capita</i>)	−0,028 (0,045)	−0,049 (0,045)	−0,300 (0,109)
Desemprego estadual (%)	0,069 (0,505)	1,31 (0,389)	0,968 (0,794)
log(renda estadual <i>per capita</i>)	0,049 (0,213)	0,084 (0,162)	−0,098 (0,465)
Taxa de pobreza	−0,000 (0,002)	−0,001 (0,001)	−0,005 (0,004)
Efeitos fixos de estado e de tempo	Sim	Sim	Sim

(a) Interprete o coeficiente de *Abort* na coluna (1). Qual o efeito predito nos crimes violentos de um aumento de 100 unidades em *Abort*? O efeito é significativo? Construa um intervalo de confiança de 95% para ele.

(b) Na coluna (2), quais controles são estatisticamente significantes? Qual o efeito predito de um aumento de um ponto percentual no desemprego? A pobreza tem efeito sobre crimes contra a propriedade?

(c) Interprete o coeficiente de *Abort* na coluna (3) e repita o cálculo do item (a) para os assassinatos.

(d) Discuta a validade interna e externa dos resultados.

10.9.2 Questão 2 — Fatalidades no trânsito

Considere o efeito do consumo de cerveja sobre a taxa de fatalidade no trânsito, num painel de estados americanos para 1982–1988. A variável dependente é a taxa de fatalidade (mortes por 10.000 habitantes).

Tabela 10: Painel de fatalidades no trânsito. Erros-padrão entre parênteses.

Regressor	Coefficiente
<i>BeerTax</i>	−0,45 (0,30)
Idade mínima 18 (binária)	0,028 (0,070)
Idade mínima 19 (binária)	−0,018 (0,50)
Idade mínima 20 (binária)	0,032 (0,051)
Milhas médias por motorista	0,008 (0,007)
Taxa de desemprego	−0,063 (0,013)
log(renda real <i>per capita</i>)	1,82 (0,64)
Efeitos de estado	Sim
Efeitos de tempo	Sim

(a) New Jersey tem 8,1 milhões de habitantes. Se o imposto sobre a cerveja aumentar em \$1, qual o efeito predito sobre o **número** de fatalidades no trânsito? Construa um intervalo de confiança de 95%.

(b) Se a renda real *per capita* aumentar 1% em New Jersey, qual o efeito predito sobre o número de fatalidades? Construa um intervalo de confiança de 95%.

(c) Explique as duas formas de estimar com efeitos fixos na *cross-section* e no tempo. Explique também como a hipótese de média condicional zero é modificada em dados de painel.

10.9.3 Gabarito da Lista de Painel

Questão 1(a). A variável dependente está em log e *Abort* em nível: o modelo é log-lin, e pelo Seção 8 o coeficiente é uma **variação proporcional** por unidade de *X*. Um aumento de **uma** unidade em *Abort* reduz os crimes violentos em 0,129%. Para 100 unidades:

$$\Delta\% = 100 \times (-0,00129) \times 100 = -12,9\%.$$

Para o teste de significância, $t = -0,00129/0,00024 = -5,38$, muito acima de 1,96 em valor absoluto: o efeito é significativo a 1%. O intervalo de 95% para o coeficiente é

$$-0,00129 \pm 1,96 \times 0,00024 = (-0,00176; -0,00082),$$

e o intervalo para o **efeito de 100 unidades** é obtido multiplicando por 100×100 :

$$(-17,6\%; -8,2\%).$$

Note que o intervalo é construído para o coeficiente e só então reescalado — a transformação é linear, de modo que os extremos se transformam diretamente.

Questão 1(b). Comparando cada $|t| = |\text{coef}|/\text{EP}$ com 1,96:

- $\log(\text{prisioneiros})$: $t = -0,159/0,036 = -4,42$ — **significante**;
- $\log(\text{policiais})$: $t = -0,049/0,045 = -1,09$ — não significativo;
- desemprego : $t = 1,31/0,389 = 3,37$ — **significante**;
- $\log(\text{renda})$: $t = 0,084/0,162 = 0,52$ — não significativo;
- pobreza : $t = -0,001/0,001 = -1,00$ — não significativo.

O desemprego entra em **pontos percentuais** e a dependente em log, de modo que um aumento de um ponto percentual no desemprego está associado a um aumento de $1,31 \times 100 = 131\%$ nos crimes contra a propriedade — um número implausivelmente grande, que sugere que a variável esteja medida em fração e não em pontos percentuais, ou que haja problema de especificação. Vale registrar a estranheza em vez de repeti-la mecanicamente.

Quanto à pobreza: o coeficiente é $-0,001$ com erro-padrão $0,001$, $t = -1,00$. **Não se rejeita** a nula de efeito zero. Cuidado com a formulação da pergunta: não se conclui que a pobreza **não tem** efeito, apenas que estes dados não permitem distinguir seu efeito de zero — a distinção do Seção 5 entre não rejeitar e aceitar.

Questão 1(c). Mesmo raciocínio do item (a), coluna (3). Um aumento de 100 unidades em *Abort* reduz os assassinatos em $100 \times 0,00121 \times 100 = 12,1\%$. A estatística é $t = -0,00121/0,00042 = -2,88$, significativa a 1%. O intervalo de 95% para o coeficiente é $-0,00121 \pm 1,96 \times 0,00042 = (-0,00203; -0,00039)$, e para o efeito de 100 unidades, $(-20,3\%; -3,9\%)$ — bem mais largo que o da coluna (1), refletindo o erro-padrão maior: assassinatos são eventos mais raros e a série, mais ruidosa.

Questão 1(d). Sobre a **validade interna**, os efeitos fixos de estado e de tempo eliminam, respectivamente, tudo que é fixo no estado (cultura, instituições, demografia estrutural) e tudo que é comum ao ano (ciclo econômico nacional, epidemia de *crack*, mudanças federais). Restam pelo menos três ameaças, na taxonomia do Seção 9:

1. **Variáveis omitidas que variam no tempo dentro do estado** — o efeito fixo nada faz contra elas. A epidemia de *crack*, se atingiu estados em momentos diferentes, é o exemplo clássico levantado contra o artigo.
2. **Causalidade simultânea / exogeneidade estrita** — estados com criminalidade em alta podem ter alterado políticas de saúde reprodutiva, criando *feedback* de u para X futuros, que é precisamente o que a exogeneidade estrita proíbe.
3. **Erro de medida** — a contagem de abortos por estado de ocorrência, e não de residência, introduz erro de medida clássico e portanto viés de atenuação.

Sobre a **validade externa**, os resultados dizem respeito aos EUA de 1985 a 1997, com sua composição demográfica, seu sistema de justiça criminal e seu contexto particular. Extrapolar para outros países ou outras décadas exige argumento substantivo, não apenas estatístico.

Questão 2(a). O coeficiente de *BeerTax* é $-0,45$, e a dependente é a taxa por **10.000 habitantes**. Um aumento de \$1 no imposto reduz a taxa em 0,45 mortes por 10.000 habitantes. Para converter em **número** de mortes em New Jersey, com 8,1 milhões de habitantes, isto é, 810 grupos de 10.000:

$$\Delta \text{mortes} = -0,45 \times \frac{8.100.000}{10.000} = -0,45 \times 810 = -364,5.$$

O intervalo de 95% para o coeficiente é $-0,45 \pm 1,96 \times 0,30 = (-1,038; 0,138)$. Multiplicando por 810:

$$(-840,8; +111,8).$$

O intervalo **contém zero** — coerentemente com $t = -0,45/0,30 = -1,5$, que não rejeita a nula a 5%. A estimativa pontual é grande, mas a incerteza não permite afirmar sequer o sinal do efeito.

Questão 2(b). Aqui a dependente está em nível e o regressor em log: é o caso **lin-log** do Seção 8, em que o efeito de um aumento de 1% em X é $\beta/100$. Assim, um aumento de 1% na renda real *per capita* eleva a taxa em $1,82/100 = 0,0182$ mortes por 10.000 habitantes. Em número de mortes em New Jersey:

$$0,0182 \times 810 = +14,7 \text{ mortes.}$$

Para o intervalo, $1,82 \pm 1,96 \times 0,64 = (0,566; 3,074)$; dividindo por 100 e multiplicando por 810, obtém-se $(+4,6; +24,9)$ mortes. O intervalo **não** contém zero: o efeito é significativo, e positivo — mais renda, mais mortes no trânsito, o que é compatível com mais veículos e mais quilômetros rodados.

Questão 2(c). Sobre as **duas formas de estimação**, como em Seção 10.4: (i) o método das **variáveis binárias**, incluindo $n - 1$ indicadoras de estado e $T - 1$ indicadoras de ano na regressão, estimada por MQO — direto, mas custoso quando n é grande; e (ii) o método da **centragem nas médias**, subtraindo de cada variável a média de sua unidade e a média de seu período e somando de volta a média geral, conforme a função **centrar2()** do laboratório, seguido de um MQO simples nas variáveis transformadas. As duas produzem estimativas e erros-padrão idênticos para β_1 ; variantes mistas (centrar numa dimensão e usar binárias na outra) também são equivalentes.

Sobre a **modificação da hipótese de média condicional zero**, é o ponto de Seção 10.5. Em corte transversal, exigia-se $\mathbb{E}(u_i | X_i) = 0$. Em painel, a hipótese torna-se a de **exogeneidade estrita**,

$$\mathbb{E}(u_{it} | X_{i1}, X_{i2}, \dots, X_{iT}, \alpha_i) = 0,$$

que é mais forte: o erro de **cada** período deve ser não correlacionado com os regressores de **todos** os períodos daquela unidade — inclusive os futuros — e com o efeito fixo. As duas consequências práticas são a proibição de defasagens da dependente como regressor e a exigência de ausência de *feedback* de choques presentes para valores futuros de X .

Apêndice — Trabalho Empírico A1

Sobre este apêndice

O **Trabalho Empírico A1** da disciplina (Prof. Marcelo Mello; monitor: Matheus Porto Pimentel) pede que se estime o retorno da escolaridade sobre a renda no Brasil, usando os microdados da **PNAD Contínua**, e que se investigue o que compromete essa estimação. Cada grupo trabalha com um recorte próprio — região, ano (2012 ou 2019) e situação do domicílio (rural ou urbano) —, sempre com o **terceiro trimestre** da amostra.

O que segue **não é um relatório pronto**: os números dependem do recorte de cada grupo, e entregá-los seria inútil. É um **gabarito metodológico** — para cada um dos treze itens, o que se espera, como fazer, o que os resultados tipicamente mostram e, sobretudo, **qual conceito do curso o item está cobrando**. O código em R é dado no essencial, para ser adaptado ao recorte.

O trabalho é, na prática, uma reencenação aplicada da equação de Mincer (Mincer 1974) com todos os problemas do Seção 6 à vista: viés de variável omitida, heterogeneidade de efeitos, forma funcional e viés de seleção.

O arco do trabalho

Antes dos itens, vale enxergar a estrutura, porque ela não é acidental. O trabalho é uma **demonstração progressiva de que a regressão simples do item 7 não serve**, seguida das correções sucessivas:

1. **Itens 1–6** montam a base e olham para os dados — a etapa que nenhum econometrista pula e que separa um resultado defensável de um artefato de limpeza malfeita.
2. **Item 7** estima a regressão ingênua: $\log(\text{salário})$ sobre anos de estudo.
3. **Item 8** mostra, com duas regressões auxiliares, que a **condição (I)** do viés de variável omitida está satisfeita — escolaridade é correlacionada com sexo e raça.
4. **Item 9** mostra que o efeito é **heterogêneo** entre homens e mulheres, o que exige interação.
5. **Itens 10–12** constroem a especificação completa: controles, interação, não linearidade na experiência, efeitos fixos de estado.
6. **Item 13** fecha admitindo que nada disso resolve o problema mais fundo — a **seleção** na decisão de trabalhar.

Quem escrever o relatório seguindo esse fio terá, de quebra, escrito uma boa introdução.

Preparação: dados e variáveis (itens 1 a 3)

Item 1 — obtenção dos dados. O caminho mais direto é o pacote PNADcIBGE:

```
library(PNADcIBGE)
library(dplyr)

# ATENCAO: ajustar ano ao recorte do grupo (2012 ou 2019), sempre 3o trimestre
vars <- c("UF", "V1022", "V2007", "V2009", "V2010",      # UF, situacao, sexo, idade, cor
```

```

      "V3009A", "VD3005",          # curso mais elevado, anos de estudo
      "VD4001", "VD4002", "VD4009", # força de trabalho, ocupacao, posicao
      "VD4016", "VD4031")          # rendimento habitual, horas habituais
pnad <- get_pnadc(year = 2019, quarter = 3, vars = vars, design = FALSE)

```

Duas advertências. Primeira: os códigos de variável **mudam entre edições** da PNAD, e a lista acima deve ser conferida no **dicionário** do trimestre efetivamente baixado — o enunciado insiste nisso, e é a fonte mais comum de erro no trabalho. Segunda: **design = FALSE** devolve um **data.frame** simples; com **design = TRUE** obtém-se o objeto de desenho amostral complexo, que é o correto para estatísticas descritivas populacionais. Para as regressões pedidas, o MQO não ponderado é aceitável, mas **vale registrar a escolha no relatório** — a PNAD é uma amostra complexa com pesos, e ignorá-los é uma decisão, não um padrão.

Item 2 — as variáveis. As pedidas são: rendimento mensal efetivo de todos os trabalhos, horas habitualmente trabalhadas, UF, situação (rural/urbano), sexo, idade, cor ou raça, curso mais elevado frequentado, anos de estudo, condição em relação à força de trabalho, condição de ocupação e setor do trabalho.

Item 3 — limpeza. Os pontos que costumam morder:

- **Não resposta.** Rendimento e horas trazem NA para quem não trabalha. Distinguir “zero” de “não se aplica” é essencial — imputar zero a quem não está ocupado contamina toda a análise.
- **Códigos categóricos.** Sexo, cor/raça e nível de instrução vêm como códigos numéricos. Convertê-los em **factor** com rótulos legíveis, conferindo o dicionário.
- **Top-coding e valores extremos.** Rendimentos muito altos podem estar censurados. Qualquer truncamento aplicado deve ser **reportado**, e vale lembrar a Hipótese 3 do MQO: quarto momento finito. Uma cauda muito pesada é exatamente o cenário em que ela é duvidosa.
- **Filtro de idade.** O item 4 pede 20 a 60 anos.

Item 4 — participação na força de trabalho

O item pede a proporção de pessoas **economicamente ativas** condicional a escolaridade, a sexo e a idade, **separadamente**; primeiro para o Brasil, depois para o recorte do grupo; e uma análise das diferenças.

```

base <- pnad |>
  filter(V2009 >= 20, V2009 <= 60) |>
  mutate(ativo = as.integer(VD4001 == "Pessoas na força de trabalho"))

# condicional a escolaridade
base |> group_by(instrucao) |> summarise(p_ativo = mean(ativo, na.rm = TRUE))
# idem para sexo e para faixas de idade

```

O que se espera encontrar. Três padrões são robustos nos dados brasileiros:

- **Escolaridade:** participação **crescente** — quem tem mais anos de estudo participa mais, com o salto mais visível na conclusão do ensino médio e no superior.

- **Sexo:** participação masculina significativamente **maior**, com diferencial na casa de 15 a 25 pontos percentuais conforme o recorte.
- **Idade:** perfil de **U invertido** — baixa entre 20 e 24, planalto entre 30 e 45, queda após os 50.

O que o item está realmente cobrando. Note o que se está calculando: uma **média condicional** de uma variável binária, que é uma probabilidade. É o objeto do Seção 3 e o que a regressão estima. Feito com as três variáveis simultaneamente e por MQO, isso teria o nome de **modelo de probabilidade linear** — e o exercício aqui é sua versão não paramétrica.

Sobre as diferenças entre o resultado nacional e o do grupo, as causas plausíveis a discutir são: composição etária e educacional distinta entre regiões; estrutura produtiva local (agricultura familiar no rural, informalidade urbana); e — o ponto mais interessante — a **própria definição de “economicamente ativo”**, que classifica boa parte do trabalho agrícola e doméstico de maneira ambígua, o que morde de modo desigual nos recortes rural e urbano.

Este item volta no item 13, e vale deixá-lo bem feito por isso.

Item 5 — estatísticas descritivas

Após filtrar para **trabalhadores do setor privado, empregados** na data da amostra: uma tabela com mínimo, máximo, média, desvio-padrão e quantis das variáveis contínuas (idade tratada como contínua), e as proporções de cada categoria para as variáveis de nível.

A pergunta conceitual do item — “é importante que nenhuma variável tenha todas as observações iguais; explique qual seria o problema caso contrário” — tem duas respostas corretas, e a boa resposta dá as duas:

Resposta algébrica. Uma variável constante é uma **combinação linear exata da coluna do intercepto** — é o caso de **multicolinearidade perfeita** do Seção 6. A matriz $\mathbf{X}'\mathbf{X}$ torna-se singular e o MQO não tem solução única.

Resposta substantiva, que é a que importa. Sem variação no regressor não há nada a estimar. A fórmula $\hat{\beta}_1 = s_{XY}/s_X^2$ tem denominador zero, e a Equação 8 mostra que a variância do estimador explode conforme a variação do regressor encolhe. Estimar o efeito de uma variável exige **observar o que acontece quando ela muda** — e se ela não muda na amostra, a amostra é muda a respeito dela.

Isso é imediatamente prático no trabalho: num recorte “Centro-Oeste, rural”, a variável **situacao** é constante por construção do filtro, e a UF tem pouquíssimas categorias. São variáveis que **não podem** entrar na regressão do item 12 — e explicar por quê é parte do que se está avaliando.

Item 6 — histogramas e a distribuição condicional

Calcular o salário de cada indivíduo, gerar histogramas condicionais ao nível de educação, e repetir com o **logaritmo**.

```
base <- base |>
  mutate(salario = VD4016 / (4.345 * VD4031), # rendimento mensal -> por hora
         lsalario = log(salario)) |>
  filter(is.finite(lsalario), salario > 0)

library(ggplot2)
ggplot(base, aes(salario)) + geom_histogram(bins = 50) + facet_wrap(~instrucao, scales = "free_
ggplot(base, aes(lsalario)) + geom_histogram(bins = 50) + facet_wrap(~instrucao, scales = "free_
```

A resposta. O conjunto **em logaritmo** é o que mais se assemelha a uma normal. Os salários em nível são fortemente **assimétricos à direita**, com cauda longa; o logaritmo comprime a cauda e produz histogramas aproximadamente simétricos e unimodais em cada nível de instrução. É um fato empírico antigo e robusto: a distribuição de rendimentos é aproximadamente **log-normal**.

A relação com as hipóteses de MQO — que é o que o item pede comentar. Aqui é preciso cuidado, porque há uma armadilha:

- A normalidade da distribuição condicional de Y dado X **não** é hipótese de MQO. Nem o não-viés nem a consistência dependem dela. Como visto na Questão 6 da Lista 2, ela é uma hipótese *adicional* que compra inferência exata em amostras pequenas — e com n na casa dos milhares, ela é dispensável, pelo TCL.
- O que a transformação logarítmica **de fato** compra, e que é relevante:
 1. **Hipótese 3** (quarto momento finito): a cauda pesada dos salários em nível torna a hipótese frágil e o estimador sensível a poucas observações extremas. O log a domestica.
 2. **Homocedasticidade**: a dispersão dos salários em nível cresce com a média — heterocedasticidade clássica em forma de funil, como na figura do Seção 5. Em log, ela fica muito mais estável.
 3. **Interpretação**: o coeficiente vira aproximadamente uma **variação percentual**, que é a quantidade economicamente interessante — e é a forma funcional que a equação de Mincer justifica teoricamente.

Uma boa resposta diz explicitamente que a normalidade **não** é o motivo pelo qual usamos o log, ainda que os histogramas fiquem mais bonitos.

Item 7 — a regressão simples

$$\log(\text{Salário}_i) = \beta_0 + \beta_1 \text{AnosEstudo}_i + u_i.$$

```
m7 <- lm(lsalario ~ anos_estudo, data = base)
summary(m7)
# erros-padrao robustos: ver ep_robusto() no preambulo destas notas
```

O que esperar. $\hat{\beta}_1$ entre **0,08 e 0,12** — cada ano adicional de estudo associado a 8% a 12% de salário a mais. O valor-p será essencialmente zero (a amostra tem milhares de observações) e o R^2 ficará em torno de 0,20 a 0,30.

Os testes de hipótese usuais, comentados. É aqui que se aplica o Seção 5 inteiro: estatística t para $H_0 : \beta_1 = 0$, valor-p, intervalo de 95%. Duas observações que separam uma resposta boa de uma mecânica:

1. **Significância não é relevância.** O valor-p ser 10^{-40} não torna o efeito grande; torna-o precisamente estimado. A pergunta econômica é sobre a **magnitude** e o **intervalo de confiança** — e 10% ao ano é, de fato, grande.
2. **Use erros-padrão robustos.** Há heterocedasticidade evidente em dados de renda mesmo em log, e a Questão 6(d) da Lista 2 explica por que os EP usuais são inválidos sob ela. Vale reportar os dois e comentar a diferença.

A ressalva que já deve aparecer aqui, antecipando o item 8: $\hat{\beta}_1$ é uma associação, não o retorno causal da escolaridade. A **habilidade** não observada é o confundidor canônico, e o item seguinte torna o problema concreto.

Item 8 — o viés de variável omitida, diagnosticado

Duas regressões auxiliares: anos de escolaridade sobre **sexo** e sobre **raça**.

```
m8a <- lm(anos_estudo ~ mulher, data = base)
m8b <- lm(anos_estudo ~ nao_branco, data = base)
```

O que esperar. Coeficientes **significantes** em ambas. Tipicamente mulheres têm cerca de **meio a um ano a mais** de estudo que homens na população ocupada; e pessoas pretas e pardas têm cerca de **um a dois anos a menos** que brancas.

O que isso diz sobre a validade do item 7. Esta é a pergunta central, e a resposta deve ser estruturada pelas **duas condições** do Seção 6:

- **Condição (I) — a variável omitida é correlacionada com o regressor?** As duas regressões auxiliares respondem: **sim**, e é exatamente isso que elas foram feitas para verificar. Coeficiente significativo em m8a/m8b é a evidência de $\text{Cov}(X_1, X_2) \neq 0$.
- **Condição (II) — a variável omitida é determinante de Y ?** Não é testada por essas regressões; é sustentada por conhecimento do problema. E é abundante: a literatura brasileira documenta diferenciais salariais expressivos por sexo e por raça, condicionais a escolaridade.

Ambas valendo, o $\hat{\beta}_1$ do item 7 é **viesado**.

A direção do viés. Aplicando a Equação 1, viés = $\beta_2 \cdot \rho_{X_1 X_2} \sigma_{X_2} / \sigma_{X_1}$, o sinal é o do produto $\beta_2 \times \rho$:

Variável omitida	β_2 (efeito sobre o log-salário)	ρ com escolaridade	Sinal do viés
Mulher	– (mulheres ganham menos)	+ (mulheres estudam mais)	negativo
Não branco	– (não brancos ganham menos)	– (estudam menos)	positivo

O resultado é instrutivo e vale desenvolver no relatório: os **dois vieses têm sinais opostos**. Omitir sexo puxa a estimativa do retorno da escolaridade para **baixo**; omitir raça a puxa para **cima**. O efeito líquido não é determinável *a priori* — só se resolve estimando com ambos incluídos, que é o item 10. E o próprio exercício de ordenar os sinais é exatamente o raciocínio pedido na Questão 2 dos exercícios do Seção 6.

Vale acrescentar o confundidor que **nenhum dos itens do trabalho resolve**: a habilidade. Ela não está na PNAD, é positivamente correlacionada com escolaridade e é determinante do salário — de modo que o viés é **positivo** e sobrevive a todos os controles que virão. Esta é a limitação honesta do trabalho, e reconhecê-la vale mais do que escondê-la.

Item 9 — heterogeneidade entre homens e mulheres

Duas regressões separadas de $\log(\text{salário})$ sobre anos de educação, uma só com mulheres e outra só com homens, mais um gráfico com a nuvem de pontos e as duas retas.

```
m9f <- lm(lsalario ~ anos_estudo, data = filter(base, mulher == 1))
m9m <- lm(lsalario ~ anos_estudo, data = filter(base, mulher == 0))

set.seed(1)
ggplot(slice_sample(base, n = 5000), aes(anos_estudo, lsalario, colour = factor(mulher))) +
  geom_point(alpha = 0.15) +
  geom_smooth(method = "lm", se = FALSE)
```

O que esperar. Os coeficientes **não são iguais**. Tipicamente o retorno estimado é **maior para mulheres** — em torno de 1 a 3 pontos percentuais acima do masculino —, e os interceptos são bem distintos, com o feminino bem abaixo. Graficamente: duas retas com inclinações diferentes que **convergem** conforme a escolaridade cresce, ou seja, o diferencial salarial de gênero é **maior na base** da distribuição educacional.

O que isso diz sobre a regressão completa — a pergunta do item. Rodar duas regressões separadas equivale a permitir que **tanto o intercepto quanto a inclinação** difiram entre os grupos. Para reproduzir isso numa regressão única, não basta incluir a *dummy* de sexo — isso permitiria apenas interceptos diferentes, duas retas **paralelas**. É preciso incluir também o **termo de interação**:

$$\log(\text{Sal}_i) = \beta_0 + \beta_1 \text{Educ}_i + \beta_2 \text{Mulher}_i + \beta_3 (\text{Educ}_i \times \text{Mulher}_i) + u_i.$$

Sob essa especificação, β_1 é o retorno para homens, $\beta_1 + \beta_3$ é o retorno para mulheres, e β_3 é a **diferença entre os dois retornos** — que é exatamente o objeto do item 10. Vale verificar que estimar esse modelo por MQO reproduz **exatamente** os coeficientes das duas regressões separadas; é um bom teste de sanidade do código.

Item 10 — a regressão completa

Incluir todas as variáveis vistas até aqui, interpretar os coeficientes e sua significância, e responder: qual o valor marginal de um ano adicional de escolaridade para um homem? E para uma mulher? São estatisticamente iguais?

```
m10 <- lm(lsalario ~ anos_estudo * mulher + idade + I(idade^2) +
          raca + setor + horas, data = base)
summary(m10)
```

A interpretação dos coeficientes. Com $\log(Y)$ à esquerda, cada coeficiente é aproximadamente a **variação percentual** de Y — aproximação boa para valores pequenos. Para coeficientes de *dummies* grandes em módulo, a conversão exata é $100 \times (e^\beta - 1)\%$, e vale usá-la para o diferencial de gênero, que costuma ser grande o bastante para a diferença importar.

A resposta central do item. Do modelo com interação:

$$\left. \frac{\partial \log(Sal)}{\partial Educ} \right|_{\text{homem}} = \hat{\beta}_1, \quad \left. \frac{\partial \log(Sal)}{\partial Educ} \right|_{\text{mulher}} = \hat{\beta}_1 + \hat{\beta}_3.$$

“Eles são estatisticamente iguais?” — esta é a parte que mais se erra, e a resposta é precisa: testar a igualdade dos dois retornos é testar

$$H_0 : \beta_3 = 0,$$

o que se lê **diretamente na linha da interação** da tabela de regressão, com sua estatística t e seu valor- p . Não é preciso teste conjunto nem cálculo adicional. Se $\hat{\beta}_3$ é significativo, os retornos **diferem** estatisticamente; se não, os dados não permitem distingui-los.

Um erro comum: comparar os dois intervalos de confiança do item 9 e concluir “eles se sobrepõem, logo são iguais”. Isso **não** é um teste válido — a sobreposição de intervalos é um critério mais conservador que o teste correto, e pode falhar em rejeitar quando o teste apropriado rejeitaria. O teste de $\beta_3 = 0$ é o procedimento correto.

Sobre os demais coeficientes — e aqui vale trazer a última seção do Seção 6: a variável de interesse é a escolaridade. Sexo, raça, setor e horas são **variáveis de controle**, e seus coeficientes não devem ser lidos causalmente. O coeficiente de raça, em particular, não mede “o efeito causal de ser negro sobre o salário” — mede a diferença condicional média, que mistura discriminação com toda a desvantagem acumulada que os controles não capturam. Dizer isso explicitamente no relatório é um sinal de que se entendeu o capítulo.

Item 11 — não linearidade na experiência

“Como poderíamos incorporar efeitos não lineares no modelo?” Três respostas, todas válidas, e a boa resposta menciona ao menos duas:

1. **Polinômios** — incluir $Exper$ e $Exper^2$. É o que a equação de Mincer faz, e o que o item pede em seguida.

2. **Logaritmos** — já usados na variável dependente; poderiam ser usados no regressor.
3. **Discretização** — substituir a variável contínua por um conjunto de *dummies* de faixa, o que é a especificação mais flexível possível (não impõe forma funcional alguma).

O ponto conceitual que vale registrar: **o modelo de regressão linear é linear nos parâmetros, não nas variáveis**. Incluir $Exper^2$ não sai do arcabouço de MQO — $Exper^2$ é apenas mais uma coluna de $\mathbf{X}$, e todo o Seção 6 se aplica sem alteração.

O nível de experiência que maximiza o salário. Com a especificação

$$\log(Sal) = \dots + \beta_e Exper + \beta_{e2} Exper^2 + \dots,$$

o efeito marginal de um ano adicional de experiência **não é constante**:

$$\frac{\partial \log(Sal)}{\partial Exper} = \beta_e + 2\beta_{e2} Exper.$$

Igualando a zero e resolvendo:

$$Exper^* = -\frac{\beta_e}{2\beta_{e2}}$$

Para que esse ponto seja um **máximo**, é preciso $\beta_{e2} < 0$ — concavidade —, que é o que se encontra empiricamente. Usando a proxy padrão de Mincer, $Exper = Idade - AnosEstudo - 6$, o valor típico de $Exper^*$ fica **entre 25 e 35 anos** de experiência, o que corresponde a um pico salarial em torno dos 45 aos 55 anos de idade. É um resultado notavelmente estável na literatura, e obtê-lo é um bom sinal de que a especificação está correta.

Duas observações para o relatório: (i) o ponto de máximo deve ser reportado com incerteza — ele é uma **razão de coeficientes estimados**, e seu erro-padrão exige o método delta ou *bootstrap*; (ii) convém verificar se $Exper^*$ cai **dentro do suporte dos dados** — se o máximo estimado estiver em 60 anos de experiência, ele é uma extrapolação, e o que os dados de fato dizem é apenas que o efeito é decrescente.

Item 12 — efeitos fixos de estado

Incluir a UF de cada indivíduo na regressão e comentar.

```
m12 <- lm(lsalario ~ anos_estudo * mulher + idade + I(idade^2) +
          raca + setor + horas + factor(UF), data = base)
```

O que esperar. O coeficiente da escolaridade tipicamente **cai um pouco**, e o R^2 sobe. A interpretação: parte do que se atribuíra ao retorno da escolaridade era, na verdade, **diferença de nível salarial entre estados** — pessoas mais escolarizadas concentram-se em estados de renda mais alta, e a regressão sem UF creditava essa composição geográfica à educação. Incluir as *dummies* de estado elimina esse canal e o coeficiente passa a medir o retorno estimado **dentro** de cada estado.

O que registrar sobre a mecânica. Três pontos que o item cobra implicitamente:

1. **A armadilha da *dummy*.** Com intercepto, apenas $G - 1$ *dummies* de UF entram; o R omite uma automaticamente ao usar `factor(UF)`, e ela vira a categoria de referência. Os coeficientes de UF medem diferenças **em relação a esse estado**, e não têm interpretação absoluta.
2. **Variáveis de controle, de novo.** Nenhum coeficiente de UF tem interpretação causal — eles absorvem tudo o que é fixo no estado: custo de vida, estrutura produtiva, mercado de trabalho local, qualidade média da educação.
3. **O limite do recorte.** Grupos cujo recorte tem poucas UFs (Centro-Oeste, por exemplo) terão poucas *dummies* e ganho pequeno. E, se o recorte tivesse uma única UF, ela seria **constante** — o problema do item 5 —, e não poderia entrar.

Vale a comparação explícita, numa tabela de três colunas, entre os modelos dos itens 7, 10 e 12, mostrando o que acontece com $\hat{\beta}_{Educ}$ a cada bloco de controles acrescentado. É o formato padrão da literatura aplicada, e é a maneira mais direta de mostrar que se entendeu a Equação 1.

Item 13 (bônus) — viés de seleção

O item é opcional, mas é o mais interessante do trabalho, e liga tudo ao item 4.

O problema. Toda a análise dos itens 7 a 12 usa apenas quem **está trabalhando** e declarou rendimento. Mas trabalhar é uma **decisão**, e ela depende das mesmas características que entram na regressão: escolaridade, sexo, idade, raça. A amostra de salários observados não é, portanto, uma amostra aleatória da população — é uma amostra **selecionada** por um processo correlacionado com os regressores.

A formalização por salário de reserva. Um indivíduo trabalha quando o salário oferecido w_i excede seu **salário de reserva** w_i^r — o mínimo que o faria aceitar o emprego. Observamos w_i apenas quando $w_i > w_i^r$. Se o salário de reserva depende de características Z_i que se sobrepõem aos regressores, a seleção é **não aleatória** em relação a X .

Como o salário de reserva varia — a pergunta do item:

- **Com a escolaridade:** cresce. Mais escolaridade eleva as alternativas (inclusive continuar estudando) e a renda familiar, elevando o piso de aceitação. Mas o **salário ofertado** cresce ainda mais rápido, o que explica a participação crescente do item 4.
- **Com o sexo:** historicamente muito mais alto para mulheres, por causa da distribuição assimétrica do trabalho doméstico e de cuidado não remunerado. É a explicação direta do diferencial de participação encontrado no item 4.
- **Com a idade:** perfil de U — alto na juventude (estudo como alternativa), baixo na fase adulta, alto de novo perto da aposentadoria. Espelha exatamente o U invertido da participação.

Como isso gera viés. O mecanismo é o do Seção 6, com uma variável omitida específica. A regressão observada é, condicional à seleção,

$$\mathbb{E}(\log w_i \mid Educ_i, \text{trabalha}) = \beta_0 + \beta_1 Educ_i + \underbrace{\mathbb{E}(u_i \mid Educ_i, w_i > w_i^r)}_{\neq 0}.$$

O último termo é o problema: **condicionar na seleção quebra a Hipótese 1**, mesmo que ela valesse na população inteira. O termo omitido é uma função dos regressores — o famoso *inverse Mills ratio* na formulação de Heckman —, e omiti-lo é literalmente viés de variável omitida.

A direção. O argumento clássico é intuitivo: entre os pouco escolarizados, só trabalham aqueles cujo salário ofertado supera o de reserva — isto é, os que têm **choque positivo** de habilidade, sorte ou rede de contatos. Entre os muito escolarizados, quase todos trabalham, selecionados ou não. Logo o grupo de baixa escolaridade observado é **positivamente selecionado** em relação ao seu grupo populacional, enquanto o de alta escolaridade não é. Isso **comprime** o diferencial observado e **subestima** β_1 .

O efeito é mais forte na subamostra feminina, onde a taxa de participação é menor e a seleção portanto mais severa — o que oferece uma explicação alternativa e interessante para o retorno feminino aparentemente maior do item 9: parte dele pode ser artefato de seleção, não retorno genuíno.

A conclusão honesta. Este viés **não é corrigível** com as ferramentas vistas até aqui. Adicionar controles não resolve, porque o problema não é uma variável faltando na regressão — é a **amostra** que não é aleatória. As soluções (correção de Heckman em dois estágios, métodos de *bounds*) dependem de hipóteses adicionais e ficam fora do escopo do trabalho. Reconhecer o limite, e dizer em que direção ele empurra a estimativa, é exatamente o tipo de julgamento que o Seção 1 chamava de **arte** da econometria.

Uma lista de checagem para o relatório

Antes de entregar, vale conferir:

- ☐ O recorte do grupo (região, ano, situação) está correto e explicitado logo na abertura?
- ☐ Os códigos das variáveis foram conferidos no dicionário **daquele** trimestre?
- ☐ O tratamento de NA e de valores extremos está descrito e justificado?
- ☐ Foi dito se os pesos amostrais foram ou não usados, e por quê?
- ☐ As regressões reportam **erros-padrão robustos**, ou justificam não os usar?
- ☐ A discussão do item 8 identifica as **duas condições** do viés e o **signal** de cada um?
- ☐ O teste de igualdade dos retornos (item 10) é feito sobre o **coeficiente da interação**, e não por sobreposição de intervalos?
- ☐ Os coeficientes de controle são apresentados **sem** linguagem causal?
- ☐ O ponto de máximo do item 11 cai dentro do suporte dos dados?
- ☐ Há uma tabela comparando as especificações dos itens 7, 10 e 12 lado a lado?

Referências

- Angrist, Joshua D., e Jörn-Steffen Pischke. 2009. *Mostly Harmless Econometrics: An Empiricist's Companion*. Princeton University Press.
- Angrist, Joshua D., e Jörn-Steffen Pischke. 2015. *Mastering 'Metrics: The Path from Cause to Effect*. Princeton University Press.
- Bombardier, Claire, Loren Laine, Alise Reicin, et al. 2000. "Comparison of Upper Gastrointestinal Toxicity of Rofecoxib and Naproxen in Patients with Rheumatoid Arthritis". *New England Journal of Medicine* 343 (21): 1520–28.
- Borba, Mayla G. S., Fernando F. A. Val, Vanderson S. Sampaio, et al. 2020. "Effect of High vs Low Doses of Chloroquine Diphosphate as Adjunctive Therapy for Patients Hospitalized with Severe Acute Respiratory Syndrome Coronavirus 2 (SARS-CoV-2) Infection". *JAMA Network Open* 3 (4): e208857.
- Doll, Richard, e A. Bradford Hill. 1954. "The Mortality of Doctors in Relation to Their Smoking Habits". *British Medical Journal* 1 (4877): 1451–55.
- Mincer, Jacob. 1974. "Schooling, Experience, and Earnings". *NBER Books*.
- Stock, James H., e Mark W. Watson. 2020. *Introduction to Econometrics*. 4^o ed. Pearson.
- White, Halbert. 1980. "A Heteroskedasticity-Consistent Covariance Matrix Estimator and a Direct Test for Heteroskedasticity". *Econometrica* 48 (4): 817–38.
- Wooldridge, Jeffrey M. 2016. *Introductory Econometrics: A Modern Approach*. 7^o ed. Cengage Learning.
- Wynder, Ernest L., e Evarts A. Graham. 1950. "Tobacco Smoking as a Possible Etiologic Factor in Bronchiogenic Carcinoma". *Journal of the American Medical Association* 143 (4): 329–36.